

文生图 / 文生视频课程 Roadmap

这套笔记面向 AI（Artificial Intelligence，人工智能）算法工程师的文生图、文生视频和多模态生成面试准备。目标不是背产品名，而是形成一套可迁移的框架：生成模型基础、diffusion / flow matching、文本与图像条件、编辑与控制、视频时序建模、视频数据和训练实操、SOTA 技术报告阅读、评测 harness、安全与产品化。

截至 2026 年 6 月，面试里只讲 DDPM（Denoising Diffusion Probabilistic Model，去噪扩散概率模型）和 Stable Diffusion 已经不够了。你还需要能讨论 GPT-4o Image、Gemini / Nano Banana、Imagen 4、Qwen-Image、Seedream 4.0、Stable Diffusion 3 / 3.5、FLUX.1 Kontext、Sora / Sora 2、Veo 3.1、Movie Gen、Runway Gen-4、HunyuanVideo、Seedance 2.0 这类系统背后的共性。

0.1 全局符号和缩写说明

符号/缩写	English	中文	含义
AI	Artificial Intelligence	人工智能	本课程讨论的上层技术领域。
GenAI	Generative Artificial Intelligence	生成式人工智能	生成图像、视频、音频、文本等内容的模型和系统。
T2I	Text-to-Image	文生图	用文本 prompt 生成图像。
T2V	Text-to-Video	文生视频	用文本 prompt 生成视频。
I2I	Image-to-Image	图生图	用图像和文本条件编辑或重绘图像。
I2V	Image-to-Video	图生视频	用图像作为起点生成视频。
V2V	Video-to-Video	视频到视频	用输入视频做编辑、风格迁移或重生成。
AV	Audio-Video	音视频	联合生成画面、声音、对白、音效的任务。
AR	Autoregressive	自回归	逐 token 或逐 patch 预测下一个元素的生成范式。
VAE	Variational Autoencoder	变分自编码器	把图像或视频压缩到 latent，再解码回像素。
VQ-VAE	Vector Quantized Variational Autoencoder	向量量化变分自编码器	把视觉内容离散化成 codebook token 的自编码器。
DDPM	Denoising Diffusion Probabilistic Model	去噪扩散概率模型	通过加噪和反向去噪生成样本。
DDIM	Denoising Diffusion Implicit Model	去噪扩散隐式模型	常用于更少步数的 diffusion 采样。

符号/缩写	English	中文	含义
EDM	Elucidated Diffusion Model	解析化扩散模型设计	Karras 等提出的一套噪声调度和采样设计空间。
SDE	Stochastic Differential Equation	随机微分方程	连续时间 diffusion 的一种建模方式。
ODE	Ordinary Differential Equation	常微分方程	确定性采样路经常用的数学表示。
FM	Flow Matching	流匹配	直接学习从噪声到数据的连续向量场。
RF	Rectified Flow	矫正流	用更直的生成路径提升训练和采样效率的 flow 方法。
CFM	Conditional Flow Matching	条件流匹配	带条件变量的 flow matching 训练方式。
LDM	Latent Diffusion Model	潜空间扩散模型	在 VAE latent space 中做 diffusion。
U-Net	U-Net Architecture	U-Net 架构	diffusion 早期常用 denoiser backbone。
DiT	Diffusion Transformer	扩散 Transformer	用 Transformer 作为 diffusion / flow backbone。
MMDiT	Multimodal Diffusion Transformer	多模态扩散 Transformer	文本和图像 token 分支交互的 DiT 架构。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	Black Forest Labs 的图像生成和编辑模型系列。
LLM	Large Language Model	大语言模型	用于 prompt planning、captioning、judge 或原生多模态生成的语言模型。
VLM	Vision-Language Model	视觉语言模型	同时处理图像和文本，常用于 caption、评测和审核。
MLLM	Multimodal Large Language Model	多模态大语言模型	同时处理文本、图像、视频、音频等模态的大模型。
CLIP	Contrastive Language-Image Pre-training	对比式图文预训练	用于图文语义对齐、检索和评测。
T5	Text-to-Text Transfer Transformer	文本到文本迁移 Transformer	Imagen、Stable Diffusion 3 等系统常用的强 text encoder。

符号/缩写	English	中文	含义
GPT-4o	Generative Pre-trained Transformer 4o	GPT-4o 多模态模型	OpenAI 的原生多模态模型系列，包含图像生成能力。
CFG	Classifier-Free Guidance	无分类器引导	采样时增强条件遵循度的技巧。
SFT	Supervised Fine-Tuning	监督微调	用高质量指令、编辑或偏好数据微调模型。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人工偏好训练 reward，再优化生成策略。
DPO	Direct Preference Optimization	直接偏好优化	不显式训练 reward model 的偏好优化方法。
LoRA	Low-Rank Adaptation	低秩适配	低成本个性化或风格微调方法。
C2PA	Coalition for Content Provenance and Authenticity	内容来源与真实性联盟	用 Content Credentials 标记内容来源和编辑历史的开放标准。
FID	Fréchet Inception Distance	Fréchet Inception 距离	评估生成图像分布和真实图像分布差异的指标。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成常用的分布距离指标。
CLIPScore	CLIP Score	CLIP 相似度得分	用 CLIP 衡量图文语义相似。
VQAScore	Visual Question Answering Score	视觉问答得分	用 VQA 模型评估 prompt 中属性是否被满足。
HPS	Human Preference Score	人类偏好得分	用人类偏好数据训练出的自动偏好指标。
DINO	Self-distillation with No Labels	自监督视觉表征模型	常用于 reference similarity 或视觉一致性评测。
LPIPS	Learned Perceptual Image Patch Similarity	学习感知图像块相似度	衡量图像感知差异，常用于编辑保真评测。
API	Application Programming Interface	应用程序编程接口	产品接入生成模型或评测服务的接口。
x_θ	Clean Sample	干净样本	原始图像、视频帧或 latent。
x_t	Noisy Sample at step t	第 t 步噪声样本	forward diffusion 后的样本。
ε	Gaussian Noise	高斯噪声	加到样本上的噪声。
ε_θ	Noise Predictor	噪声预测器	diffusion model 预测的噪声。

符号/缩写	English	中文	含义
v_θ	Velocity Predictor	速度预测器	diffusion / flow 模型预测的速度或方向。
c	Condition	条件	文本、图像、mask、边缘、pose、音频、参考视频等控制条件。
z	Latent	潜变量	VAE 编码后的低维表示。

0.2 学习路线

章节	主题	面试产出
第 1 章	生成模型、DDPM、score、flow matching、rectified flow	能把 diffusion 和 flow 的训练目标讲清楚。
第 2 章	文生图架构：CLIP、Imagen、Stable Diffusion、DiT、MMDiT、原生多模态图像生成	能比较 DALL-E / Imagen / Stable Diffusion / SD3 / FLUX / GPT-4o Image。
第 3 章	Conditioning、editing、control、reference consistency	能解释 CFG、ControlNet、IP-Adapter、LoRA、Kontext、Nano Banana 类编辑。
第 4 章	文生视频、时空 token、world model、音视频联合生成	能讨论 Sora、Veo、Movie Gen、Runway、HunyuanVideo、Seedance。
第 5 章	文生视频数据构造、预处理与训练实操	能讲清 shot detection、caption、T2V/I2V/V2V 数据、视频 RLHF、distillation。
第 6 章	文生视频工作流、控制、评测与项目实操	能设计分镜、首尾帧、参考图、音频、视频 eval harness 和 badcase 归因。
第 7 章	面试速查、项目表达、常见追问	能把项目讲成模型、数据、评测、安全、线上闭环。
第 8 章	2026 SOTA 技术报告阅读地图	能快速拆解最新模型报告，而不是只背榜单。
第 9 章	Eval harness、benchmarking、人评和自动评测	能设计可复现的图像/视频生成评测系统。
第 10 章	训练、对齐、安全、provenance、产品化	能讨论真实系统怎么训练、过滤、上线、治理。
References	论文、官方技术报告、模型页面、基准	面试前用于定位原始材料。

0.3 推荐学习顺序

1. 先读第 1 章，把 DDPM、score、flow matching 的共同目标理解成“从简单分布到数据分布的可学习路径”。

2. 再读第 2 章，把文生图架构按 text encoder、visual tokenizer、denoiser / flow model、decoder、post-training 拆开。
3. 第 3 章关注真实需求：一致性、局部编辑、多图参考、结构控制、低成本个性化。
4. 第 4 章转向视频，把难点从“单帧好看”升级为“时间、物理、镜头、声音、角色一致”。
5. 第 5 章补视频训练实操：数据清洗、caption、T2V/I2V/V2V 样本、偏好数据、蒸馏。
6. 第 6 章补视频产品工作流：分镜、参考图、首尾帧、音频、评测 harness、badcase 归因。
7. 第 8 章按报告读 SOTA：每篇只抓任务定义、数据、架构、训练、评测、安全、限制。
8. 第 9 和第 10 章放到面试前重点复习，因为它们最能拉开“会用模型”和“能做系统”的差距。

0.4 面试目标

学完后你应该能回答：

- DDPM 的 forward process、reverse denoising 和 denoising loss 在做什么。
- 为什么很多新模型从 noise prediction 转向 v-prediction、flow matching 或 rectified flow。
- Stable Diffusion 为什么在 latent space 做 diffusion，VAE bottleneck 的收益和代价是什么。
- SD3 的 MMDiT、FLUX.1 的 flow matching、GPT-4o Image 的原生多模态生成分别代表什么趋势。
- Nano Banana / FLUX.1 Kontext / Qwen-Image / Seedream 4.0 这类编辑模型为什么强调 reference consistency。
- 文生视频相比文生图多了哪些难点，为什么 Sora / Veo / Movie Gen / Seedance 都强调时空 token、数据 curation、captioning 和 post-training。
- 文生视频训练数据如何构造：shot detection、frame sampling、caption / recaption、ASR / OCR、T2V / I2V / V2V schema。
- 如何把文生视频做成工作流：storyboard、shot list、首尾帧、参考资产、音频、评测和审核闭环。
- 如何设计一个文生图/视频 eval harness，并让结果可复现、可对比、能服务产品决策。
- 安全和合规怎么落到工程：输入输出审核、水印、C2PA、SynthID、真人肖像、版权/IP、训练数据过滤、日志和申诉。

第 1 章：生成模型、DDPM、Score 与 Flow Matching

1.1 本章符号说明

符号/缩写	English	中文	含义
GAN	Generative Adversarial Network	生成对抗网络	generator 和 discriminator 对抗训练的生成模型。
VAE	Variational Autoencoder	变分自编码器	学习 latent distribution 的生成模型。
AR	Autoregressive	自回归	逐 token 或逐 patch 生成的模型族。
DDPM	Denoising Diffusion Probabilistic Model	去噪扩散概率模型	通过加噪和去噪生成样本。
DDIM	Denoising Diffusion Implicit Model	去噪扩散隐式模型	常用于更少步数的确定性或半确定性采样。
EDM	Elucidated Diffusion Model	解析化扩散模型设计	对噪声参数化、预条件和采样器做系统整理。
SDE	Stochastic Differential Equation	随机微分方程	连续时间扩散过程的数学描述。
ODE	Ordinary Differential Equation	常微分方程	确定性生成轨迹的数学描述。
FM	Flow Matching	流匹配	直接学习噪声分布到数据分布的速度场。
RF	Rectified Flow	矫正流	让生成路径更直、更容易少步采样的 flow 方法。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	flow matching 图像生成和编辑模型系列。
Score	Score Function	分数函数	$\nabla_x \log p(x)$ ，表示数据密度方向。
x_0	Clean Data	干净数据	原始图像或 latent。
x_t	Noisy Data	噪声数据	第 t 步加噪后的样本。

符号/缩写	English	中文	含义
ε	Gaussian Noise	高斯噪声	forward process 中加入的噪声。
β_t	Noise Schedule	噪声调度	每一步加入噪声的强度。
α_t	Retained Signal Rate	保留信号率	通常 $\alpha_t = 1 - \beta_t$ 。
σ_t	Noise Level	噪声等级	EDM 和连续时间采样器常用的噪声尺度。
ε_θ	Noise Predictor	噪声预测器	模型预测噪声的网络。
v_θ	Velocity Predictor	速度预测器	模型预测从噪声到数据的方向或速度。

1.2 本章目标

- 理解生成模型要学习 $p_{data}(x)$ 。
- 掌握 diffusion 的 forward 和 reverse。
- 理解为什么训练目标常写成预测噪声。
- 能解释 score、v-prediction、flow matching、rectified flow 的关系。
- 能解释 diffusion 和 GAN / VAE / AR 的直觉差异。

1.3 生成模型在学什么

生成模型希望从数据分布中采样：

$$x \sim p_{data}(x)$$

但真实 p_{data} 不可直接写出。不同生成模型有不同近似方式：

模型	English	中文	直觉
VAE	Variational Autoencoder	变分自编码器	学一个连续 latent space，再 decode。
GAN	Generative Adversarial Network	生成对抗网络	generator 骗过 discriminator。
Autoregressive	Autoregressive Model	自回归模型	逐 token 或逐 patch 生成。
Diffusion	Diffusion Model	扩散模型	先加噪破坏数据，再学习反向去噪。
Flow Matching	Flow Matching Model	流匹配模型	学习把噪声连续搬运到数据的速度场。

1.4 Forward Diffusion

forward process 逐步给干净样本 x_0 加噪：

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$

经过足够多步后， x_T 接近标准高斯噪声。

利用重参数化，可以一步采样任意 t ：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\varepsilon$$

其中：

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s, \varepsilon \sim \mathcal{N}(0, I)$$

1.5 Reverse Denoising

反向过程从噪声开始，逐步去噪：

$$p_\theta(x_{t-1} | x_t)$$

模型常被训练成预测噪声：

$$\varepsilon_\theta(x_t, t) \approx \varepsilon$$

常见简化 loss：

$$L(\theta) = \mathbb{E}_{x_0, t, \varepsilon} [\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2]$$

直觉：

模型看到一张被加噪的图和当前噪声等级 t ，学习判断“哪些部分是噪声”，然后采样时反复去噪，最终从纯噪声变成图像。

1.6 三种常见预测参数化

同一个 denoising 任务可以用不同输出形式训练：

参数化	English	中文	预测内容	面试重点
ε -prediction	Noise Prediction	噪声预测	预测加到样本上的噪声 ε	DDPM 最常见，公式直观。
x_0 -prediction	Clean Sample Prediction	干净样本预测	直接预测无噪样本 x_0	容易解释，但不同噪声等级权重敏感。
v -prediction	Velocity Prediction	速度预测	预测 noise 和 data 的组合方向 v	常用于更稳定的训练和采样。

面试里可以这样说：

这些参数化本质上都是从 noisy sample 估计去噪方向。差异在于数值稳定性、不同 noise level 的 loss 权重，以及采样器怎么把预测量转换成下一步样本。

1.7 为什么 Diffusion 稳定

相比 GAN，diffusion 的训练更像 supervised denoising：

- 每个训练样本可以构造不同噪声等级。
- loss 稳定，不需要 discriminator 对抗。
- mode coverage 通常更好。

代价：

- 采样需要多步迭代。
- 高分辨率训练和推理成本大。
- prompt alignment 需要 conditioning 和 guidance。

1.8 从 Diffusion 到 Flow Matching

新一代图像和视频模型经常使用 flow matching 或 rectified flow。一个简化理解是：diffusion 学习反向去噪分布，flow matching 学习连续路径上的速度场。

构造一条从噪声 x_0 到数据 x_I 的路径：

$$x_t = (1-t)x_0 + t x_I$$

模型学习速度：

$$v_{\theta}(x_t, t, c) \approx x_I - x_0$$

其中 c 是文本、图像或视频条件。

为什么它重要：

- 训练目标更直接：预测“往哪里走”，而不是只预测噪声。
- 采样路径可以更直，少步采样更有希望。
- 很适合和 DiT / MMDiT 结合，成为 SD3、FLUX、Seedream 等模型报告里的核心词。

不要把 flow matching 理解成 diffusion 的完全替代。面试里更稳的说法是：

diffusion、score model 和 flow matching 都在学习从简单分布到数据分布的生成路径。区别在于路径定义、预测目标、采样方程和数值稳定性。

1.9 采样器和速度

训练好模型后，还需要采样器把噪声变成图像或视频。

采样相关概念	English	中文	影响
Step Count	Number of Sampling Steps	采样步数	步数多通常质量更稳，但延迟更高。
Noise Schedule	Noise Schedule	噪声调度	决定不同阶段去噪强度。
Solver	Numerical Solver	数值求解器	DDIM、DPM-Solver、Euler 等会影响速度和质量。
Distillation	Distillation	蒸馏	把多步模型压到少步模型，如 turbo / lightning 类模型。
Consistency Model	Consistency Model	一致性模型	训练模型在不同噪声等级输出一致，支持少步采样。

工程上，采样器不是细枝末节。线上系统常常要在质量、成本、延迟、稳定性之间做 trade-off。

1.10 本章面试高频问题

1.10.1 DDPM 的 forward process 是什么？

forward process 是固定的加噪过程，从 x_0 逐步采样 x_t ，直到接近高斯噪声。训练时不需要学习 forward，只学习 reverse denoising。

1.10.2 为什么可以训练模型预测 ε ？

因为 x_t 可以由 x_0 和噪声 ε 闭式构造。知道 x_t 、 t 和预测噪声后，就能估计干净样本或反向采样方向。

1.10.3 Diffusion 和 GAN 的区别？

GAN 通过对抗训练直接生成样本，采样快但训练可能不稳定。Diffusion 通过多步去噪生成，训练稳定、质量高，但推理通常更慢。

1.10.4 Flow matching 和 diffusion 是什么关系？

两者都在学习从简单噪声分布到数据分布的生成过程。diffusion 通常从加噪过程推导反向去噪，flow matching 更直接学习路径上的速度场。现在很多 SOTA 图像模型会把 flow matching、rectified flow、DiT 和多模态条件结合起来。

1.10.5 为什么少步采样难？

少步采样要求每一步都走得很准。步数减少后，误差没有足够机会被修正，容易出现结构崩坏、细节伪影、prompt 不遵循。解决思路包括更好的 solver、distillation、consistency training、flow matching 和后训练。

1.11 本章 References

- [Denoising Diffusion Probabilistic Models](#)
- [Classifier-Free Diffusion Guidance](#)
- [Elucidating the Design Space of Diffusion-Based Generative Models](#)

- [Flow Matching for Generative Modeling](#)
- [Rectified Flow](#)

第 2 章：文生图架构：CLIP、Imagen、Stable Diffusion、DiT 与原生多模态生成

2.1 本章符号说明

符号/缩写	English	中文	含义
T2I	Text-to-Image	文生图	根据文本生成图像。
TI2I	Text-Image-to-Image	文图到图	输入文本和参考图，输出编辑后的图像。
CLIP	Contrastive Language-Image Pre-training	对比式图文预训练	学习图文共享语义空间。
T5	Text-to-Text Transfer Transformer	文本到文本迁移 Transformer	Imagen、SD3 等常用的强 text encoder。
LDM	Latent Diffusion Model	潜空间扩散模型	在 VAE latent 中做扩散。
DiT	Diffusion Transformer	扩散 Transformer	用 Transformer 替代 U-Net denoiser。
MMDiT	Multimodal Diffusion Transformer	多模态扩散 Transformer	文本 token 和图像 token 使用不同权重并交互的扩散 Transformer。
MM-LLM	Multimodal Large Language Model	多模态大语言模型	能理解或生成多种模态的语言模型体系。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	flow matching 图像生成和编辑模型系列。
GPT-4o	Generative Pre-trained Transformer 4o	GPT-4o 多模态模型	OpenAI 的原生多模态模型系列。
VAE	Variational Autoencoder	变分自编码器	把图像压缩到 latent，再 decode 回像素。
U-Net	U-Net Architecture	U-Net 架构	常见 diffusion denoiser backbone。
OCR	Optical Character Recognition	光学字符识别	用于读取图像中文字，也用于文字渲染评测。
VLM	Vision-Language Model	视觉语言模型	同时处理图像和文本的模型。

符号/缩写	English	中文	含义
LLM	Large Language Model	大语言模型	可用于 caption、prompt planning、judge 或原生多模态生成。
FM	Flow Matching	流匹配	新一代图像生成模型常用的训练目标。
c	Condition	条件	文本 embedding、图像 embedding、layout 等条件。
z	Latent	潜变量	压缩后的图像表示。
$\varepsilon_{\theta}(z_p, t, c)$	Conditional Noise Predictor	条件噪声预测器	输入 noisy latent、时间步和条件，预测噪声。
$v_{\theta}(z_p, t, c)$	Conditional Velocity Predictor	条件速度预测器	输入 noisy latent、时间和条件，预测 flow 方向。

2.2 本章目标

- 理解文生图如何把文本条件注入生成过程。
- 掌握 DALL-E 2、Imagen、Stable Diffusion 的架构差异。
- 理解 latent diffusion 为什么重要。
- 理解 DiT / MMDiT / flow matching 为什么代表可扩展趋势。
- 能讨论 GPT-4o Image、Gemini / Nano Banana、Qwen-Image、Seedream 这类原生编辑和多模态生成系统。

2.3 文本条件怎么进入图像生成

文本 prompt 先经过 text encoder：

$$c = E_{\text{text}}(T)$$

然后 diffusion denoiser 在每一步使用条件 c ：

$$\varepsilon_{\theta}(x_p, t, c)$$

注入方式包括：

- cross-attention。
- adaptive normalization。
- class/text embedding conditioning。
- 拼接 image/text latent。

2.4 DALL-E 2 / unCLIP

DALL-E 2 使用 CLIP latent 作为桥：

1. text encoder 得到 text embedding。
2. prior model 预测 image embedding。
3. diffusion decoder 根据 image embedding 生成图像。

直觉：

CLIP embedding 捕捉语义和风格，先在语义空间规划图像，再由 diffusion decoder 生成像素。

2.5 Imagen

Imagen 的关键发现之一：强语言模型对文生图非常重要。它使用大规模 frozen T5 text encoder，再用级联 diffusion model 生成高分辨率图像。

面试表达：

Imagen 说明 text encoder 的语言理解能力会显著影响图文对齐。生成质量不只取决于 image diffusion backbone，也取决于 prompt 被理解得多好。

2.6 Stable Diffusion / LDM

像素空间 diffusion 成本高。Latent Diffusion 先用 VAE 把图像压缩：

$$x \rightarrow z = E_{VAE}(x)$$

在 latent space 做 diffusion：

$$\varepsilon_{\theta}(z_p, t, c)$$

最后 decode：

$$\hat{x} = D_{VAE}(\hat{z})$$

优点：

- 大幅降低训练和推理成本。
- 支持高分辨率生成。
- cross-attention 可以接入文本、mask、box 等条件。

代价：

- VAE 会带来信息损失。
- 细节和文字可能受 latent bottleneck 影响。
- 需要额外维护 text encoder、VAE、denoiser。

2.7 DiT

DiT 把 latent 切成 patch token，用 Transformer 做 denoiser。

核心变化：

- U-Net 依赖卷积和多尺度结构。
- DiT 更接近 Transformer scaling 范式。
- 增大 depth、width、token 数通常能带来更可预测的扩展。

面试表达：

DiT 的意义不只是把 U-Net 换成 Transformer，而是让 diffusion backbone 更符合大模型 scaling 经验，便于统一图像、视频和多模态生成。

2.8 Stable Diffusion 3 / 3.5: MMDiT 与 Rectified Flow

Stable Diffusion 3 系列的公开报告把两个词推到前台：MMDiT 和 rectified flow。

MMDiT 的直觉：

- 文本 token 和图像 latent token 不是同一种信号。
- 让它们完全共享 Transformer 权重可能不够灵活。
- MMDiT 用不同权重处理不同模态，再通过 attention 交互。

Stable Diffusion 3 还组合了多个 text encoder，例如 CLIP 和 T5。面试里可以这样回答：

SD3 的核心不是“又一个 Stable Diffusion”，而是把 latent diffusion 从 U-Net 时代推进到多模态 Transformer 时代。它用更强的 text encoder、更可扩展的 MMDiT，以及 rectified flow 训练目标来提升 prompt adherence、文字渲染和复杂构图。

2.9 FLUX.1: Flow Matching 与编辑统一化

FLUX.1 系列的代表意义在于把 flow matching、DiT 和高质量图像生成结合起来。FLUX.1 Kontext 进一步强调统一的图像生成和编辑：

- 输入可以是文本，也可以是参考图和文本。
- 局部编辑、全局风格迁移、角色一致、文字编辑都尽量放进一个模型范式。
- 用 benchmark 评估编辑一致性，而不是只看单张生成图好不好。

面试高分点：

新一代图像模型的竞争已经从“能不能生成漂亮图”转向“能不能按复杂意图稳定编辑，并在多轮交互里保持主体、文字、风格和布局一致”。

2.10 GPT-4o Image 与 Gemini / Nano Banana: 原生多模态生成

传统文生图系统常是“语言模型写 prompt + 图像模型生成”。GPT-4o Image 和 Gemini / Nano Banana 这类系统代表另一个方向：把图像生成作为多模态模型的原生能力。

它们的面试关注点：

能力	English	中文	为什么重要
Text Rendering	Text Rendering	文字渲染	海报、UI、信息图、商品图都需要准确文字。
Multi-turn Editing	Multi-turn Editing	多轮编辑	用户会连续改图，模型要记住上下文。
Reference Consistency	Reference Consistency	参考一致性	人物、商品、品牌资产不能漂移。
World Knowledge	World Knowledge	世界知识	能把事实知识和视觉生成结合。
Instruction Following	Instruction Following	指令遵循	复杂 prompt 中多个对象、关系、约束都要满足。

这类系统也有典型限制：

- 长文本排版仍可能出错。
- 多主体、多约束时容易遗漏。
- 事实细节需要外部校验。
- 真实人物、品牌和版权内容必须有更强安全策略。

2.11 Qwen-Image 与 Seedream 4.0：中文文字和多图编辑

中文场景里，文字渲染和图像编辑是非常现实的面试点。Qwen-Image 技术报告强调中文和复杂文字渲染、图像编辑一致性；Seedream 4.0 报告强调统一 T2I、image editing、多图组合和高效 DiT / VAE。

为什么这些点重要：

- 中文文字是 logographic writing system，形状更复杂，OCR-style 容错更低。
- 商品图、海报、社媒素材依赖准确文字和品牌一致性。
- 多图参考让模型从“生成一张图”变成“理解素材库并合成新素材”。
- 编辑模型要同时保持语义一致性和视觉保真度。

2.12 架构拆解模板

看到任何新文生图报告，都按下面拆：

模块	你要问的问题
Data	图文数据从哪里来，如何过滤水印、低质、违法、隐私和 OCR 噪声？
Captioning	是否用 VLM / LLM 重新描述图像，caption 是否包含布局、文字、风格、关系？

模块	你要问的问题
Tokenizer	像素空间、VAE latent、VQ token，压缩率和重建质量如何？
Text Encoder	CLIP、T5、LLM、VLM，是否冻结，是否多 encoder？
Backbone	U-Net、DiT、MMDiT、原生多模态 LM，条件如何注入？
Objective	DDPM、EDM、v-prediction、flow matching、rectified flow？
Post-training	是否做 SFT、偏好优化、编辑数据微调、安全对齐？
Evaluation	用哪些自动指标、人评、编辑 benchmark、线上 A/B？
Safety	水印、C2PA、真人肖像、版权、训练数据合规怎么处理？

2.13 本章面试高频问题

2.13.1 为什么 Stable Diffusion 在 latent space 做 diffusion？

因为直接在高分辨率像素空间做 diffusion 成本很高。VAE latent 保留主要语义和视觉结构，同时降低空间维度，使训练和推理更便宜。

2.13.2 DALL-E 2 和 Stable Diffusion 的差异？

DALL-E 2 使用 CLIP latent prior + diffusion decoder；Stable Diffusion 使用 VAE latent space + U-Net denoiser + text cross-attention。二者都利用 diffusion，但条件路径和训练开放性不同。

2.13.3 Imagen 的核心启发是什么？

强 text encoder 对 prompt adherence 很关键。更好的语言理解可以提升图文对齐和复杂 prompt 的遵循。

2.13.4 DiT 为什么重要？

DiT 用 Transformer 做 denoiser，更适合 scaling，也更容易扩展到视频中的 spacetime token。

2.13.5 MMDiT 和普通 DiT 有什么区别？

普通 DiT 可以把文本条件作为 embedding 或 cross-attention 条件。MMDiT 更强调多模态 token 的联合建模：文本和图像有不同表示路径，并在 Transformer 内交互，因此更适合复杂 prompt、文字渲染和多模态生成。

2.13.6 为什么原生多模态图像生成值得关注？

因为真实产品不是一次性 prompt 生成，而是连续对话、上传参考图、要求局部修改、生成带文字的素材。原生多模态模型更容易把语言理解、视觉理解和图像生成放到同一个交互闭环里。

2.14 本章 References

- [Learning Transferable Visual Models From Natural Language Supervision](#)
- [Hierarchical Text-Conditional Image Generation with CLIP Latents](#)
- [Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding](#)
- [High-Resolution Image Synthesis with Latent Diffusion Models](#)

- [Scalable Diffusion Models with Transformers](#)
- [DALL·E 3 official page](#)
- [Imagen official page](#)
- [Stable Diffusion 3 Research Paper announcement](#)
- [Stable Diffusion 3.5 announcement](#)
- [Introducing 4o Image Generation](#)
- [Gemini 2.5 Flash Image](#)
- [Nano Banana Pro](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)
- [FLUX.1 Kontext](#)

第 3 章：Conditioning、Editing、Control 与 Reference Consistency

3.1 本章符号说明

符号/缩写	English	中文	含义
CFG	Classifier-Free Guidance	无分类器引导	用 conditional/unconditional 预测差控制生成。
TI2I	Text-Image-to-Image	文图到图	用文本和参考图共同生成或编辑图像。
Inpainting	Inpainting	局部重绘	给定 mask，只生成缺失或指定区域。
Outpainting	Outpainting	外扩绘制	在原图边界外继续生成内容。
ControlNet	ControlNet	控制网络	给 diffusion 接入边缘、深度、pose 等结构控制。
IP-Adapter	Image Prompt Adapter	图像提示适配器	用图像作为 prompt 条件控制风格或身份。
LoRA	Low-Rank Adaptation	低秩适配	用少量参数适配特定角色、风格或商品。
DreamBooth	DreamBooth	个性化微调方法	用少量图片学习特定主体。
OCR	Optical Character Recognition	光学字符识别	文字识别，也常用于图像中文字生成评测。
ROI	Region of Interest	感兴趣区域	局部编辑或检测关注的区域。
ID	Identity	身份	人物、商品、角色等需要保持一致的视觉身份。
DINO	Self-distillation with No Labels	自监督视觉表征模型	常用于 reference similarity 或视觉一致性评测。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	统一图像生成和编辑的模型系列。
c	Condition	条件	文本、图像、边缘、深度、pose、mask 等。
s	Guidance Scale	引导强度	CFG 中控制文本遵循强度的系数。
ϵ_{cond}	Conditional Prediction	条件预测	有 prompt 条件时的噪声预测。

符号/缩写	English	中文	含义
ϵ_{uncond}	Unconditional Prediction	无条件预测	无 prompt 条件时的噪声预测。
m	Mask	掩码	指定需要编辑或保护的区域。

3.2 本章目标

- 理解 CFG 的公式和直觉。
- 掌握 inpainting / outpainting / image-to-image。
- 理解 ControlNet 和 adapter 类方法。
- 理解 reference consistency、multi-image editing、多轮编辑为什么是 2026 面试重点。
- 能写出可复用的生成和编辑 prompt 结构。

3.3 Classifier-Free Guidance

CFG 同时利用 unconditional 和 conditional 预测：

$$\epsilon_{cfg} = \epsilon_{uncond} + s(\epsilon_{cond} - \epsilon_{uncond})$$

其中 s 是 guidance scale。

直觉：

- s 越大，越贴近 prompt，但可能更僵硬、过饱和、失真。
- s 越小，多样性更高，但可能不听 prompt。

面试表达：

CFG 通过放大 conditional 和 unconditional denoising direction 的差异，提高条件遵循度。它是采样阶段的控制技巧，不需要额外 classifier。

3.4 Image-to-Image

image-to-image 通常先把输入图像编码并加噪到某个强度，再按 prompt 去噪。

关键超参：

- denoise strength 高：改动大。
- denoise strength 低：保留原图结构更多。
- prompt 控制语义方向。
- negative prompt 控制避免元素。

2026 面试里要补一句：

图生图不再只是“改变风格”。主流需求已经变成 reference-based generation：保留商品、人物、角

色、logo、服饰、构图关系，同时按文本做可控改动。

3.5 Inpainting

inpainting 输入：

- 原图。
- mask。
- prompt。

模型只重绘 mask 区域，非 mask 区域尽量保持。

难点：

- mask 边缘融合。
- 光照和材质一致。
- 透视一致。
- 局部编辑不能破坏全局语义。

3.6 ControlNet

ControlNet 给 diffusion 增加结构条件，例如：

- Canny edge。
- depth map。
- human pose。
- segmentation map。
- scribble。

直觉：

原始 text prompt 擅长语义控制，但不擅长精确布局。ControlNet 把结构图作为条件输入，让模型在保持生成质量的同时遵循空间结构。

3.7 Adapter、LoRA 与个性化

真实业务很少只用裸模型。常见轻量适配方式：

方法	English	中文	适合场景
LoRA	Low-Rank Adaptation	低秩适配	学特定风格、角色、商品，成本低。
DreamBooth	DreamBooth	个性化微调	少量图片绑定一个新主体。
Textual Inversion	Textual Inversion	文本反演	学一个新 token 表示特定概念。

方法	English	中文	适合场景
IP-Adapter	Image Prompt Adapter	图像提示适配器	不微调主模型，用参考图控制身份或风格。

面试里要讲 trade-off：

- LoRA 可控但需要训练和版本管理。
- IP-Adapter 上手快，但复杂编辑可能身份漂移。
- DreamBooth 容易过拟合，需要正则和数据增强。
- 多个 adapter 叠加可能互相冲突。

3.8 多图参考与多轮编辑

Nano Banana、FLUX.1 Kontext、Qwen-Image、Seedream 4.0 这类系统都把编辑能力放在核心位置。原因很简单：真实用户往往不是“从零生成”，而是上传参考图，然后连续提出修改。

多图参考常见输入：

- 主体参考图：这个人、这件商品、这个角色。
- 风格参考图：色调、材质、镜头语言。
- 布局参考图：构图、pose、空间关系。
- 文字或 logo 参考图：品牌资产、海报标题。

多轮编辑的主要失败模式：

失败模式	English	中文	例子
Identity Drift	Identity Drift	身份漂移	连续修改后人物脸变了，商品形状变了。
Attribute Leakage	Attribute Leakage	属性泄漏	只想换背景，却把衣服颜色也改了。
Over-editing	Over-editing	过度编辑	局部编辑导致整张图风格被重写。
Text Corruption	Text Corruption	文字损坏	原本正确的 logo 或标题被改错。
Layout Collapse	Layout Collapse	布局崩坏	多个主体的位置关系变乱。

3.9 编辑任务怎么建数据

编辑模型比纯 T2I 更依赖数据设计。常见训练样本形式：

样本	English	中文	用途
Before / After Pair	Before / After Pair	编辑前后图对	学局部和全局编辑。

样本	English	中文	用途
Masked Pair	Masked Pair	带 mask 图对	学 inpainting 和区域保护。
Multi-reference Pair	Multi-reference Pair	多参考图对	学组合多个视觉条件。
Synthetic Edit	Synthetic Edit	合成编辑数据	用渲染、分割、VLM caption 自动构造。
Human Preference	Human Preference	人类偏好数据	学哪个编辑结果更符合意图。

一个成熟 pipeline 往往包括：

1. 自动生成编辑指令。
2. 用分割、检测、OCR、captioning 生成结构化标签。
3. 过滤低质、违规、版权敏感样本。
4. 训练后用 VLM / OCR / embedding similarity 做自动筛选。
5. 对高价值场景做人工偏好标注。

3.10 Prompt 结构

通用 prompt 模板：

主体 + 场景 + 构图 + 风格 + 光照 + 镜头 + 细节 + 质量约束

视频 prompt 还要补：

动作 + 镜头运动 + 时间变化 + 主体一致性 + 场景连续性

面试里不要把 prompt 说成唯一核心。真正的系统还包括：

- 模型选择。
- 分辨率和采样器。
- seed 管理。
- control condition。
- 后处理。
- safety filter。
- 人工审核。

编辑 prompt 建议更结构化：

保留：主体身份、商品形状、logo、构图
修改：背景、光照、服饰颜色、局部物体
禁止：改变脸、改变文字、添加额外主体、破坏品牌色
输出：分辨率、比例、风格、是否透明背景

3.11 工程侧控制面板

一个好用的图像生成工具通常会暴露这些控制项：

控制项	English	中文	作用
Seed	Random Seed	随机种子	复现和 A/B 比较。
Sampler	Sampler	采样器	控制速度和质量。
Guidance Scale	Guidance Scale	引导强度	控制 prompt adherence。
Denoise Strength	Denoise Strength	去噪强度	控制编辑幅度。
Reference Weight	Reference Weight	参考权重	控制身份或风格保留。
Mask Feather	Mask Feather	掩码羽化	改善边缘融合。
Negative Prompt	Negative Prompt	负向提示	减少不需要的元素。

3.12 本章面试高频问题

3.12.1 CFG scale 太大会怎样？

模型更强地追随 prompt，但可能降低多样性，产生过饱和、纹理异常、构图僵硬或细节崩坏。

3.12.2 ControlNet 解决什么问题？

解决纯文本控制不精确的问题。通过边缘、深度、pose、segmentation 等结构条件，约束生成图像的布局和姿态。

3.12.3 Inpainting 为什么容易边缘不自然？

因为局部区域需要同时满足 prompt、mask 内语义、mask 外上下文、边界纹理、光照和透视一致性。任何一个不匹配都会让边缘显得突兀。

3.12.4 Reference consistency 怎么评估？

可以用人评、CLIP / DINO embedding similarity、face / product recognition、OCR、局部检测和多轮编辑回归集。关键是把“保留什么”和“允许改什么”写进测试用例，而不是只看最终图好不好看。

3.12.5 为什么多轮编辑比单轮编辑难？

多轮编辑会累积误差。模型每次生成都会重新解释图像和指令，如果没有稳定的视觉记忆、mask 约束、参考权重和回归测试，就容易身份漂移、文字损坏或不相关区域被改动。

3.13 本章 References

- [Classifier-Free Diffusion Guidance](#)

- [SDEdit: Guided Image Synthesis and Editing with Stochastic Differential Equations](#)
- [Adding Conditional Control to Text-to-Image Diffusion Models](#)
- [IP-Adapter: Text Compatible Image Prompt Adapter for Text-to-Image Diffusion Models](#)
- [FLUX.1 Kontext](#)
- [Gemini 2.5 Flash Image](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)

第 4 章：文生视频、Temporal Consistency、World Model 与音视频生成

4.1 本章符号说明

符号/缩写	English	中文	含义
T2V	Text-to-Video	文生视频	根据文本生成视频。
I2V	Image-to-Video	图生视频	根据图像起点生成视频。
V2V	Video-to-Video	视频到视频	根据输入视频做风格化或编辑。
T2AV	Text-to-Audio-Video	文生音视频	文本输入同时生成画面和声音。
SVD	Stable Video Diffusion	稳定视频扩散	Stability AI 的 latent video diffusion 模型。
DiT	Diffusion Transformer	扩散 Transformer	视频模型常用的时空 token backbone。
VAE	Variational Autoencoder	变分自编码器	视频模型常用的空间或时空压缩器。
FPS	Frames Per Second	每秒帧数	视频时间分辨率。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成分布质量指标。
VBench	Video Benchmark	视频生成基准	从多个维度评估 T2V 质量的 benchmark。
F	Frames	帧序列	视频由多帧图像组成。
T	Time Length	时间长度	视频时长或帧数。
H / W	Height / Width	高 / 宽	视频空间分辨率。
$z_{t,h,w}$	Spacetime Latent Token	时空 latent token	视频压缩后在时间和空间上的 token。

4.2 本章目标

- 理解视频生成相比图像生成多出的难点。
- 掌握 Make-A-Video、Imagen Video、Stable Video Diffusion 的思路。
- 理解 Sora 的 spacetime patch 和 variable aspect ratio。
- 理解 Veo、Movie Gen、Runway Gen-4、HunyuanVideo、Seedance 2.0 的系统趋势。
- 能讨论视频生成评测、安全、音视频同步和产品化难点。

4.3 视频比图像难在哪里

视频生成需要同时满足：

- 单帧质量。
- 帧间一致性。
- 运动自然。
- 物体永久性。
- 镜头运动。
- 角色身份一致。
- 物理和因果关系。
- 长时程 coherence。

文生图只需要生成 $H \times W$ 的空间结构；文生视频要生成 $T \times H \times W$ 的时空结构。

4.4 Make-A-Video

Make-A-Video 的思路是把 text-to-image 进展迁移到 text-to-video：

- 从 text-image 数据学外观和语义。
- 从无文本视频学运动。
- 使用时空模块扩展图像生成模型。

核心观点：

不一定需要大量 paired text-video data，也可以把图像语义和视频运动分开学习。

4.5 Imagen Video

Imagen Video 使用级联 video diffusion：

- base video generation。
- spatial super-resolution。
- temporal super-resolution。
- progressive distillation 加速采样。

直觉：

先生成低分辨率、低帧率视频，再逐步提升空间和时间分辨率，类似 Imagen 图像生成中的 cascade 思路。

4.6 Stable Video Diffusion

SVD 强调 latent video diffusion 的训练流程：

1. text-to-image pretraining。

2. video pretraining。
3. high-quality video finetuning。

它说明视频数据质量和 curation 非常关键。视频不是简单把图像数据堆起来，因为帧间运动、剪辑、字幕、镜头切换都会影响训练。

4.7 Sora: Spacetime Patch

Sora 技术报告里，一个关键思想是把视觉数据统一成 patch：

- 先把视频压缩到 latent space。
- 再切成 spacetime patches。
- 用 diffusion transformer 在 patch token 上训练。
- 支持不同分辨率、时长、宽高比。

可以抽象成：

video → latent → spacetime patches → DiT

这和 LLM 里的 tokenization 有相似之处：用统一 token 表示复杂数据，从而更容易 scale。

4.8 Veo 与产品化趋势

以 Veo、Sora、Runway 等系统为代表，产品化视频生成更关注：

- 更长时长。
- 更高分辨率。
- 音频同步。
- 镜头语言。
- 角色一致性。
- 可编辑性。
- 安全和 provenance。

面试时不要只说“模型更大”。要说明：

- 数据 curation。
- captioning。
- temporal architecture。
- controllability。
- evaluation。
- safety filter。
- serving cost。

4.9 本章面试高频问题

4.9.1 文生视频相比文生图最大难点是什么？

除了单帧质量，还要保证时间一致性、运动自然、角色和物体持续存在、物理因果关系合理，以及长视频的全局 coherence。

4.9.2 为什么视频生成适合 spacetime patch?

spacetime patch 把时间和空间统一成 token，让模型能在同一架构里处理不同分辨率、宽高比和时长的视频，也便于 Transformer scaling。

4.9.3 视频数据 curation 为什么重要?

低质量视频、剪辑跳变、字幕水印、运动模糊、错误 caption 都会污染模型。视频生成对数据的时序一致性和 caption 质量更敏感。

4.9.4 Sora 仍有哪些限制?

官方技术报告提到它仍可能不能准确模拟复杂物理、因果和状态变化，长时程也可能出现不一致或物体自发出现。

4.10 Sora 2：音频、对话与可控性

Sora 2 的公开产品说明把方向从“能生成视频”推进到“更像可交互视频创作工具”：

- 更强的物理一致性和失败后状态延续。
- 同步对话、音效和背景声。
- 更好的可控性和多镜头叙事。
- 支持真实人物 cameo 类功能，但也带来更强的身份、同意和安全要求。

注意一个时间点：OpenAI 页面显示 Sora 产品已在 2026 年 4 月 26 日停止提供，但 Sora / Sora 2 的技术方向仍然是面试里理解视频生成演进的好材料。回答时不要把“产品仍可用”当作事实。

4.11 Veo 3.1：音频和剪辑控制

Veo 3.1 的产品方向强调：

- 文生视频和图生视频。
- 更强 prompt adherence 和 realism。
- audio across features，即在多个功能里支持声音。
- Ingredients to Video、Frames to Video、Extend、Insert/remove 等编辑能力。
- 用 SynthID 标记生成内容。

面试表达：

Veo 的重点不是单个模型参数，而是把视频生成做成可控工作流：参考图、首尾帧、扩展、局部插入、移除、音频同步、安全水印。

4.12 Movie Gen：统一视频、音频、编辑和个性化

Meta Movie Gen 的公开材料强调四类能力：

- text-to-video。
- personalized video。
- precise video editing。
- synchronized audio generation。

Movie Gen 报告里的高频关键词：

关键词	English	中文	面试解读
1080p	Full HD Resolution	全高清分辨率	视频模型开始逼近生产级素材质量。
16 fps	Frames Per Second	每秒 16 帧	说明时间分辨率仍是成本和质量 trade-off。
Audio	Audio Generation	音频生成	音效、音乐、环境声要和画面事件一致。
Personalization	Personalization	个性化	参考人物或主体生成新视频，安全要求更高。
Editing	Instruction-based Editing	指令式编辑	不只是生成，还要能改现有视频。

4.13 Runway Gen-4：一致性和生产 workflow

Runway Gen-4 的公开材料把“world consistency”放在中心：用参考图和指令，在不同镜头中保持角色、地点、物体和风格一致。

对面试很有用的点：

- 长视频不是一次生成一整段，而常常是分镜 + 镜头生成 + 编辑拼接。
- 产品级视频工具需要角色库、场景库、参考资产和版本管理。
- 生成模型要服务导演式 workflow，而不是只做 demo prompt。

4.14 HunyuanVideo、Open-Sora、Seedance：开源和产业化路线

闭源模型质量很强，但面试时也要了解开放技术报告，因为它们会披露更多训练细节。

模型/报告	English	中文	重点
HunyuanVideo	HunyuanVideo	混元视频	13B 级开源视频基础模型，强调数据、架构、训练和推理框架。
Open-Sora 2.0	Open-Sora 2.0	开放 Sora 2.0	强调用有限预算训练商业级视频模型的工程路线。
Seedance 1.0	Seedance 1.0	即梦/Seed 视频 1.0	强调数据 curation、caption、视频 RLHF、多阶段蒸馏和速度优化。
Seedance 2.0	Seedance 2.0	即梦/Seed 视频 2.0	强调文本、图像、音频、视频多模态输入和音视频联合生成。

Seedance 1.0 报告尤其适合面试，因为它明确提到：

- multi-source data curation。
- precision video captioning。
- native multi-shot generation。
- joint T2V / I2V learning。
- fine-grained SFT。
- video-specific RLHF。
- multi-stage distillation。

这些关键词能把你的回答从“会讲模型”拉到“知道产业系统怎么训、怎么快、怎么稳”。

4.15 视频生成系统的通用 pipeline

需求 / prompt
→ LLM 拆分成 storyboard / shots / camera plan
→ 生成关键帧或参考图
→ T2V / I2V 生成每个镜头
→ 一致性检查：角色、物体、场景、文字、品牌
→ 音频生成或配音
→ 剪辑、转场、字幕、调色
→ 安全审核、版权审核、watermark / provenance

这也是项目面试里最推荐的表达方式：不要说“我调用了一个视频模型”，要说“我搭了一个可评测、可回滚、可审核的创意生产 pipeline”。

4.16 视频生成失败模式

失败模式	English	中文	例子
Temporal Flicker	Temporal Flicker	时间闪烁	背景或纹理帧间跳动。
Identity Drift	Identity Drift	身份漂移	人物、商品、角色越生成越不像。
Object Disappearance	Object Disappearance	物体消失	关键物体中途消失或变形。
Physics Violation	Physics Violation	物理违背	碰撞、重力、液体、反射不合理。
Camera Incoherence	Camera Incoherence	镜头不连贯	镜头运动和空间关系冲突。
Audio-Visual Mismatch	Audio-Visual Mismatch	音画不匹配	动作和音效不同步。

失败模式	English	中文	例子
Text Degradation	Text Degradation	文字退化	字幕、logo、标牌随时间变形。

4.17 本章补充面试高频问题

4.17.1 为什么视频模型更依赖 caption?

视频 caption 不只要描述主体，还要描述动作、镜头、时间变化、场景转移、因果关系和声音。caption 粗糙时，模型很难学到 prompt 到运动的对应关系。

4.17.2 什么是多镜头生成?

多镜头生成不是简单延长时长，而是生成多个 shot，并保持角色、场景、风格和叙事连续。它更接近真实创作流程，也更考验 planning、reference consistency 和后处理评测。

4.17.3 音视频联合生成为什么难?

因为声音要同时满足语义、时间点、物理因果和空间感。比如脚步、碰撞、口型、环境声都要和画面事件同步，单独评估视频质量不够。

4.18 本章 References

- [Make-A-Video: Text-to-Video Generation without Text-Video Data](#)
- [Imagen Video: High Definition Video Generation with Diffusion Models](#)
- [Stable Video Diffusion](#)
- [Video generation models as world simulators](#)
- [Sora 2](#)
- [Veo official page](#)
- [Veo 3.1 and Flow updates](#)
- [Movie Gen](#)
- [Movie Gen paper page](#)
- [Introducing Runway Gen-4](#)
- [HunyuanVideo](#)
- [Open-Sora 2.0](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)

第 5 章：文生视频数据构造、预处理与训练实操

这一章专门讲文生视频的训练侧。视频生成模型不是把文生图模型“多生成几帧”就完事了，真正难点在视频数据、caption、镜头边界、时间一致性、音视频同步、训练样本打包和后训练。面试里能把这些讲清楚，会比单纯背 Sora、Veo、Movie Gen、Seedance 的名字更有说服力。

5.1 本章符号说明

符号/缩写	English	中文	含义
T2V	Text-to-Video	文生视频	根据文本 prompt 生成视频。
I2V	Image-to-Video	图生视频	根据起始图、参考图或关键帧生成视频。
V2V	Video-to-Video	视频到视频	根据输入视频做编辑、风格化或重生
AV	Audio-Video	音视频	联合生成或理解画面与声音。
FPS	Frames Per Second	每秒帧数	视频时间分辨率。
Shot	Shot	镜头	连续拍摄或生成的一段画面。
ASR	Automatic Speech Recognition	自动语音识别	把视频中的语音转成文字。
OCR	Optical Character Recognition	光学字符识别	识别视频帧中的文字。
VAE	Variational Autoencoder	变分自编码器	把视频压缩到 latent space 的编码器/解码器。
DiT	Diffusion Transformer	扩散 Transformer	视频 diffusion / flow 常用 backbone。
SFT	Supervised Fine-Tuning	监督微调	用高质量指令和样本微调模型。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好优化视频生成质量。
DPO	Direct Preference Optimization	直接偏好优化	用偏好对直接优化模型偏好。
Distillation	Knowledge Distillation	知识蒸馏	用大模型或多步采样结果训练更快模型。
V	Video	视频	输入或输出的视频片段。
F	Frames	帧序列	视频由多帧图像组成。

符号/缩写	English	中文	含义
T	Time Length	时间长度	视频时长或帧数。
H / W	Height / Width	高 / 宽	视频空间分辨率。
z	Latent	潜变量	VAE 编码后的视频 latent。
c	Condition	条件	文本、首帧、尾帧、参考图、mask、audio 等控制输入。

5.2 本章目标

- 能讲清视频数据从采集到训练样本的完整 pipeline。
- 能解释 caption、shot detection、frame sampling、音频处理为什么关键。
- 能区分 T2V、I2V、V2V、editing、AV 训练样本。
- 能说明视频 post-training、RLHF、distillation 怎么服务产品质量和成本。

5.3 视频数据为什么比图像数据更难

图像样本通常是单帧语义，视频样本包含：

- 时间顺序。
- 镜头切换。
- 角色身份保持。
- 物体状态变化。
- 相机运动。
- 动作和物理因果。
- 音频、对白、环境声。
- 字幕、水印、logo 和剪辑痕迹。

同样一条 caption, “a person opens a door” 对视频来说还不够。训练需要知道门从关到开的过程、人的位置变化、镜头是否移动、声音是否出现、有没有切镜头。

面试表达：

文生视频的数据核心不是“有视频就行”，而是要把视频拆成可学习的时空事件：镜头、动作、主体、场景、相机、声音和状态变化。caption 越能描述时间变化，模型越容易学到 prompt 到 motion 的映射。

5.4 视频数据 Pipeline

- 原始视频
- > 解码、格式统一、fps / 分辨率标准化
 - > shot detection: 切镜头、去片头片尾、去黑帧
 - > 质量过滤: 清晰度、运动模糊、压缩、水印、字幕、NSFW、版权
 - > frame sampling: 均匀采样、关键帧、运动峰值、首尾帧
 - > captioning / recaptioning: 主体、动作、镜头、时间变化、声音
 - > ASR / OCR / audio tagging: 对白、字幕、屏幕文字、音效
 - > task packaging: T2V、I2V、V2V、editing、AV
 - > train / dev / test 切分、去重、去污染
 - > tokenization / VAE latent / spacetime patch
 - > pretraining、SFT、preference、distillation、eval

5.5 数据过滤维度

过滤维度	English	中文	影响
Resolution	Resolution	分辨率	太低会损伤细节和文字。
Compression	Compression Artifact	压缩伪影	会让模型学到噪声和块状纹理。
Motion Blur	Motion Blur	运动模糊	影响主体和动作学习。
Shot Boundary	Shot Boundary	镜头边界	不切镜头会造成时序不连续。
Watermark	Watermark	水印	模型可能生成水印或 logo 残影。
Subtitle	Subtitle	字幕	可能污染画面文字和语义。
NSFW	Not Safe For Work	不适宜工作场景内容	安全和合规风险。
Copyright	Copyright	版权	训练授权和生成风险。
Identity	Identity	身份信息	真人肖像、未成年人、隐私风险。
Audio Quality	Audio Quality	音频质量	影响音视频联合训练。

5.6 Caption 要描述什么

视频 caption 至少要覆盖六类信息：

类别	例子
主体	一名穿红色外套的滑雪者、一辆白色 SUV。
动作	从坡顶滑下、转弯、停住、挥手。
时间变化	开始在远处，随后靠近镜头，最后离开画面。
相机	handheld、pan left、slow zoom in、drone shot。

类别	例子
场景	雪山、黄昏、城市街道、室内厨房。
声音	风声、脚步声、门铃、对白、背景音乐。

不好的 caption:

```
a person skiing
```

更好的 caption:

```
A skier in a red jacket descends a snowy slope, makes two wide turns, slows near the camera, and raises one hand. The camera stays fixed while wind noise is heard in the background.
```

如果训练目标是中文产品，也要有中文 caption 或双语 caption，否则中文 prompt adherence 会弱。

5.7 训练样本 Schema

T2V 样本:

```
{
  "id": "t2v_000001",
  "task": "text_to_video",
  "prompt": "黄昏时，一辆白色汽车沿海边公路行驶，镜头缓慢跟拍。",
  "video": "clips/t2v_000001.mp4",
  "metadata": {
    "fps": 16,
    "duration_sec": 5,
    "resolution": "720p",
    "camera": "tracking shot",
    "source": "licensed"
  }
}
```

I2V 样本:

```
{
  "id": "i2v_000018",
  "task": "image_to_video",
  "image": "keyframes/start.png",
  "prompt": "让画面中的花朵在微风中轻轻摆动，背景保持不变。",
  "video": "clips/i2v_000018.mp4",
  "metadata": {
    "motion": "subtle object motion",
    "identity_preservation": true
  }
}
```

视频编辑样本：

```
{
  "id": "v2v_edit_000042",
  "task": "video_editing",
  "input_video": "clips/input.mp4",
  "instruction": "把天空改成傍晚橙色，但保持人物和镜头运动不变。",
  "target_video": "clips/target.mp4",
  "metadata": {
    "edit_type": "local_style",
    "preserve": ["person_identity", "motion", "composition"]
  }
}
```

5.8 训练阶段

阶段	English	中文	目标
Image Pretraining	Image Pretraining	图像预训练	学习外观、语义、构图。
Video Pretraining	Video Pretraining	视频预训练	学习运动、时序和相机变化。
High-quality Finetuning	High-quality Fine-tuning	高质量微调	提升美学、清晰度、prompt adherence。
Task SFT	Task Supervised Fine-Tuning	任务监督微调	支持 T2V、I2V、V2V、editing、AV。
Preference Tuning	Preference Tuning	偏好调优	优化人类偏好、一致性、安全。

阶段	English	中文	目标
Video RLHF	Video Reinforcement Learning from Human Feedback	视频人类反馈强化学习	针对视频质量、运动、物理和安全优化。
Distillation	Distillation	蒸馏	缩短采样步数、降低 TTV。
Safety Tuning	Safety Tuning	安全调优	降低不合规、侵权、身份滥用。

面试表达：

工业视频模型通常是多阶段训练：先从图像学外观，再从视频学运动，再用高质量数据和偏好数据修产品体验，最后用蒸馏把慢模型变成可上线的低延迟模型。

5.9 Batch 和 Token Budget

视频样本的成本由 T 、 H 、 W 和 latent 压缩率共同决定。直觉上：

$$N_v \propto T \times H \times W$$

这意味着时长、分辨率和帧率不能同时无脑拉满。常见训练策略：

- 短片段先训，逐步增加时长。
- 低分辨率预训练，高分辨率微调。
- frame dropping 或 temporal compression 控制成本。
- 按宽高比和时长做 bucket。
- 混合 T2I、T2V、I2V 数据维持外观和运动。

5.10 偏好数据怎么构造

视频偏好通常不是简单“哪个好看”，而是拆维度：

偏好维度	中文	判断问题
Prompt Adherence	提示遵循	是否满足 prompt 里的主体、动作、风格。
Temporal Consistency	时间一致性	是否闪烁、身份漂移、物体消失。
Motion Naturalness	运动自然度	动作是否连贯，物理是否合理。
Visual Quality	视觉质量	清晰度、构图、光照、美学。
Camera Control	镜头控制	镜头运动是否符合要求。
Audio Sync	音画同步	声音是否和动作、对白同步。
Safety	安全	是否有违规、肖像、版权、暴力等风险。

偏好数据可以是 pairwise，也可以是多维评分。面试时要强调：多维偏好比单一总分更可诊断。

5.11 本章面试高频问题

5.11.1 为什么文生视频需要 shot detection?

因为一个视频文件可能包含多个镜头、剪辑和转场。如果不切镜头，模型会把突然切换的画面当成连续运动学习，导致生成时出现跳变、空间关系混乱和身份漂移。

5.11.2 视频 caption 和图像 caption 的区别?

图像 caption 主要描述静态内容，视频 caption 还要描述动作、时间变化、镜头、事件顺序和声音。文生视频 prompt adherence 很依赖 caption 对 motion 的覆盖。

5.11.3 为什么视频模型常先用图像预训练?

图像数据规模更大、质量更高，可以让模型先学会外观、语义和构图；视频训练再补充运动和时序。这样比只用视频从零训练更高效。

5.11.4 Distillation 在视频生成里为什么重要?

视频采样成本高，线上 TTV 很敏感。蒸馏可以减少采样步数或压缩模型，让生成速度接近产品可用，同时尽量保留质量。

5.12 本章 References

- [Make-A-Video: Text-to-Video Generation without Text-Video Data](#)
- [Imagen Video: High Definition Video Generation with Diffusion Models](#)
- [Stable Video Diffusion](#)
- [Video generation models as world simulators](#)
- [Movie Gen: A Cast of Media Foundation Models](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)

第 6 章：文生视频 workflows、控制、评测与项目实操

上一章讲视频模型怎么训练，这一章讲视频生成系统怎么用、怎么评测、怎么落地。文生视频的产品形态越来越不像“一条 prompt 生成一段视频”，而更像导演式 workflow：分镜、参考图、首尾帧、镜头控制、局部编辑、音频、审核和版本管理。

6.1 本章符号说明

符号/缩写	English	中文	含义
T2V	Text-to-Video	文生视频	根据文本生成视频。
I2V	Image-to-Video	图生视频	根据图片或关键帧生成视频。
V2V	Video-to-Video	视频到视频	基于输入视频做编辑或重生成。
AV	Audio-Video	音视频	联合处理画面和声音。
FPS	Frames Per Second	每秒帧数	视频时间分辨率。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成分布级指标。
VBench	Video Benchmark	视频生成基准	多维度评估视频生成质量的 benchmark。
CLIPScore	CLIP Score	CLIP 相似度得分	衡量文本和视觉语义匹配。
DINO	Self-distillation with No Labels	自监督视觉表征模型	可用于参考一致性评测。
LPIPS	Learned Perceptual Image Patch Similarity	学习感知图像块相似度	评估感知差异和编辑保真。
OCR	Optical Character Recognition	光学字符识别	检查视频中文字是否稳定和正确。
VLM	Vision-Language Model	视觉语言模型	用于自动评测、caption、审核和 badcase 归因。
C2PA	Coalition for Content Provenance and Authenticity	内容来源与真实性联盟	标记内容来源和编辑历史的标准。
SynthID	SynthID Watermarking	SynthID 水印	Google 用于标记生成内容的水印技术。
TTV	Time to Video	视频生成耗时	从请求到视频可用的端到端延迟。
KPI	Key Performance Indicator	关键业务指标	业务效果指标，如通过率、点击率、转化率。

符号/缩写	English	中文	含义
p	Prompt	提示词	用户或系统给模型的生成指令。
r	Reference	参考资产	参考图、角色、商品、首尾帧或视频片段。
s_i	Shot	第 i 个镜头	分镜计划中的一个镜头。

6.2 本章目标

- 能把文生视频讲成可控创作 workflow，而不是单次生成。
- 能设计视频生成 eval harness 和 badcase 归因体系。
- 能说明首尾帧、参考图、mask、camera control、audio control 的作用。
- 能把项目表达成“生成、评测、安全、成本、线上反馈”的闭环。

6.3 产品级视频生成 Workflow

一个通用 pipeline：

用户需求 / brief
-> LLM 拆分 storyboard、shot list、camera plan
-> 生成或上传 reference：角色、商品、场景、首帧、尾帧
-> T2V / I2V 生成每个镜头
-> 一致性检查：人物、商品、场景、文字、品牌
-> 局部编辑：mask edit、object insert/remove、extend
-> 音频：对白、音效、环境声、音乐
-> 剪辑：排序、转场、字幕、调色、封面
-> 评测：自动指标、人评、业务审核、badcase 标签
-> 安全：身份同意、版权、watermark、C2PA、日志

面试表达：

真实文生视频系统不是一次 prompt 出片，而是把视频拆成 shot-level generation 和 edit-level control。模型负责生成候选，系统负责规划、参考资产管理、一致性校验、评测、审核和回滚。

6.4 控制信号地图

控制信号	English	中文	解决什么问题
Prompt	Text Prompt	文本提示	主体、动作、风格、场景。
First Frame	First Frame	首帧	控制开头构图和主体。
Last Frame	Last Frame	尾帧	控制结束状态和转场目标。

控制信号	English	中文	解决什么问题
Reference Image	Reference Image	参考图	保持人物、商品、风格一致。
Multi-reference	Multiple References	多参考图	组合角色、场景、商品、风格。
Mask	Mask	蒙版	局部编辑、插入、移除。
Pose / Depth	Pose or Depth Condition	姿态或深度条件	控制人物动作和空间结构。
Camera Plan	Camera Plan	镜头计划	pan、zoom、dolly、orbit 等镜头运动。
Audio Prompt	Audio Prompt	音频提示	音效、环境声、对白、音乐。
Negative Prompt	Negative Prompt	负向提示	避免不需要的物体、风格或风险。

这些控制信号可以组合，但组合越多，模型越容易出现冲突。比如首帧要求人物站着，prompt 要求人物从椅子上起身，尾帧又要求人物躺下，系统需要先做 prompt normalization 和冲突检查。

6.5 视频评测维度

维度	English	中文	典型检查
Visual Quality	Visual Quality	视觉质量	清晰、构图、光照、美学。
Prompt Adherence	Prompt Adherence	提示遵循	主体、动作、风格、场景是否满足。
Temporal Consistency	Temporal Consistency	时间一致性	是否闪烁、漂移、跳变。
Identity Consistency	Identity Consistency	身份一致性	人物、商品、角色是否保持。
Motion Naturalness	Motion Naturalness	运动自然度	动作是否连贯、物理是否合理。
Camera Coherence	Camera Coherence	镜头一致性	镜头运动是否稳定、空间是否连贯。
Text Stability	Text Stability	文字稳定性	logo、字幕、标牌是否变形。
Audio Sync	Audio-Visual Synchronization	音画同步	口型、脚步、碰撞、环境声是否同步。
Edit Faithfulness	Edit Faithfulness	编辑保真	该改的改，不该改的保持。

维度	English	中文	典型检查
Safety	Safety	安全	肖像、版权、暴力、成人、误导性内容。

6.6 视频 Eval Harness

一个视频生成 harness 至少需要：

模块	内容
Prompt Suite	T2V、I2V、V2V、首尾帧、参考图、音频、编辑任务。
Asset Registry	参考图、mask、角色库、商品库、版权和授权信息。
Run Config	模型版本、seed、分辨率、fps、时长、sampler、guidance。
Runner	批量提交、失败重试、缓存、队列、成本记录。
Auto Metrics	FVD、CLIPScore、OCR、DINO/LPIPS、motion、safety classifier。
VLM Judge	多维打分、pairwise preference、badcase 解释。
Human Review	盲评、pairwise、业务审核、安全审核。
Report	分维度分数、置信区间、成本、延迟、失败样例。

注意：FVD 这种指标适合分布级比较，但不适合直接判断单条视频是否满足 prompt。产品评测必须有 prompt-level、人评和 badcase 维度。

6.7 Badcase 归因

失败类型	English	中文	处理方向
Flicker	Temporal Flicker	时间闪烁	数据过滤、temporal loss、后处理。
Identity Drift	Identity Drift	身份漂移	reference consistency、角色 embedding、I2V。
Object Disappearance	Object Disappearance	物体消失	更强时序建模、分镜约束、检测回归。
Physics Violation	Physics Violation	物理违背	更好 motion 数据、偏好数据、world model 评测。
Camera Conflict	Camera Conflict	镜头冲突	prompt 规范化、camera plan 拆解。
Audio Mismatch	Audio-Visual Mismatch	音画不匹配	AV 数据、同步评测、后期对齐。

失败类型	English	中文	处理方向
Text Degradation	Text Degradation	文字退化	OCR-aware 数据、短视频后处理、文字单独渲染。
Over-editing	Over-editing	过度编辑	mask、preserve loss、编辑数据改进。
Safety Violation	Safety Violation	安全违规	输入输出审核、拒绝策略、provenance。

6.8 项目实操一：广告短视频生成

1. 输入：商品图、卖点、品牌规范、目标人群。
2. 规划：LLM 生成 3-5 个 shot，包含镜头、字幕、CTA。
3. 生成：商品 I2V + 背景 T2V + 局部编辑。
4. 评测：商品一致性、文字正确率、品牌安全、转化素材人评。
5. 上线：素材审核、A/B 测试、CTR/CVR、成本监控。

亮点表达：

广告视频项目的核心不是“生成好看视频”，而是商品和品牌不能漂移，文字不能错，素材要可审核、可回滚，并且最终用 CTR/CVR 和人工审核通过率闭环。

6.9 项目实操二：影视分镜预览

1. 输入：剧本片段、人物设定、场景设定。
2. 规划：拆分 shot list、camera plan、情绪、动作。
3. 资产：角色参考图、场景参考图、风格板。
4. 生成：每个 shot 用 I2V 或 T2V 生成多候选。
5. 评测：角色一致性、镜头连续性、动作自然度、导演偏好。
6. 后处理：剪辑、配音、临时音乐、字幕。

这个项目特别适合说明“视频生成越来越 agentic”：LLM 做规划，图像模型做 keyframe，视频模型做 shot，VLM/judge 做评测和回归。

6.10 项目实操三：视频编辑和合规审核

输入现有视频，做 object remove、背景替换、风格化、logo 清理或字幕修改。

关键评测：

- 修改区域是否完成。
- 未修改区域是否保持。
- 人物身份是否保持。
- 镜头运动是否保持。

- 音频是否仍然同步。
- 是否引入版权、肖像、误导性风险。

面试时强调：编辑任务比生成任务更需要 preserve 约束和 before/after 评测。

6.11 面试高频问题

6.11.1 为什么文生视频产品要分镜？

长视频一次生成成本高、可控性差、失败难修。分镜可以把复杂需求拆成短镜头，每个镜头独立生成和评测，再通过剪辑保持叙事连续。

6.11.2 首尾帧控制有什么用？

首帧保证起始构图和主体，尾帧约束最终状态。它比纯文本 prompt 更适合控制转场、角色位置和动作结果。

6.11.3 自动指标为什么不够？

视频质量包含美学、语义、运动、物理、身份、安全和业务偏好。单个自动指标很难覆盖，必须结合多维指标、VLM judge、人评和业务指标。

6.11.4 文生视频项目怎么证明上线价值？

离线看 prompt adherence、时序一致性、身份一致性、安全通过率；线上看生成成功率、TTV、人工审核通过率、CTR/CVR、用户留存和成本。

6.12 本章 References

- [VBench: Comprehensive Benchmark Suite for Video Generative Models](#)
- [VideoPhy: Evaluating Physical Commonsense for Video Generation](#)
- [Movie Gen: A Cast of Media Foundation Models](#)
- [Introducing Runway Gen-4](#)
- [Veo official page](#)
- [Veo 3.1 and Flow updates](#)
- [C2PA Technical Specification](#)

第 7 章：面试速查、项目表达与常见追问

这一章不是替代后面的评测和安全章节，而是给你一个面试现场可直接复述的框架。文生图/文生视频项目不要讲成“调 prompt 调出来了”，而要讲成：任务定义、数据、模型、控制、评测、安全、成本、线上闭环。

7.1 本章符号说明

符号/缩写	English	中文	含义
KPI	Key Performance Indicator	关键业务指标	项目最终服务的业务目标，如通过率、转化率、成本。
CTR	Click-Through Rate	点击率	创意素材或广告常见线上指标。
CVR	Conversion Rate	转化率	点击后购买、注册、提交等转化比例。
A/B	A/B Testing	A/B 测试	比较不同策略或素材效果的线上实验。
SLA	Service Level Agreement	服务等级协议	延迟、稳定性、可用性等服务承诺。
TTI	Time to Image	图像生成耗时	从请求到图像可用的端到端延迟。
TTV	Time to Video	视频生成耗时	从请求到视频可用的端到端延迟。
QA	Quality Assurance	质量保证	人工或自动质量检查流程。
ROI	Region of Interest	感兴趣区域	局部编辑、商品主体、人物脸部等重点区域。

7.2 30 分钟复习路线

- 1. 5 分钟：DDPM forward / reverse / denoising loss。
- 2. 5 分钟：CFG、sampling、guidance scale、少步采样。
- 3. 5 分钟：LDM、VAE、Stable Diffusion、DiT、MMDiT。
- 4. 5 分钟：flow matching、rectified flow、SD3 / FLUX。
- 5. 5 分钟：ControlNet、IP-Adapter、LoRA、reference consistency。
- 6. 5 分钟：Sora / Veo / Movie Gen / Seedance，重点讲时序一致性和评测。

7.3 一分钟回答模板

如果面试官问“你怎么理解文生图/文生视频系统”，你可以这样答：

我会把它拆成生成路径、条件注入、数据和评测四层。底层是 diffusion 或 flow matching，从噪声到数据分布；架构上从 U-Net 发展到 DiT / MMDiT，多模态条件通过 text encoder、cross-attention、reference image 或统一 token 注入；工程上要处理 caption、数据过滤、采样器、编辑控制、成本和延迟；最后必须有 eval harness，把 prompt adherence、视觉质量、身份一致性、文字渲染、视频时序、物理合理性和安全都拆开评测。

这段回答的好处是：它不是背模型名，而是能自然展开到任何追问。

7.4 高频知识点速查

问题	短答
为什么 diffusion 训练稳定？	它把生成任务转成监督式去噪，不需要 GAN 式对抗训练。
为什么采样慢？	从噪声到数据需要多步迭代，少步采样会放大误差。
为什么用 latent diffusion？	在 VAE latent 中生成能大幅降低计算量，但会带来细节和文字 bottleneck。
CFG 的副作用是什么？	scale 太高会过饱和、僵硬、细节崩坏，太低则 prompt adherence 差。
DiT 为什么重要？	Transformer backbone 更符合 scaling 经验，也方便扩展到视频时空 token。
MMDiT 的价值是什么？	文本和图像 token 用不同路径建模再交互，更适合复杂多模态条件。
flow matching 为什么火？	直接学习生成路径速度场，适合更直路径和少步采样。
文生视频最大的难点？	单帧质量之外，还要保证时间一致、运动自然、物理合理、角色和场景不漂移。
图像编辑最难点？	既要改目标区域，又要保持不该改的主体、文字、风格和布局。
为什么要 eval harness？	生成质量主观且不稳定，必须固定 prompt、seed、版本、指标和人评流程才能比较。

7.5 项目表达模板

讲项目时按这个顺序：

模块	面试官想听什么
Problem	解决什么业务问题，输入输出是什么，为什么不能只靠人工或模板。
Data	训练或评测数据怎么来，如何过滤低质、侵权、隐私、脏标注。
Model	用 T2I / I2I / T2V / I2V 哪种模型，是否需要 LoRA、ControlNet、VLM 审核。
Control	如何保证商品、人物、文字、品牌、构图、视频时序一致。
Evaluation	离线指标、人评、线上 A/B、失败样例库怎么设计。
Safety	真人肖像、版权、色情暴力、未成年人、政治误导、watermark 怎么处理。

模块	面试官想听什么
Serving	延迟、成本、并发、缓存、降级、重试、可观测性怎么做。
Iteration	用户反馈、badcase、线上数据如何回流。

7.6 项目 1：商品图生成和编辑

任务：

- 输入商品图、品牌规范、营销文案。
- 输出不同场景、不同风格、不同尺寸的商品营销图。
- 支持背景替换、局部修复、文案排版、风格统一。

方案：

1. 用 segmentation 或检测得到商品主体和 ROI。
2. I2I / inpainting 生成背景和局部区域。
3. 用 ControlNet 或 layout condition 保持构图。
4. 用 OCR 检查文案，文字复杂时用渲染引擎后贴。
5. 用 VLM 做商品一致性、品牌合规和安全审核。

指标：

- 商品一致性。
- 背景质量。
- 文案文字正确率。
- 品牌规范通过率。
- 人工审核通过率。
- TTI 和单位生成成本。

面试亮点：

我不会只用 CLIPScore 看图文相似，而会单独评估商品主体是否变形、logo 是否正确、文案 OCR 是否准确、背景是否违规，以及人工审核通过率和线上 CTR。

7.7 项目 2：短视频广告生成

任务：

- 输入商品图、卖点、目标人群、时长。
- 输出 5 到 15 秒短视频或分镜草稿。

方案：

1. LLM 生成 storyboard、shot list、camera movement。
2. T2I / I2I 生成关键帧。

3. I2V / T2V 生成每个镜头。
4. 用 reference image 保持商品和角色一致。
5. 生成或添加配音、字幕、音效。
6. VLM / OCR / audio checker 做一致性和安全审核。

难点：

- 主体一致性。
- 多镜头叙事连续。
- 字幕和 logo 稳定。
- 音画同步。
- 版权和真人肖像安全。
- TTV 成本高，失败重试贵。

7.8 项目 3：创意素材 A/B 生成

任务：

- 批量生成不同风格、构图、文案、卖点的创意素材。
- 根据人工偏好、历史表现和线上 A/B 选择投放。

技术亮点：

- prompt 参数化和版本管理。
- seed、sampler、model version 固化。
- 自动打分 + 人工复核 + 线上反馈闭环。
- 维护 badcase 集和 regression set。

面试表达：

我会把生成系统做成实验平台，而不是一次性脚本。每次模型、prompt、采样器或审核规则变化，都能在同一套 prompt suite 和人评协议上复测。

7.9 常见追问

7.9.1 文生图如何提升文字渲染？

数据上需要高质量 OCR 标注、复杂排版样本和合成文字数据；模型上需要更强语言理解和视觉 tokenizer；评测上要单独做 OCR accuracy；产品上可以把长文本交给排版引擎而不是完全依赖生成模型。

7.9.2 视频生成怎么保持角色一致？

用参考图、identity embedding、多帧一致性约束、tracking-based conditioning、首尾帧控制、镜头级回归测试和人工审核。长视频通常要拆分镜头并保持资产库，而不是一次生成到底。

7.9.3 如何降低生成成本？

降低采样步数、使用 distilled model、缓存中间结果、分级模型路由、先低清预览再高清重绘、失败检测提前终止、批处理和异步队列。

7.9.4 如何处理 badcase?

把 badcase 结构化：prompt、输入图、模型版本、seed、sampler、失败标签、自动指标、人评结论、修复策略。然后放进 regression harness，每次升级都跑。

7.9.5 为什么不能只看 leaderboards?

leaderboard prompt 分布可能和业务不一致，而且很多指标不能覆盖文字、品牌、真人肖像、局部编辑、长视频时序和安全风险。业务系统必须有自己的评测集。

7.10 最后检查清单

- 能写出 $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\epsilon$ 。
- 能解释为什么训练可以预测 ϵ 、 x_0 或 v 。
- 能解释 CFG 的公式和副作用。
- 能讲清 latent diffusion 的优势和代价。
- 能讲清 DiT / MMDiT 和 U-Net 的差异。
- 能讲清 flow matching 和 rectified flow 的动机。
- 能讲清文生视频的 temporal consistency、identity drift、physics plausibility。
- 能设计一个图像/视频生成项目的 eval harness 和安全策略。

第 8 章：2026 SOTA 技术报告阅读地图

这一章帮你把 SOTA（State of the Art，当前最佳水平）模型放进同一张地图。面试里不要只说“我看过 Sora、Veo、FLUX”，而要能说出每个报告在数据、架构、训练、评测、安全上的关键启发。

8.1 本章符号说明

符号/缩写	English	中文	含义
SOTA	State of the Art	当前最佳水平	当前公开或行业中表现领先的技术。
T2I	Text-to-Image	文生图	文本生成图像。
T2V	Text-to-Video	文生视频	文本生成视频。
I2I	Image-to-Image	图生图	图像编辑或重绘。
I2V	Image-to-Video	图生视频	参考图生成视频。
MMDiT	Multimodal Diffusion Transformer	多模态扩散 Transformer	文本和图像 token 交互的 DiT。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	图像生成和编辑模型系列。
FM	Flow Matching	流匹配	学习生成路径速度场。
RF	Rectified Flow	矫正流	用更直接路径提升生成效率。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好优化模型行为。
LLM	Large Language Model	大语言模型	用于 caption、规划、评测或多模态生成。
VLM	Vision-Language Model	视觉语言模型	同时处理图像和文本的模型。
AV	Audio-Video	音视频	联合视频和声音生成。

8.2 读技术报告的统一框架

每篇报告按 9 个问题拆：

维度	你要找什么
Task	它解决 T2I、I2I、T2V、I2V、V2V、AV 还是多任务统一？
Data	数据规模、来源、过滤、caption、版权和安全处理怎么做？

维度	你要找什么
Tokenizer	用像素、VAE latent、3D VAE、spacetime patch、discrete token 还是原生多模态 token？
Backbone	U-Net、DiT、MMDiT、LLM-style transformer、cascade 还是混合架构？
Objective	DDPM、EDM、v-prediction、flow matching、rectified flow、autoregressive？
Conditioning	文本、参考图、多图、首尾帧、mask、pose、audio、video reference 怎么注入？
Post-training	SFT、偏好优化、RLHF、distillation、安全对齐做了什么？
Evaluation	自动指标、人评、benchmark、业务测试、失败维度怎么设计？
Safety	watermark、C2PA、SynthID、真人肖像、版权、红队、安全过滤怎么做？

这张表就是你的“报告阅读 harness”。

8.3 文生图与图像编辑主线

模型/报告	时间线	关键词	面试重点
Stable Diffusion 3 / 3.5	2024	MMDiT、rectified flow、CLIP + T5、typography	从 U-Net LDM 转向多模态 Transformer 和 flow。
FLUX.1 Kontext	2025	unified generation and editing、flow matching、KontextBench	把生成和编辑统一到一个模型范式，强调参考一致性。
GPT-4o Image	2025	native multimodal generation、text rendering、multi-turn editing	图像生成成为多模态 LM 原生能力。
Gemini 2.5 Flash Image / Nano Banana	2025	multi-image fusion、character consistency、local edit、world knowledge	编辑、参考一致和世界知识结合。
Nano Banana Pro	2025	Gemini 3 Pro Image、4K、layout、richer text	更强文字、信息图和专业设计场景。
Qwen-Image	2025	Chinese text rendering、multi-task editing、Qwen2.5-VL + MMDiT	中文文字渲染和编辑一致性是核心卖点。
Seedream 4.0	2025	multimodal image generation、T2I + editing + multi-image composition、efficient DiT / VAE	统一生成、编辑和多图组合，关注效率和工业化。
Imagen 4	2025	safety filtering、SynthID、high fidelity	Google 图像生成产品化和安全水印路线。

8.3.1 图像模型的共同趋势

1. 从 U-Net 到 DiT / MMDiT。
2. 从 noise prediction 到 v-prediction / flow matching / rectified flow。

- 3. 从单 prompt 生成到 reference-based multi-turn editing。
- 4. 从英文 prompt 到多语言、中文、复杂文字渲染。
- 5. 从“漂亮图”到“可用图”：商品、海报、UI、信息图、品牌一致性。
- 6. 从模型单点到工作流：安全、审核、版本、回归测试、成本。

8.4 文生视频与音视频主线

模型/报告	时间线	关键词	面试重点
Sora	2024	spacetime patches、DiT、variable duration / resolution / aspect ratio	把视频和图像统一成可扩展时空 token。
Sora 2	2025	audio、dialogue、better physics、cameo safety	视频生成从画面扩展到音频和可控互动。
Veo 3.1	2025	audio across features、Flow、Ingredients / Frames / Extend / Insert-remove	产品化视频工作流和音画同步。
Movie Gen	2024	1080p、audio、personalization、instruction-based editing	Meta 的统一视频、音频、编辑、个性化路线。
Runway Gen-4	2025	world consistency、reference-based characters / locations / objects	生产工作流里的角色和场景一致性。
HunyuanVideo	2024	open-source 13B video foundation model、data + architecture + infra	开源视频大模型报告，披露工程细节更多。
Open-Sora 2.0	2025	cost-efficient training、data curation、system optimization	低预算训练高质量视频模型的工程路线。
Seedance 1.0	2025	video captioning、multi-shot、T2V + I2V、video RLHF、distillation	产业系统如何做数据、后训练和加速。
Seedance 2.0	2026	text / image / audio / video inputs、audio-video joint generation	多模态输入和音视频联合生成。

8.4.1 视频模型的共同趋势

- 1. 从短 clip 到多镜头、多分镜和更长时程。
- 2. 从 silent video 到 audio-video joint generation。
- 3. 从单次生成到编辑、扩展、插入、移除和首尾帧控制。
- 4. 从 text prompt 到多模态 reference：图像、视频、音频、角色资产。
- 5. 从纯质量评测到时序、物理、音画一致、安全和版权评测。

8.5 重点报告怎么读

8.5.1 Stable Diffusion 3 / 3.5

你要抓：

- 为什么引入 MMDiT。

- 为什么使用多个 text encoder。
- rectified flow 相比传统 DDPM 训练的动机。
- typography 和 prompt adherence 为什么被单独强调。
- 3.5 为什么强调可定制、开源和消费级硬件。

可复述答案：

SD3 系列代表 latent diffusion 从 U-Net + cross-attention 走向 MMDiT + flow 的范式变化。它的面试价值在于说明 text encoder、backbone、objective 和数据共同决定 prompt adherence 和文字渲染。

8.5.2 GPT-4o Image

你要抓：

- 它把图像生成当成多模态模型能力，而不是外接图片模型。
- 多轮上下文、文字渲染、in-context learning 和世界知识是重点。
- C2PA metadata、内部搜索和真实人物限制体现了产品级安全。

可复述答案：

GPT-4o Image 的关键不是“又一个文生图模型”，而是把语言理解、视觉理解和图像生成放到一个原生多模态交互里，所以多轮编辑、准确文字和复杂指令遵循更自然。

8.5.3 FLUX.1 Kontext

你要抓：

- generation 和 editing 统一。
- 只用文本和图像上下文，尽量减少任务特化 pipeline。
- KontextBench 用来评估编辑能力，而不是只评估单图质量。

可复述答案：

Kontext 代表图像模型从 T2I 走向 instruction-based visual editing。评测也必须从 FID / CLIPScore 扩展到编辑前后的一致性、目标区域变化和非目标区域保持。

8.5.4 Qwen-Image / Seedream 4.0

你要抓：

- 中文和复杂文字渲染。
- 图像编辑一致性。
- 多图参考和组合。
- 高效 VAE / DiT 对生产成本的影响。

可复述答案：

中文图像生成不能只看 aesthetics。文字形态、排版、logo、商品一致性和多图编辑会成为核心体验，所以数据 pipeline、OCR 标注和编辑 benchmark 很关键。

8.5.5 Sora / Veo / Movie Gen / Seedance

你要抓：

- 视频不是 T 张独立图，而是时空生成。
- 时空 patch、3D VAE、temporal attention、multi-shot planning 都是为一致性服务。
- 视频 caption 要描述动作、镜头、场景转移和声音。
- 音视频联合生成引入 lip-sync、音效、物理因果和声音安全。
- 产品系统必须支持编辑、扩展、审核和 provenance。

可复述答案：

2026 的视频生成竞争不只是分辨率和时长，而是谁能把多模态参考、分镜控制、音画同步、角色一致性、安全水印和低延迟生成做成稳定工作流。

8.6 面试里如何谈“最新”

不要说“某模型永远最强”。更好的说法：

截至 2026 年 6 月，公开材料里能看到几个清晰方向：图像侧是 DiT / MMDiT、flow matching、原生多模态编辑、文字渲染和多图一致性；视频侧是时空 token、音视频联合生成、多镜头控制、reference consistency、video RLHF 和安全 provenance。具体榜单会变，但这些方向是稳定的。

这句话很稳，因为它不依赖单一 leaderboard。

8.7 本章 References

- [Stable Diffusion 3 Research Paper announcement](#)
- [Stable Diffusion 3.5 announcement](#)
- [FLUX.1 Kontext](#)
- [Introducing 4o Image Generation](#)
- [Gemini 2.5 Flash Image](#)
- [Nano Banana Pro](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)
- [Imagen official page](#)
- [Video generation models as world simulators](#)
- [Sora 2](#)
- [Veo official page](#)
- [Veo 3.1 and Flow updates](#)

- [Movie Gen](#)
- [Introducing Runway Gen-4](#)
- [HunyuanVideo](#)
- [Open-Sora 2.0](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)

第 9 章：Eval Harness、Benchmarking、人评与自动评测

生成模型评测最容易陷入“我觉得好看”。面试里你要主动引入 eval harness：固定输入、固定配置、固定指标、固定人评协议、固定版本记录，让每次模型或 prompt 改动都可复现、可对比、可回归。

9.1 本章符号说明

符号/缩写	English	中文	含义
Harness	Evaluation Harness	评测工具链	统一管理数据、配置、运行、打分、报告和回归的评测系统。
FID	Fréchet Inception Distance	Fréchet Inception 距离	图像生成分布级质量指标。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成分布级质量指标。
IS	Inception Score	Inception 分数	早期图像生成质量和多样性指标。
CLIPScore	CLIP Score	CLIP 相似度得分	用 CLIP 衡量图文匹配。
VQA	Visual Question Answering	视觉问答	用问答形式判断图像或视频是否满足条件。
VQAScore	Visual Question Answering Score	视觉问答得分	用 VQA 判断 prompt 中属性是否满足。
HPS	Human Preference Score	人类偏好得分	基于人类偏好训练的自动指标。
PickScore	PickScore	偏好选择得分	用偏好数据训练出的图像偏好模型。
ImageReward	ImageReward	图像奖励模型	用人类反馈训练的图像生成 reward。
OCR	Optical Character Recognition	光学字符识别	用于评测图像或视频中的文字是否正确。
DINO	Self-distillation with No Labels	自监督视觉表征模型	常用于 reference similarity 或视觉一致性评测。
LPIPS	Learned Perceptual Image Patch Similarity	学习感知图像块相似度	衡量图像感知差异，常用于编辑保真评测。
MLLM	Multimodal Large Language Model	多模态大语言模型	可作为自动评委，但需要校准。

符号/缩写	English	中文	含义
ELO	Elo Rating System	Elo 评分系统	pairwise preference 常用排名方法。
CI	Confidence Interval	置信区间	衡量评测结果不确定性。

9.2 什么是 Eval Harness

一个最小可用 harness 至少包括：

模块	内容
Prompt Suite	固定 prompt、参考图、mask、首尾帧、音频、负向提示。
Run Config	固定模型版本、seed、sampler、steps、CFG scale、分辨率、后处理。
Inference Runner	统一生成任务提交、重试、缓存、日志。
Auto Metrics	自动指标、VLM judge、OCR、检测器、embedding similarity。
Human Eval	人评界面、pairwise 比较、blind review、审核一致性。
Report	输出表格、失败样例、置信区间、版本差异。
Regression Set	每次升级必跑的 badcase 和核心场景。

一句话：

Harness 不是一个指标，而是一整套让生成模型评测可复现的实验系统。

9.3 Prompt Suite 怎么设计

文生图 prompt suite 至少覆盖：

- 单主体。
- 多主体。
- 复杂属性组合。
- 空间关系。
- 计数。
- 文字渲染。
- 风格迁移。
- 商品和 logo。
- 人物和身份一致。
- 安全边界。
- 多语言，尤其中文。
- 局部编辑和多轮编辑。

文生视频 prompt suite 还要覆盖：

- 静态镜头。
- 镜头运动。
- 主体运动。
- 多主体交互。
- 物体永久性。
- 快速动作。
- 复杂物理。
- 首尾帧控制。
- 多镜头叙事。
- 音画同步。
- 字幕和标牌随时间稳定。

9.4 固定运行配置

没有固定 config，评测结果就很难复现。建议记录：

```
model:
  name: image-video-model
  version: 2026-06-22
  checkpoint: release-or-commit-id
generation:
  task: t2i
  seed: 12345
  width: 1024
  height: 1024
  sampler: euler
  steps: 28
  guidance_scale: 4.5
  negative_prompt: low quality, distorted text
inputs:
  prompt_id: poster_zh_text_001
  prompt: 生成一张中文促销海报，标题必须为“夏日新品”
  reference_images: []
postprocess:
  upscaler: none
  safety_filter: v3
```

视频还要记录：

```

video:
  duration_seconds: 8
  fps: 24
  resolution: 1280x720
  audio_enabled: true
  first_frame_id: optional
  last_frame_id: optional
  shot_plan_id: optional

```

9.5 图像自动指标

维度	可用指标/方法	局限
Visual Fidelity	FID、aesthetic score、sharpness、artifact detector	和人类偏好不总一致。
Text Alignment	CLIPScore、VQAScore、MLLM judge	复杂关系、计数和否定容易误判。
Text Rendering	OCR accuracy、edit distance、layout check	OCR 本身也会出错。
Identity Consistency	face/product embedding、DINO similarity、人评	对非人主体要定制检测器。
Editing Preservation	mask 外 similarity、LPIPS、结构检测	保留和修改的边界必须定义清楚。
Safety	moderation model、face recognition、copyright detector	需要人工复核和规则兜底。

GenAI-Bench 的启发是：复杂组合 prompt 需要更细粒度评测，VQAScore 往往比单纯 CLIPScore 更适合判断对象、属性和关系是否满足。

9.6 视频自动指标

维度	可用指标/方法	局限
Frame Quality	FID-like frame score、aesthetic score、artifact detector	单帧好不代表视频好。
Temporal Consistency	optical flow consistency、temporal flicker score、embedding stability	快速运动和镜头切换会干扰。
Motion Quality	action recognition、motion magnitude、VBench motion dimensions	很难覆盖创意镜头语言。
Text-Video Alignment	VLM / MLLM judge、caption-video similarity	长 prompt 和多事件很难评。

维度	可用指标/方法	局限
Physics	T2V-PhysBench、AV-Phys Bench、rule-based check	物理 commonsense 仍是开放问题。
Audio-Visual Sync	lip-sync score、event-audio alignment、audio caption consistency	声音语义和物理因果都难。
Identity Consistency	tracking + embedding similarity、人评	遮挡、侧脸、光照变化会影响。

VBench 的价值是把视频质量拆成多维度，而不是只给一个总分。对业务来说，你也应该拆成“可用性维度”：比如商品广告更重视商品不变形和品牌安全，影视分镜更重视镜头和角色一致性。

9.7 人评协议

自动指标只能做初筛。人评要设计成可统计的协议：

设计项	推荐做法
Blind Review	隐藏模型名和生成参数。
Pairwise Preference	两两比较更稳定，适合 ELO 或 Bradley-Terry 排名。
Absolute Rating	1 到 5 分可解释，但人之间校准困难。
Multi-axis Rubric	分开打质量、对齐、文字、身份、安全、视频时序。
Rater Calibration	给标注员示例和边界样例。
Inter-rater Agreement	统计一致性，发现分歧维度。
Confidence Interval	给出 CI，避免小样本过度解读。

9.8 VLM / MLLM Judge 怎么用

VLM judge 可以降低成本，但不能无脑信。

适合：

- 判断 prompt 中是否有某个对象。
- OCR 辅助。
- 简单安全分类。
- 对比两张图哪个更符合 prompt。
- 生成失败原因标签。

不适合完全替代人评：

- 审美偏好。
- 微妙身份一致。
- 复杂物理。
- 版权和真人肖像。

- 高风险安全结论。

建议做法：

1. 先用人评样本校准 VLM judge。
2. 统计 judge 和人评的一致率。
3. 只把 judge 用在高一致维度。
4. 对低一致或高风险维度保留人工审核。

9.9 生成模型回归测试

每次升级模型、prompt、采样器、安全策略，都要跑 regression set。

回归集应该包含：

- 历史 badcase。
- 高频业务场景。
- 安全边界。
- 长尾复杂 prompt。
- 多语言和中文文字。
- 多轮编辑链路。
- 视频时序和音画同步。

输出报告至少包含：

字段	含义
Win Rate	新版本相对旧版本的人评胜率。
Metric Delta	自动指标变化。
Safety Regression	新增安全失败数。
Cost Delta	单次生成成本变化。
Latency Delta	TTI / TTV 变化。
Badcase Gallery	失败样例图或视频。
Decision	发布、灰度、回滚或继续训练。

9.10 面试高频问题

9.10.1 为什么 FID 不够？

FID 是分布级指标，不能直接判断单个 prompt 是否被遵循，也不能衡量文字、身份一致、局部编辑、视频时序和安全。它适合看总体分布，不适合独立决定产品质量。

9.10.2 CLIPScore 有什么问题？

CLIPScore 对粗粒度语义有用，但对计数、否定、空间关系、中文文字和细节属性不稳定。复杂 prompt 更适合结合 VQAScore、VLM judge、OCR 和人评。

9.10.3 视频为什么更难评？

视频同时有空间质量、时间一致、运动自然、物体永久性、物理合理、镜头语言、音画同步和安全风险。单个指标很难覆盖这些维度。

9.10.4 如何评估图像编辑？

要同时看目标区域是否按指令改变，以及非目标区域是否保持。可以用 mask 内外指标、reference similarity、OCR、检测器、人评和多轮回归测试。

9.10.5 线上 A/B 和离线评测冲突怎么办？

先确认 prompt 分布是否一致，再看线上指标是否受推荐、流量、人群和审核策略影响。离线评测解释模型能力，线上 A/B 解释业务效果，两者都要保留。

9.11 本章 References

- [GenAI-Bench](#)
- [VBench](#)
- [T2V-CompBench](#)
- [T2VTextBench](#)
- [T2VPhysBench](#)
- [AV-Phys Bench](#)
- [Pick-a-Pic and PickScore](#)
- [ImageReward](#)
- [HPSv2](#)

第 10 章：训练、对齐、安全、Provenance 与产品化

最后一章回答真实工作里的问题：模型怎么训，怎么对齐，怎么防滥用，怎么上线。面试官越资深，越会从“模型原理”追到“你怎么把它做成可靠系统”。

10.1 本章符号说明

符号/缩写	English	中文	含义
SFT	Supervised Fine-Tuning	监督微调	用高质量指令、编辑或安全数据微调模型。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好训练 reward 并优化模型。
DPO	Direct Preference Optimization	直接偏好优化	不显式训练 reward model 的偏好优化方法。
RM	Reward Model	奖励模型	预测人类偏好的模型。
RLAIF	Reinforcement Learning from AI Feedback	基于 AI 反馈的强化学习	用 AI judge 生成偏好或奖励信号。
VLM	Vision-Language Model	视觉语言模型	用于 caption、审核、评测和自动标注。
OCR	Optical Character Recognition	光学字符识别	用于文字数据构造、评测和审核。
PII	Personally Identifiable Information	个人可识别信息	可能指向个人身份的敏感信息。
IP	Intellectual Property	知识产权	版权、商标、角色、品牌资产等。
C2PA	Coalition for Content Provenance and Authenticity	内容来源与真实性联盟	用 Content Credentials 表示内容来源和编辑历史。
DRM	Digital Rights Management	数字版权管理	管理数字内容访问和使用权限的机制。
SLA	Service Level Agreement	服务等级协议	产品服务可用性、延迟和稳定性要求。
API	Application Programming Interface	应用程序编程接口	产品调用生成、审核、评测和素材服务的接口。

10.2 训练 Pipeline 总览

一个产业级文生图/视频训练 pipeline 通常长这样：

```
数据采集
→ 去重、质量过滤、安全过滤、版权/隐私过滤
→ captioning / recaptioning / OCR / audio caption
→ tokenizer / VAE / 3D VAE 训练或复用
→ base model pretraining
→ task-specific SFT
→ preference data / reward model / RLHF 或 DPO
→ distillation / acceleration
→ safety tuning
→ eval harness
→ 灰度发布和线上反馈回流
```

面试里你可以强调：

文生图/视频的效果不是单纯由 backbone 决定。数据质量、caption、tokenizer、后训练、采样器、评测和安全共同决定最终产品体验。

10.3 数据与 Captioning

训练数据的关键问题：

问题	影响
Low-quality Data	模糊、水印、压缩、低审美会直接影响生成质量。
Bad Captions	caption 不描述动作、文字、布局，模型就学不到 prompt 对齐。
Duplicates	数据重复会导致 memorization 和版权风险。
Unsafe Content	色情、暴力、仇恨、未成年人、隐私内容会污染模型。
Copyright Risk	未授权 IP、角色、品牌、影视片段会带来法律和产品风险。
OCR Noise	文字识别错会伤害文字渲染能力。
Temporal Noise	视频剪辑跳变、字幕、水印、转场会伤害时序建模。

recaptioning 很重要。DALL-E 3、Sora、Seedance 等公开材料都强调过更高质量 caption 或 recaption 对 prompt adherence 的价值。

高质量 caption 应该包括：

- 主体、属性、数量。
- 空间关系和构图。
- 风格、材质、光照、镜头。

- 图像中文字。
- 视频动作、镜头运动、时间变化。
- 音频事件和声源。
- 安全敏感标签。

10.4 Base Training、SFT 与 Preference Optimization

训练阶段可以拆成：

阶段	English	中文	作用
Pretraining	Pretraining	预训练	学通用视觉分布、语言条件和运动。
SFT	Supervised Fine-Tuning	监督微调	学指令、编辑、产品风格和安全边界。
Preference Training	Preference Training	偏好训练	让输出更符合人类偏好和业务目标。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用 reward 优化质量、对齐和安全。
DPO	Direct Preference Optimization	直接偏好优化	更简单地利用 preference pair。
Distillation	Distillation	蒸馏	降低采样步数和推理成本。

视频报告里常见的 video-specific RLHF 特别值得关注。它说明视频不是只靠预训练，还要通过多维 reward 改善运动、时序、prompt adherence 和审美。

10.5 Reward 该怎么设计

图像 reward 可以拆成：

- prompt adherence。
- visual fidelity。
- aesthetics。
- text rendering。
- identity consistency。
- editing preservation。
- safety compliance。

视频 reward 还要加：

- temporal consistency。
- motion naturalness。
- physics plausibility。
- camera coherence。
- audio-visual sync。

- multi-shot narrative consistency。

不要用单一 reward。单指标优化容易 reward hacking，比如 CLIPScore 变高但图像变丑，或者视频看起来清晰但动作僵硬。

10.6 安全策略分层

一个稳的安全系统通常分层：

层级	做什么
Policy	定义允许和禁止的内容，包括真人肖像、未成年人、色情暴力、政治误导、IP。
Input Moderation	prompt、参考图、参考视频、音频上传时审核。
Generation Constraint	模型侧拒绝、负向条件、安全 LoRA、过滤敏感身份。
Output Moderation	图像、视频、音频、OCR、face、logo、IP 检测。
Provenance	C2PA、SynthID、watermark、metadata。
Human Review	高风险内容进入人工审核。
Logging	记录请求、版本、审核结果、申诉和处置。
Red Team	持续构造绕过样例，更新策略和模型。

10.7 Provenance：C2PA、SynthID 与 Watermark

C2PA 的核心是给内容附加可验证的来源和编辑记录。它更像“内容营养标签”，告诉用户这个内容从哪里来、被怎样处理过。

SynthID 的核心是不可见水印和检测能力。Google 公开材料强调 SynthID 可用于图像、音频、文本、视频，并设计为对裁剪、滤镜、压缩等变换有一定鲁棒性。

注意它们不是万能安全：

- 元数据可能被剥离。
- 水印可能被攻击或转码削弱。
- 检测有误报和漏报。
- 对恶意截屏、重拍、二次生成要有额外策略。

面试表达：

Provenance 是安全链路的一层，不是全部。真正可靠的系统需要输入审核、输出审核、行为风控、模型对齐、水印、日志、人工复核和申诉机制一起工作。

10.8 真人肖像、版权和 IP

文生图/视频最敏感三类风险：

风险	例子	防线
Likeness	未授权生成真实人物或公众人物	face detection、identity allowlist/denylist、consent workflow。
Copyright	生成受保护角色、影视风格或片段	IP detector、prompt policy、训练数据过滤、人工审核。
Trademark	logo、商品包装、品牌资产错误使用	logo detector、品牌规则、客户素材授权管理。

产品策略上要区分：

- 用户上传自己有权使用的素材。
- 用户请求生成公众人物或受保护角色。
- 用户生成商业投放素材。
- 用户只做个人娱乐。

风险等级不同，审核强度也不同。

10.9 Serving 与成本

上线时要关心：

维度	常见策略
Latency	preview model、低清预览、异步队列、分阶段生成。
Cost	模型路由、缓存、distillation、批处理、失败提前终止。
Reliability	超时重试、任务状态机、幂等、断点续跑。
Quality	自动筛选多个候选、VLM 审核、人工兜底。
Observability	记录 prompt、seed、版本、耗时、审核结果、失败标签。
Rollback	模型版本、prompt template、安全策略都要可回滚。

视频尤其适合异步任务：

```
submit job
→ validate inputs
→ generate storyboard
→ generate previews
→ user selects
→ high-quality render
→ safety review
→ deliver and archive provenance
```

10.10 产品化架构

一个推荐架构：

```
API Gateway
→ Input Moderation
→ Prompt / Storyboard Planner
→ Asset Manager
→ Model Router
→ Generation Workers
→ Auto Evaluation
→ Safety Review
→ Post-processing
→ Storage + C2PA / Watermark
→ User Feedback + Badcase Store
```

其中 Asset Manager 很重要：它管理用户上传的参考图、角色图、品牌 logo、mask、首尾帧、视频片段、音频素材和授权状态。

10.11 面试高频问题

10.11.1 训练数据怎么过滤？

先做去重、质量过滤、安全过滤、版权和隐私过滤，再做 caption / OCR / VLM 标注。视频还要过滤剪辑跳变、水印、字幕覆盖、低帧率、运动模糊和错误音频。

10.11.2 为什么需要 recaptioning？

原始 alt-text 通常太短、噪声大，不描述布局、动作、文字和关系。recaptioning 能把训练信号和用户 prompt 更好对齐，提高 prompt adherence。

10.11.3 图像生成也能做 RLHF 吗？

可以。常见做法是收集 pairwise preference，训练 reward model，然后优化模型或采样策略。视频还可以设计针对 motion、temporal consistency、prompt adherence 的 reward。

10.11.4 安全水印能解决 deepfake 吗？

不能单独解决。水印和 provenance 有帮助，但还需要真人肖像策略、上传审核、输出审核、行为风控、平台治理和人工复核。

10.11.5 线上模型升级如何避免退化？

先跑离线 regression harness，再小流量灰度，对比质量、人评、安全失败率、延迟、成本和业务指标。发现安全或质量退化时能按模型版本和策略版本回滚。

10.12 本章 References

- [DALL-E 3 System Card](#)
- [Introducing 4o Image Generation](#)

- [Video generation models as world simulators](#)
- [Sora 2](#)
- [Veo official page](#)
- [SynthID](#)
- [C2PA](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)

文生图 / 文生视频 References

R.1 Diffusion、Flow 与生成模型基础

- Ho et al., 2020, [Denoising Diffusion Probabilistic Models](#)
- Ho and Salimans, 2022, [Classifier-Free Diffusion Guidance](#)
- Karras et al., 2022, [Elucidating the Design Space of Diffusion-Based Generative Models](#)
- Lipman et al., 2022, [Flow Matching for Generative Modeling](#)
- Liu et al., 2022, [Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow](#)

R.2 Text-to-Image 与图像生成架构

- Radford et al., 2021, [CLIP](#)
- Ramesh et al., 2022, [DALL-E 2 / unCLIP](#)
- Saharia et al., 2022, [Imagen](#)
- Rombach et al., 2021, [Latent Diffusion Models](#)
- Peebles and Xie, 2022, [Scalable Diffusion Models with Transformers](#)
- OpenAI, [DALL-E 3 official page](#)
- Google DeepMind, [Imagen official page](#)
- Stability AI, [Stable Diffusion 3 Research Paper announcement](#)
- Stability AI, [Stable Diffusion 3.5 announcement](#)
- OpenAI, [Introducing 4o Image Generation](#)
- Google, [Gemini 2.5 Flash Image](#)
- Google, [Nano Banana Pro](#)
- Wu et al., 2025, [Qwen-Image Technical Report](#)
- Team Seedream, 2025, [Seedream 4.0](#)

R.3 Editing、Control 与 Reference Consistency

- Meng et al., 2021, [SDEdit](#)
- Zhang et al., 2023, [ControlNet](#)
- Ye et al., 2023, [IP-Adapter](#)
- Segalis et al., 2023, [Principled Recaptioning Improves Image Generation](#)
- Black Forest Labs, 2025, [FLUX.1 Kontext](#)

R.4 Text-to-Video、Video Editing 与 Audio-Video

- Singer et al., 2022, [Make-A-Video](#)
- Ho et al., 2022, [Imagen Video](#)
- Blattmann et al., 2023, [Stable Video Diffusion](#)
- OpenAI, 2024, [Video generation models as world simulators](#)

- OpenAI, 2025, [Sora 2](#)
- Google DeepMind, [Veo official page](#)
- Google, 2025, [Veo 3.1 and Flow updates](#)
- Meta, 2024, [Movie Gen](#)
- Meta, 2024, [Movie Gen paper page](#)
- Runway, 2025, [Introducing Runway Gen-4](#)
- Kong et al., 2024, [HunyuanVideo](#)
- Peng et al., 2025, [Open-Sora 2.0](#)
- Gao et al., 2025, [Seedance 1.0](#)
- Team Seedance, 2026, [Seedance 2.0](#)

R.5 Evaluation、Benchmarks 与 Harness

- Li et al., 2024, [GenAI-Bench](#)
- Huang et al., 2023, [VBench](#)
- Sun et al., 2024, [T2V-CompBench](#)
- Liu et al., 2025, [T2VTextBench](#)
- Wang et al., 2025, [T2VPhysBench](#)
- Cui et al., 2026, [AV-Phys Bench](#)
- Kirstain et al., 2023, [Pick-a-Pic and PickScore](#)
- Xu et al., 2023, [ImageReward](#)
- Wu et al., 2023, [HPSv2](#)

R.6 Safety、Watermark 与 Provenance

- OpenAI, [DALL-E 3 System Card](#)
- Google DeepMind, [SynthID](#)
- C2PA, [Coalition for Content Provenance and Authenticity](#)
- Fernandez et al., 2025, [SynthID-Image](#)
- Roedig et al., 2026, [C2PA Alone Is Not Enough](#)