

文生图 / 文生视频课程 Roadmap

这套笔记面向 AI（Artificial Intelligence，人工智能）算法工程师的文生图、文生视频和多模态生成面试准备。目标不是背产品名，而是形成一套可迁移的框架：生成模型基础、diffusion / flow matching、文本与图像条件、编辑与控制、视频时序建模、视频数据和训练实操、SOTA 技术报告阅读、评测 harness、安全与产品化。

截至 2026 年 6 月，面试里只讲 DDPM（Denoising Diffusion Probabilistic Model，去噪扩散概率模型）和 Stable Diffusion 已经不够了。你还需要能讨论 GPT-4o Image、Gemini / Nano Banana、Imagen 4、Qwen-Image、Seedream 4.0、Stable Diffusion 3 / 3.5、FLUX.1 Kontext、Sora / Sora 2、Veo 3.1、Movie Gen、Runway Gen-4、HunyuanVideo、Seedance 2.0 这类系统背后的共性。

0.1 全局符号和缩写说明

符号/缩写	English	中文	含义
AI	Artificial Intelligence	人工智能	本课程讨论的上层技术领域。
GenAI	Generative Artificial Intelligence	生成式人工智能	生成图像、视频、音频、文本等内容的模型和系统。
T2I	Text-to-Image	文生图	用文本 prompt 生成图像。
T2V	Text-to-Video	文生视频	用文本 prompt 生成视频。
I2I	Image-to-Image	图生图	用图像和文本条件编辑或重绘图像。
I2V	Image-to-Video	图生视频	用图像作为起点生成视频。
V2V	Video-to-Video	视频到视频	用输入视频做编辑、风格迁移或重生成。
AV	Audio-Video	音视频	联合生成画面、声音、对白、音效的任务。
AR	Autoregressive	自回归	逐 token 或逐 patch 预测下一个元素的生成范式。
VAE	Variational Autoencoder	变分自编码器	把图像或视频压缩到 latent，再解码回像素。
VQ-VAE	Vector Quantized Variational Autoencoder	向量量化变分自编码器	把视觉内容离散化成 codebook token 的自编码器。
DDPM	Denoising Diffusion Probabilistic Model	去噪扩散概率模型	通过加噪和反向去噪生成样本。

符号/缩写	English	中文	含义
DDIM	Denoising Diffusion Implicit Model	去噪扩散隐式模型	常用于更少步数的 diffusion 采样。
EDM	Elucidated Diffusion Model	解析化扩散模型设计	Karras 等提出的一套噪声调度和采样设计空间。
SDE	Stochastic Differential Equation	随机微分方程	连续时间 diffusion 的一种建模方式。
ODE	Ordinary Differential Equation	常微分方程	确定性采样路径常用的数学表示。
FM	Flow Matching	流匹配	直接学习从噪声到数据的连续向量场。
RF	Rectified Flow	矫正流	用更直的生成路径提升训练和采样效率的 flow 方法。
CFM	Conditional Flow Matching	条件流匹配	带条件变量的 flow matching 训练方式。
LDM	Latent Diffusion Model	潜空间扩散模型	在 VAE latent space 中做 diffusion。
U-Net	U-Net Architecture	U-Net 架构	diffusion 早期常用 denoiser backbone。
DiT	Diffusion Transformer	扩散 Transformer	用 Transformer 作为 diffusion / flow backbone。
MMDiT	Multimodal Diffusion Transformer	多模态扩散 Transformer	文本和图像 token 分支交互的 DiT 架构。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	Black Forest Labs 的图像生成和编辑模型系列。
LLM	Large Language Model	大语言模型	用于 prompt planning、captioning、judge 或原生多模态生成的语言模型。
VLM	Vision-Language Model	视觉语言模型	同时处理图像和文本，常用于 caption、评测和审核。
MLLM	Multimodal Large Language Model	多模态大语言模型	同时处理文本、图像、视频、音频等模态的大模型。
CLIP	Contrastive Language-Image Pre-training	对比式图文预训练	用于图文语义对齐、检索和评测。

符号/缩写	English	中文	含义
T5	Text-to-Text Transfer Transformer	文本到文本迁移 Transformer	Imagen、Stable Diffusion 3 等系统常用的强 text encoder。
GPT-4o	Generative Pre-trained Transformer 4o	GPT-4o 多模态模型	OpenAI 的原生多模态模型系列，包含图像生成能力。
CFG	Classifier-Free Guidance	无分类器引导	采样时增强条件遵循度的技巧。
SFT	Supervised Fine-Tuning	监督微调	用高质量指令、编辑或偏好数据微调模型。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人工偏好训练 reward，再优化生成策略。
DPO	Direct Preference Optimization	直接偏好优化	不显式训练 reward model 的偏好优化方法。
LoRA	Low-Rank Adaptation	低秩适配	低成本个性化或风格微调方法。
C2PA	Coalition for Content Provenance and Authenticity	内容来源与真实性联盟	用 Content Credentials 标记内容来源和编辑历史的开放标准。
FID	Fréchet Inception Distance	Fréchet Inception 距离	评估生成图像分布和真实图像分布差异的指标。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成常用的分布距离指标。
CLIPScore	CLIP Score	CLIP 相似度得分	用 CLIP 衡量图文语义相似。
VQAScore	Visual Question Answering Score	视觉问答得分	用 VQA 模型评估 prompt 中属性是否被满足。
HPS	Human Preference Score	人类偏好得分	用人类偏好数据训练出的自动偏好指标。
DINO	Self-distillation with No Labels	自监督视觉表征模型	常用于 reference similarity 或视觉一致性评测。
LPIPS	Learned Perceptual Image Patch Similarity	学习感知图像块相似度	衡量图像感知差异，常用于编辑保真评测。
API	Application Programming Interface	应用程序编程接口	产品接入生成模型或评测服务的接口。
x_0	Clean Sample	干净样本	原始图像、视频帧或 latent。
x_t	Noisy Sample at step t	第 t 步噪声样本	forward diffusion 后的样本。
ε	Gaussian Noise	高斯噪声	加到样本上的噪声。

符号/缩写	English	中文	含义
ϵ_{θ}	Noise Predictor	噪声预测器	diffusion model 预测的噪声。
v_{θ}	Velocity Predictor	速度预测器	diffusion / flow 模型预测的速度或方向。
c	Condition	条件	文本、图像、mask、边缘、pose、音频、参考视频等控制条件。
z	Latent	潜变量	VAE 编码后的低维表示。

0.2 学习路线

章节	主题	面试产出
第 1 章	生成模型、DDPM、score、flow matching、rectified flow	能把 diffusion 和 flow 的训练目标讲清楚。
第 2 章	文生图架构：CLIP、Imagen、Stable Diffusion、DiT、MMDiT、原生多模态图像生成	能比较 DALL-E / Imagen / Stable Diffusion / SD3 / FLUX / GPT-4o Image。
第 3 章	Conditioning、editing、control、reference consistency	能解释 CFG、ControlNet、IP-Adapter、LoRA、Kontext、Nano Banana 类编辑。
第 4 章	文生视频、时空 token、world model、音视频联合生成	能讨论 Sora、Veo、Movie Gen、Runway、HunyuanVideo、Seedance。
第 5 章	文生视频数据构造、预处理与训练实操	能讲清 shot detection、caption、T2V/I2V/V2V 数据、视频 RLHF、distillation。
第 6 章	文生视频 workflow、控制、评测与项目实操	能设计分镜、首尾帧、参考图、音频、视频 eval harness 和 badcase 归因。
第 7 章	面试速查、项目表达、常见追问	能把项目讲成模型、数据、评测、安全、线上闭环。
第 8 章	2026 SOTA 技术报告阅读地图	能快速拆解最新模型报告，而不是只背榜单。
第 9 章	Eval harness、benchmarking、人评和自动评测	能设计可复现的图像/视频生成评测系统。
第 10 章	训练、对齐、安全、provenance、产品化	能讨论真实系统怎么训练、过滤、上线、治理。
References	论文、官方技术报告、模型页面、基准	面试前用于定位原始材料。

0.3 推荐学习顺序

1. 先读第 1 章，把 DDPM、score、flow matching 的共同目标理解成“从简单分布到数据分布的可学习路径”。
2. 再读第 2 章，把文生图架构按 text encoder、visual tokenizer、denoiser / flow model、decoder、post-training 拆开。
3. 第 3 章关注真实需求：一致性、局部编辑、多图参考、结构控制、低成本个性化。
4. 第 4 章转向视频，把难点从“单帧好看”升级为“时间、物理、镜头、声音、角色一致”。
5. 第 5 章补视频训练实操：数据清洗、caption、T2V/I2V/V2V 样本、偏好数据、蒸馏。
6. 第 6 章补视频产品工作流：分镜、参考图、首尾帧、音频、评测 harness、badcase 归因。
7. 第 8 章按报告读 SOTA：每篇只抓任务定义、数据、架构、训练、评测、安全、限制。
8. 第 9 和第 10 章放到面试前重点复习，因为它们最能拉开“会用模型”和“能做系统”的差距。

0.4 面试目标

学完后你应该能回答：

- DDPM 的 forward process、reverse denoising 和 denoising loss 在做什么。
- 为什么很多新模型从 noise prediction 转向 v-prediction、flow matching 或 rectified flow。
- Stable Diffusion 为什么在 latent space 做 diffusion，VAE bottleneck 的收益和代价是什么。
- SD3 的 MMDiT、FLUX.1 的 flow matching、GPT-4o Image 的原生多模态生成分别代表什么趋势。
- Nano Banana / FLUX.1 Kontext / Qwen-Image / Seedream 4.0 这类编辑模型为什么强调 reference consistency。
- 文生视频相比文生图多了哪些难点，为什么 Sora / Veo / Movie Gen / Seedance 都强调时空 token、数据 curation、captioning 和 post-training。
- 文生视频训练数据如何构造：shot detection、frame sampling、caption / recaption、ASR / OCR、T2V / I2V / V2V schema。
- 如何把文生视频做成工作流：storyboard、shot list、首尾帧、参考资产、音频、评测和审核闭环。
- 如何设计一个文生图/视频 eval harness，并让结果可复现、可对比、能服务产品决策。
- 安全和合规怎么落到工程：输入输出审核、水印、C2PA、SynthID、真人肖像、版权/IP、训练数据过滤、日志和申诉。

[章节索引](#)

[← 上一章](#) [下一章 →](#)