

第 1 章：生成模型、DDPM、Score 与 Flow Matching

本章符号说明

符号/缩写	English	中文	含义
GAN	Generative Adversarial Network	生成对抗网络	generator 和 discriminator 对抗训练的生成模型。
VAE	Variational Autoencoder	变分自编码器	学习 latent distribution 的生成模型。
AR	Autoregressive	自回归	逐 token 或逐 patch 生成的模型族。
DDPM	Denoising Diffusion Probabilistic Model	去噪扩散概率模型	通过加噪和去噪生成样本。
DDIM	Denoising Diffusion Implicit Model	去噪扩散隐式模型	常用于更少步数的确定性或半确定性采样。
EDM	Elucidated Diffusion Model	解析化扩散模型设计	对噪声参数化、预条件和采样器做系统整理。
SDE	Stochastic Differential Equation	随机微分方程	连续时间扩散过程的数学描述。
ODE	Ordinary Differential Equation	常微分方程	确定性生成轨迹的数学描述。
FM	Flow Matching	流匹配	直接学习噪声分布到数据分布的速度场。
RF	Rectified Flow	矫正流	让生成路径更直、更容易少步采样的 flow 方法。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	flow matching 图像生成和编辑模型系列。
Score	Score Function	分数函数	$\nabla_x \log p(x)$ ，表示数据密度方向。
x_0	Clean Data	干净数据	原始图像或 latent。

符号/缩写	English	中文	含义
x_t	Noisy Data	噪声数据	第 t 步加噪后的样本。
ε	Gaussian Noise	高斯噪声	forward process 中加入的噪声。
β_t	Noise Schedule	噪声调度	每一步加入噪声的强度。
α_t	Retained Signal Rate	保留信号率	通常 $\alpha_t = 1 - \beta_t$ 。
σ_t	Noise Level	噪声等级	EDM 和连续时间采样器常用的噪声尺度。
ε_θ	Noise Predictor	噪声预测器	模型预测噪声的网络。
v_θ	Velocity Predictor	速度预测器	模型预测从噪声到数据的方向或速度。

本章目标

- 理解生成模型要学习 $p_{data}(x)$ 。
- 掌握 diffusion 的 forward 和 reverse。
- 理解为什么训练目标常写成预测噪声。
- 能解释 score、v-prediction、flow matching、rectified flow 的关系。
- 能解释 diffusion 和 GAN / VAE / AR 的直觉差异。

生成模型在学什么

生成模型希望从数据分布中采样：

$$x \sim p_{data}(x)$$

但真实 p_{data} 不可直接写出。不同生成模型有不同近似方式：

模型	English	中文	直觉
VAE	Variational Autoencoder	变分自编码器	学一个连续 latent space，再 decode。
GAN	Generative Adversarial Network	生成对抗网络	generator 骗过 discriminator。
Autoregressive	Autoregressive Model	自回归模型	逐 token 或逐 patch 生成。
Diffusion	Diffusion Model	扩散模型	先加噪破坏数据，再学习反向去噪。
Flow Matching	Flow Matching Model	流匹配模型	学习把噪声连续搬运到数据的速度场。

Forward Diffusion

forward process 逐步给干净样本 x_0 加噪：

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1-\beta_t}x_{t-1}, \beta_t I)$$

经过足够多步后， x_T 接近标准高斯噪声。

利用重参数化，可以一步采样任意 t ：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\varepsilon$$

其中：

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s, \varepsilon \sim \mathcal{N}(0, I)$$

Reverse Denoising

反向过程从噪声开始，逐步去噪：

$$p_\theta(x_{t-1} | x_t)$$

模型常被训练成预测噪声：

$$\varepsilon_\theta(x_t, t) \approx \varepsilon$$

常见简化 loss：

$$L(\theta) = \mathbb{E}_{x_0, t, \varepsilon} [\|\varepsilon - \varepsilon_\theta(x_t, t)\|^2]$$

直觉：

模型看到一张被加噪的图和当前噪声等级 t ，学习判断“哪些部分是噪声”，然后采样时反复去噪，最终从纯噪声变成图像。

三种常见预测参数化

同一个 denoising 任务可以用不同输出形式训练：

参数化	English	中文	预测内容	面试重点
ε -prediction	Noise Prediction	噪声预测	预测加到样本上的噪声 ε	DDPM 最常见，公式直观。
x_0 -prediction	Clean Sample Prediction	干净样本预测	直接预测无噪样本 x_0	容易解释，但不同噪声等级权重敏感。

参数化	English	中文	预测内容	面试重点
v -prediction	Velocity Prediction	速度预测	预测 noise 和 data 的组合方向 v	常用于更稳定的训练和采样。

面试里可以这样说：

这些参数化本质上都是从 noisy sample 估计去噪方向。差异在于数值稳定性、不同 noise level 的 loss 权重，以及采样器怎么把预测量转换成下一步样本。

为什么 Diffusion 稳定

相比 GAN，diffusion 的训练更像 supervised denoising：

- 每个训练样本可以构造不同噪声等级。
- loss 稳定，不需要 discriminator 对抗。
- mode coverage 通常更好。

代价：

- 采样需要多步迭代。
- 高分辨率训练和推理成本大。
- prompt alignment 需要 conditioning 和 guidance。

从 Diffusion 到 Flow Matching

新一代图像和视频模型经常使用 flow matching 或 rectified flow。一个简化理解是：diffusion 学习反向去噪分布，flow matching 学习连续路径上的速度场。

构造一条从噪声 x_0 到数据 x_I 的路径：

$$x_t = (1-t)x_0 + t x_I$$

模型学习速度：

$$v_{\theta}(x_t, t, c) \approx x_I - x_0$$

其中 c 是文本、图像或视频条件。

为什么它重要：

- 训练目标更直接：预测“往哪里走”，而不是只预测噪声。
- 采样路径可以更直，少步采样更有希望。
- 很适合和 DiT / MMDiT 结合，成为 SD3、FLUX、Seedream 等模型报告里的核心词。

不要把 flow matching 理解成 diffusion 的完全替代。面试里更稳的说法是：

diffusion、score model 和 flow matching 都在学习从简单分布到数据分布的生成路径。区别在于路径定义、预测目标、采样方程和数值稳定性。

采样器和速度

训练好模型后，还需要采样器把噪声变成图像或视频。

采样相关概念	English	中文	影响
Step Count	Number of Sampling Steps	采样步数	步数多通常质量更稳，但延迟更高。
Noise Schedule	Noise Schedule	噪声调度	决定不同阶段去噪强度。
Solver	Numerical Solver	数值求解器	DDIM、DPM-Solver、Euler 等会影响速度和质量。
Distillation	Distillation	蒸馏	把多步模型压到少步模型，如 turbo / lightning 类模型。
Consistency Model	Consistency Model	一致性模型	训练模型在不同噪声等级输出一致，支持少步采样。

工程上，采样器不是细枝末节。线上系统常常要在质量、成本、延迟、稳定性之间做 trade-off。

本章面试高频问题

1. DDPM 的 forward process 是什么？

forward process 是固定的加噪过程，从 x_0 逐步采样 x_t ，直到接近高斯噪声。训练时不需要学习 forward，只学习 reverse denoising。

2. 为什么可以训练模型预测 ϵ ？

因为 x_t 可以由 x_0 和噪声 ϵ 闭式构造。知道 x_t 、 t 和预测噪声后，就能估计干净样本或反向采样方向。

3. Diffusion 和 GAN 的区别？

GAN 通过对抗训练直接生成样本，采样快但训练可能不稳定。Diffusion 通过多步去噪生成，训练稳定、质量高，但推理通常更慢。

4. Flow matching 和 diffusion 是什么关系？

两者都在学习从简单噪声分布到数据分布的生成过程。diffusion 通常从加噪过程推导反向去噪，flow matching 更直接学习路径上的速度场。现在很多 SOTA 图像模型会把 flow matching、rectified flow、DiT 和多模态条件结合起来。

5. 为什么少步采样难？

少步采样要求每一步都走得很准。步数减少后，误差没有足够机会被修正，容易出现结构崩坏、细节伪影、prompt 不遵循。解决思路包括更好的 solver、distillation、consistency training、flow matching 和后训练。

本章 References

- [Denoising Diffusion Probabilistic Models](#)
- [Classifier-Free Diffusion Guidance](#)
- [Elucidating the Design Space of Diffusion-Based Generative Models](#)
- [Flow Matching for Generative Modeling](#)
- [Rectified Flow](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)
