

第 2 章：文生图架构：CLIP、Imagen、Stable Diffusion、DiT 与原生多模态生成

2.1 本章符号说明

符号/缩写	English	中文	含义
T2I	Text-to-Image	文生图	根据文本生成图像。
TI2I	Text-Image-to-Image	文图到图	输入文本和参考图，输出编辑后的图像。
CLIP	Contrastive Language-Image Pre-training	对比式图文预训练	学习图文共享语义空间。
T5	Text-to-Text Transfer Transformer	文本到文本迁移 Transformer	Imagen、SD3 等常用的强 text encoder。
LDM	Latent Diffusion Model	潜空间扩散模型	在 VAE latent 中做扩散。
DiT	Diffusion Transformer	扩散 Transformer	用 Transformer 替代 U-Net denoiser。
MMDiT	Multimodal Diffusion Transformer	多模态扩散 Transformer	文本 token 和图像 token 使用不同权重并交互的扩散 Transformer。
MM-LLM	Multimodal Large Language Model	多模态大语言模型	能理解或生成多种模态的语言模型体系。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	flow matching 图像生成和编辑模型系列。
GPT-4o	Generative Pre-trained Transformer 4o	GPT-4o 多模态模型	OpenAI 的原生多模态模型系列。
VAE	Variational Autoencoder	变分自编码器	把图像压缩到 latent，再 decode 回像素。
U-Net	U-Net Architecture	U-Net 架构	常见 diffusion denoiser backbone。
OCR	Optical Character Recognition	光学字符识别	用于读取图像中文字，也用于文字渲染评测。

符号/缩写	English	中文	含义
VLM	Vision-Language Model	视觉语言模型	同时处理图像和文本的模型。
LLM	Large Language Model	大语言模型	可用于 caption、prompt planning、judge 或原生多模态生成。
FM	Flow Matching	流匹配	新一代图像生成模型常用的训练目标。
c	Condition	条件	文本 embedding、图像 embedding、layout 等条件。
z	Latent	潜变量	压缩后的图像表示。
$\varepsilon_{\theta}(z_p, t, c)$	Conditional Noise Predictor	条件噪声预测器	输入 noisy latent、时间步和条件，预测噪声。
$v_{\theta}(z_p, t, c)$	Conditional Velocity Predictor	条件速度预测器	输入 noisy latent、时间和条件，预测 flow 方向。

2.2 本章目标

- 理解文生图如何把文本条件注入生成过程。
- 掌握 DALL-E 2、Imagen、Stable Diffusion 的架构差异。
- 理解 latent diffusion 为什么重要。
- 理解 DiT / MMDiT / flow matching 为什么代表可扩展趋势。
- 能讨论 GPT-4o Image、Gemini / Nano Banana、Qwen-Image、Seedream 这类原生编辑和多模态生成系统。

2.3 文本条件怎么进入图像生成

文本 prompt 先经过 text encoder：

$$c = E_{\text{text}}(T)$$

然后 diffusion denoiser 在每一步使用条件 c ：

$$\varepsilon_{\theta}(x_p, t, c)$$

注入方式包括：

- cross-attention。
- adaptive normalization。
- class/text embedding conditioning。
- 拼接 image/text latent。

2.4 DALL-E 2 / unCLIP

DALL-E 2 使用 CLIP latent 作为桥：

1. text encoder 得到 text embedding。
2. prior model 预测 image embedding。
3. diffusion decoder 根据 image embedding 生成图像。

直觉：

CLIP embedding 捕捉语义和风格，先在语义空间规划图像，再由 diffusion decoder 生成像素。

2.5 Imagen

Imagen 的关键发现之一：强语言模型对文生图非常重要。它使用大规模 frozen T5 text encoder，再用级联 diffusion model 生成高分辨率图像。

面试表达：

Imagen 说明 text encoder 的语言理解能力会显著影响图文对齐。生成质量不只取决于 image diffusion backbone，也取决于 prompt 被理解得多好。

2.6 Stable Diffusion / LDM

像素空间 diffusion 成本高。Latent Diffusion 先用 VAE 把图像压缩：

$$x \rightarrow z = E_{VAE}(x)$$

在 latent space 做 diffusion：

$$\varepsilon_{\theta}(z_p, t, c)$$

最后 decode：

$$\hat{x} = D_{VAE}(\hat{z})$$

优点：

- 大幅降低训练和推理成本。
- 支持高分辨率生成。
- cross-attention 可以接入文本、mask、box 等条件。

代价：

- VAE 会带来信息损失。
- 细节和文字可能受 latent bottleneck 影响。

- 需要额外维护 text encoder、VAE、denoiser。

2.7 DiT

DiT 把 latent 切成 patch token，用 Transformer 做 denoiser。

核心变化：

- U-Net 依赖卷积和多尺度结构。
- DiT 更接近 Transformer scaling 范式。
- 增大 depth、width、token 数通常能带来更可预测的扩展。

面试表达：

DiT 的意义不只是把 U-Net 换成 Transformer，而是让 diffusion backbone 更符合大模型 scaling 经验，便于统一图像、视频和多模态生成。

2.8 Stable Diffusion 3 / 3.5：MMDiT 与 Rectified Flow

Stable Diffusion 3 系列的公开报告把两个词推到前台：MMDiT 和 rectified flow。

MMDiT 的直觉：

- 文本 token 和图像 latent token 不是同一种信号。
- 让它们完全共享 Transformer 权重可能不够灵活。
- MMDiT 用不同权重处理不同模态，再通过 attention 交互。

Stable Diffusion 3 还组合了多个 text encoder，例如 CLIP 和 T5。面试里可以这样回答：

SD3 的核心不是“又一个 Stable Diffusion”，而是把 latent diffusion 从 U-Net 时代推进到多模态 Transformer 时代。它用更强的 text encoder、更可扩展的 MMDiT，以及 rectified flow 训练目标来提升 prompt adherence、文字渲染和复杂构图。

2.9 FLUX.1：Flow Matching 与编辑统一化

FLUX.1 系列的代表意义在于把 flow matching、DiT 和高质量图像生成结合起来。FLUX.1 Kontext 进一步强调统一的图像生成和编辑：

- 输入可以是文本，也可以是参考图和文本。
- 局部编辑、全局风格迁移、角色一致、文字编辑都尽量放进一个模型范式。
- 用 benchmark 评估编辑一致性，而不是只看单张生成图好不好。

面试高分点：

新一代图像模型的竞争已经从“能不能生成漂亮图”转向“能不能按复杂意图稳定编辑，并在多轮交互里保持主体、文字、风格和布局一致”。

2.10 GPT-4o Image 与 Gemini / Nano Banana：原生多模态生成

传统文生图系统常是“语言模型写 prompt + 图像模型生成”。GPT-4o Image 和 Gemini / Nano Banana 这类系统代表另一个方向：把图像生成作为多模态模型的原生能力。

它们的面试关注点：

能力	English	中文	为什么重要
Text Rendering	Text Rendering	文字渲染	海报、UI、信息图、商品图都需要准确文字。
Multi-turn Editing	Multi-turn Editing	多轮编辑	用户会连续改图，模型要记住上下文。
Reference Consistency	Reference Consistency	参考一致性	人物、商品、品牌资产不能漂移。
World Knowledge	World Knowledge	世界知识	能把事实知识和视觉生成结合。
Instruction Following	Instruction Following	指令遵循	复杂 prompt 中多个对象、关系、约束都要满足。

这类系统也有典型限制：

- 长文本排版仍可能出错。
- 多主体、多约束时容易遗漏。
- 事实细节需要外部校验。
- 真实人物、品牌和版权内容必须有更强安全策略。

2.11 Qwen-Image 与 Seedream 4.0：中文文字和多图编辑

中文场景里，文字渲染和图像编辑是非常现实的面试点。Qwen-Image 技术报告强调中文和复杂文字渲染、图像编辑一致性；Seedream 4.0 报告强调统一 T2I、image editing、多图组合和高效 DiT / VAE。

为什么这些点重要：

- 中文文字是 logographic writing system，形状更复杂，OCR-style 容错更低。
- 商品图、海报、社媒素材依赖准确文字和品牌一致性。
- 多图参考让模型从“生成一张图”变成“理解素材库并合成新素材”。
- 编辑模型要同时保持语义一致性和视觉保真度。

2.12 架构拆解模板

看到任何新文生图报告，都按下面拆：

模块	你要问的问题
Data	图文数据从哪里来，如何过滤水印、低质、违法、隐私和 OCR 噪声？

模块	你要问的问题
Captioning	是否用 VLM / LLM 重新描述图像，caption 是否包含布局、文字、风格、关系？
Tokenizer	像素空间、VAE latent、VQ token，压缩率和重建质量如何？
Text Encoder	CLIP、T5、LLM、VLM，是否冻结，是否多 encoder？
Backbone	U-Net、DiT、MMDiT、原生多模态 LM，条件如何注入？
Objective	DDPM、EDM、v-prediction、flow matching、rectified flow？
Post-training	是否做 SFT、偏好优化、编辑数据微调、安全对齐？
Evaluation	用哪些自动指标、人评、编辑 benchmark、线上 A/B？
Safety	水印、C2PA、真人肖像、版权、训练数据合规怎么处理？

2.13 本章面试高频问题

2.13.1 为什么 Stable Diffusion 在 latent space 做 diffusion？

因为直接在高分辨率像素空间做 diffusion 成本很高。VAE latent 保留主要语义和视觉结构，同时降低空间维度，使训练和推理更便宜。

2.13.2 DALL-E 2 和 Stable Diffusion 的差异？

DALL-E 2 使用 CLIP latent prior + diffusion decoder；Stable Diffusion 使用 VAE latent space + U-Net denoiser + text cross-attention。二者都利用 diffusion，但条件路径和训练开放性不同。

2.13.3 Imagen 的核心启发是什么？

强 text encoder 对 prompt adherence 很关键。更好的语言理解可以提升图文对齐和复杂 prompt 的遵循。

2.13.4 DiT 为什么重要？

DiT 用 Transformer 做 denoiser，更适合 scaling，也更容易扩展到视频中的 spacetime token。

2.13.5 MMDiT 和普通 DiT 有什么区别？

普通 DiT 可以把文本条件作为 embedding 或 cross-attention 条件。MMDiT 更强调多模态 token 的联合建模：文本和图像有不同表示路径，并在 Transformer 内交互，因此更适合复杂 prompt、文字渲染和多模态生成。

2.13.6 为什么原生多模态图像生成值得关注？

因为真实产品不是一次性 prompt 生成，而是连续对话、上传参考图、要求局部修改、生成带文字的素材。原生多模态模型更容易把语言理解、视觉理解和图像生成放到同一个交互闭环里。

2.14 本章 References

- [Learning Transferable Visual Models From Natural Language Supervision](#)
- [Hierarchical Text-Conditional Image Generation with CLIP Latents](#)

- [Photorealistic Text-to-Image Diffusion Models with Deep Language Understanding](#)
- [High-Resolution Image Synthesis with Latent Diffusion Models](#)
- [Scalable Diffusion Models with Transformers](#)
- [DALL·E 3 official page](#)
- [Imagen official page](#)
- [Stable Diffusion 3 Research Paper announcement](#)
- [Stable Diffusion 3.5 announcement](#)
- [Introducing 4o Image Generation](#)
- [Gemini 2.5 Flash Image](#)
- [Nano Banana Pro](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)
- [FLUX.1 Kontext](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)