

第 3 章：Conditioning、Editing、Control 与 Reference Consistency

本章符号说明

符号/缩写	English	中文	含义
CFG	Classifier-Free Guidance	无分类器引导	用 conditional/unconditional 预测差控制生成。
TI2I	Text-Image-to-Image	文图到图	用文本和参考图共同生成或编辑图像。
Inpainting	Inpainting	局部重绘	给定 mask，只生成缺失或指定区域。
Outpainting	Outpainting	外扩绘制	在原图边界外继续生成内容。
ControlNet	ControlNet	控制网络	给 diffusion 接入边缘、深度、pose 等结构控制。
IP-Adapter	Image Prompt Adapter	图像提示适配器	用图像作为 prompt 条件控制风格或身份。
LoRA	Low-Rank Adaptation	低秩适配	用少量参数适配特定角色、风格或商品。
DreamBooth	DreamBooth	个性化微调方法	用少量图片学习特定主体。
OCR	Optical Character Recognition	光学字符识别	文字识别，也常用于图像中文字生成评测。
ROI	Region of Interest	感兴趣区域	局部编辑或检测关注的区域。
ID	Identity	身份	人物、商品、角色等需要保持一致的视觉身份。
DINO	Self-distillation with No Labels	自监督视觉表征模型	常用于 reference similarity 或视觉一致性评测。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	统一图像生成和编辑的模型系列。
c	Condition	条件	文本、图像、边缘、深度、pose、mask 等。
s	Guidance Scale	引导强度	CFG 中控制文本遵循强度的系数。

符号/缩写	English	中文	含义
ϵ_{cond}	Conditional Prediction	条件预测	有 prompt 条件时的噪声预测。
ϵ_{uncond}	Unconditional Prediction	无条件预测	无 prompt 条件时的噪声预测。
m	Mask	掩码	指定需要编辑或保护的区域。

本章目标

- 理解 CFG 的公式和直觉。
- 掌握 inpainting / outpainting / image-to-image。
- 理解 ControlNet 和 adapter 类方法。
- 理解 reference consistency、multi-image editing、多轮编辑为什么是 2026 面试重点。
- 能写出可复用的生成和编辑 prompt 结构。

Classifier-Free Guidance

CFG 同时利用 unconditional 和 conditional 预测：

$$\epsilon_{cfg} = \epsilon_{uncond} + s(\epsilon_{cond} - \epsilon_{uncond})$$

其中 s 是 guidance scale。

直觉：

- s 越大，越贴近 prompt，但可能更僵硬、过饱和、失真。
- s 越小，多样性更高，但可能不听 prompt。

面试表达：

CFG 通过放大 conditional 和 unconditional denoising direction 的差异，提高条件遵循度。它是采样阶段的控制技巧，不需要额外 classifier。

Image-to-Image

image-to-image 通常先把输入图像编码并加噪到某个强度，再按 prompt 去噪。

关键超参：

- denoise strength 高：改动大。
- denoise strength 低：保留原图结构更多。
- prompt 控制语义方向。
- negative prompt 控制避免元素。

2026 面试里要补一句：

图生图不再只是“改变风格”。主流需求已经变成 reference-based generation：保留商品、人物、角色、logo、服饰、构图关系，同时按文本做可控改动。

Inpainting

inpainting 输入：

- 原图。
- mask。
- prompt。

模型只重绘 mask 区域，非 mask 区域尽量保持。

难点：

- mask 边缘融合。
- 光照和材质一致。
- 透视一致。
- 局部编辑不能破坏全局语义。

ControlNet

ControlNet 给 diffusion 增加结构条件，例如：

- Canny edge。
- depth map。
- human pose。
- segmentation map。
- scribble。

直觉：

原始 text prompt 擅长语义控制，但不擅长精确布局。ControlNet 把结构图作为条件输入，让模型在保持生成质量的同时遵循空间结构。

Adapter、LoRA 与个性化

真实业务很少只用裸模型。常见轻量适配方式：

方法	English	中文	适合场景
LoRA	Low-Rank Adaptation	低秩适配	学特定风格、角色、商品，成本低。
DreamBooth	DreamBooth	个性化微调	少量图片绑定一个新主体。
Textual Inversion	Textual Inversion	文本反演	学一个新 token 表示特定概念。

方法	English	中文	适合场景
IP-Adapter	Image Prompt Adapter	图像提示适配器	不微调主模型，用参考图控制身份或风格。

面试里要讲 trade-off：

- LoRA 可控但需要训练和版本管理。
- IP-Adapter 上手快，但复杂编辑可能身份漂移。
- DreamBooth 容易过拟合，需要正则和数据增强。
- 多个 adapter 叠加可能互相冲突。

多图参考与多轮编辑

Nano Banana、FLUX.1 Kontext、Qwen-Image、Seedream 4.0 这类系统都把编辑能力放在核心位置。原因很简单：真实用户往往不是“从零生成”，而是上传参考图，然后连续提出修改。

多图参考常见输入：

- 主体参考图：这个人、这件商品、这个角色。
- 风格参考图：色调、材质、镜头语言。
- 布局参考图：构图、pose、空间关系。
- 文字或 logo 参考图：品牌资产、海报标题。

多轮编辑的主要失败模式：

失败模式	English	中文	例子
Identity Drift	Identity Drift	身份漂移	连续修改后人物脸变了，商品形状变了。
Attribute Leakage	Attribute Leakage	属性泄漏	只想换背景，却把衣服颜色也改了。
Over-editing	Over-editing	过度编辑	局部编辑导致整张图风格被重写。
Text Corruption	Text Corruption	文字损坏	原本正确的 logo 或标题被改错。
Layout Collapse	Layout Collapse	布局崩坏	多个主体的位置关系变乱。

编辑任务怎么建数据

编辑模型比纯 T2I 更依赖数据设计。常见训练样本形式：

样本	English	中文	用途
Before / After Pair	Before / After Pair	编辑前后图对	学局部和全局编辑。

样本	English	中文	用途
Masked Pair	Masked Pair	带 mask 图对	学 inpainting 和区域保护。
Multi-reference Pair	Multi-reference Pair	多参考图对	学组合多个视觉条件。
Synthetic Edit	Synthetic Edit	合成编辑数据	用渲染、分割、VLM caption 自动构造。
Human Preference	Human Preference	人类偏好数据	学哪个编辑结果更符合意图。

一个成熟 pipeline 往往包括：

1. 自动生成编辑指令。
2. 用分割、检测、OCR、captioning 生成结构化标签。
3. 过滤低质、违规、版权敏感样本。
4. 训练后用 VLM / OCR / embedding similarity 做自动筛选。
5. 对高价值场景做人工偏好标注。

Prompt 结构

通用 prompt 模板：

主体 + 场景 + 构图 + 风格 + 光照 + 镜头 + 细节 + 质量约束

视频 prompt 还要补：

动作 + 镜头运动 + 时间变化 + 主体一致性 + 场景连续性

面试里不要把 prompt 说成唯一核心。真正的系统还包括：

- 模型选择。
- 分辨率和采样器。
- seed 管理。
- control condition。
- 后处理。
- safety filter。
- 人工审核。

编辑 prompt 建议更结构化：

保留：主体身份、商品形状、logo、构图
修改：背景、光照、服饰颜色、局部物体
禁止：改变脸、改变文字、添加额外主体、破坏品牌色
输出：分辨率、比例、风格、是否透明背景

工程侧控制面板

一个好用的图像生成工具通常会暴露这些控制项：

控制项	English	中文	作用
Seed	Random Seed	随机种子	复现和 A/B 比较。
Sampler	Sampler	采样器	控制速度和质量。
Guidance Scale	Guidance Scale	引导强度	控制 prompt adherence。
Denoise Strength	Denoise Strength	去噪强度	控制编辑幅度。
Reference Weight	Reference Weight	参考权重	控制身份或风格保留。
Mask Feather	Mask Feather	掩码羽化	改善边缘融合。
Negative Prompt	Negative Prompt	负向提示	减少不需要的元素。

本章面试高频问题

1. CFG scale 太大会怎样？

模型更强地追随 prompt，但可能降低多样性，产生过饱和、纹理异常、构图僵硬或细节崩坏。

2. ControlNet 解决什么问题？

解决纯文本控制不精确的问题。通过边缘、深度、pose、segmentation 等结构条件，约束生成图像的布局和姿态。

3. Inpainting 为什么容易边缘不自然？

因为局部区域需要同时满足 prompt、mask 内语义、mask 外上下文、边界纹理、光照和透视一致性。任何一个不匹配都会让边缘显得突兀。

4. Reference consistency 怎么评估？

可以用人评、CLIP / DINO embedding similarity、face / product recognition、OCR、局部检测和多轮编辑回归集。关键是把“保留什么”和“允许改什么”写进测试用例，而不是只看最终图好不好看。

5. 为什么多轮编辑比单轮编辑难？

多轮编辑会累积误差。模型每次生成都会重新解释图像和指令，如果没有稳定的视觉记忆、mask 约束、参考权重和回归测试，就容易身份漂移、文字损坏或不相关区域被改动。

本章 References

- [Classifier-Free Diffusion Guidance](#)

- [SDEdit: Guided Image Synthesis and Editing with Stochastic Differential Equations](#)
- [Adding Conditional Control to Text-to-Image Diffusion Models](#)
- [IP-Adapter: Text Compatible Image Prompt Adapter for Text-to-Image Diffusion Models](#)
- [FLUX.1 Kontext](#)
- [Gemini 2.5 Flash Image](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)