

第 4 章：文生视频、Temporal Consistency、World Model 与音视频生成

本章符号说明

符号/缩写	English	中文	含义
T2V	Text-to-Video	文生视频	根据文本生成视频。
I2V	Image-to-Video	图生视频	根据图像起点生成视频。
V2V	Video-to-Video	视频到视频	根据输入视频做风格化或编辑。
T2AV	Text-to-Audio-Video	文生音视频	文本输入同时生成画面和声音。
SVD	Stable Video Diffusion	稳定视频扩散	Stability AI 的 latent video diffusion 模型。
DiT	Diffusion Transformer	扩散 Transformer	视频模型常用的时空 token backbone。
VAE	Variational Autoencoder	变分自编码器	视频模型常用的空间或时空压缩器。
FPS	Frames Per Second	每秒帧数	视频时间分辨率。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成分布质量指标。
VBench	Video Benchmark	视频生成基准	从多个维度评估 T2V 质量的 benchmark。
F	Frames	帧序列	视频由多帧图像组成。
T	Time Length	时间长度	视频时长或帧数。
H / W	Height / Width	高 / 宽	视频空间分辨率。
$z_{t,h,w}$	Spacetime Latent Token	时空 latent token	视频压缩后在时间和空间上的 token。

本章目标

- 理解视频生成相比图像生成多出的难点。
- 掌握 Make-A-Video、Imagen Video、Stable Video Diffusion 的思路。
- 理解 Sora 的 spacetime patch 和 variable aspect ratio。
- 理解 Veo、Movie Gen、Runway Gen-4、HunyuanVideo、Seedance 2.0 的系统趋势。
- 能讨论视频生成评测、安全、音视频同步和产品化难点。

视频比图像难在哪里

视频生成需要同时满足：

- 单帧质量。
- 帧间一致性。
- 运动自然。
- 物体永久性。
- 镜头运动。
- 角色身份一致。
- 物理和因果关系。
- 长时程 coherence。

文生图只需要生成 $H \times W$ 的空间结构；文生视频要生成 $T \times H \times W$ 的时空结构。

Make-A-Video

Make-A-Video 的思路是把 text-to-image 进展迁移到 text-to-video：

- 从 text-image 数据学外观和语义。
- 从无文本视频学运动。
- 使用时空模块扩展图像生成模型。

核心观点：

不一定需要大量 paired text-video data，也可以把图像语义和视频运动分开学习。

Imagen Video

Imagen Video 使用级联 video diffusion：

- base video generation。
- spatial super-resolution。
- temporal super-resolution。
- progressive distillation 加速采样。

直觉：

先生成低分辨率、低帧率视频，再逐步提升空间和时间分辨率，类似 Imagen 图像生成中的 cascade 思路。

Stable Video Diffusion

SVD 强调 latent video diffusion 的训练流程：

1. text-to-image pretraining。

2. video pretraining。
3. high-quality video finetuning。

它说明视频数据质量和 curation 非常关键。视频不是简单把图像数据堆起来，因为帧间运动、剪辑、字幕、镜头切换都会影响训练。

Sora：Spacetime Patch

Sora 技术报告里，一个关键思想是把视觉数据统一成 patch：

- 先把视频压缩到 latent space。
- 再切成 spacetime patches。
- 用 diffusion transformer 在 patch token 上训练。
- 支持不同分辨率、时长、宽高比。

可以抽象成：

video → latent → spacetime patches → DiT

这和 LLM 里的 tokenization 有相似之处：用统一 token 表示复杂数据，从而更容易 scale。

Veo 与产品化趋势

以 Veo、Sora、Runway 等系统为代表，产品化视频生成更关注：

- 更长时长。
- 更高分辨率。
- 音频同步。
- 镜头语言。
- 角色一致性。
- 可编辑性。
- 安全和 provenance。

面试时不要只说“模型更大”。要说明：

- 数据 curation。
- captioning。
- temporal architecture。
- controllability。
- evaluation。
- safety filter。
- serving cost。

本章面试高频问题

1. 文生视频相比文生图最大难点是什么？

除了单帧质量，还要保证时间一致性、运动自然、角色和物体持续存在、物理因果关系合理，以及长视频的全局 coherence。

2. 为什么视频生成适合 spacetime patch?

spacetime patch 把时间和空间统一成 token，让模型能在同一架构里处理不同分辨率、宽高比和时长的视频，也便于 Transformer scaling。

3. 视频数据 curation 为什么重要?

低质量视频、剪辑跳变、字幕水印、运动模糊、错误 caption 都会污染模型。视频生成对数据的时序一致性和 caption 质量更敏感。

4. Sora 仍有哪些限制?

官方技术报告提到它仍可能不能准确模拟复杂物理、因果和状态变化，长时程也可能出现不一致或物体自发出现。

Sora 2：音频、对话与可控性

Sora 2 的公开产品说明把方向从“能生成视频”推进到“更像可交互视频创作工具”：

- 更强的物理一致性和失败后状态延续。
- 同步对话、音效和背景声。
- 更好的可控性和多镜头叙事。
- 支持真实人物 cameo 类功能，但也带来更强的身份、同意和安全要求。

注意一个时间点：OpenAI 页面显示 Sora 产品已在 2026 年 4 月 26 日停止提供，但 Sora / Sora 2 的技术方向仍然是面试里理解视频生成演进的好材料。回答时不要把“产品仍可用”当作事实。

Veo 3.1：音频和剪辑控制

Veo 3.1 的产品方向强调：

- 文生视频和图生视频。
- 更强 prompt adherence 和 realism。
- audio across features，即在多个功能里支持声音。
- Ingredients to Video、Frames to Video、Extend、Insert/remove 等编辑能力。
- 用 SynthID 标记生成内容。

面试表达：

Veo 的重点不是单个模型参数，而是把视频生成做成可控工作流：参考图、首尾帧、扩展、局部插入、移除、音频同步、安全水印。

Movie Gen：统一视频、音频、编辑和个性化

Meta Movie Gen 的公开材料强调四类能力：

- text-to-video。
- personalized video。
- precise video editing。
- synchronized audio generation。

Movie Gen 报告里的高频关键词：

关键词	English	中文	面试解读
1080p	Full HD Resolution	全高清分辨率	视频模型开始逼近生产级素材质量。
16 fps	Frames Per Second	每秒 16 帧	说明时间分辨率仍是成本和质量 trade-off。
Audio	Audio Generation	音频生成	音效、音乐、环境声要和画面事件一致。
Personalization	Personalization	个性化	参考人物或主体生成新视频，安全要求更高。
Editing	Instruction-based Editing	指令式编辑	不只是生成，还要能改现有视频。

Runway Gen-4：一致性和生产 workflow

Runway Gen-4 的公开材料把“world consistency”放在中心：用参考图和指令，在不同镜头中保持角色、地点、物体和风格一致。

对面试很有用的点：

- 长视频不是一次生成一整段，而常常是分镜 + 镜头生成 + 编辑拼接。
- 产品级视频工具需要角色库、场景库、参考资产和版本管理。
- 生成模型要服务导演式 workflow，而不是只做 demo prompt。

HunyuanVideo、Open-Sora、Seedance：开源和产业化路线

闭源模型质量很强，但面试时也要了解开放技术报告，因为它们会披露更多训练细节。

模型/报告	English	中文	重点
HunyuanVideo	HunyuanVideo	混元视频	13B 级开源视频基础模型，强调数据、架构、训练和推理框架。
Open-Sora 2.0	Open-Sora 2.0	开放 Sora 2.0	强调用有限预算训练商业级视频模型的工程路线。
Seedance 1.0	Seedance 1.0	即梦/Seed 视频 1.0	强调数据 curation、caption、视频 RLHF、多阶段蒸馏和速度优化。
Seedance 2.0	Seedance 2.0	即梦/Seed 视频 2.0	强调文本、图像、音频、视频多模态输入和音视频联合生成。

Seedance 1.0 报告尤其适合面试，因为它明确提到：

- multi-source data curation。
- precision video captioning。
- native multi-shot generation。
- joint T2V / I2V learning。
- fine-grained SFT。
- video-specific RLHF。
- multi-stage distillation。

这些关键词能把你的回答从“会讲模型”拉到“知道产业系统怎么训、怎么快、怎么稳”。

视频生成系统的通用 pipeline

需求 / prompt
→ LLM 拆分成 storyboard / shots / camera plan
→ 生成关键帧或参考图
→ T2V / I2V 生成每个镜头
→ 一致性检查：角色、物体、场景、文字、品牌
→ 音频生成或配音
→ 剪辑、转场、字幕、调色
→ 安全审核、版权审核、watermark / provenance

这也是项目面试里最推荐的表达方式：不要说“我调用了一个视频模型”，要说“我搭了一个可评测、可回滚、可审核的创意生产 pipeline”。

视频生成失败模式

失败模式	English	中文	例子
Temporal Flicker	Temporal Flicker	时间闪烁	背景或纹理帧间跳动。
Identity Drift	Identity Drift	身份漂移	人物、商品、角色越生成越不像。
Object Disappearance	Object Disappearance	物体消失	关键物体中途消失或变形。
Physics Violation	Physics Violation	物理违背	碰撞、重力、液体、反射不合理。
Camera Incoherence	Camera Incoherence	镜头不连贯	镜头运动和空间关系冲突。
Audio-Visual Mismatch	Audio-Visual Mismatch	音画不匹配	动作和音效不同步。

失败模式	English	中文	例子
Text Degradation	Text Degradation	文字退化	字幕、logo、标牌随时间变形。

本章补充面试高频问题

5. 为什么视频模型更依赖 caption?

视频 caption 不只要描述主体，还要描述动作、镜头、时间变化、场景转移、因果关系和声音。caption 粗糙时，模型很难学到 prompt 到运动的对应关系。

6. 什么是多镜头生成?

多镜头生成不是简单延长时长，而是生成多个 shot，并保持角色、场景、风格和叙事连续。它更接近真实创作流程，也更考验 planning、reference consistency 和后处理评测。

7. 音视频联合生成为什么难?

因为声音要同时满足语义、时间点、物理因果和空间感。比如脚步、碰撞、口型、环境声都要和画面事件同步，单独评估视频质量不够。

本章 References

- [Make-A-Video: Text-to-Video Generation without Text-Video Data](#)
- [Imagen Video: High Definition Video Generation with Diffusion Models](#)
- [Stable Video Diffusion](#)
- [Video generation models as world simulators](#)
- [Sora 2](#)
- [Veo official page](#)
- [Veo 3.1 and Flow updates](#)
- [Movie Gen](#)
- [Movie Gen paper page](#)
- [Introducing Runway Gen-4](#)
- [HunyuanVideo](#)
- [Open-Sora 2.0](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)