

第 5 章：文生视频数据构造、预处理与训练实操

这一章专门讲文生视频的训练侧。视频生成模型不是把文生图模型“多生成几帧”就完事了，真正难点在视频数据、caption、镜头边界、时间一致性、音视频同步、训练样本打包和后训练。面试里能把这些讲清楚，会比单纯背 Sora、Veo、Movie Gen、Seedance 的名字更有说服力。

本章符号说明

符号/缩写	English	中文	含义
T2V	Text-to-Video	文生视频	根据文本 prompt 生成视频。
I2V	Image-to-Video	图生视频	根据起始图、参考图或关键帧生成视频。
V2V	Video-to-Video	视频到视频	根据输入视频做编辑、风格化或重生成。
AV	Audio-Video	音视频	联合生成或理解画面与声音。
FPS	Frames Per Second	每秒帧数	视频时间分辨率。
Shot	Shot	镜头	连续拍摄或生成的一段画面。
ASR	Automatic Speech Recognition	自动语音识别	把视频中的语音转成文字。
OCR	Optical Character Recognition	光学字符识别	识别视频帧中的文字。
VAE	Variational Autoencoder	变分自编码器	把视频压缩到 latent space 的编码器/解码器。
DiT	Diffusion Transformer	扩散 Transformer	视频 diffusion / flow 常用 backbone。
SFT	Supervised Fine-Tuning	监督微调	用高质量指令和样本微调模型。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好优化视频生成质量。
DPO	Direct Preference Optimization	直接偏好优化	用偏好对直接优化模型偏好。
Distillation	Knowledge Distillation	知识蒸馏	用大模型或多步采样结果训练更快模型。
V	Video	视频	输入或输出的视频片段。

符号/缩写	English	中文	含义
F	Frames	帧序列	视频由多帧图像组成。
T	Time Length	时间长度	视频时长或帧数。
H / W	Height / Width	高 / 宽	视频空间分辨率。
z	Latent	潜变量	VAE 编码后的视频 latent。
c	Condition	条件	文本、首帧、尾帧、参考图、mask、audio 等控制输入。

本章目标

- 能讲清视频数据从采集到训练样本的完整 pipeline。
- 能解释 caption、shot detection、frame sampling、音频处理为什么关键。
- 能区分 T2V、I2V、V2V、editing、AV 训练样本。
- 能说明视频 post-training、RLHF、distillation 怎么服务产品质量和成本。

视频数据为什么比图像数据更难

图像样本通常是单帧语义，视频样本包含：

- 时间顺序。
- 镜头切换。
- 角色身份保持。
- 物体状态变化。
- 相机运动。
- 动作和物理因果。
- 音频、对白、环境声。
- 字幕、水印、logo 和剪辑痕迹。

同样一条 caption, “a person opens a door” 对视频来说还不够。训练需要知道门从关到开的过程、人的位置变化、镜头是否移动、声音是否出现、有没有切镜头。

面试表达：

文生视频的数据核心不是“有视频就行”，而是要把视频拆成可学习的时空事件：镜头、动作、主体、场景、相机、声音和状态变化。caption 越能描述时间变化，模型越容易学到 prompt 到 motion 的映射。

视频数据 Pipeline

原始视频

- > 解码、格式统一、fps / 分辨率标准化
- > shot detection: 切镜头、去片头片尾、去黑帧
- > 质量过滤: 清晰度、运动模糊、压缩、水印、字幕、NSFW、版权
- > frame sampling: 均匀采样、关键帧、运动峰值、首尾帧
- > captioning / recaptioning: 主体、动作、镜头、时间变化、声音
- > ASR / OCR / audio tagging: 对白、字幕、屏幕文字、音效
- > task packaging: T2V、I2V、V2V、editing、AV
- > train / dev / test 切分、去重、去污染
- > tokenization / VAE latent / spacetime patch
- > pretraining、SFT、preference、distillation、eval

数据过滤维度

过滤维度	English	中文	影响
Resolution	Resolution	分辨率	太低会损伤细节和文字。
Compression	Compression Artifact	压缩伪影	会让模型学到噪声和块状纹理。
Motion Blur	Motion Blur	运动模糊	影响主体和动作学习。
Shot Boundary	Shot Boundary	镜头边界	不切镜头会造成时序不连续。
Watermark	Watermark	水印	模型可能生成水印或 logo 残影。
Subtitle	Subtitle	字幕	可能污染画面文字和语义。
NSFW	Not Safe For Work	不适宜工作场景内容	安全和合规风险。
Copyright	Copyright	版权	训练授权和生成风险。
Identity	Identity	身份信息	真人肖像、未成年人、隐私风险。
Audio Quality	Audio Quality	音频质量	影响音视频联合训练。

Caption 要描述什么

视频 caption 至少要覆盖六类信息：

类别	例子
主体	一名穿红色外套的滑雪者、一辆白色 SUV。
动作	从坡顶滑下、转弯、停住、挥手。
时间变化	开始在远处，随后靠近镜头，最后离开画面。
相机	handheld、pan left、slow zoom in、drone shot。

类别	例子
场景	雪山、黄昏、城市街道、室内厨房。
声音	风声、脚步声、门铃、对白、背景音乐。

不好的 caption：

a person skiing

更好的 caption：

A skier in a red jacket descends a snowy slope, makes two wide turns, slows near the camera, and raises one hand. The camera stays fixed while wind noise is heard in the background.

如果训练目标是中文产品，也要有中文 caption 或双语 caption，否则中文 prompt adherence 会弱。

训练样本 Schema

T2V 样本：

```
{
  "id": "t2v_000001",
  "task": "text_to_video",
  "prompt": "黄昏时，一辆白色汽车沿海边公路行驶，镜头缓慢跟拍。",
  "video": "clips/t2v_000001.mp4",
  "metadata": {
    "fps": 16,
    "duration_sec": 5,
    "resolution": "720p",
    "camera": "tracking shot",
    "source": "licensed"
  }
}
```

I2V 样本：

```
{
  "id": "i2v_000018",
  "task": "image_to_video",
  "image": "keyframes/start.png",
  "prompt": "让画面中的花朵在微风中轻轻摆动，背景保持不变。",
  "video": "clips/i2v_000018.mp4",
  "metadata": {
    "motion": "subtle object motion",
    "identity_preservation": true
  }
}
```

视频编辑样本：

```
{
  "id": "v2v_edit_000042",
  "task": "video_editing",
  "input_video": "clips/input.mp4",
  "instruction": "把天空改成傍晚橙色，但保持人物和镜头运动不变。",
  "target_video": "clips/target.mp4",
  "metadata": {
    "edit_type": "local_style",
    "preserve": ["person_identity", "motion", "composition"]
  }
}
```

训练阶段

阶段	English	中文	目标
Image Pretraining	Image Pretraining	图像预训练	学习外观、语义、构图。
Video Pretraining	Video Pretraining	视频预训练	学习运动、时序和相机变化。
High-quality Finetuning	High-quality Fine-tuning	高质量微调	提升美学、清晰度、prompt adherence。
Task SFT	Task Supervised Fine-Tuning	任务监督微调	支持 T2V、I2V、V2V、editing、AV。
Preference Tuning	Preference Tuning	偏好调优	优化人类偏好、一致性、安全。

阶段	English	中文	目标
Video RLHF	Video Reinforcement Learning from Human Feedback	视频人类反馈强化学习	针对视频质量、运动、物理和安全优化。
Distillation	Distillation	蒸馏	缩短采样步数、降低 TTV。
Safety Tuning	Safety Tuning	安全调优	降低不合规、侵权、身份滥用。

面试表达：

工业视频模型通常是多阶段训练：先从图像学外观，再从视频学运动，再用高质量数据和偏好数据修产品体验，最后用蒸馏把慢模型变成可上线的低延迟模型。

Batch 和 Token Budget

视频样本的成本由 T 、 H 、 W 和 latent 压缩率共同决定。直觉上：

$$N_v \propto T \times H \times W$$

这意味着时长、分辨率和帧率不能同时无脑拉满。常见训练策略：

- 短片段先训，逐步增加时长。
- 低分辨率预训练，高分辨率微调。
- frame dropping 或 temporal compression 控制成本。
- 按宽高比和时长做 bucket。
- 混合 T2I、T2V、I2V 数据维持外观和运动。

偏好数据怎么构造

视频偏好通常不是简单“哪个好看”，而是拆维度：

偏好维度	中文	判断问题
Prompt Adherence	提示遵循	是否满足 prompt 里的主体、动作、风格。
Temporal Consistency	时间一致性	是否闪烁、身份漂移、物体消失。
Motion Naturalness	运动自然度	动作是否连贯，物理是否合理。
Visual Quality	视觉质量	清晰度、构图、光照、美学。
Camera Control	镜头控制	镜头运动是否符合要求。
Audio Sync	音画同步	声音是否和动作、对白同步。
Safety	安全	是否有违规、肖像、版权、暴力等风险。

偏好数据可以是 pairwise，也可以是多维评分。面试时要强调：多维偏好比单一总分更可诊断。

本章面试高频问题

1. 为什么文生视频需要 shot detection?

因为一个视频文件可能包含多个镜头、剪辑和转场。如果不切镜头，模型会把突然切换的画面当成连续运动学习，导致生成时出现跳变、空间关系混乱和身份漂移。

2. 视频 caption 和图像 caption 的区别?

图像 caption 主要描述静态内容，视频 caption 还要描述动作、时间变化、镜头、事件顺序和声音。文生视频 prompt adherence 很依赖 caption 对 motion 的覆盖。

3. 为什么视频模型常先用图像预训练?

图像数据规模更大、质量更高，可以让模型先学会外观、语义和构图；视频训练再补充运动和时序。这样比只用视频从零训练更高效。

4. Distillation 在视频生成里为什么重要?

视频采样成本高，线上 TTV 很敏感。蒸馏可以减少采样步数或压缩模型，让生成速度接近产品可用，同时尽量保留质量。

本章 References

- [Make-A-Video: Text-to-Video Generation without Text-Video Data](#)
- [Imagen Video: High Definition Video Generation with Diffusion Models](#)
- [Stable Video Diffusion](#)
- [Video generation models as world simulators](#)
- [Movie Gen: A Cast of Media Foundation Models](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)