

第 6 章：文生视频工作流、控制、评测与项目实操

上一章讲视频模型怎么训练，这一章讲视频生成系统怎么用、怎么评测、怎么落地。文生视频的产品形态越来越不像“一条 prompt 生成一段视频”，而更像导演式工作流：分镜、参考图、首尾帧、镜头控制、局部编辑、音频、审核和版本管理。

6.1 本章符号说明

符号/缩写	English	中文	含义
T2V	Text-to-Video	文生视频	根据文本生成视频。
I2V	Image-to-Video	图生视频	根据图片或关键帧生成视频。
V2V	Video-to-Video	视频到视频	基于输入视频做编辑或重生成。
AV	Audio-Video	音视频	联合处理画面和声音。
FPS	Frames Per Second	每秒帧数	视频时间分辨率。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成分布级指标。
VBench	Video Benchmark	视频生成基准	多维度评估视频生成质量的 benchmark。
CLIPScore	CLIP Score	CLIP 相似度得分	衡量文本和视觉语义匹配。
DINO	Self-distillation with No Labels	自监督视觉表征模型	可用于参考一致性评测。
LPIPS	Learned Perceptual Image Patch Similarity	学习感知图像块相似度	评估感知差异和编辑保真。
OCR	Optical Character Recognition	光学字符识别	检查视频中文字是否稳定和正确。
VLM	Vision-Language Model	视觉语言模型	用于自动评测、caption、审核和 badcase 归因。
C2PA	Coalition for Content Provenance and Authenticity	内容来源与真实性联盟	标记内容来源和编辑历史的标准。
SynthID	SynthID Watermarking	SynthID 水印	Google 用于标记生成内容的水印技术。
TTV	Time to Video	视频生成耗时	从请求到视频可用的端到端延迟。

符号/缩写	English	中文	含义
KPI	Key Performance Indicator	关键业务指标	业务效果指标，如通过率、点击率、转化率。
p	Prompt	提示词	用户或系统给模型的生成指令。
r	Reference	参考资产	参考图、角色、商品、首尾帧或视频片段。
s_i	Shot	第 i 个镜头	分镜计划中的一个镜头。

6.2 本章目标

- 能把文生视频讲成可控创作 workflow，而不是单次生成。
- 能设计视频生成 eval harness 和 badcase 归因体系。
- 能说明首尾帧、参考图、mask、camera control、audio control 的作用。
- 能把项目表达成“生成、评测、安全、成本、线上反馈”的闭环。

6.3 产品级视频生成 Workflow

一个通用 pipeline：

```
用户需求 / brief
-> LLM 拆分 storyboard、shot list、camera plan
-> 生成或上传 reference：角色、商品、场景、首帧、尾帧
-> T2V / I2V 生成每个镜头
-> 一致性检查：人物、商品、场景、文字、品牌
-> 局部编辑：mask edit、object insert/remove、extend
-> 音频：对白、音效、环境声、音乐
-> 剪辑：排序、转场、字幕、调色、封面
-> 评测：自动指标、人评、业务审核、badcase 标签
-> 安全：身份同意、版权、watermark、C2PA、日志
```

面试表达：

真实文生视频系统不是一次 prompt 出片，而是把视频拆成 shot-level generation 和 edit-level control。模型负责生成候选，系统负责规划、参考资产管理、一致性校验、评测、审核和回滚。

6.4 控制信号地图

控制信号	English	中文	解决什么问题
Prompt	Text Prompt	文本提示	主体、动作、风格、场景。
First Frame	First Frame	首帧	控制开头构图和主体。

控制信号	English	中文	解决什么问题
Last Frame	Last Frame	尾帧	控制结束状态和转场目标。
Reference Image	Reference Image	参考图	保持人物、商品、风格一致。
Multi-reference	Multiple References	多参考图	组合角色、场景、商品、风格。
Mask	Mask	蒙版	局部编辑、插入、移除。
Pose / Depth	Pose or Depth Condition	姿态或深度条件	控制人物动作和空间结构。
Camera Plan	Camera Plan	镜头计划	pan、zoom、dolly、orbit 等镜头运动。
Audio Prompt	Audio Prompt	音频提示	音效、环境声、对白、音乐。
Negative Prompt	Negative Prompt	负向提示	避免不需要的物体、风格或风险。

这些控制信号可以组合，但组合越多，模型越容易出现冲突。比如首帧要求人物站着，prompt 要求人物从椅子上起身，尾帧又要求人物躺下，系统需要先做 prompt normalization 和冲突检查。

6.5 视频评测维度

维度	English	中文	典型检查
Visual Quality	Visual Quality	视觉质量	清晰、构图、光照、美学。
Prompt Adherence	Prompt Adherence	提示遵循	主体、动作、风格、场景是否满足。
Temporal Consistency	Temporal Consistency	时间一致性	是否闪烁、漂移、跳变。
Identity Consistency	Identity Consistency	身份一致性	人物、商品、角色是否保持。
Motion Naturalness	Motion Naturalness	运动自然度	动作是否连贯、物理是否合理。
Camera Coherence	Camera Coherence	镜头一致性	镜头运动是否稳定、空间是否连贯。
Text Stability	Text Stability	文字稳定性	logo、字幕、标牌是否变形。
Audio Sync	Audio-Visual Synchronization	音画同步	口型、脚步、碰撞、环境声是否同步。
Edit Faithfulness	Edit Faithfulness	编辑保真	该改的改，不该改的保持。

维度	English	中文	典型检查
Safety	Safety	安全	肖像、版权、暴力、成人、误导性内容。

6.6 视频 Eval Harness

一个视频生成 harness 至少需要：

模块	内容
Prompt Suite	T2V、I2V、V2V、首尾帧、参考图、音频、编辑任务。
Asset Registry	参考图、mask、角色库、商品库、版权和授权信息。
Run Config	模型版本、seed、分辨率、fps、时长、sampler、guidance。
Runner	批量提交、失败重试、缓存、队列、成本记录。
Auto Metrics	FVD、CLIPScore、OCR、DINO/LPIPS、motion、safety classifier。
VLM Judge	多维打分、pairwise preference、badcase 解释。
Human Review	盲评、pairwise、业务审核、安全审核。
Report	分维度分数、置信区间、成本、延迟、失败样例。

注意：FVD 这种指标适合分布级比较，但不适合直接判断单条视频是否满足 prompt。产品评测必须有 prompt-level、人评和 badcase 维度。

6.7 Badcase 归因

失败类型	English	中文	处理方向
Flicker	Temporal Flicker	时间闪烁	数据过滤、temporal loss、后处理。
Identity Drift	Identity Drift	身份漂移	reference consistency、角色 embedding、I2V。
Object Disappearance	Object Disappearance	物体消失	更强时序建模、分镜约束、检测回归。
Physics Violation	Physics Violation	物理违背	更好 motion 数据、偏好数据、world model 评测。
Camera Conflict	Camera Conflict	镜头冲突	prompt 规范化、camera plan 拆解。
Audio Mismatch	Audio-Visual Mismatch	音画不匹配	AV 数据、同步评测、后期对齐。

失败类型	English	中文	处理方向
Text Degradation	Text Degradation	文字退化	OCR-aware 数据、短视频后处理、文字单独渲染。
Over-editing	Over-editing	过度编辑	mask、preserve loss、编辑数据改进。
Safety Violation	Safety Violation	安全违规	输入输出审核、拒绝策略、provenance。

6.8 项目实操一：广告短视频生成

1. 输入：商品图、卖点、品牌规范、目标人群。
2. 规划：LLM 生成 3-5 个 shot，包含镜头、字幕、CTA。
3. 生成：商品 I2V + 背景 T2V + 局部编辑。
4. 评测：商品一致性、文字正确率、品牌安全、转化素材人评。
5. 上线：素材审核、A/B 测试、CTR/CVR、成本监控。

亮点表达：

广告视频项目的核心不是“生成好看视频”，而是商品和品牌不能漂移，文字不能错，素材要可审核、可回滚，并且最终用 CTR/CVR 和人工审核通过率闭环。

6.9 项目实操二：影视分镜预览

1. 输入：剧本片段、人物设定、场景设定。
2. 规划：拆分 shot list、camera plan、情绪、动作。
3. 资产：角色参考图、场景参考图、风格板。
4. 生成：每个 shot 用 I2V 或 T2V 生成多候选。
5. 评测：角色一致性、镜头连续性、动作自然度、导演偏好。
6. 后处理：剪辑、配音、临时音乐、字幕。

这个项目特别适合说明“视频生成越来越 agentic”：LLM 做规划，图像模型做 keyframe，视频模型做 shot，VLM/judge 做评测和回归。

6.10 项目实操三：视频编辑和合规审核

输入现有视频，做 object remove、背景替换、风格化、logo 清理或字幕修改。

关键评测：

- 修改区域是否完成。
- 未修改区域是否保持。
- 人物身份是否保持。
- 镜头运动是否保持。

- 音频是否仍然同步。
- 是否引入版权、肖像、误导性风险。

面试时强调：编辑任务比生成任务更需要 preserve 约束和 before/after 评测。

6.11 面试高频问题

6.11.1 为什么文生视频产品要分镜？

长视频一次生成成本高、可控性差、失败难修。分镜可以把复杂需求拆成短镜头，每个镜头独立生成和评测，再通过剪辑保持叙事连续。

6.11.2 首尾帧控制有什么用？

首帧保证起始构图和主体，尾帧约束最终状态。它比纯文本 prompt 更适合控制转场、角色位置和动作结果。

6.11.3 自动指标为什么不够？

视频质量包含美学、语义、运动、物理、身份、安全和业务偏好。单个自动指标很难覆盖，必须结合多维指标、VLM judge、人评和业务指标。

6.11.4 文生视频项目怎么证明上线价值？

离线看 prompt adherence、时序一致性、身份一致性、安全通过率；线上看生成成功率、TTV、人工审核通过率、CTR/CVR、用户留存和成本。

6.12 本章 References

- [VBench: Comprehensive Benchmark Suite for Video Generative Models](#)
- [VideoPhy: Evaluating Physical Commonsense for Video Generation](#)
- [Movie Gen: A Cast of Media Foundation Models](#)
- [Introducing Runway Gen-4](#)
- [Veo official page](#)
- [Veo 3.1 and Flow updates](#)
- [C2PA Technical Specification](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)