

## 第 8 章：2026 SOTA 技术报告阅读地图

这一章帮你把 SOTA（State of the Art，当前最佳水平）模型放进同一张地图。面试里不要只说“我看过 Sora、Veo、FLUX”，而要能说出每个报告在数据、架构、训练、评测、安全上的关键启发。

### 8.1 本章符号说明

| 符号/缩写  | English                                    | 中文                      | 含义                                 |
|--------|--------------------------------------------|-------------------------|------------------------------------|
| SOTA   | State of the Art                           | 当前最佳水平                  | 当前公开或行业中表现领先的技术。                   |
| T2I    | Text-to-Image                              | 文生图                     | 文本生成图像。                            |
| T2V    | Text-to-Video                              | 文生视频                    | 文本生成视频。                            |
| I2I    | Image-to-Image                             | 图生图                     | 图像编辑或重绘。                           |
| I2V    | Image-to-Video                             | 图生视频                    | 参考图生成视频。                           |
| MMDiT  | Multimodal Diffusion Transformer           | 多模态扩散 Transformer       | 文本和图像 token 交互的 DiT。               |
| SD3    | Stable Diffusion 3                         | Stable Diffusion 3 模型系列 | 使用 MMDiT 和 rectified flow 的图像生成系列。 |
| FLUX.1 | FLUX.1 Model Family                        | FLUX.1 模型系列             | 图像生成和编辑模型系列。                       |
| FM     | Flow Matching                              | 流匹配                     | 学习生成路径速度场。                         |
| RF     | Rectified Flow                             | 矫正流                     | 用更直接路径提升生成效率。                      |
| RLHF   | Reinforcement Learning from Human Feedback | 基于人类反馈的强化学习             | 用人类偏好优化模型行为。                       |
| LLM    | Large Language Model                       | 大语言模型                   | 用于 caption、规划、评测或多模态生成。            |
| VLM    | Vision-Language Model                      | 视觉语言模型                  | 同时处理图像和文本的模型。                      |
| AV     | Audio-Video                                | 音视频                     | 联合视频和声音生成。                         |

### 8.2 读技术报告的统一框架

每篇报告按 9 个问题拆：

| 维度   | 你要找什么                               |
|------|-------------------------------------|
| Task | 它解决 T2I、I2I、T2V、I2V、V2V、AV 还是多任务统一？ |

| 维度            | 你要找什么                                                               |
|---------------|---------------------------------------------------------------------|
| Data          | 数据规模、来源、过滤、caption、版权和安全处理怎么做？                                      |
| Tokenizer     | 用像素、VAE latent、3D VAE、spacetime patch、discrete token 还是原生多模态 token？ |
| Backbone      | U-Net、DiT、MMDiT、LLM-style transformer、cascade 还是混合架构？               |
| Objective     | DDPM、EDM、v-prediction、flow matching、rectified flow、autoregressive？  |
| Conditioning  | 文本、参考图、多图、首尾帧、mask、pose、audio、video reference 怎么注入？                 |
| Post-training | SFT、偏好优化、RLHF、distillation、安全对齐做了什么？                                |
| Evaluation    | 自动指标、人评、benchmark、业务测试、失败维度怎么设计？                                    |
| Safety        | watermark、C2PA、SynthID、真人肖像、版权、红队、安全过滤怎么做？                          |

这张表就是你的“报告阅读 harness”。

### 8.3 文生图与图像编辑主线

| 模型/报告                                | 时间线  | 关键词                                                                                     | 面试重点                                  |
|--------------------------------------|------|-----------------------------------------------------------------------------------------|---------------------------------------|
| Stable Diffusion 3 / 3.5             | 2024 | MMDiT、rectified flow、CLIP + T5、typography                                               | 从 U-Net LDM 转向多模态 Transformer 和 flow。 |
| FLUX.1 Kontext                       | 2025 | unified generation and editing、flow matching、KontextBench                               | 把生成和编辑统一到一个模型范式，强调参考一致性。              |
| GPT-4o Image                         | 2025 | native multimodal generation、text rendering、multi-turn editing                          | 图像生成成为多模态 LM 原生能力。                    |
| Gemini 2.5 Flash Image / Nano Banana | 2025 | multi-image fusion、character consistency、local edit、world knowledge                     | 编辑、参考一致和世界知识结合。                       |
| Nano Banana Pro                      | 2025 | Gemini 3 Pro Image、4K、layout、richer text                                                | 更强文字、信息图和专业设计场景。                      |
| Qwen-Image                           | 2025 | Chinese text rendering、multi-task editing、Qwen2.5-VL + MMDiT                            | 中文文字渲染和编辑一致性是核心卖点。                    |
| Seedream 4.0                         | 2025 | multimodal image generation、T2I + editing + multi-image composition、efficient DiT / VAE | 统一生成、编辑和多图组合，关注效率和工业化。                |
| Imagen 4                             | 2025 | safety filtering、SynthID、high fidelity                                                  | Google 图像生成产品化和安全水印路线。                |

#### 8.3.1 图像模型的共同趋势

1. 从 U-Net 到 DiT / MMDiT。

- 2. 从 noise prediction 到 v-prediction / flow matching / rectified flow。
- 3. 从单 prompt 生成到 reference-based multi-turn editing。
- 4. 从英文 prompt 到多语言、中文、复杂文字渲染。
- 5. 从“漂亮图”到“可用图”：商品、海报、UI、信息图、品牌一致性。
- 6. 从模型单点到工作流：安全、审核、版本、回归测试、成本。

### 8.4 文生视频与音视频主线

| 模型/报告         | 时间线  | 关键词                                                                      | 面试重点                    |
|---------------|------|--------------------------------------------------------------------------|-------------------------|
| Sora          | 2024 | spacetime patches、DiT、variable duration / resolution / aspect ratio      | 把视频和图像统一成可扩展时空 token。   |
| Sora 2        | 2025 | audio、dialogue、better physics、cameo safety                               | 视频生成从画面扩展到音频和可控互动。      |
| Veo 3.1       | 2025 | audio across features、Flow、Ingredients / Frames / Extend / Insert-remove | 产品化视频工作流和音画同步。          |
| Movie Gen     | 2024 | 1080p、audio、personalization、instruction-based editing                    | Meta 的统一视频、音频、编辑、个性化路线。 |
| Runway Gen-4  | 2025 | world consistency、reference-based characters / locations / objects       | 生产工作流里的角色和场景一致性。        |
| HunyuanVideo  | 2024 | open-source 13B video foundation model、data + architecture + infra       | 开源视频大模型报告，披露工程细节更多。     |
| Open-Sora 2.0 | 2025 | cost-efficient training、data curation、system optimization                | 低预算训练高质量视频模型的工程路线。      |
| Seedance 1.0  | 2025 | video captioning、multi-shot、T2V + I2V、video RLHF、distillation            | 产业系统如何做数据、后训练和加速。       |
| Seedance 2.0  | 2026 | text / image / audio / video inputs、audio-video joint generation         | 多模态输入和音视频联合生成。          |

#### 8.4.1 视频模型的共同趋势

- 1. 从短 clip 到多镜头、多分镜和更长时程。
- 2. 从 silent video 到 audio-video joint generation。
- 3. 从单次生成到编辑、扩展、插入、移除和首尾帧控制。
- 4. 从 text prompt 到多模态 reference：图像、视频、音频、角色资产。
- 5. 从纯质量评测到时序、物理、音画一致、安全和版权评测。

### 8.5 重点报告怎么读

#### 8.5.1 Stable Diffusion 3 / 3.5

你要抓：

- 为什么引入 MMdIT。
- 为什么使用多个 text encoder。
- rectified flow 相比传统 DDPM 训练的动机。
- typography 和 prompt adherence 为什么被单独强调。
- 3.5 为什么强调可定制、开源和消费级硬件。

可复述答案：

SD3 系列代表 latent diffusion 从 U-Net + cross-attention 走向 MMdIT + flow 的范式变化。它的面试价值在于说明 text encoder、backbone、objective 和数据共同决定 prompt adherence 和文字渲染。

### 8.5.2 GPT-4o Image

你要抓：

- 它把图像生成当成多模态模型能力，而不是外接图片模型。
- 多轮上下文、文字渲染、in-context learning 和世界知识是重点。
- C2PA metadata、内部搜索和真实人物限制体现了产品级安全。

可复述答案：

GPT-4o Image 的关键不是“又一个文生图模型”，而是把语言理解、视觉理解和图像生成放到一个原生多模态交互里，所以多轮编辑、准确文字和复杂指令遵循更自然。

### 8.5.3 FLUX.1 Kontext

你要抓：

- generation 和 editing 统一。
- 只用文本和图像上下文，尽量减少任务特化 pipeline。
- KontextBench 用来评估编辑能力，而不是只评估单图质量。

可复述答案：

Kontext 代表图像模型从 T2I 走向 instruction-based visual editing。评测也必须从 FID / CLIPScore 扩展到编辑前后的一致性、目标区域变化和非目标区域保持。

### 8.5.4 Qwen-Image / Seedream 4.0

你要抓：

- 中文和复杂文字渲染。
- 图像编辑一致性。
- 多图参考和组合。
- 高效 VAE / DiT 对生产成本的影响。

可复述答案：

中文图像生成不能只看 aesthetics。文字形态、排版、logo、商品一致性和多图编辑会成为核心体验，所以数据 pipeline、OCR 标注和编辑 benchmark 很关键。

### 8.5.5 Sora / Veo / Movie Gen / Seedance

你要抓：

- 视频不是  $T$  张独立图，而是时空生成。
- 时空 patch、3D VAE、temporal attention、multi-shot planning 都是为一致性服务。
- 视频 caption 要描述动作、镜头、场景转移和声音。
- 音视频联合生成引入 lip-sync、音效、物理因果和声音安全。
- 产品系统必须支持编辑、扩展、审核和 provenance。

可复述答案：

2026 的视频生成竞争不只是分辨率和时长，而是谁能把多模态参考、分镜控制、音画同步、角色一致性、安全水印和低延迟生成做成稳定工作流。

## 8.6 面试里如何谈“最新”

不要说“某模型永远最强”。更好的说法：

截至 2026 年 6 月，公开材料里能看到几个清晰方向：图像侧是 DiT / MMDiT、flow matching、原生多模态编辑、文字渲染和多图一致性；视频侧是时空 token、音视频联合生成、多镜头控制、reference consistency、video RLHF 和安全 provenance。具体榜单会变，但这些方向是稳定的。

这句话很稳，因为它不依赖单一 leaderboard。

## 8.7 本章 References

- [Stable Diffusion 3 Research Paper announcement](#)
- [Stable Diffusion 3.5 announcement](#)
- [FLUX.1 Kontext](#)
- [Introducing 4o Image Generation](#)
- [Gemini 2.5 Flash Image](#)
- [Nano Banana Pro](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)
- [Imagen official page](#)
- [Video generation models as world simulators](#)
- [Sora 2](#)
- [Veo official page](#)
- [Veo 3.1 and Flow updates](#)

- [Movie Gen](#)
- [Introducing Runway Gen-4](#)
- [HunyuanVideo](#)
- [Open-Sora 2.0](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)