

第 8 章：2026 SOTA 技术报告阅读地图

这一章帮你把 SOTA（State of the Art，当前最佳水平）模型放进同一张地图。面试里不要只说“我看过 Sora、Veo、FLUX”，而要能说出每个报告在数据、架构、训练、评测、安全上的关键启发。

本章符号说明

符号/缩写	English	中文	含义
SOTA	State of the Art	当前最佳水平	当前公开或行业中表现领先的技术。
T2I	Text-to-Image	文生图	文本生成图像。
T2V	Text-to-Video	文生视频	文本生成视频。
I2I	Image-to-Image	图生图	图像编辑或重绘。
I2V	Image-to-Video	图生视频	参考图生成视频。
MMDiT	Multimodal Diffusion Transformer	多模态扩散 Transformer	文本和图像 token 交互的 DiT。
SD3	Stable Diffusion 3	Stable Diffusion 3 模型系列	使用 MMDiT 和 rectified flow 的图像生成系列。
FLUX.1	FLUX.1 Model Family	FLUX.1 模型系列	图像生成和编辑模型系列。
FM	Flow Matching	流匹配	学习生成路径速度场。
RF	Rectified Flow	矫正流	用更直接路径提升生成效率。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好优化模型行为。
LLM	Large Language Model	大语言模型	用于 caption、规划、评测或多模态生成。
VLM	Vision-Language Model	视觉语言模型	同时处理图像和文本的模型。
AV	Audio-Video	音视频	联合视频和声音生成。

读技术报告的统一框架

每篇报告按 9 个问题拆：

维度	你要找什么
Task	它解决 T2I、I2I、T2V、I2V、V2V、AV 还是多任务统一？

维度	你要找什么
Data	数据规模、来源、过滤、caption、版权和安全处理怎么做？
Tokenizer	用像素、VAE latent、3D VAE、spacetime patch、discrete token 还是原生多模态 token？
Backbone	U-Net、DiT、MMDiT、LLM-style transformer、cascade 还是混合架构？
Objective	DDPM、EDM、v-prediction、flow matching、rectified flow、autoregressive？
Conditioning	文本、参考图、多图、首尾帧、mask、pose、audio、video reference 怎么注入？
Post-training	SFT、偏好优化、RLHF、distillation、安全对齐做了什么？
Evaluation	自动指标、人评、benchmark、业务测试、失败维度怎么设计？
Safety	watermark、C2PA、SynthID、真人肖像、版权、红队、安全过滤怎么做？

这张表就是你的“报告阅读 harness”。

文生图与图像编辑主线

模型/报告	时间线	关键词	面试重点
Stable Diffusion 3 / 3.5	2024	MMDiT、rectified flow、CLIP + T5、typography	从 U-Net LDM 转向多模态 Transformer 和 flow。
FLUX.1 Kontext	2025	unified generation and editing、flow matching、KontextBench	把生成和编辑统一到一个模型范式，强调参考一致性。
GPT-4o Image	2025	native multimodal generation、text rendering、multi-turn editing	图像生成成为多模态 LM 原生能力。
Gemini 2.5 Flash Image / Nano Banana	2025	multi-image fusion、character consistency、local edit、world knowledge	编辑、参考一致和世界知识结合。
Nano Banana Pro	2025	Gemini 3 Pro Image、4K、layout、richer text	更强文字、信息图和专业设计场景。
Qwen-Image	2025	Chinese text rendering、multi-task editing、Qwen2.5-VL + MMDiT	中文文字渲染和编辑一致性是核心卖点。
Seedream 4.0	2025	multimodal image generation、T2I + editing + multi-image composition、efficient DiT / VAE	统一生成、编辑和多图组合，关注效率和工业化。
Imagen 4	2025	safety filtering、SynthID、high fidelity	Google 图像生成产品化和安全水印路线。

图像模型的共同趋势

1. 从 U-Net 到 DiT / MMDiT。

- 2. 从 noise prediction 到 v-prediction / flow matching / rectified flow。
- 3. 从单 prompt 生成到 reference-based multi-turn editing。
- 4. 从英文 prompt 到多语言、中文、复杂文字渲染。
- 5. 从“漂亮图”到“可用图”：商品、海报、UI、信息图、品牌一致性。
- 6. 从模型单点到工作流：安全、审核、版本、回归测试、成本。

文生视频与音视频主线

模型/报告	时间线	关键词	面试重点
Sora	2024	spacetime patches、DiT、variable duration / resolution / aspect ratio	把视频和图像统一成可扩展时空 token。
Sora 2	2025	audio、dialogue、better physics、cameo safety	视频生成从画面扩展到音频和可控互动。
Veo 3.1	2025	audio across features、Flow、Ingredients / Frames / Extend / Insert-remove	产品化视频工作流和音画同步。
Movie Gen	2024	1080p、audio、personalization、instruction-based editing	Meta 的统一视频、音频、编辑、个性化路线。
Runway Gen-4	2025	world consistency、reference-based characters / locations / objects	生产工作流里的角色和场景一致性。
HunyuanVideo	2024	open-source 13B video foundation model、data + architecture + infra	开源视频大模型报告，披露工程细节更多。
Open-Sora 2.0	2025	cost-efficient training、data curation、system optimization	低预算训练高质量视频模型的工程路线。
Seedance 1.0	2025	video captioning、multi-shot、T2V + I2V、video RLHF、distillation	产业系统如何做数据、后训练和加速。
Seedance 2.0	2026	text / image / audio / video inputs、audio-video joint generation	多模态输入和音视频联合生成。

视频模型的共同趋势

- 1. 从短 clip 到多镜头、多分镜和更长时程。
- 2. 从 silent video 到 audio-video joint generation。
- 3. 从单次生成到编辑、扩展、插入、移除和首尾帧控制。
- 4. 从 text prompt 到多模态 reference：图像、视频、音频、角色资产。
- 5. 从纯质量评测到时序、物理、音画一致、安全和版权评测。

重点报告怎么读

Stable Diffusion 3 / 3.5

你要抓：

- 为什么引入 MMDiT。
- 为什么使用多个 text encoder。
- rectified flow 相比传统 DDPM 训练的动机。
- typography 和 prompt adherence 为什么被单独强调。
- 3.5 为什么强调可定制、开源和消费级硬件。

可复述答案：

SD3 系列代表 latent diffusion 从 U-Net + cross-attention 走向 MMDiT + flow 的范式变化。它的面试价值在于说明 text encoder、backbone、objective 和数据共同决定 prompt adherence 和文字渲染。

GPT-4o Image

你要抓：

- 它把图像生成当成多模态模型能力，而不是外接图片模型。
- 多轮上下文、文字渲染、in-context learning 和世界知识是重点。
- C2PA metadata、内部搜索和真实人物限制体现了产品级安全。

可复述答案：

GPT-4o Image 的关键不是“又一个文生图模型”，而是把语言理解、视觉理解和图像生成放到一个原生多模态交互里，所以多轮编辑、准确文字和复杂指令遵循更自然。

FLUX.1 Kontext

你要抓：

- generation 和 editing 统一。
- 只用文本和图像上下文，尽量减少任务特化 pipeline。
- KontextBench 用来评估编辑能力，而不是只评估单图质量。

可复述答案：

Kontext 代表图像模型从 T2I 走向 instruction-based visual editing。评测也必须从 FID / CLIPScore 扩展到编辑前后的一致性、目标区域变化和非目标区域保持。

Qwen-Image / Seedream 4.0

你要抓：

- 中文和复杂文字渲染。
- 图像编辑一致性。
- 多图参考和组合。
- 高效 VAE / DiT 对生产成本的影响。

可复述答案：

中文图像生成不能只看 aesthetics。文字形态、排版、logo、商品一致性和多图编辑会成为核心体验，所以数据 pipeline、OCR 标注和编辑 benchmark 很关键。

Sora / Veo / Movie Gen / Seedance

你要抓：

- 视频不是 T 张独立图，而是时空生成。
- 时空 patch、3D VAE、temporal attention、multi-shot planning 都是为一致性服务。
- 视频 caption 要描述动作、镜头、场景转移和声音。
- 音视频联合生成引入 lip-sync、音效、物理因果和声音安全。
- 产品系统必须支持编辑、扩展、审核和 provenance。

可复述答案：

2026 的视频生成竞争不只是分辨率和时长，而是谁能把多模态参考、分镜控制、音画同步、角色一致性、安全水印和低延迟生成做成稳定工作流。

面试里如何谈“最新”

不要说“某模型永远最强”。更好的说法：

截至 2026 年 6 月，公开材料里能看到几个清晰方向：图像侧是 DiT / MMDiT、flow matching、原生多模态编辑、文字渲染和多图一致性；视频侧是时空 token、音视频联合生成、多镜头控制、reference consistency、video RLHF 和安全 provenance。具体榜单会变，但这些方向是稳定的。

这句话很稳，因为它不依赖单一 leaderboard。

本章 References

- [Stable Diffusion 3 Research Paper announcement](#)
- [Stable Diffusion 3.5 announcement](#)
- [FLUX.1 Kontext](#)
- [Introducing 4o Image Generation](#)
- [Gemini 2.5 Flash Image](#)
- [Nano Banana Pro](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)
- [Imagen official page](#)
- [Video generation models as world simulators](#)
- [Sora 2](#)
- [Veo official page](#)
- [Veo 3.1 and Flow updates](#)

- [Movie Gen](#)
- [Introducing Runway Gen-4](#)
- [HunyuanVideo](#)
- [Open-Sora 2.0](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)