

第 9 章：Eval Harness、Benchmarking、人评与自动评测

生成模型评测最容易陷入“我觉得好看”。面试里你要主动引入 eval harness：固定输入、固定配置、固定指标、固定人评协议、固定版本记录，让每次模型或 prompt 改动都可复现、可对比、可回归。

9.1 本章符号说明

符号/缩写	English	中文	含义
Harness	Evaluation Harness	评测工具链	统一管理数据、配置、运行、打分、报告和回归的评测系统。
FID	Fréchet Inception Distance	Fréchet Inception 距离	图像生成分布级质量指标。
FVD	Fréchet Video Distance	Fréchet Video 距离	视频生成分布级质量指标。
IS	Inception Score	Inception 分数	早期图像生成质量和多样性指标。
CLIPScore	CLIP Score	CLIP 相似度得分	用 CLIP 衡量图文匹配。
VQA	Visual Question Answering	视觉问答	用问答形式判断图像或视频是否满足条件。
VQAScore	Visual Question Answering Score	视觉问答得分	用 VQA 判断 prompt 中属性是否满足。
HPS	Human Preference Score	人类偏好得分	基于人类偏好训练的自动指标。
PickScore	PickScore	偏好选择得分	用偏好数据训练出的图像偏好模型。
ImageReward	ImageReward	图像奖励模型	用人类反馈训练的图像生成 reward。
OCR	Optical Character Recognition	光学字符识别	用于评测图像或视频中的文字是否正确。
DINO	Self-distillation with No Labels	自监督视觉表征模型	常用于 reference similarity 或视觉一致性评测。
LPIPS	Learned Perceptual Image Patch Similarity	学习感知图像块相似度	衡量图像感知差异，常用于编辑保真评测。
MLLM	Multimodal Large Language Model	多模态大语言模型	可作为自动评委，但需要校准。

符号/缩写	English	中文	含义
ELO	Elo Rating System	Elo 评分系统	pairwise preference 常用排名方法。
CI	Confidence Interval	置信区间	衡量评测结果不确定性。

9.2 什么是 Eval Harness

一个最小可用 harness 至少包括：

模块	内容
Prompt Suite	固定 prompt、参考图、mask、首尾帧、音频、负向提示。
Run Config	固定模型版本、seed、sampler、steps、CFG scale、分辨率、后处理。
Inference Runner	统一生成任务提交、重试、缓存、日志。
Auto Metrics	自动指标、VLM judge、OCR、检测器、embedding similarity。
Human Eval	人评界面、pairwise 比较、blind review、审核一致性。
Report	输出表格、失败样例、置信区间、版本差异。
Regression Set	每次升级必跑的 badcase 和核心场景。

一句话：

Harness 不是一个指标，而是一整套让生成模型评测可复现的实验系统。

9.3 Prompt Suite 怎么设计

文生图 prompt suite 至少覆盖：

- 单主体。
- 多主体。
- 复杂属性组合。
- 空间关系。
- 计数。
- 文字渲染。
- 风格迁移。
- 商品和 logo。
- 人物和身份一致。
- 安全边界。
- 多语言，尤其中文。
- 局部编辑和多轮编辑。

文生视频 prompt suite 还要覆盖：

- 静态镜头。
- 镜头运动。
- 主体运动。
- 多主体交互。
- 物体永久性。
- 快速动作。
- 复杂物理。
- 首尾帧控制。
- 多镜头叙事。
- 音画同步。
- 字幕和标牌随时间稳定。

9.4 固定运行配置

没有固定 config，评测结果就很难复现。建议记录：

```
model:
  name: image-video-model
  version: 2026-06-22
  checkpoint: release-or-commit-id
generation:
  task: t2i
  seed: 12345
  width: 1024
  height: 1024
  sampler: euler
  steps: 28
  guidance_scale: 4.5
  negative_prompt: low quality, distorted text
inputs:
  prompt_id: poster_zh_text_001
  prompt: 生成一张中文促销海报，标题必须为“夏日新品”
  reference_images: []
postprocess:
  upscaler: none
  safety_filter: v3
```

视频还要记录：

```
video:
  duration_seconds: 8
  fps: 24
  resolution: 1280x720
  audio_enabled: true
  first_frame_id: optional
  last_frame_id: optional
  shot_plan_id: optional
```

9.5 图像自动指标

维度	可用指标/方法	局限
Visual Fidelity	FID、aesthetic score、sharpness、artifact detector	和人类偏好不总一致。
Text Alignment	CLIPScore、VQAScore、MLLM judge	复杂关系、计数和否定容易误判。
Text Rendering	OCR accuracy、edit distance、layout check	OCR 本身也会出错。
Identity Consistency	face/product embedding、DINO similarity、人评	对非人主体要定制检测器。
Editing Preservation	mask 外 similarity、LPIPS、结构检测	保留和修改的边界必须定义清楚。
Safety	moderation model、face recognition、copyright detector	需要人工复核和规则兜底。

GenAI-Bench 的启发是：复杂组合 prompt 需要更细粒度评测，VQAScore 往往比单纯 CLIPScore 更适合判断对象、属性和关系是否满足。

9.6 视频自动指标

维度	可用指标/方法	局限
Frame Quality	FID-like frame score、aesthetic score、artifact detector	单帧好不代表视频好。
Temporal Consistency	optical flow consistency、temporal flicker score、embedding stability	快速运动和镜头切换会干扰。
Motion Quality	action recognition、motion magnitude、VBench motion dimensions	很难覆盖创意镜头语言。
Text-Video Alignment	VLM / MLLM judge、caption-video similarity	长 prompt 和多事件很难评。

维度	可用指标/方法	局限
Physics	T2V-PhysBench、AV-Phys Bench、rule-based check	物理 commonsense 仍是开放问题。
Audio-Visual Sync	lip-sync score、event-audio alignment、audio caption consistency	声音语义和物理因果都难。
Identity Consistency	tracking + embedding similarity、人评	遮挡、侧脸、光照变化会影响。

VBench 的价值是把视频质量拆成多维度，而不是只给一个总分。对业务来说，你也应该拆成“可用性维度”：比如商品广告更重视商品不变形和品牌安全，影视分镜更重视镜头和角色一致性。

9.7 人评协议

自动指标只能做初筛。人评要设计成可统计的协议：

设计项	推荐做法
Blind Review	隐藏模型名和生成参数。
Pairwise Preference	两两比较更稳定，适合 ELO 或 Bradley-Terry 排名。
Absolute Rating	1 到 5 分可解释，但人之间校准困难。
Multi-axis Rubric	分开打质量、对齐、文字、身份、安全、视频时序。
Rater Calibration	给标注员示例和边界样例。
Inter-rater Agreement	统计一致性，发现分歧维度。
Confidence Interval	给出 CI，避免小样本过度解读。

9.8 VLM / MLLM Judge 怎么用

VLM judge 可以降低成本，但不能无脑信。

适合：

- 判断 prompt 中是否有某个对象。
- OCR 辅助。
- 简单安全分类。
- 对比两张图哪个更符合 prompt。
- 生成失败原因标签。

不适合完全替代人评：

- 审美偏好。
- 微妙身份一致。
- 复杂物理。
- 版权和真人肖像。

- 高风险安全结论。

建议做法：

1. 先用人评样本校准 VLM judge。
2. 统计 judge 和人评的一致率。
3. 只把 judge 用在高一致维度。
4. 对低一致或高风险维度保留人工审核。

9.9 生成模型回归测试

每次升级模型、prompt、采样器、安全策略，都要跑 regression set。

回归集应该包含：

- 历史 badcase。
- 高频业务场景。
- 安全边界。
- 长尾复杂 prompt。
- 多语言和中文文字。
- 多轮编辑链路。
- 视频时序和音画同步。

输出报告至少包含：

字段	含义
Win Rate	新版本相对旧版本的人评胜率。
Metric Delta	自动指标变化。
Safety Regression	新增安全失败数。
Cost Delta	单次生成成本变化。
Latency Delta	TTI / TTV 变化。
Badcase Gallery	失败样例图或视频。
Decision	发布、灰度、回滚或继续训练。

9.10 面试高频问题

9.10.1 为什么 FID 不够？

FID 是分布级指标，不能直接判断单个 prompt 是否被遵循，也不能衡量文字、身份一致、局部编辑、视频时序和安全。它适合看总体分布，不适合独立决定产品质量。

9.10.2 CLIPScore 有什么问题？

CLIPScore 对粗粒度语义有用，但对计数、否定、空间关系、中文文字和细节属性不稳定。复杂 prompt 更适合结合 VQAScore、VLM judge、OCR 和人评。

9.10.3 视频为什么更难评？

视频同时有空间质量、时间一致、运动自然、物体永久性、物理合理、镜头语言、音画同步和安全风险。单个指标很难覆盖这些维度。

9.10.4 如何评估图像编辑？

要同时看目标区域是否按指令改变，以及非目标区域是否保持。可以用 mask 内外指标、reference similarity、OCR、检测器、人评和多轮回归测试。

9.10.5 线上 A/B 和离线评测冲突怎么办？

先确认 prompt 分布是否一致，再看线上指标是否受推荐、流量、人群和审核策略影响。离线评测解释模型能力，线上 A/B 解释业务效果，两者都要保留。

9.11 本章 References

- [GenAI-Bench](#)
- [VBench](#)
- [T2V-CompBench](#)
- [T2VTextBench](#)
- [T2VPhysBench](#)
- [AV-Phys Bench](#)
- [Pick-a-Pic and PickScore](#)
- [ImageReward](#)
- [HPSv2](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)