

第 10 章：训练、对齐、安全、Provenance 与产品化

最后一章回答真实工作里的问题：模型怎么训，怎么对齐，怎么防滥用，怎么上线。面试官越资深，越会从“模型原理”追到“你怎么把它做成可靠系统”。

本章符号说明

符号/缩写	English	中文	含义
SFT	Supervised Fine-Tuning	监督微调	用高质量指令、编辑或安全数据微调模型。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好训练 reward 并优化模型。
DPO	Direct Preference Optimization	直接偏好优化	不显式训练 reward model 的偏好优化方法。
RM	Reward Model	奖励模型	预测人类偏好的模型。
RLAIF	Reinforcement Learning from AI Feedback	基于 AI 反馈的强化学习	用 AI judge 生成偏好或奖励信号。
VLM	Vision-Language Model	视觉语言模型	用于 caption、审核、评测和自动标注。
OCR	Optical Character Recognition	光学字符识别	用于文字数据构造、评测和审核。
PII	Personally Identifiable Information	个人可识别信息	可能指向个人身份的敏感信息。
IP	Intellectual Property	知识产权	版权、商标、角色、品牌资产等。
C2PA	Coalition for Content Provenance and Authenticity	内容来源与真实性联盟	用 Content Credentials 表示内容来源和编辑历史。
DRM	Digital Rights Management	数字版权管理	管理数字内容访问和使用权限的机制。
SLA	Service Level Agreement	服务等级协议	产品服务可用性、延迟和稳定性要求。
API	Application Programming Interface	应用程序编程接口	产品调用生成、审核、评测和素材服务的接口。

训练 Pipeline 总览

一个产业级文生图/视频训练 pipeline 通常长这样：

```
数据采集
→ 去重、质量过滤、安全过滤、版权/隐私过滤
→ captioning / recaptioning / OCR / audio caption
→ tokenizer / VAE / 3D VAE 训练或复用
→ base model pretraining
→ task-specific SFT
→ preference data / reward model / RLHF 或 DPO
→ distillation / acceleration
→ safety tuning
→ eval harness
→ 灰度发布和线上反馈回流
```

面试里你可以强调：

文生图/视频的效果不是单纯由 backbone 决定。数据质量、caption、tokenizer、后训练、采样器、评测和安全共同决定最终产品体验。

数据与 Captioning

训练数据的关键问题：

问题	影响
Low-quality Data	模糊、水印、压缩、低审美会直接影响生成质量。
Bad Captions	caption 不描述动作、文字、布局，模型就学不到 prompt 对齐。
Duplicates	数据重复会导致 memorization 和版权风险。
Unsafe Content	色情、暴力、仇恨、未成年人、隐私内容会污染模型。
Copyright Risk	未授权 IP、角色、品牌、影视片段会带来法律和产品风险。
OCR Noise	文字识别错会伤害文字渲染能力。
Temporal Noise	视频剪辑跳变、字幕、水印、转场会伤害时序建模。

recaptioning 很重要。DALL-E 3、Sora、Seedance 等公开材料都强调过更高质量 caption 或 recaption 对 prompt adherence 的价值。

高质量 caption 应该包括：

- 主体、属性、数量。
- 空间关系和构图。
- 风格、材质、光照、镜头。

- 图像中文字。
- 视频动作、镜头运动、时间变化。
- 音频事件和声源。
- 安全敏感标签。

Base Training、SFT 与 Preference Optimization

训练阶段可以拆成：

阶段	English	中文	作用
Pretraining	Pretraining	预训练	学通用视觉分布、语言条件和运动。
SFT	Supervised Fine-Tuning	监督微调	学指令、编辑、产品风格和安全边界。
Preference Training	Preference Training	偏好训练	让输出更符合人类偏好和业务目标。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用 reward 优化质量、对齐和安全。
DPO	Direct Preference Optimization	直接偏好优化	更简单地利用 preference pair。
Distillation	Distillation	蒸馏	降低采样步数和推理成本。

视频报告里常见的 video-specific RLHF 特别值得关注。它说明视频不是只靠预训练，还要通过多维 reward 改善运动、时序、prompt adherence 和审美。

Reward 该怎么设计

图像 reward 可以拆成：

- prompt adherence。
- visual fidelity。
- aesthetics。
- text rendering。
- identity consistency。
- editing preservation。
- safety compliance。

视频 reward 还要加：

- temporal consistency。
- motion naturalness。
- physics plausibility。
- camera coherence。
- audio-visual sync。

- multi-shot narrative consistency。

不要用单一 reward。单指标优化容易 reward hacking，比如 CLIPScore 变高但图像变丑，或者视频看起来清晰但动作僵硬。

安全策略分层

一个稳的安全系统通常分层：

层级	做什么
Policy	定义允许和禁止的内容，包括真人肖像、未成年人、色情暴力、政治误导、IP。
Input Moderation	prompt、参考图、参考视频、音频上传时审核。
Generation Constraint	模型侧拒绝、负向条件、安全 LoRA、过滤敏感身份。
Output Moderation	图像、视频、音频、OCR、face、logo、IP 检测。
Provenance	C2PA、SynthID、watermark、metadata。
Human Review	高风险内容进入人工审核。
Logging	记录请求、版本、审核结果、申诉和处置。
Red Team	持续构造绕过样例，更新策略和模型。

Provenance：C2PA、SynthID 与 Watermark

C2PA 的核心是给内容附加可验证的来源和编辑记录。它更像“内容营养标签”，告诉用户这个内容从哪里来、被怎样处理过。

SynthID 的核心是不可见水印和检测能力。Google 公开材料强调 SynthID 可用于图像、音频、文本、视频，并设计为对裁剪、滤镜、压缩等变换有一定鲁棒性。

注意它们不是万能安全：

- 元数据可能被剥离。
- 水印可能被攻击或转码削弱。
- 检测有误报和漏报。
- 对恶意截屏、重拍、二次生成要有额外策略。

面试表达：

Provenance 是安全链路的一层，不是全部。真正可靠的系统需要输入审核、输出审核、行为风控、模型对齐、水印、日志、人工复核和申诉机制一起工作。

真人肖像、版权和 IP

文生图/视频最敏感三类风险：

风险	例子	防线
Likeness	未授权生成真实人物或公众人物	face detection、identity allowlist/denylist、consent workflow。
Copyright	生成受保护角色、影视风格或片段	IP detector、prompt policy、训练数据过滤、人工审核。
Trademark	logo、商品包装、品牌资产错误使用	logo detector、品牌规则、客户素材授权管理。

产品策略上要区分：

- 用户上传自己有权使用的素材。
- 用户请求生成公众人物或受保护角色。
- 用户生成商业投放素材。
- 用户只做个人娱乐。

风险等级不同，审核强度也不同。

Serving 与成本

上线时要关心：

维度	常见策略
Latency	preview model、低清预览、异步队列、分阶段生成。
Cost	模型路由、缓存、distillation、批处理、失败提前终止。
Reliability	超时重试、任务状态机、幂等、断点续跑。
Quality	自动筛选多个候选、VLM 审核、人工兜底。
Observability	记录 prompt、seed、版本、耗时、审核结果、失败标签。
Rollback	模型版本、prompt template、安全策略都要可回滚。

视频尤其适合异步任务：

```
submit job
→ validate inputs
→ generate storyboard
→ generate previews
→ user selects
→ high-quality render
→ safety review
→ deliver and archive provenance
```

产品化架构

一个推荐架构：

```

API Gateway
→ Input Moderation
→ Prompt / Storyboard Planner
→ Asset Manager
→ Model Router
→ Generation Workers
→ Auto Evaluation
→ Safety Review
→ Post-processing
→ Storage + C2PA / Watermark
→ User Feedback + Badcase Store
  
```

其中 Asset Manager 很重要：它管理用户上传的参考图、角色图、品牌 logo、mask、首尾帧、视频片段、音频素材和授权状态。

面试高频问题

1. 训练数据怎么过滤？

先做去重、质量过滤、安全过滤、版权和隐私过滤，再做 caption / OCR / VLM 标注。视频还要过滤剪辑跳变、水印、字幕覆盖、低帧率、运动模糊和错误音频。

2. 为什么需要 recaptioning？

原始 alt-text 通常太短、噪声大，不描述布局、动作、文字和关系。recaptioning 能把训练信号和用户 prompt 更好对齐，提高 prompt adherence。

3. 图像生成也能做 RLHF 吗？

可以。常见做法是收集 pairwise preference，训练 reward model，然后优化模型或采样策略。视频还可以设计针对 motion、temporal consistency、prompt adherence 的 reward。

4. 安全水印能解决 deepfake 吗？

不能单独解决。水印和 provenance 有帮助，但还需要真人肖像策略、上传审核、输出审核、行为风控、平台治理和人工复核。

5. 线上模型升级如何避免退化？

先跑离线 regression harness，再小流量灰度，对比质量、人评、安全失败率、延迟、成本和业务指标。发现安全或质量退化时能按模型版本和策略版本回滚。

本章 References

- [DALL-E 3 System Card](#)
- [Introducing 4o Image Generation](#)

- [Video generation models as world simulators](#)
- [Sora 2](#)
- [Veo official page](#)
- [SynthID](#)
- [C2PA](#)
- [Seedance 1.0](#)
- [Seedance 2.0](#)
- [Qwen-Image Technical Report](#)
- [Seedream 4.0](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)
