

第 1 章：Transformer、Tokenization 与自回归预训练

本章符号说明

符号/缩写	English	中文	含义
Transformer	Transformer Architecture	Transformer 架构	基于 self-attention 的序列建模架构。
BPE	Byte Pair Encoding	字节对编码	常见 subword tokenization 方法。
MHA	Multi-Head Attention	多头注意力	在多个子空间并行计算 attention 的模块。
X	Input Embedding Matrix	输入嵌入矩阵	一段 token embedding 组成的矩阵。
$Q / K / V$	Query / Key / Value	查询 / 键 / 值	attention 中由 X 线性投影得到的表示。
d_k	Key Dimension	key 向量维度	attention 缩放项中的维度。
$P(w_t / w_{< t})$	Next-token Probability	下一个 token 概率	自回归语言模型的训练目标。
CE	Cross Entropy	交叉熵	预测 token 分布与真实 token 的损失。

本章目标

- 理解 tokenization 为什么重要。
- 掌握 self-attention 的矩阵公式。
- 区分 encoder-only、decoder-only、encoder-decoder。
- 理解 next-token prediction 为什么能学到通用能力。
- 能解释 pretraining loss 和 inference decoding。

Tokenization

LLM 不能直接处理字符串，通常先把文本切成 token，再映射成 embedding。

常见 tokenization 方法：

- word-level：按词切分，词表大，未登录词问题明显。
- char-level：按字符切分，词表小，但序列很长。

- subword：折中方案，BPE、WordPiece、SentencePiece 都属于这一类。

面试表达：

Tokenization 决定了模型看到的最小语义单位，也影响上下文长度、压缩率、多语言表现和代码能力。中文、代码、数学表达式通常对 tokenizer 更敏感。

Self-Attention

输入 embedding 矩阵为：

$$X \in \mathbb{R}^{n \times d}$$

通过线性投影得到：

$$Q = XW_Q, K = XW_K, V = XW_V$$

scaled dot-product attention：

$$Attention(Q, K, V) = softmax(QK^T / \sqrt{(d_k)})V$$

直觉：

- Q 表示当前位置想找什么信息。
- K 表示每个位置能被什么信息匹配。
- V 表示真正被聚合的内容。
- 除以 $\sqrt{(d_k)}$ 是为了避免点积随维度变大而过大，使 softmax 过于尖锐。

Multi-Head Attention

multi-head attention 让模型在多个子空间里计算 attention：

$$head_i = Attention(XW_i^Q, XW_i^K, XW_i^V)$$

然后拼接：

$$MHA(X) = Concat(head_1, \dots, head_h)W^O$$

面试直觉：

不同 head 可以关注不同关系，例如局部语法、长程依赖、实体指代、代码括号匹配。它不是保证每个 head 都有清晰可解释含义，但增加了并行建模不同关系的能力。

Decoder-only LLM

主流生成式 LLM 多用 decoder-only Transformer。训练目标是自回归 next-token prediction：

$$\max_{\theta} \sum_{t=1}^T \log P_{\theta}(w_t / w_{<t})$$

对应最小化 cross entropy：

$$L(\theta) = - \sum_{t=1}^T \log P_{\theta}(w_t / w_{<t})$$

为了防止模型看到未来 token，会使用 causal mask：

$$mask_{ij}=0 \text{ if } j \leq i$$

为什么 next-token prediction 有用

next-token prediction 看起来只是预测下一个词，但要做好它，模型需要隐式学习：

- 语法和语义。
- 世界知识。
- 长程依赖。
- 代码和数学模式。
- 指令和对话格式。

但它也有天然限制：

- 目标是拟合语料分布，不等于遵循用户意图。
- 训练目标不直接惩罚幻觉。
- 模型可能学到偏见、噪声和过期知识。

这就是为什么后续还需要 SFT、RLHF、DPO 和 RAG。

Inference Decoding

推理时，模型会根据当前上下文预测下一个 token，然后把生成 token 拼回上下文继续生成。

常见 decoding 策略：

方法	English	中文	直觉
Greedy	Greedy Decoding	贪心解码	每步选概率最高 token，稳定但容易死板。
Beam Search	Beam Search	束搜索	保留多个候选，适合翻译，不一定适合开放生成。
Temperature	Temperature Sampling	温度采样	调整分布尖锐程度。
Top-k	Top-k Sampling	Top-k 采样	只从最高的 k 个 token 采样。

方法	English	中文	直觉
Top-p	Nucleus Sampling	核采样	从累计概率达到 p 的 token 集合中采样。

本章面试高频问题

1. Transformer 相比 RNN 的核心优势是什么？

Transformer 用 attention 直接建模任意 token 间关系，并且训练时可以并行处理序列位置；RNN 顺序递推，长程依赖和并行效率都更弱。

2. 为什么 attention 要除以 $\sqrt{d_k}$ ？

点积的方差会随维度变大而增大，如果不缩放，softmax 会过于尖锐，梯度变小，训练不稳定。除以 $\sqrt{d_k}$ 可以让 attention logits 的尺度更稳定。

3. decoder-only 为什么适合生成？

decoder-only 使用 causal mask，只能看当前位置之前的 token，天然匹配从左到右生成。GPT 系列、LLaMA 系列、Qwen 系列都属于这一路线。

4. next-token prediction 为什么能产生 few-shot 能力？

大规模语料里存在大量任务描述、示例、问答、代码和推理模式。模型在预训练中学习这些分布后，可以在 prompt 中根据少量示例适配新任务。

本章 References

- [Attention Is All You Need](#)
- [Language Models are Few-Shot Learners](#)
- [FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)