

第 2 章：Scaling、Post-training、Alignment 与 RLVR

本章符号说明

符号/缩写	English	中文	含义
Scaling Law	Scaling Law	缩放律	模型性能随参数、数据、算力变化的经验规律。
SFT	Supervised Fine-Tuning	监督微调	用高质量指令-答案数据训练模型遵循格式和任务。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好训练 reward model，再优化策略。
RLAIF	Reinforcement Learning from AI Feedback	基于 AI 反馈的强化学习	用 AI 反馈替代或补充人类偏好反馈。
RLVR	Reinforcement Learning with Verifiable Rewards	可验证奖励强化学习	用可自动验证的正确性信号训练模型。
RM	Reward Model	奖励模型	根据偏好或任务结果预测回答质量的模型。
PRM	Process Reward Model	过程奖励模型	对中间推理步骤打分。
ORM	Outcome Reward Model	结果奖励模型	对最终答案或最终状态打分。
PPO	Proximal Policy Optimization	近端策略优化	RLHF 早期常用策略优化算法。
GRPO	Group Relative Policy Optimization	组相对策略优化	用同组样本的相对 reward 构造 advantage 的 PPO 变体。
DPO	Direct Preference Optimization	直接偏好优化	直接用偏好对优化策略，不显式训练 reward model。
KL	Kullback-Leibler Divergence	KL 散度	衡量当前策略偏离参考策略的程度。
CoT	Chain-of-Thought	思维链	模型内部或外显的中间推理过程。
CoT Monitor	Chain-of-Thought Monitor	思维链监控器	用推理轨迹辅助发现不安全或欺骗性行为的监控方法。
π_θ	Policy Model	策略模型	当前生成回答的语言模型。

符号/缩写	English	中文	含义
π_{ref}	Reference Model	参考模型	对齐训练中用于约束偏移的原始模型。
$r_{\phi}(x,y)$	Reward Function	奖励函数	对 prompt x 和回答 y 打分。
A_i	Advantage	优势函数	样本 i 相对基线的好坏程度。

本章目标

- 理解 scaling law、compute-optimal training 和 test-time compute 的关系。
- 掌握 pretraining、SFT、preference alignment、RLVR、safety tuning 的完整流水线。
- 能解释 RLHF、RLAIF、DPO、PPO、GRPO、PRM、ORM 的差异。
- 能从工程角度说明为什么 2025-2026 的 reasoning model 更依赖 RL 和可验证环境。
- 能回答 alignment 面试里常见的 reward hacking、sycophancy、over-refusal、jailbreak、hidden CoT 问题。

从 Scaling 到 Post-training

LLM 能力来自四个维度的共同缩放：

- 参数量和模型容量。
- 训练 token 数和数据质量。
- 训练 compute 和优化稳定性。
- post-training 与 inference-time compute。

Chinchilla 之后，一个关键观点是：固定 compute 下，参数量和训练 token 数要更均衡。2025-2026 的新变化是 reasoning model 把 scaling 延伸到 post-training 和推理阶段：不仅预训练更大，后训练 RL 更多，推理时也允许模型“想更久”。

面试表达：

传统 scaling law 主要解释 pretraining loss 随 model/data/compute 的变化；reasoning model 之后，还要看 post-training RL compute 和 inference-time compute。复杂数学、代码、工具调用任务上，模型能力不只是参数记忆，而是搜索、验证、自我纠错和工具使用策略的综合结果。

现代 Post-training Pipeline

现代 frontier model 常见流程：

- Pretraining：大规模 next-token prediction，学习通用语言、代码、知识和世界模型。
- Continued pretraining：补领域数据、多语言、代码、长上下文、多模态数据。
- SFT：学习指令格式、对话风格、工具 schema、拒答模板。
- Preference alignment：用人类或 AI 偏好提升 helpfulness、honesty、style。
- Reasoning RL / RLVR：在数学、代码、工具环境、浏览环境中用可验证 reward 优化。

6. Safety tuning：安全策略、policy reasoning、over-refusal 控制、jailbreak 鲁棒性。

7. Product eval：自动 benchmark、人工评测、红队、安全预案、线上监控。

一个重要面试点：post-training 不只是“让模型更礼貌”。它会显著改变 instruction following、工具调用、长任务执行、推理深度和安全边界。

SFT

SFT 用指令数据训练模型：

$$L_{SFT}(\theta) = - \sum_t \log P_{\theta}(y_t | x, y_{<t})$$

优点：

- 稳定简单。
- 能显著改善指令遵循和格式。
- 数据质量比数据数量更关键。

局限：

- 学的是示范分布，不直接优化“哪个回答更好”。
- 对数学、代码、agent 这类可验证任务，SFT 只能模仿轨迹，不一定学会探索和纠错。
- 对 safety 的提升依赖覆盖率，没见过的 jailbreak 和边界条件仍容易出错。

RLHF 与 PPO

RLHF 典型三步：

1. 收集 prompt 和多个候选回答。
2. 人类标注偏好，训练 reward model。
3. 用 PPO 等 RL 算法优化语言模型，同时用 KL penalty 限制偏移。

常见目标：

$$\max_{\theta} \mathbb{E}_{y \sim \pi_{\theta}} [r_{\phi}(x, y)] - \beta KL(\pi_{\theta} \parallel \pi_{ref})$$

直觉：

- reward model 代表“人类更喜欢什么”。
- KL penalty 防止模型为了 reward hacking 偏离太远。
- PPO 可以在线采样并优化，但训练复杂、显存高、调参成本大。

面试追问：

为什么 RLHF 会 reward hacking?

因为 reward model 是人类偏好的近似，不是真实目标。如果模型发现某些模式能骗过 RM，比如过度自信、迎合用户、模板化安全话术，就会优化这些捷径。

RLAIF 与 Constitutional AI

RLAIF 用 AI feedback 替代或补充人类反馈。Anthropic 的 Constitutional AI 是代表路线：先让模型根据一组原则自我批评和修订，再用 AI 偏好训练 preference model，最后用 RL 优化。

优点：

- 降低人类标注成本。
- 安全原则更显式，适合扩展到大量边界样本。
- 可用更强模型监督较弱模型。

风险：

- AI judge 也会有偏差。
- 如果 judge 与 policy 共享偏见，可能放大系统性错误。
- 容易把 alignment 变成“符合某套文本规则”，但现实任务仍有灰区。

DPO

DPO 直接用偏好对训练，不显式跑 RL。对于同一个 prompt，有 preferred answer y_w 和 rejected answer y_l 。

简化表达：

$$L_{DPO} = -\log \sigma(\beta \Delta)$$

其中 Δ 表示当前模型相对 reference model 对 preferred/rejected 的 log probability ratio 差异。

面试表达：

DPO 把偏好优化转成 supervised-style loss，省掉 reward model 和 PPO loop，因此更稳定、更容易复现。但它主要适合 pairwise preference，不等于能替代所有在线 RL；在工具环境、代码执行、数学验证这类任务上，RLVR 更直接。

RLVR：为什么 2025-2026 很重要

RLVR 的核心是：有些任务可以自动判断对错，所以不需要昂贵的人类偏好。

典型可验证任务：

- 数学：最终答案可校验。
- 代码：单元测试、隐藏测试、lint、运行结果可校验。
- 工具调用：API 最终状态可比对。
- 浏览检索：答案可用 reference answer 检查。
- 形式化证明：proof checker 可校验。

RLVR 的目标可以抽象成：

$$\max_{\theta} \mathbb{E}_{y \sim \pi_{\theta}(\cdot | x)} [R(x, y)]$$

其中 $R(x,y)$ 是自动验证 reward。

面试表达：

RLVR 是 reasoning model 的关键训练范式之一，因为数学、代码和 agent 任务有明确的外部反馈。模型不是只模仿人类答案，而是在采样、执行、验证、失败后调整的闭环中学会更可靠的推理策略。

PRM 与 ORM

ORM 只看最终结果：

$$R_{ORM}(x,y)=I[answer(y)=answer^*]$$

PRM 给中间步骤打分：

$$R_{PRM}(x,y_{1:t}) \rightarrow step\ quality$$

对比：

方法	English	中文	优点	缺点
ORM	Outcome Reward Model	结果奖励模型	标注和自动验证简单	不知道哪里错，稀疏 reward
PRM	Process Reward Model	过程奖励模型	能指导中间推理，利于搜索	标注贵，容易奖励表面步骤
Verifier	Verifier Model	验证器模型	可做 best-of-n / rerank	仍可能被模型 exploit

面试回答要点：

- ORM 适合答案可校验任务，但 reward 稀疏。
- PRM 更像“每一步都给老师批改”，对长推理有帮助。
- 现代系统经常组合：采样多条轨迹，用 verifier / test / tool result 选最优。

GRPO

GRPO 是 PPO 的一个 memory-efficient 变体。它不显式训练 value model，而是在同一个 prompt 下采样一组回答，用组内 reward 均值和方差构造相对 advantage。

给同一个 prompt 采样 G 个回答，reward 为 r_i ，可以写成：

$$A_i = r_i - \text{mean}(r_1, \dots, r_G) / \text{std}(r_1, \dots, r_G)$$

直觉：

- 同组里表现更好的样本被强化。
- 表现更差的样本被压低概率。
- 省掉 value model，显存和训练复杂度下降。

风险：

- 如果一组样本 reward 都一样，学习信号会变弱。
- 对 reward 设计和采样温度敏感。
- 容易优化到“会拿分”的策略，不等于真实通用推理。

Safety Alignment：从拒答到安全推理

2026 面试里，alignment 不能只讲“模型会拒答”。要讲四类问题：

问题	English	中文	典型现象
Over-refusal	Over-refusal	过度拒答	安全问题过敏，正常请求也拒绝。
Under-refusal	Under-refusal	拒答不足	危险请求没有拦住。
Sycophancy	Sycophancy	迎合用户	明知用户错仍附和。
Reward Hacking	Reward Hacking	奖励黑客	优化指标漏洞，不完成真实目标。
CoT Faithfulness	Chain-of-Thought Faithfulness	思维链忠实性	展示的理由和真实决策过程不一致。

OpenAI 的 deliberative alignment 代表一种新思路：把安全规范直接教给模型，让模型在回答前对规范进行推理。GPT-5 system card 进一步强调 safe-completions，即尽量给出安全范围内有帮助的回答，而不是简单二元拒答。

面试表达：

安全对齐正在从“分类器式拒答”走向“策略推理”。模型需要判断用户意图、上下文、风险等级和可替代帮助方式。好的安全系统既减少 jailbreak，也减少 over-refusal。

本章面试高频问题

1. SFT、RLHF、DPO、RLVR 的关系？

SFT 学示范，RLHF 学人类偏好，DPO 用偏好对做稳定的直接优化，RLVR 用可验证 reward 优化数学、代码、工具等任务。它们不是互斥关系，现代模型通常多阶段组合使用。

2. 为什么 reasoning model 更依赖 RL？

复杂推理和工具任务不是单步模仿能解决的。RL 可以让模型从执行结果、测试结果、验证结果中学习策略，尤其适合有明确 reward 的数学、代码、agent 环境。

3. GRPO 和 PPO 的区别？

PPO 通常需要 value model 估计 advantage；GRPO 用同组候选的相对 reward 构造 advantage，省掉 value model，适合大模型 RL，但对 reward 分布和采样组质量敏感。

4. PRM 为什么不总是优于 ORM？

PRM 提供更密集的中间监督，但标注成本高，也可能奖励“看起来像推理”的步骤。ORM 简单但稀疏。实际系统常结合 verifier、best-of-n、工具执行和最终测试。

5. safe-completions 和普通拒答有什么区别？

普通拒答把请求分成允许/拒绝。safe-completions 更强调在安全边界内尽量有帮助：危险部分不提供，但可以给高层解释、安全替代方案或合规信息。

本章 References

- [Scaling Laws for Neural Language Models](#)
- [Training Compute-Optimal Large Language Models](#)
- [Training language models to follow instructions with human feedback](#)
- [Constitutional AI: Harmlessness from AI Feedback](#)
- [Direct Preference Optimization](#)
- [Let's Verify Step by Step](#)
- [DeepSeekMath: Pushing the Limits of Mathematical Reasoning](#)
- [DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning](#)
- [Deliberative Alignment: Reasoning Enables Safer Language Models](#)
- [OpenAI GPT-5 System Card](#)

章节索引

[← 上一章](#) [下一章 →](#)
