

第 4 章：VLM 基础、ViT、CLIP 与图文对齐

本章符号说明

符号/缩写	English	中文	含义
VLM	Vision-Language Model	视觉语言模型	同时建模视觉和语言的模型。
ViT	Vision Transformer	视觉 Transformer	把图像 patch 当作 token 输入 Transformer。
CLIP	Contrastive Language-Image Pre-training	对比式图文预训练	学习图像和文本共享 embedding 空间。
ITC	Image-Text Contrastive Loss	图文对比损失	拉近匹配图文，拉远不匹配图文。
VQA	Visual Question Answering	视觉问答	根据图像回答问题。
OCR	Optical Character Recognition	光学字符识别	识别图像中的文字。
I	Image	图像	输入图像。
T	Text	文本	输入文本或 caption。
z_I	Image Embedding	图像向量	图像编码器输出的全局表示。
z_T	Text Embedding	文本向量	文本编码器输出的全局表示。

本章目标

- 理解图像如何变成 token。
- 掌握 CLIP 的 contrastive learning 目标。
- 理解 zero-shot classification 和 image-text retrieval。
- 认识 VLM 常见任务和瓶颈。

ViT：图像变 token

ViT 把图像切成 patch：

$$I \rightarrow [p_1, p_2, ..., p_n]$$

每个 patch 线性投影成 embedding，再加 position embedding，输入 Transformer encoder。

直觉：

- CNN 有强局部归纳偏置。
- ViT 更依赖数据规模和预训练。
- 对 VLM 来说，patch token 很自然地可以和 text token 对齐或融合。

CLIP

CLIP 同时训练 image encoder 和 text encoder。给定 batch 内 N 对图文样本：

$$(I_1, T_1), \dots, (I_N, T_N)$$

模型得到：

$$z_I = f_{img}(I), z_T = f_{text}(T)$$

相似度：

$$s_{ij} = z_{I_i}^T z_{T_j} / \tau$$

训练目标是让匹配的 (I_i, T_j) 相似度高，不匹配的 (I_i, T_j) 相似度低。

面试表达：

CLIP 的关键是用大规模图文对做 contrastive learning，把图像和文本投到同一个语义空间。可以通过文本 prompt 表示类别，实现 zero-shot image classification。

Zero-shot Classification

CLIP 做分类时，可以把类别写成 prompt：

```
a photo of a dog
a photo of a cat
```

然后计算图像 embedding 和每个文本 embedding 的相似度，选最高的类别。

优点：

- 不需要为每个新类别训练分类头。
- 类别可以由自然语言描述。
- 能做开放词表分类。

缺点：

- prompt 模板敏感。
- 对细粒度、计数、空间关系仍可能弱。
- 训练数据偏差会影响 zero-shot 表现。

VLM 常见任务

任务	English	中文	说明
Image Captioning	Image Captioning	图像描述	输入图像，输出自然语言描述。
VQA	Visual Question Answering	视觉问答	输入图像和问题，输出答案。
OCR QA	OCR Question Answering	文字识别问答	需要读取图像中的文字。
Chart QA	Chart Question Answering	图表问答	需要解析图表结构和数值。
Document QA	Document Question Answering	文档问答	需要理解版面、表格和文本。
Referring	Referring Expression	指代表达理解	根据文字定位图像中的对象。
Grounding	Visual Grounding	视觉定位	输出框、点或区域。

VLM 为什么难

VLM 不只是“把图片丢给 LLM”。

难点包括：

- 视觉 token 数量大，计算成本高。
- 图像包含空间、局部细节和文字信息。
- 文本 token 是离散符号，视觉 token 是连续空间表示。
- OCR、chart、document 需要精确读数和版面理解。
- 多图、多页、长视频带来上下文和时间建模问题。

本章面试高频问题

1. CLIP 为什么能 zero-shot?

CLIP 学到了图像和文本的共享语义空间。分类时把类别变成文本 prompt，比较图像与类别文本的相似度，就能不用训练分类头完成 zero-shot classification。

2. CLIP 和传统监督分类有什么区别？

传统分类学习固定 label space；CLIP 学图文对齐，label 可以由自然语言动态表达，因此更开放。

3. VLM 在文档理解上为什么难？

文档理解需要 OCR、版面结构、表格关系、阅读顺序和跨区域推理。单纯全局图像 embedding 往往不够，需要高分辨率、动态切图或专门的 document training data。

本章 References

- [An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale](#)
- [Learning Transferable Visual Models From Natural Language Supervision](#)
- [MMBench: Is Your Multi-modal Model an All-around Player?](#)
- [MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)
