

第 5 章：MLLM 架构、训练流程与代表模型

本章符号说明

符号/缩写	English	中文	含义
MLLM	Multimodal Large Language Model	多模态大语言模型	在 LLM 上接入视觉等模态的模型。
BLIP-2	Bootstrapping Language-Image Pre-training 2	BLIP-2 模型	用 Q-Former 桥接 frozen image encoder 和 frozen LLM。
Flamingo	Flamingo VLM	Flamingo 视觉语言模型	用 gated cross-attention 接入视觉信息。
LLaVA	Large Language and Vision Assistant	大语言视觉助手	CLIP vision encoder + projection + LLM 的开源 VLM 路线。
Q-Former	Querying Transformer	查询 Transformer	BLIP-2 中从视觉特征抽取 query 表示的模块。
Projector	Projection Layer	投影层	把视觉特征映射到 LLM hidden size。
E_v	Vision Encoder	视觉编码器	把图像编码成视觉特征。
E_t	Text Encoder	文本编码器	把文本编码成语言表示。
H_v	Visual Hidden States	视觉隐状态	视觉 encoder 输出的 token 表示。

本章目标

- 掌握 VLM 接入 LLM 的主流方式。
- 理解 BLIP-2、Flamingo、LLaVA 的架构差异。
- 理解多模态预训练和 instruction tuning。
- 能解释现代 VLM 的动态分辨率和视频理解趋势。

VLM 接入 LLM 的三种思路

1. Late Fusion

先分别编码图像和文本，再在较高层融合。

优点是模块清晰，缺点是细粒度交互可能不足。

2. Cross-Attention

语言 token 在若干层 cross-attend 到视觉 token。Flamingo 是代表路线。

优点是视觉信息可在生成过程中被持续访问；缺点是架构改动较多。

3. Projector / Adapter

视觉 encoder 输出经过 projector 映射成 LLM 可读 token，再拼到文本 token 前后。LLaVA 是代表路线。

优点是简单、工程友好；缺点是视觉-语言对齐很依赖训练数据和 projector 能力。

BLIP-2

BLIP-2 的核心思想：冻结强大的 image encoder 和 LLM，只训练轻量 Q-Former 来桥接模态。

流程：

$$I \rightarrow E_v(I) \rightarrow QFormer(H_v) \rightarrow LLM$$

优点：

- 训练成本低。
- 利用已有视觉和语言模型能力。
- Q-Former 起到信息瓶颈和模态桥接作用。

Flamingo

Flamingo 支持 interleaved image-text 输入，即文本和多张图像交错出现。核心包括：

- frozen vision encoder。
- frozen language model。
- perceiver resampler。
- gated cross-attention。

面试表达：

Flamingo 的重点是让 LLM 在生成时通过 cross-attention 访问视觉特征，并能处理多图交错上下文，因此在此 few-shot 多模态任务上很有代表性。

LLaVA

LLaVA 的典型结构：

$$Image \rightarrow CLIP\ Encoder \rightarrow Projector \rightarrow LLM$$

训练通常分两阶段：

1. Pre-alignment：冻结大部分模块，只训练 projector，让视觉 token 对齐语言空间。
2. Visual instruction tuning：用图文指令数据训练模型对话能力。

优点：

- 架构简单。
- 复现成本相对低。
- 很适合面试中说明 open-source MLLM pipeline。

Qwen2.5-VL 代表的新趋势

现代 VLM 不只做单图问答，还强调：

- dynamic resolution。
- document parsing。
- grounding with box/point。
- long-video understanding。
- agentic computer/mobile 操作。
- OCR、chart、table 的结构化抽取。

面试表达：

早期 VLM 更像图像 caption/VQA 模型，现代 MLLM 更像通用视觉 agent：能读文档、看视频、定位对象、调用工具并完成任务。

训练数据

常见数据阶段：

阶段	English	中文	作用
Image-Text Pretraining	Image-Text Pretraining	图文预训练	学习基础图文对齐。
Caption Data	Caption Data	图像描述数据	学会描述视觉内容。
VQA Data	Visual QA Data	视觉问答数据	学会根据问题聚焦视觉信息。
OCR/Doc Data	OCR/Document Data	OCR/文档数据	学会读文字、表格、版面。
Instruction Data	Instruction Data	指令数据	学会对话格式和复杂任务。
Preference Data	Preference Data	偏好数据	改善回答质量、安全和风格。

本章面试高频问题

1. BLIP-2 为什么要冻结 image encoder 和 LLM?

冻结可以显著降低训练成本，同时复用强视觉模型和强语言模型的能力。Q-Former 作为桥接模块学习如何把视觉信息转成 LLM 能理解的表示。

2. Flamingo 和 LLaVA 的主要区别？

Flamingo 通过 gated cross-attention 在语言模型层内接入视觉信息，支持 interleaved image-text few-shot。LLaVA 更简单，用 CLIP encoder 加 projector 把视觉 token 映射到 LLM 输入空间。

3. VLM 为什么需要 instruction tuning？

图文预训练让模型学会对齐视觉和文本，但不一定会遵循用户问题、输出格式或多轮对话。instruction tuning 让模型学会以助手形式完成多模态任务。

4. 高分辨率图像为什么难？

图像分辨率越高，patch token 越多，attention 成本越高。需要动态分辨率、裁剪、多尺度、窗口 attention 或视觉 token 压缩。

本章 References

- [Flamingo: a Visual Language Model for Few-Shot Learning](#)
- [BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models](#)
- [Visual Instruction Tuning](#)
- [Qwen2.5-VL Technical Report](#)
- [GPT-4 Technical Report](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)
