

第 6 章：VLM 数据构造、预处理与训练实操

这一章把 VLM（Vision-Language Model，视觉语言模型）从“模型结构”推进到“怎么训”。面试里如果只说 CLIP、LLaVA、Qwen2.5-VL，很容易停在概念层；真正能拉开差距的是说明多模态数据如何构造、清洗、打标、打包，以及每个训练阶段解决什么问题。

本章符号说明

符号/缩写	English	中文	含义
VLM	Vision-Language Model	视觉语言模型	同时处理视觉和语言输入的模型。
MLLM	Multimodal Large Language Model	多模态大语言模型	把图像、视频、音频等模态接入 LLM 的模型族。
LLM	Large Language Model	大语言模型	多模态模型中负责语言理解、推理和生成的核心。
OCR	Optical Character Recognition	光学字符识别	从图像、截图、扫描件中识别文字。
VQA	Visual Question Answering	视觉问答	根据图像或视频回答问题。
SFT	Supervised Fine-Tuning	监督微调	用指令-答案数据训练模型遵循任务。
DPO	Direct Preference Optimization	直接偏好优化	用偏好对直接优化模型输出偏好。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好训练 reward，再优化模型。
RLVR	Reinforcement Learning with Verifiable Rewards	可验证奖励强化学习	用自动可验证的任务结果作为奖励信号。
ETL	Extract, Transform, Load	抽取、转换、加载	数据工程里的标准处理流程。
JSONL	JSON Lines	JSON 行格式	每行一个 JSON 样本，常用于训练数据。
DPI	Dots Per Inch	每英寸点数	文档扫描件和截图清晰度指标。
ROI	Region of Interest	感兴趣区域	图像中需要重点理解或裁剪的区域。
ViT	Vision Transformer	视觉 Transformer	把图像切成 patch token 的视觉编码器。

符号/缩写	English	中文	含义
CLIP	Contrastive Language-Image Pre-training	对比式图文预训练	学习图文共享语义空间的经典模型。
I	Image	图像	输入的单张图像。
V	Video	视频	输入的视频片段或帧序列。
T_v	Visual Tokens	视觉 token	图像或视频经 encoder/tokenizer 后得到的 token。
T_x	Text Tokens	文本 token	prompt、问题、答案或系统指令的 token。
N_v	Number of Visual Tokens	视觉 token 数量	决定上下文占用和 attention 成本。
D	Dataset	数据集	多模态训练样本集合。
q	Question	问题	VQA、文档问答或视觉推理中的用户问题。
a	Answer	答案	模型需要生成的目标回答。

本章目标

- 能讲清 VLM 数据从原始资产到训练样本的完整 pipeline。
- 能区分 image-text pretraining、instruction tuning、preference tuning、RLVR 数据。
- 能解释 dynamic resolution、tiling、OCR、document parsing 为什么重要。
- 能设计一个 VLM 项目的数据 schema、质量过滤和训练阶段。

VLM 数据为什么要单独拆

LLM 的数据主要是 token 序列，VLM 的数据同时包含视觉内容、文本描述、布局、时间、坐标和任务格式。问题不只是“有没有图”，而是：

- 图像是否清晰、完整、无水印、无隐私风险。
- caption 是否描述了细粒度属性、关系、文字和动作。
- OCR 文本是否和图像坐标、版面结构对齐。
- 高分辨率图像如何压进有限 visual token budget。
- 文档、图表、UI、视频是否有适合任务的标注。
- 训练样本是否覆盖模型上线后的真实问题分布。

面试表达：

VLM 的训练效果很大一部分来自数据工程。视觉输入不是普通文本 token，必须先处理分辨率、裁剪、版面、OCR、caption、坐标和任务 schema，否则模型很容易在 OCR、图表、空间关系和细粒度

grounding 上掉链子。

数据类型地图

数据类型	English	中文	典型用途	常见风险
Image-Text Pair	Image-Text Pair	图文对	图文对齐、caption、检索	caption 粗糙、噪声大、版权不清
Interleaved Data	Interleaved Image-Text Data	图文交错数据	多图理解、上下文学习	顺序错乱、图文引用不清
VQA Data	Visual Question Answering Data	视觉问答数据	视觉问答、细粒度理解	答案过短、问题模板化
OCR Data	Optical Character Recognition Data	文字识别数据	文档、票据、截图、UI	低 DPI、文字遮挡、标注错
Document Data	Document Understanding Data	文档理解数据	PDF、表格、版面解析	结构丢失、页码和区域不对齐
Chart Data	Chart and Table Data	图表数据	图表问答、数值读取	数字精度、坐标轴语义错误
Grounding Data	Grounding Data	定位数据	box、point、region QA	坐标归一化错误
Video Data	Video Understanding Data	视频理解数据	动作、事件、时间推理	采样稀疏、caption 不含时间变化
UI Data	User Interface Data	界面数据	computer-use、GUI agent	点击坐标、状态变化难标注
Preference Data	Preference Data	偏好数据	回答质量、安全、格式	judge 偏差、偏好维度混淆

从原始数据到训练样本

一个 VLM 数据 pipeline 可以这样讲：

原始图片 / 视频 / PDF / 截图
-> 去重、质量过滤、安全过滤、版权和隐私过滤
-> OCR / layout parsing / object detection / captioning / recaptioning
-> 任务构造: caption、VQA、doc QA、chart QA、grounding、UI action
-> schema 统一: messages、images、boxes、metadata、source、license
-> train / dev / test 切分与去污染
-> packing、resolution bucket、visual token budget 控制
-> SFT / preference / RLVR / eval harness

这里每一步都可能决定模型上线质量。比如 OCR 数据如果没有保留坐标，模型可能能“读字”，但不能回答“右上角表格第二列是多少”；视频 caption 如果只写“一个人在走路”，模型很难学到镜头、动作变化和事件顺序。

图像预处理：分辨率、裁剪和 visual token

图像进入 VLM 前通常会被切成 patch 或由 vision encoder 编码。对于 ViT 类模型，粗略可以理解成：

$$N_v \approx H/p \times W/p$$

其中 H (Height, 高度) 和 W (Width, 宽度) 是图像尺寸, p (Patch Size, patch 尺寸) 是每个视觉 patch 的边长, N_v (Number of Visual Tokens, 视觉 token 数量) 决定计算成本。

常见策略：

策略	English	中文	适合场景	代价
Resize	Resize	缩放	普通自然图像	小字、细节丢失
Center Crop	Center Crop	中心裁剪	主体居中图片	边缘信息丢失
Dynamic Resolution	Dynamic Resolution	动态分辨率	多宽高比、多任务	训练和 batch 更复杂
Tiling	Image Tiling	图像切块	文档、长图、截图	token 数多，跨 tile 关系难
ROI Crop	Region of Interest Crop	重点区域裁剪	OCR、商品、图表	依赖检测或规则
Multi-scale	Multi-scale Encoding	多尺度编码	细节和全局都重要	推理成本高

面试表达：

高分辨率 VLM 不是简单把图片放大。真正的问题是如何在有限 visual token budget 里同时保留全局布局 and 局部细节，所以 dynamic resolution、tiling、ROI crop 和多尺度策略会直接影响 OCR、文档和图表能力。

Caption 与 Recaption

早期图文对 caption 很粗，例如“a dog on grass”。现代 VLM 训练更需要 rich caption：

- 主体、属性、数量、颜色、材质。
- 空间关系和相对位置。
- OCR 文本和可见标志。
- 图表坐标轴、单位、趋势。
- 文档版面、标题、表格、脚注。
- 视频里的动作、镜头、时间顺序。
- 不确定性和遮挡说明。

常用做法是用强 VLM 或人工标注生成 recaption，再用规则和 judge 过滤低质量描述。

高质量 caption 不是越长越好，而是要和任务相关。如果目标是文档 QA，就要保留版面、表格结构和 OCR；如果目标是商品理解，就要保留品牌、类目、材质、缺陷和使用场景。

训练样本 Schema

一个工程上常用的 VLM SFT 样本可以长这样：

```
{
  "id": "docqa_000001",
  "images": ["page_001.png"],
  "messages": [
    {"role": "system", "content": "You are a visual document assistant."},
    {"role": "user", "content": "根据图片中的表格，2025 Q4 的收入是多少？"},
    {"role": "assistant", "content": "2025 Q4 的收入是 1280 万元。"}
  ],
  "metadata": {
    "task": "document_qa",
    "source": "internal_synthetic",
    "ocr_available": true,
    "answer_type": "numeric"
  }
}
```

带 grounding 的样本还要记录坐标：

```
{
  "id": "grounding_000017",
  "images": ["shelf.png"],
  "messages": [
    {"role": "user", "content": "请指出红色瓶装饮料的位置。"},
    {"role": "assistant", "content": "<box>0.62,0.31,0.78,0.67</box>"}
  ],
  "metadata": {
    "task": "grounding",
    "coordinate": "normalized_xyxy"
  }
}
```

注意两点：

- schema 要稳定，否则训练和评测难复现。
- 坐标格式必须明确，例如 normalized xyxy、pixel xyxy、center-width-height，混用会造成灾难性错误。

训练阶段怎么拆

阶段	English	中文	主要数据	目标
Vision Encoder Pretraining	Vision Encoder Pretraining	视觉编码器预训练	图像、图文对	获得视觉表征
Projector Alignment	Projector Alignment	投影层对齐	image-caption	让视觉 token 进入 LLM 语义空间
Multimodal Pretraining	Multimodal Pretraining	多模态预训练	大规模图文/图文交错	学习跨模态对齐和基础生成
Instruction Tuning	Instruction Tuning	指令微调	VQA、doc QA、OCR、grounding	学会按用户问题回答
Preference Tuning	Preference Tuning	偏好调优	pairwise response	改善有用性、格式、安全和拒答
RLVR	Reinforcement Learning with Verifiable Rewards	可验证奖励强化学习	OCR、数学图表、UI 状态、代码截图	用自动判定提升可验证任务
Distillation	Knowledge Distillation	知识蒸馏	teacher 输出、轨迹	降低成本、提升小模型能力

面试里可以说：

VLM 训练通常不是一步到位。先解决视觉-语言对齐，再解决指令遵循，再针对 OCR、文档、图表、grounding、视频和 agent 任务做专门数据，最后用偏好或可验证奖励修正输出质量。

VLM 数据质量检查清单

检查项	说明
去重	同图、近似图、视频帧重复会让训练和评测虚高。
去污染	benchmark、dev/test、线上回归集不能泄漏到训练集。
图像质量	过滤过低分辨率、严重模糊、遮挡、水印、损坏文件。
OCR 质量	检查文字框、读取顺序、表格结构和单位。
Caption 质量	检查是否覆盖主体、属性、关系、文字、动作。
安全和隐私	过滤人脸、身份证、手机号、医疗、未成年人等敏感内容。
版权和来源	记录 source、license、爬取时间、授权范围。
分布覆盖	覆盖目标业务场景，不要只优化公开 benchmark。
Schema 一致	坐标、messages、图片路径、metadata 字段必须稳定。

实操项目：企业文档 VLM

如果你要在面试里讲一个 VLM 项目，可以用企业文档 QA：

1. 数据：PDF、扫描件、表格、票据、PPT 截图。
2. 预处理：PDF render、OCR、layout parsing、table extraction、page image。
3. 训练：doc caption、page QA、table QA、区域定位、拒答样本。
4. 评测：DocVQA、TextVQA、ChartQA、自建业务集。
5. 指标：exact match、numeric tolerance、citation accuracy、OCR error attribution。
6. 风险：权限、PII、表格错读、跨页引用、幻觉引用。

一句话版本：

我不会把企业文档 VLM 做成单纯图片问答，而是会同时建 OCR/layout 结构、page image、检索和可验证问答数据，让模型既能看版面，也能输出可追溯答案。

本章面试高频问题

1. VLM 数据和 LLM 数据最大的区别？

VLM 数据需要处理视觉质量、分辨率、版面、OCR、坐标、时间和多模态 schema。LLM 数据主要是文本序列，VLM 数据还要保证图文对齐、区域对齐和任务对齐。

2. 为什么 VLM 容易在 OCR 和图表上出错？

OCR 和图表要求细粒度视觉识别、布局理解、数值读取和推理。普通 caption/VQA 数据不一定训练这些能力，高分辨率处理和结构化标注不足时，模型容易看错字、读错轴、算错数。

3. Dynamic resolution 有什么价值？

它允许模型根据图片宽高比和任务复杂度使用不同视觉 token 数，在成本可控的情况下保留更多细节，尤其对文档、长图、截图、图表很重要。

4. VLM 为什么需要 preference 或 RLVR？

SFT 能让模型会回答，但不一定可靠。preference 可以优化回答风格、拒答和安全；RLVR 可以在 OCR、表格数值、UI 状态、数学图形等可验证任务上提供更强学习信号。

本章 References

- [BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models](#)
- [Visual Instruction Tuning](#)
- [Qwen2.5-VL Technical Report](#)
- [InternVL 2.5: Expanding Performance Boundaries of Open-Source Multimodal Models](#)
- [DocVQA: A Dataset for VQA on Document Images](#)
- [ChartQA: A Benchmark for Question Answering about Charts](#)

