

第 7 章：VLM 评测 Harness、Benchmark 与项目实操

VLM（Vision-Language Model，视觉语言模型）的评测不能只看一个总分。一个模型可能 MMMU 很高，但 OCR 错；可能文档 QA 好，但空间关系差；可能单图强，但视频理解弱。面试里要把评测讲成 harness：固定数据、输入、模型版本、prompt、采样参数、工具、指标、judge 和 badcase 归因。

本章符号说明

符号/缩写	English	中文	含义
VLM	Vision-Language Model	视觉语言模型	同时处理视觉和语言输入的模型。
MLLM	Multimodal Large Language Model	多模态大语言模型	统一处理文本、图像、视频等模态的大模型。
Eval	Evaluation	评测	对模型能力、风险、成本和稳定性的测量。
Harness	Evaluation Harness	评测框架	统一管理数据、prompt、运行、打分、报告和回归的系统。
Benchmark	Benchmark	基准测试	固定任务集合和指标，用于横向比较。
Judge	Judge Model	裁判模型	对开放式回答打分或比较的模型。
Oracle	Oracle	标准判定器	可可靠判断答案或状态是否正确的程序或标注。
Trace	Trace	轨迹日志	记录输入、输出、中间步骤、工具调用和分数。
OCR	Optical Character Recognition	光学字符识别	识别图片、文档、截图中的文字。
VQA	Visual Question Answering	视觉问答	根据视觉内容回答问题。
DocVQA	Document Visual Question Answering	文档视觉问答	针对文档图片的问题回答任务。
ChartQA	Chart Question Answering	图表问答	针对图表内容的问题回答任务。
TextVQA	Text Visual Question Answering	文字视觉问答	需要读取图中文字的 VQA 任务。

符号/缩写	English	中文	含义
MMMU	Massive Multi-discipline Multimodal Understanding	大规模多学科多模态理解基准	专家级多学科 VLM 评测。
MME	Multimodal Evaluation Benchmark	多模态评测基准	评估感知和认知能力的 VLM benchmark。
VHELM	Vision Holistic Evaluation of Language Models	视觉语言模型整体评测	HELM 思路扩展到 VLM 的综合评测。
UI	User Interface	用户界面	GUI/computer-use agent 需要理解和操作的界面。
GUI	Graphical User Interface	图形用户界面	包含按钮、文本、布局、状态的可视化界面。
IoU	Intersection over Union	交并比	目标定位框重叠程度指标。
EM	Exact Match	精确匹配	预测答案和标准答案完全一致。
M	Model	模型	被评测的 VLM 或系统。
T	Task Set	任务集合	评测样本集合。
s_i	Score	样本分数	第 i 个样本的得分。

本章目标

- 能设计 VLM eval harness，而不是只引用 benchmark 分数。
- 能按 OCR、文档、图表、空间、视频、GUI、推理拆分能力。
- 能说明 VLM judge 的优缺点和校准方式。
- 能把 VLM 项目讲成数据、模型、评测、上线闭环。

VLM 评测为什么容易误导

VLM 评测有几个常见陷阱：

- 单图 benchmark 高，不代表文档、图表、视频、UI 强。
- 多选题高，不代表开放式回答可靠。
- OCR benchmark 高，不代表能做跨区域、跨页、表格推理。
- VLM judge 打分高，不代表事实正确。
- 图片经过压缩、裁剪或 resize 后，模型能力会明显变化。
- prompt、resolution、max tokens、工具权限不同，benchmark 不可比。

面试表达：

VLM 的核心不是报一个总分，而是按任务维度拆能力，再用固定 harness 控制输入分辨率、prompt、模型版本、工具和打分方式。否则很容易把模型能力、数据处理能力和评测脚手架混在一起。

能力矩阵

能力	English	中文	典型数据	指标
Perception	Visual Perception	视觉感知	MME、POPE	accuracy、F1
OCR	Optical Character Recognition	文字识别	TextVQA、OCRBench	EM、edit distance
Document QA	Document Question Answering	文档问答	DocVQA、自建 PDF 集	EM、numeric tolerance、citation
Chart QA	Chart Question Answering	图表问答	ChartQA、PlotQA	accuracy、numeric tolerance
Spatial Reasoning	Spatial Reasoning	空间推理	图形、几何、关系题	accuracy、reasoning judge
Grounding	Visual Grounding	视觉定位	RefCOCO、box/point 数据	IoU、point accuracy
Video Understanding	Video Understanding	视频理解	Video-MME、MVBench	accuracy、temporal consistency
GUI Understanding	User Interface Understanding	界面理解	OSWorld、UI 任务集	task success、click accuracy
Safety	Safety Evaluation	安全评测	红队集、隐私集	violation rate、refusal quality

一个 VLM Eval Harness 长什么样

Dataset Registry

- > Input Renderer: 图片、PDF 页面、视频帧、UI 截图
- > Prompt Builder: 固定系统指令、问题模板、输出格式
- > Model Adapter: OpenAI / Gemini / Qwen / GLM / local model
- > Runner: 并发、重试、缓存、seed、版本记录
- > Scorer: EM、F1、IoU、numeric tolerance、judge、human review
- > Error Analyzer: OCR、视觉感知、推理、格式、拒答、幻觉归因
- > Report: 总分、分场景、badcase、成本、延迟、回归趋势

最重要的是 trace。每个样本至少记录：

- 原始图片或视频 hash。

- 输入分辨率、裁剪、tile 配置。
- prompt 和输出格式。
- 模型名称、版本、temperature、max tokens。
- OCR、检索、工具调用等中间结果。
- 标准答案、自动分数、人评分数。
- badcase 标签。

没有 trace，就很难解释“为什么这次模型变差了”。

VLM Judge 的使用边界

VLM judge 可以提高开放式评测效率，但不能无脑相信。

适合：

- 图像描述质量。
- 多答案开放题。
- 参考一致性。
- 安全和拒答质量。
- 复杂项目的 pairwise 比较。

不适合单独承担：

- 数字精确读取。
- OCR 字符级正确性。
- 坐标定位。
- 业务规则判定。
- 权限和隐私合规。

建议做法：

任务	首选打分	辅助打分
OCR	edit distance、EM	judge 解释错误类型
表格数值	numeric tolerance	judge 归因
Grounding	IoU、point accuracy	人工抽检
开放描述	pairwise judge	人评校准
安全	rule + classifier	judge + 人评
GUI agent	final state oracle	trace review

Badcase 归因

VLM 项目里，badcase 不能只写“回答错了”。建议至少分成：

Badcase 类型	中文	说明
Perception Error	感知错误	没看清主体、颜色、数量、位置。
OCR Error	文字识别错误	看错字、漏字、读序错误。
Layout Error	版面错误	表格、列、标题、跨页关系错。
Reasoning Error	推理错误	视觉读对了，但推理或计算错。
Grounding Error	定位错误	box、point、区域对应错。
Format Error	格式错误	没按 JSON、表格或字段要求输出。
Refusal Error	拒答错误	该答不答或不该答却答。
Hallucination	幻觉	生成图中没有的内容或引用不存在证据。
Tool Error	工具错误	OCR、检索、浏览器、GUI 工具返回错误或使用不当。

这个标签体系能直接反推下一步改数据、改模型、改预处理还是改 harness。

项目实操一：文档理解助手

面试讲法：

- 任务：企业 PDF、扫描件、报表、合同问答。
- 数据：真实脱敏文档、合成文档、公开 DocVQA/ChartQA、业务高频问题。
- 预处理：PDF render、OCR、layout parsing、table extraction、page-level image。
- 模型：VLM + RAG，长文档先检索页，再让 VLM 看对应页面。
- 评测：answer EM、numeric tolerance、citation precision、page recall、拒答准确率。
- 风险：权限、PII、跨页引用、表格错读、过期文档。

亮点表达：

文档 VLM 不应该让模型盲看整份 PDF。更稳的做法是把检索、OCR/layout 和 VLM 结合起来：先定位页和区域，再让 VLM 基于证据回答，并把 citation 和 page id 作为评测对象。

项目实操二：视觉质检和商品理解

适合电商、广告、内容审核场景：

模块	说明
数据	商品主图、详情图、用户上传图、质检标签。
任务	类目识别、属性抽取、缺陷检测、敏感元素检测。
模型	VLM 做开放理解，检测器做硬约束。

模块	说明
评测	属性 F1、缺陷 recall、误杀率、人工复核一致性。
上线	高风险样本进入人工审核，低风险样本自动通过。

面试要强调：VLM 适合开放语义，硬安全和精确定位最好结合专用 detector、OCR、规则和人工复核。

项目实操三：GUI / Computer-use Agent

VLM 在 GUI agent 里的作用是读界面、定位控件、理解状态变化。

一个可复现评测要记录：

- 初始网页或 app 状态。
- 用户目标。
- 每一步 screenshot。
- 模型动作，例如 click、type、scroll。
- 工具 observation。
- 最终状态 oracle。
- 是否触发权限或安全边界。

指标不要只看“模型说完成了”，而要看最终状态是否真的满足目标。

面试高频问题

1. VLM benchmark 怎么选？

先按业务能力拆分：OCR、文档、图表、空间、视频、GUI、安全。公开 benchmark 用来横向比较，自建 regression set 用来覆盖真实业务。二者都要有，不能只跑 leaderboard。

2. 为什么 VLM judge 需要校准？

VLM judge 自身也会 hallucinate，对风格、长度和模型家族有偏好。需要人工标注集校准，报告 judge-human agreement，并对精确任务使用程序化 oracle。

3. VLM 项目怎么证明有效？

用离线 benchmark 证明基础能力，用业务回归集证明场景覆盖，用线上 A/B 或人工复核指标证明收益。还要报告成本、延迟、失败类型和安全边界。

4. VLM 和 OCR/layout/RAG 怎么配合？

对于文档和企业知识库，VLM 不一定替代 OCR 和 RAG。更稳的系统通常是 OCR/layout 提供结构，RAG 定位证据，VLM 负责跨模态理解和回答，最后用 citation 和 oracle 评测。

本章 References

- [MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark](#)
- [MME: A Comprehensive Evaluation Benchmark for Multimodal Large Language Models](#)
- [VHELM: A Holistic Evaluation of Vision Language Models](#)

- [DocVQA: A Dataset for VQA on Document Images](#)
- [ChartQA: A Benchmark for Question Answering about Charts](#)
- [Video-MME: The First-Ever Comprehensive Evaluation Benchmark of Multi-modal LLMs in Video Analysis](#)
- [OSWorld: Benchmarking Multimodal Agents for Open-Ended Tasks in Real Computer Environments](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)
