

第 8 章：LLM/VLM 进阶面试速查与项目表达

8.1 高频概念横向对比

概念	English	中文	面试一句话
Transformer	Transformer Architecture	Transformer 架构	用 attention 并行建模 token 间依赖。
Pretraining	Pretraining	预训练	大规模 next-token prediction 学语言、代码、知识和分布。
SFT	Supervised Fine-Tuning	监督微调	用指令数据让模型学会按任务格式输出。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用偏好训练 reward，再优化策略。
RLAIF	Reinforcement Learning from AI Feedback	基于 AI 反馈的强化学习	用 AI judge 或 constitution 降低人类反馈成本。
DPO	Direct Preference Optimization	直接偏好优化	把偏好学习变成分类式 loss，省掉 RL loop。
RLVR	Reinforcement Learning with Verifiable Rewards	可验证奖励强化学习	用测试、答案校验、工具状态等自动 reward 训练。
GRPO	Group Relative Policy Optimization	组相对策略优化	用同组样本相对 reward 构造 advantage，省掉 value model。
PRM	Process Reward Model	过程奖励模型	给中间推理步骤打分。
ORM	Outcome Reward Model	结果奖励模型	只给最终结果打分。
LoRA	Low-Rank Adaptation	低秩适配	冻结原权重，只训练低秩更新。
RAG	Retrieval-Augmented Generation	检索增强生成	检索证据后生成，增强可更新性和溯源。
Hybrid Search	Hybrid Search	混合检索	组合 BM25、dense retrieval 和 metadata filter。
GraphRAG	Graph Retrieval-Augmented Generation	图检索增强生成	用实体关系和图结构支持多跳、全局主题类问题。
RAGAS	RAG Assessment	RAG 评估工具	自动评估 RAG faithfulness、context relevance 等指标。

概念	English	中文	面试一句话
Agent	Agent	智能体	在 observe-plan-act-verify 循环中调用工具解决任务。
Harness	Harness	评测/执行框架	管理数据、prompt、工具、环境、打分和 trace 的系统层。
Benchmark	Benchmark	基准测试	固定任务集合和指标，用于比较模型或系统。
MoE	Mixture of Experts	混合专家模型	每个 token 只激活部分专家，提升容量/成本比。
CLIP	Contrastive Language-Image Pre-training	对比式图文预训练	用对比学习把图像和文本映射到共享语义空间。
LLaVA	Large Language and Vision Assistant	大语言视觉助手	CLIP vision encoder + projector + LLM 的多模态指令路线。

8.2 高频问答

8.2.1 为什么 LLM 会 hallucination?

因为预训练目标是拟合 token 分布，不是事实数据库查询；模型会生成高概率、语义连贯但不一定真实的文本。知识过期、上下文不足、问题诱导、检索错误都会加剧 hallucination。

8.2.2 怎么降低 hallucination?

常用方法包括 RAG、引用约束、答案验证、拒答策略、tool use、结构化输出校验、领域 SFT、偏好优化、RLVR 和人工评测闭环。

8.2.3 RAG 和 fine-tuning 怎么选?

RAG 适合频繁更新、需要溯源的知识；fine-tuning 适合格式、风格、领域术语、任务习惯。知识注入优先 RAG，行为模式优先 fine-tuning。

8.2.4 RLHF、DPO、RLVR 怎么区分?

RLHF 用 reward model + RL 优化偏好；DPO 直接用偏好对优化，稳定但更偏离线；RLVR 用可验证 reward，适合数学、代码、工具调用和 agent 任务。

8.2.5 GRPO 为什么火?

GRPO 省掉 value model，用同组样本的相对 reward 估计 advantage，适合大模型 reasoning RL。但它依赖 reward 分布和采样质量，遇到全对/全错组时学习信号会弱。

8.2.6 Agent 和 function calling 的区别?

Function calling 是一次或少数几次结构化调用。Agent 是多步闭环：规划、调用工具、观察结果、调整计划、验证最终状态。

8.2.7 Harness、benchmark、scaffold 怎么区分?

Benchmark 是题和指标，harness 是执行评测的系统层，scaffold 是 agent 外层的规划、工具、记忆、验证和重试逻辑。2026 年比较 agent 时要报告 model + harness + scaffold + budget，而不是只报模型名。

8.2.8 为什么 coding agent 难？

它要理解仓库、定位 bug、编辑多个文件、运行测试、读失败日志、持续修正，并且避免过度修改。这是 long-horizon task，不是代码补全。

8.2.9 VLM 项目怎么讲？

按“任务-数据-模型-训练-评测-风险”讲。例如票据理解：任务是 OCR + table parsing + field extraction；数据是扫描件和字段标签；模型用 VLM 或 OCR+LLM pipeline；指标包括字段准确率、表格结构 F1、拒答率和人工复核成本。

8.2.10 如何评价一个 VLM？

不要只报单个 benchmark。要分 OCR、caption、VQA、chart、document、grounding、multi-image、long-video、robustness 和 safety。

8.2.11 2026 年 SOTA 大模型路线怎么总结？

主线是 reasoning + tool use + verifiable RL + long-horizon agent。闭源模型强调系统化、router、safe-completions 和 产品安全；开源模型强调 MoE、RLVR、thinking budget、agentic data 和蒸馏。

8.3 项目 1：企业知识库 RAG

任务目标：

- 支持公司内部文档问答。
- 输出答案和引用。
- 对无证据问题拒答。

技术方案：

1. 文档解析：PDF、Markdown、网页、表格。
2. Chunking：按标题、段落、表格结构切分。
3. Embedding：选择中文和英文表现稳定的 embedding model。
4. Retrieval：向量召回 + BM25 混合召回。
5. Rerank：cross-encoder 或 LLM rerank。
6. Generation：答案必须引用来源。
7. Verification：引用是否支持答案，是否越权。
8. Eval：人工 gold set + 自动一致性检查。

面试亮点：

- 你能区分 retrieval error 和 generation error。
- 你设计了拒答和引用验证。
- 你关注权限隔离和数据新鲜度。
- 你能说明 RAG harness：corpus version、index version、gold evidence、permission scope、citation scorer。

8.4 项目 2: Coding Agent

任务目标:

- 输入 issue 或用户需求。
- 自动定位代码、修改、运行测试并输出 diff。

技术方案:

1. Repository indexing: 符号索引、全文搜索、依赖图。
2. Planning: 先读问题和相关测试, 再做最小修改计划。
3. Editing: 限制文件范围, 生成 patch。
4. Verification: 运行单测、lint、类型检查、回归测试。
5. Repair loop: 根据失败日志迭代。
6. Review: 输出风险、验证命令、未覆盖点。

指标:

- issue resolution rate。
- test pass rate。
- regression rate。
- tool error rate。
- tokens / task。
- human review time reduction。
- trace replay success rate。

面试亮点:

我不会只让模型“写代码”, 而是把代码搜索、编辑、测试、日志分析、回归验证和最小权限放进闭环。最终以测试和 diff 证明任务完成。

8.5 项目 2.5: Eval Harness / Agent Harness

任务目标:

- 为 LLM/RAG/agent 系统建立可复现评测。
- 固定数据、prompt、模型版本、工具权限、预算和打分协议。
- 输出 trace、错误分类和回归报告。

技术方案:

1. Dataset adapter: 读取样本、版本和 gold answer。
2. Model adapter: 统一不同 API 和本地模型。
3. Task adapter: 构造 prompt 或 agent 环境。
4. Runner: 控制 batch、timeout、temperature、reasoning effort。
5. Scorer: 规则、oracle、LLM-as-a-judge、人工抽检。
6. Trace logger: 记录 prompt、tool call、observation、cost、latency。

7. Report: 按 failure type 聚合。

指标:

- pass@1 / pass@k。
- exact match / F1。
- judge agreement。
- cost / latency。
- tool error rate。
- permission violation rate。
- reproducibility rate。

8.6 项目 3: 多模态文档理解

任务目标:

- 输入发票、报告、截图或表格图片。
- 输出结构化 JSON。

技术方案:

1. OCR 或 VLM 读取文字。
2. Layout-aware chunking。
3. 字段抽取和 schema validation。
4. 对低置信字段触发人工复核。

指标:

- field accuracy。
- exact match。
- table F1。
- hallucinated field rate。
- human review reduction。

8.7 项目 4: Agentic Research / Deep Research

任务目标:

- 输入一个复杂研究问题。
- 自动搜索、阅读、交叉验证、生成带引用报告。

技术方案:

1. Query decomposition。
2. Web search / paper search。
3. Source credibility scoring。
4. Evidence table。
5. Draft generation。

- 6. Citation verification。
- 7. Contradiction check。

指标：

- answer correctness。
- citation precision。
- source diversity。
- unsupported claim rate。
- time-to-answer。
- human edit distance。

8.8 45 分钟复习路线

- 1. 5 分钟：Transformer、attention、causal mask。
- 2. 5 分钟：pretraining、SFT、RLHF、DPO。
- 3. 5 分钟：RLVR、GRPO、PRM/ORM、reasoning model。
- 4. 5 分钟：LoRA/QLoRA、MoE、推理优化、KV cache。
- 5. 5 分钟：RAG pipeline、hybrid retrieval、GraphRAG、RAG eval。
- 6. 5 分钟：agent loop、tool use、coding agent、harness。
- 7. 5 分钟：CLIP、BLIP-2、LLaVA、Qwen2.5-VL。
- 8. 5 分钟：GPT-5.5、Claude Opus 4.7、Gemini 2.5、DeepSeek-R1、Qwen3、Kimi K2、GLM-5.2。
- 9. 5 分钟：项目讲法和评测指标。

8.9 最后检查清单

- 能手写 attention 公式。
- 能解释为什么 next-token prediction 能学到通用能力。
- 能讲清 SFT、RLHF、DPO、RLVR 的区别。
- 能讲清 GRPO 为什么省 value model。
- 能讲清 PRM/ORM 的优缺点。
- 能讲清 RAG 失败模式。
- 能讲清 RAG harness 和 citation verification。
- 能讲清 agentic tool use 的状态、工具、权限、验证。
- 能讲清 harness、benchmark、scaffold、leaderboard 的区别。
- 能讲清 coding agent 和代码补全的差别。
- 能讲清 CLIP 的 contrastive loss 直觉。
- 能讲清 LLaVA/BLIP-2/Flamingo 的差异。
- 能给出一个完整 LLM/VLM 项目方案。

[章节索引](#)

[← 上一章](#) [下一章 →](#)