

第 11 章：2026 SOTA 技术报告阅读地图

本章符号说明

符号/缩写	English	中文	含义
SOTA	State of the Art	当前最优	某任务或评测上的前沿水平。
API	Application Programming Interface	应用程序编程接口	模型服务和工具调用的接口。
GPT	Generative Pre-trained Transformer	生成式预训练 Transformer	OpenAI GPT 系列模型名称中的缩写。
GLM	General Language Model	通用语言模型	智谱 GLM 系列模型名称中的缩写。
K2	Kimi K2	Kimi K2 模型	Moonshot AI 的 agentic MoE 模型系列。
R1	DeepSeek-R1	DeepSeek-R1 模型	DeepSeek 的 reasoning model 系列。
System Card	System Card	系统卡	描述模型能力、限制、安全评估和部署策略的官方报告。
Tech Report	Technical Report	技术报告	描述模型架构、训练、数据、评测和安全的报告。
Frontier Model	Frontier Model	前沿模型	当前能力接近行业最前沿的大模型。
Reasoning Model	Reasoning Model	推理模型	会分配额外推理计算解决复杂任务的模型。
Hybrid Reasoning	Hybrid Reasoning	混合推理	同一模型或系统支持快速回答和深度推理。
Router	Router	路由器	根据任务复杂度选择模型或推理模式的组件。
MoE	Mixture of Experts	混合专家模型	每个 token 只激活部分专家参数。
RLVR	Reinforcement Learning with Verifiable Rewards	可验证奖励强化学习	用自动验证 reward 优化推理、代码、工具任务。
GRPO	Group Relative Policy Optimization	组相对策略优化	DeepSeek-R1 相关报告中常见的 RL 算法。

符号/缩写	English	中文	含义
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好训练 reward model 并优化策略。
SFT	Supervised Fine-Tuning	监督微调	用高质量指令数据微调模型。
ARC	Agentic, Reasoning, Coding	智能体、推理、编程	GLM 系列报告中强调的三类能力。
DSA	DeepSeek Sparse Attention	DeepSeek 稀疏注意力	GLM-5 报告采用的长上下文高效注意力路线。
IndexShare	Index Sharing Sparse Attention	索引共享稀疏注意力	GLM-5.2 repo 中提出的 1M context 稀疏注意力优化。
MTP	Multi-Token Prediction	多 token 预测	GLM-5.2 repo 中用于提升 speculative decoding 接受长度的机制。
RLCS	Reinforcement Learning with Curriculum Sampling	课程采样强化学习	GLM-4.5V 报告中用于视觉推理的 RL 方法。
Agentic Coding	Agentic Coding	智能体式编程	模型能规划、修改、测试、调试代码任务。
GUI	Graphical User Interface	图形用户界面	多模态 agent 操作的网页或桌面界面。
UI	User Interface	用户界面	文档、网页、应用界面等视觉任务对象。
SWE	Software Engineering	软件工程	coding agent 和真实仓库任务所在领域。
STEM	Science, Technology, Engineering, Mathematics	科学、技术、工程、数学	高难推理和多模态评测常见领域。
Terminal-Bench	Terminal Benchmark	终端任务基准	衡量模型在 shell/terminal 中完成长期任务的 benchmark。
SWE-bench Pro	Software Engineering Benchmark Pro	软件工程进阶基准	更高难度的软件工程 agent benchmark。
Long Context	Long Context	长上下文	支持数十万到百万 token 级输入。
Multimodal	Multimodal	多模态	支持文本、图像、音频、视频等输入或输出。

本章目标

- 知道截至 2026-06-21，大模型技术报告的主线是什么。
- 能把 OpenAI、Anthropic、Google、DeepSeek、Qwen、Kimi、GLM 的报告按技术维度比较。
- 面试中能从“训练方法、推理方式、agentic 能力、评测协议、安全策略”五个角度讲模型。
- 不背模型名，而是读出趋势。

读 SOTA 报告的框架

看任何模型报告，按这 8 个问题读：

1. 模型是 dense 还是 MoE？
2. 是单模型，还是 router/system-of-models？
3. 是否支持 thinking / reasoning effort？
4. post-training 里用了 SFT、preference、RLHF、RLVR、tool RL 里的哪些？
5. agentic 能力如何评估？是否给了 scaffold、工具、预算？
6. 长上下文和多模态能力怎么做？是真支持还是只在特定 preview？
7. 安全评测覆盖哪些高风险域？是否有 system card？
8. benchmark 是否可比？是否用了 high compute、best-of-n、tool access？

OpenAI: o-series、GPT-5 与 GPT-5.5

OpenAI o3 / o4-mini system card 的重点：

- reasoning model 结合完整工具能力。
- 模型可以在推理过程中使用 web、Python、image/file analysis 等工具。
- o-series 使用 large-scale RL on chains of thought。
- deliberative alignment 用安全规范推理提升安全边界遵循。

GPT-5 system card 的重点：

- GPT-5 是 unified system，而不只是单一模型。
- 系统包含 fast model、deeper reasoning model 和 real-time router。
- 强调减少 hallucination、改善 instruction following、降低 sycophancy。
- 引入 safe-completions：在安全范围内尽量有帮助，而不是简单拒答。

GPT-5.5 官方 release 的重点：

- 面向 agentic coding、Terminal-Bench、SWE-Bench Pro、BrowseComp 等长任务。
- 强调更少 token、更少 retry、更高质量输出。
- 在 Codex 和 ChatGPT 中用于复杂工程、研究和电脑工作流。
- API 部署需要额外 safeguards，说明 frontier model 上线已经和安全治理强绑定。

面试表达：

OpenAI 这条线的关键词是 unified system、router、reasoning effort、tool-augmented reasoning 和 safe-completions。它把“模型能力”和“产品系统”绑定得更紧：同一个用户请求可能被路由到快模型、深度推理模型或工具增强流程。

Anthropic: Claude 4 到 Opus 4.7

Claude 4 报告重点：

- extended thinking with tool use。
- parallel tool execution。
- memory improvements。
- coding 和 agentic tasks 上减少 shortcut / loophole 行为。

Claude Opus 4.7 官方 release 的重点：

- 复杂长任务和高级软件工程能力提升。
- 更重视 self-verification：完成前自己检查输出。
- 图像分辨率和专业文档/UI/slide 任务增强。
- 对高风险 cybersecurity 能力做差异化削弱和自动防护。

面试表达：

Anthropic 这条线的关键词是 long-running task、tool use、memory、self-verification 和 safety gating。它特别强调模型作为“长期协作者”而不是单轮问答模型。

Google DeepMind: Gemini 2.5

Gemini 2.5 technical report 的重点：

- Gemini 2.5 Pro / Flash 是 thinking model 或 hybrid reasoning model。
- 原生多模态，文本、图像、音频、视频和长上下文结合。
- 支持 1M token 级长上下文，Gemini 2.5 Pro 可处理长视频内容。
- Sparse MoE 架构，提高容量/成本比。
- Flash 走 controllable thinking budget，覆盖质量、成本、延迟 Pareto frontier。

面试表达：

Gemini 2.5 的关键词是 native multimodality、long context、MoE 和 controllable thinking budget。它的差异化在于把长上下文、多模态和 agentic workflow 结合，而不是只做纯文本推理。

DeepSeek-R1: 开源 reasoning RL 里程碑

DeepSeek-R1 技术报告重点：

- R1-Zero 用大规模 RL，不经过传统 SFT cold start，也能出现推理能力。
- R1 引入 cold-start data 和多阶段训练，解决可读性和语言混杂问题。
- GRPO / verifiable reward 成为开源 reasoning model 训练的重要范式。
- 蒸馏出多个小模型，说明 reasoning 能力可以通过轨迹迁移。

面试表达：

DeepSeek-R1 的影响在于训练范式：它让社区看到大规模 RLVR 可以激发 reasoning behavior，并推动 GRPO、verifier、distillation 成为开源模型训练标配。

Qwen3: Thinking / Non-thinking 统一

Qwen3 technical report 重点：

- 同一模型支持 thinking mode 和 non-thinking mode。
- 引入 thinking budget，在性能、延迟和成本之间调节。
- 同时覆盖 dense 和 MoE，模型规模从小模型到 235B。
- 多语言从 Qwen2.5 的 29 种扩到 119 种语言/方言。
- 强调 agent tasks、code、math 和 multilingual 能力。

面试表达：

Qwen3 的关键不是单个分数，而是统一 reasoning 和 non-reasoning 的产品形态。它说明开源模型也在走“一个模型动态调 thinking budget”的方向。

Kimi K2 / K2.5: Open Agentic Intelligence

Kimi K2 技术报告重点：

- 1T total parameters、32B activated parameters 的 MoE。
- MuonClip optimizer 缓解训练不稳定。
- 15.5T tokens 预训练。
- post-training 里有大规模 agentic data synthesis 和 joint RL。
- 强项集中在 agentic tasks、software engineering 和 coding。

Kimi K2.5 技术报告重点：

- 多模态 agentic model。
- joint text-vision pretraining、zero-vision SFT、joint text-vision RL。
- Agent Swarm：并行分解复杂任务，降低延迟。

面试表达：

Kimi 这条线的关键词是 open agentic intelligence：不只追求聊天能力，而是把软件工程、工具交互、多模态和 agent swarm 放进训练目标。

GLM-5 / GLM-5.1 / GLM-5.2: Agentic Engineering

GLM-5 技术报告重点：

- 从 vibe coding 走向 agentic engineering。
- 延续 ARC：Agentic、Reasoning、Coding 三类能力一起优化。

- GLM-5 规模提升到 744B total parameters、40B activated parameters。
- 采用 DSA，降低长上下文训练和推理成本。
- 引入异步 reinforcement learning infrastructure，把 generation 和 training 解耦，提高 post-training 效率。
- 强调 complex systems engineering、long-horizon agentic tasks 和真实代码工程任务。

GLM-5.1 官方 repo 重点：

- 面向 agentic engineering。
- 强调模型能在更长 session 中持续实验、读结果、识别 blocker、迭代策略。
- 关注 SWE-Bench Pro、NL2Repo、Terminal-Bench 2.0 等工程基准。

GLM-5.2 官方 repo 重点：

- 最新 flagship model，主打 long-horizon tasks。
- 支持 solid 1M-token context，面向长期工作流。
- coding 能力支持 multiple thinking effort levels，在效果和延迟之间折中。
- 提出 IndexShare，在 1M context 下复用稀疏注意力 index，降低 per-token FLOPs。
- 改进 MTP layer，用于 speculative decoding，提升 acceptance length。
- 官方 repo 报告了 Terminal-Bench 2.1 和 SWE-bench Pro 等 coding benchmark 改进。

GLM-4.5V / GLM-4.1V-Thinking 仍然值得了解：

- 多模态 reasoning。
- RLCS 用于解锁视觉推理能力。
- 覆盖 STEM、video understanding、content recognition、coding、grounding、GUI agents、long document。

面试表达：

GLM 这条线已经从 GLM-4.5 的 ARC 走到 GLM-5 系列的 agentic engineering。重点不是只看开源模型分数，而是看 1M context、异步 RL、long-horizon coding、thinking effort、Terminal-Bench / SWE-bench Pro 这类长期工程任务怎么一起推动。

横向对比表

系列	English	中文	关键词	面试重点
OpenAI GPT-5/5.5	OpenAI GPT-5/5.5	OpenAI GPT-5/5.5	router、safe-completions、agentic coding	unified system，不是单模型。
OpenAI o-series	OpenAI o-series	OpenAI o 系列	CoT RL、tool reasoning、deliberative alignment	reasoning + tool use + safety reasoning。
Claude Opus 4.7	Claude Opus 4.7	Claude Opus 4.7	long-running tasks、self-verification、safety gating	长任务稳定性和工程协作。

系列	English	中文	关键词	面试重点
Gemini 2.5	Gemini 2.5	Gemini 2.5	native multimodal、1M context、MoE、thinking budget	长上下文 + 多模态 + agentic workflow。
DeepSeek-R1	DeepSeek-R1	DeepSeek-R1	RLVR、GRPO、distillation	开源 reasoning RL 范式。
Qwen3	Qwen3	Qwen3	thinking/non-thinking unified、MoE、multilingual	统一 thinking budget 和开源生态。
Kimi K2/K2.5	Kimi K2/K2.5	Kimi K2/K2.5	agentic data synthesis、joint RL、Agent Swarm	agentic intelligence 和并行任务分解。
GLM-5.2/5.1/5	GLM-5.2/5.1/5	GLM-5 系列	1M context、IndexShare、MTP、async RL、agentic engineering	long-horizon coding 和工程任务。
GLM-4.5V	GLM-4.5V	GLM-4.5V	RLCS、multimodal reasoning、GUI agents	多模态 RL 和视觉推理。

2026 技术趋势总结

1. 从单模型到系统模型

前沿产品越来越像 system-of-models：router、fast model、thinking model、tools、memory、verifier 一起工作。

2. 从 SFT 到 RLVR

数学、代码、工具调用、浏览、GUI 都有可验证 reward，RLVR 成为提升 reasoning 和 agentic 能力的核心。

3. 从聊天到长任务

SOTA 模型的竞争点从“答题准确率”转向“能不能稳定完成长周期工作”。

4. 从单 agent 到多 agent / parallel attempts

复杂任务常用并行尝试、候选筛选、agent swarm，但最终仍依赖 verifier。

5. 从安全拒答到安全完成

安全系统从二元拒答转向 safe-completions、deliberative alignment、cyber gating、preparedness framework。

6. 从 VLM 到多模态 agent

多模态不只是看图回答，而是视频、GUI、文档、浏览器、代码和工具环境的统一推理。

本章面试高频问题

1. 2026 年大模型最重要的趋势是什么？

从“更大预训练模型”转向“reasoning + tools + verifiable RL + long-horizon agents”。模型能力、系统架构和安全部署越来越不可分。

2. OpenAI、Anthropic、Gemini 的差异怎么讲？

OpenAI 强调 unified system、router、agentic coding 和 safe-completions；Anthropic 强调 long-running task、tool use、self-verification 和安全 gating；Gemini 强调 native multimodality、long context、MoE 和 controllable thinking budget。

3. 开源模型最近为什么进步快？

DeepSeek-R1、Qwen3、Kimi K2、GLM-5.2 都把 reasoning RL、MoE、agentic data、distillation、thinking budget、long-horizon coding 等技术公开化，让社区可以复现和组合。

4. 技术报告里的 benchmark 怎么看？

先看是否用了 tool、high reasoning effort、多次采样、外部 scaffold 和隐藏测试。不同协议下的分数不能直接横比。

5. 面试如何展示“我跟进了 SOTA”？

不要背模型排行榜。讲趋势和机制：RLVR 为什么重要，agent eval 为什么难，long-context 何时替代不了 RAG，safe-completions 为什么比拒答更好，多模态 agent 为什么是下一阶段。

本章 References

- [OpenAI o3 and o4-mini System Card](#)
- [Introducing OpenAI o3 and o4-mini](#)
- [OpenAI GPT-5 System Card](#)
- [Introducing GPT-5.5](#)
- [Claude 4](#)
- [Claude Opus 4.7](#)
- [Gemini 2.5 Technical Report](#)
- [DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning](#)
- [Qwen3 Technical Report](#)
- [Kimi K2: Open Agentic Intelligence](#)
- [Kimi K2.5: Visual Agentic Intelligence](#)
- [GLM-5: from Vibe Coding to Agentic Engineering](#)
- [Z.ai GLM-5.2 / GLM-5.1 / GLM-5 official repo](#)
- [GLM-4.5: Agentic, Reasoning, and Coding Foundation Models](#)
- [GLM-4.1V-Thinking and GLM-4.5V](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)
