

第 12 章：RAG 系统、Agentic RAG 与评测

12.1 本章符号说明

符号/缩写	English	中文	含义
RAG	Retrieval-Augmented Generation	检索增强生成	从外部知识源检索证据，再让模型基于证据生成答案。
LLM	Large Language Model	大语言模型	基于大规模文本预训练的生成式语言模型。
IR	Information Retrieval	信息检索	从文档集合中找到相关信息的技术领域。
API	Application Programming Interface	应用程序编程接口	RAG 从业务系统实时取数时常用的接口。
DB	Database	数据库	存储结构化或半结构化数据的系统。
SQL	Structured Query Language	结构化查询语言	查询关系型数据库的语言。
PDF	Portable Document Format	可移植文档格式	企业文档和报告常见格式。
HTML	HyperText Markup Language	超文本标记语言	网页文档常见格式。
OCR	Optical Character Recognition	光学字符识别	从扫描件或图片中识别文字。
FAQ	Frequently Asked Questions	常见问题	企业知识库常见文档类型。
HR	Human Resources	人力资源	权限敏感文档常见来源之一。
BM25	Best Matching 25	BM25 排序函数	经典 sparse retrieval 关键词匹配方法。
Dense Retrieval	Dense Retrieval	稠密检索	用 embedding 向量相似度检索语义相关文档。
Sparse Retrieval	Sparse Retrieval	稀疏检索	用词项、倒排索引、BM25 等方法检索。
Hybrid Search	Hybrid Search	混合检索	组合 sparse 和 dense retrieval。

符号/缩写	English	中文	含义
Embedding	Embedding	向量表示	文本、图片或多模态对象的稠密向量。
Vector DB	Vector Database	向量数据库	存储 embedding 并支持近邻搜索的数据库。
Chunking	Chunking	文档切块	把文档切成可检索片段。
Query Rewrite	Query Rewrite	查询改写	将用户问题改写成更适合检索的查询。
Multi-query	Multi-query Retrieval	多查询检索	为同一问题生成多个检索查询，提高召回。
HyDE	Hypothetical Document Embeddings	假设文档向量	先生成假设答案/文档，再用它做向量检索。
Reranker	Reranker	重排序模型	对初召回结果重新排序，提高 top-k 证据质量。
Cross-encoder	Cross-encoder Reranker	交叉编码重排序器	同时编码 query 和 document 计算相关性。
GraphRAG	Graph Retrieval-Augmented Generation	图检索增强生成	用知识图谱、实体关系和社区摘要增强检索。
Agentic RAG	Agentic Retrieval-Augmented Generation	智能体式 RAG	让 agent 动态规划、检索、验证和补充证据。
Long-context RAG	Long-context Retrieval-Augmented Generation	长上下文 RAG	检索后把更大证据包交给长上下文模型。
ACL	Access Control List	访问控制列表	决定用户可访问哪些文档或字段的权限配置。
PII	Personally Identifiable Information	个人可识别信息	需要脱敏和权限保护的敏感信息。
Groundedness	Groundedness	有根据性	答案是否被给定证据支持。
Faithfulness	Faithfulness	忠实性	生成内容是否忠实于检索证据。
Citation Precision	Citation Precision	引用精确率	引用是否真正支持对应答案句。
Recall@k	Recall at k	前 k 召回率	gold evidence 是否出现在前 k 个结果中。
MRR	Mean Reciprocal Rank	平均倒数排名	第一个相关结果排名的倒数均值。
nDCG	Normalized Discounted Cumulative Gain	归一化折损累计增益	考虑排序位置和相关性等级的检索指标。

符号/缩写	English	中文	含义
RAGAS	RAG Assessment	RAG 评估工具	常用于 RAG answer faithfulness、context relevance 等自动评测。
REALM	Retrieval-Augmented Language Model Pre-Training	检索增强语言模型预训练	早期把检索接入语言模型预训练的代表工作。
q	Query	查询	用户问题或检索查询。
D	Document Corpus	文档库	可检索的文档集合。
d_i	Document Chunk	第 i 个文档块	文档切块后的检索单元。
$S(q, d_i)$	Retrieval Score	检索分数	query 与文档块的相关性分数。
C_k	Retrieved Context	前 k 个上下文	检索后交给模型的证据集合。

12.2 本章目标

- 能把 RAG 讲成一个完整系统，而不是一句“向量库 + prompt”。
- 能区分 retrieval error、rerank error、context packing error 和 generation error。
- 能解释 GraphRAG、Agentic RAG、long-context RAG 的使用场景。
- 能设计 RAG 评测集、指标、线上监控和权限边界。
- 能回答“长上下文模型是不是替代 RAG”这类面试追问。

12.3 为什么 2026 年仍然要会 RAG

长上下文模型越来越强，但 RAG 没有消失。原因很简单：

- 企业知识经常更新，不能每次重新训练模型。
- 私有文档需要权限隔离，而不是把所有内容塞进 prompt。
- 生产系统需要 citation、audit log、可回放和版本控制。
- 很多问题需要从结构化系统、数据库、网页、代码仓库实时读取。
- 长上下文更贵，且模型不一定能在长证据里稳定找到关键事实。

面试表达：

Long context 解决的是“能不能塞进去”，RAG 解决的是“从哪里找、谁有权限看、证据是否支持、结果能否审计”。两者不是替代关系，生产里常见组合是 retrieval + rerank + long-context packing + citation verification。

12.4 RAG Pipeline

一个生产级 RAG 通常分为两条链路。

离线索引链路：

- 1. 文档接入：PDF、HTML、Markdown、数据库、工单、代码仓库、表格。
- 2. 解析清洗：去噪、版面恢复、表格结构、图片 OCR。
- 3. 权限绑定：把 document、chunk、metadata 和 ACL 绑定。
- 4. Chunking：按标题、语义段、表格、代码符号或页面结构切块。
- 5. Embedding：生成 dense vector。
- 6. Sparse index：建立倒排索引或 BM25。
- 7. Metadata index：保留时间、作者、部门、版本、权限、来源。

在线查询链路：

- 1. Query understanding：识别意图、语言、实体、时间范围。
- 2. Query rewrite / decomposition：改写或拆成子问题。
- 3. Hybrid retrieval：BM25 + dense retrieval。
- 4. Rerank：cross-encoder 或 LLM rerank。
- 5. Context packing：去重、压缩、保留结构、控制 token budget。
- 6. Generation：基于证据回答。
- 7. Citation verification：检查答案句和引用是否一致。
- 8. Refusal / abstention：证据不足时拒答或要求澄清。

抽象公式：

$$C_k = TopK_{d_i \in D} S(q, d_i)$$

$$\hat{y} = LLM(q, C_k)$$

这里 C_k 是检索上下文，不等于“越多越好”。上下文太多会增加成本，也可能把模型注意力从关键证据上稀释掉。

12.5 Chunking 怎么设计

Chunking 是 RAG 里最容易被低估的环节。

策略	English	中文	适合场景	风险
Fixed-size Chunking	Fixed-size Chunking	固定长度切块	快速 baseline	切断语义和表格。
Recursive Chunking	Recursive Chunking	递归切块	按标题、段落、句子逐级切	依赖解析质量。
Semantic Chunking	Semantic Chunking	语义切块	FAQ、制度文档、知识库	成本更高，边界不稳定。
Layout-aware Chunking	Layout-aware Chunking	版面感知切块	PDF、报告、票据、表格	需要 OCR/layout 模型。

策略	English	中文	适合场景	风险
Code-aware Chunking	Code-aware Chunking	代码感知切块	函数、类、调用关系	需要语法树或符号索引。
Small-to-big Retrieval	Small-to-big Retrieval	小块召回大块扩展	先精确召回，再补上下文	扩展窗口过大可能污染。

面试重点：

Chunk 太小会丢上下文，chunk 太大会降低召回精度。生产里常用小块建索引、大块给模型，配合 metadata、标题路径和邻接窗口。

12.6 Retrieval：不要只会向量库

RAG 初召回通常要混合多种信号：

方法	English	中文	优点	缺点
BM25	Best Matching 25	关键词检索	精确匹配术语、编号、错误码	同义词和语义泛化弱。
Dense Retrieval	Dense Retrieval	稠密检索	语义匹配强	专有名词、数字、代码符号可能弱。
Hybrid Search	Hybrid Search	混合检索	同时覆盖关键词和语义	分数融合需要调参。
Metadata Filter	Metadata Filtering	元数据过滤	时间、部门、权限、版本可控	metadata 质量要求高。
Graph Retrieval	Graph Retrieval	图检索	适合实体关系、多跳问题	构图和维护成本高。
SQL / API Retrieval	Structured Retrieval	结构化检索	精确、实时、可权限控制	需要 schema 和工具调用能力。

分数融合可以简单写成：

$$S(q,d)=\alpha S_{dense}(q,d)+(1-\alpha)S_{sparse}(q,d)$$

其中 α 是 dense / sparse 的权重。工程上不一定线性融合，也可以用 rank fusion、learning-to-rank 或 reranker。

12.7 Reranking 与 Context Packing

初召回要追求 recall，rerank 要追求 precision。常见做法：

- 初召回 top 50 到 top 200。

- reranker 压到 top 5 到 top 20。
- 按来源去重，避免同一段重复占满上下文。
- 保留标题路径、页码、表格 header、时间戳。
- 对长文档做 section summary，再把原文关键段落保留给模型。

Context packing 的目标不是塞满窗口，而是让模型看到：

1. 足够回答问题的证据。
2. 冲突证据和时间版本。
3. 每条证据的来源。
4. 不该看到的内容被权限过滤掉。

12.8 GraphRAG

GraphRAG 适合这些问题：

- 需要跨文档、多实体、多跳关系。
- 用户问的是主题、趋势、组织结构、事件链，而不是单点事实。
- 文档量大，单纯 top-k chunk 容易碎片化。

典型流程：

1. 从文档中抽取 entity、relation、claim。
2. 建图并做社区发现。
3. 生成社区摘要或实体摘要。
4. 查询时结合图邻域、社区摘要和原文证据。

局限：

- 构图成本高。
- 抽取错误会传播。
- 图摘要可能丢细节。
- 权限和增量更新更复杂。

面试表达：

GraphRAG 不是万能增强版 RAG，它更适合全局主题和多跳关系问题。对于精确政策条款、合同字段、错误码检索，普通 hybrid retrieval 可能更可靠。

12.9 Agentic RAG

Agentic RAG 让模型不再一次性检索，而是在循环中动态决定下一步：

```
question -> plan -> retrieve -> read -> identify gap -> retrieve again -> verify -> answer
```

它适合：

- 复杂研究问题。
- 多跳问答。
- 需要查多个系统的企业问答。
- 需要先澄清权限、时间范围或实体歧义的问题。

风险：

- 延迟和成本更高。
- 检索路径更难复现。
- 如果没有 trace 和 verifier，agent 会把错误证据越滚越大。
- prompt injection 可以通过外部文档污染下一步工具调用。

12.10 RAG Evaluation

RAG 评测要拆开来：

层级	English	中文	指标
Retrieval Eval	Retrieval Evaluation	检索评测	Recall@k、MRR、nDCG、hit rate。
Rerank Eval	Reranking Evaluation	重排序评测	top-k precision、pairwise preference。
Context Eval	Context Evaluation	上下文评测	context relevance、context coverage、token waste。
Generation Eval	Generation Evaluation	生成评测	faithfulness、answer correctness、format。
Citation Eval	Citation Evaluation	引用评测	citation precision、unsupported claim rate。
Permission Eval	Permission Evaluation	权限评测	越权检索率、PII 泄漏率。
System Eval	System Evaluation	系统评测	端到端成功率、延迟、成本、拒答准确率。

一个常见误区：只用答案正确率评估 RAG。这样看不到错误来自哪里。

更好的 eval set 至少包含：

- query。
- gold answer。
- gold evidence chunk。
- allowed document scope。
- expected citations。
- unanswerable questions。
- conflicting evidence cases。

- stale document cases。
- permission-denied cases。

12.11 RAGAS 类自动评测的价值和风险

RAGAS 类工具常评估：

- context relevance：检索上下文是否相关。
- faithfulness：答案是否被上下文支持。
- answer relevance：答案是否回答了问题。
- answer correctness：答案与标准答案是否一致。

价值：

- 快速回归。
- 适合大量样本趋势分析。
- 能把 retrieval 和 generation 问题拆开。

风险：

- LLM judge 会有偏差。
- judge 可能看漏证据。
- 没有权限、成本、延迟、线上分布就不完整。
- 自动分数不能替代人工 gold set。

面试表达：

RAG eval 不能只靠 LLM-as-a-judge。我会用人工 gold evidence 做 retrieval eval，用 citation verifier 做 grounding eval，用人工抽检校准 judge，并把权限、延迟、成本纳入 system eval。

12.12 常见失败模式

失败模式	English	中文	例子	解决方向
Missing Recall	Missing Recall	召回缺失	关键文档没进 top-k	query rewrite、hybrid search、chunk 重做。
Wrong Evidence	Wrong Evidence	错误证据	检测到旧版本政策	metadata filter、freshness、rerank。
Context Pollution	Context Pollution	上下文污染	无关段落塞满窗口	rerank、去重、context packing。
Lost in the Middle	Lost in the Middle	中间遗忘	长上下文中忽略关键段	证据排序、摘要、引用定位。
Citation Drift	Citation Drift	引用漂移	引用 A 但答案来自 B	citation verification。

失败模式	English	中文	例子	解决方向
Permission Leak	Permission Leak	权限泄漏	普通用户检到 HR 文档	ACL filter、query-time auth。
Prompt Injection	Prompt Injection	提示注入	文档要求模型泄露系统提示	工具输出不可信、指令分层。
Over-answering	Over-answering	过度回答	无证据仍编答案	abstention、confidence、verifier。

12.13 面试高频问题

12.13.1 RAG 为什么不能只用向量库？

向量检索语义泛化强，但对编号、时间、实体、代码符号和精确术语不一定稳定。生产里通常要 hybrid search、metadata filter、rerank、权限控制和 citation verification。

12.13.2 长上下文模型会替代 RAG 吗？

不会完全替代。长上下文适合一次性阅读大材料；RAG 适合动态知识、权限隔离、引用审计和成本控制。实际系统经常组合使用。

12.13.3 怎么定位 RAG 答错原因？

先看 gold evidence 是否被召回，再看 rerank 排名，再看 context 是否被正确打包，最后看生成是否忠实。不要直接把错误归因给 LLM。

12.13.4 Agentic RAG 比普通 RAG 强在哪里？

它能动态拆问题、多轮检索、发现证据缺口并补查。代价是更慢、更贵、更难复现，所以需要 trace、预算和 verifier。

12.13.5 企业 RAG 最重要的工程风险是什么？

权限和证据。用户不能检到无权限内容，答案必须能被引用支持。否则系统即使看起来聪明，也不适合上线。

12.14 本章 References

- Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks
- REALM: Retrieval-Augmented Language Model Pre-Training
- Microsoft GraphRAG
- RAGAS
- Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG
- Retrieval-Augmented Generation: A Comprehensive Survey of Architectures, Enhancements, and Robustness Frontiers