

# 第 13 章：Eval Harness、Benchmark 与可复现评测

## 本章符号说明

| 符号/缩写         | English                           | 中文       | 含义                                          |
|---------------|-----------------------------------|----------|---------------------------------------------|
| Eval          | Evaluation                        | 评测       | 对模型或系统能力、风险和成本的测量。                          |
| LLM           | Large Language Model              | 大语言模型    | 被评测的语言模型或系统核心。                              |
| LM            | Language Model                    | 语言模型     | LM Evaluation Harness 名称中的缩写。               |
| VLM           | Vision-Language Model             | 视觉语言模型   | 同时处理视觉和语言输入的模型。                             |
| RAG           | Retrieval-Augmented Generation    | 检索增强生成   | 需要单独设计 retrieval、generation、citation 评测的系统。 |
| API           | Application Programming Interface | 应用程序编程接口 | 模型或工具服务的调用接口。                               |
| Harness       | Harness                           | 评测/执行框架  | 管理数据、prompt、模型调用、工具、环境、打分和记录的系统层。           |
| Eval Harness  | Evaluation Harness                | 评测框架     | 把 benchmark 跑成可复现实验的执行框架。                   |
| Agent Harness | Agent Harness                     | 智能体执行框架  | 管理 agent 上下文、工具、状态、权限、trace 和恢复的系统层。        |
| Benchmark     | Benchmark                         | 基准测试     | 固定任务集合和指标，用于比较模型或系统。                        |
| Leaderboard   | Leaderboard                       | 排行榜      | 汇总 benchmark 分数的公开排名。                       |
| Protocol      | Evaluation Protocol               | 评测协议     | 规定 prompt、采样、工具、预算、指标和报告方式。                 |
| Model Adapter | Model Adapter                     | 模型适配器    | 把不同模型/API 统一成 harness 可调用接口。                |
| Task Adapter  | Task Adapter                      | 任务适配器    | 把数据样本转成 prompt、工具环境和期望输出。                   |
|               |                                   |          |                                             |

| 符号/缩写           | English                                       | 中文            | 含义                                     |
|-----------------|-----------------------------------------------|---------------|----------------------------------------|
| Dataset Adapter | Dataset Adapter                               | 数据集适配器        | 读取、过滤、切分和版本化数据集。                       |
| Prompt Template | Prompt Template                               | 提示模板          | 评测时固定的输入格式。                            |
| Runner          | Runner                                        | 运行器           | 批量执行模型调用或 agent 任务的组件。                 |
| Sandbox         | Sandbox                                       | 沙箱            | 隔离文件系统、网络和外部副作用的环境。                    |
| Environment     | Environment                                   | 环境            | agent 可以观察和行动的任务世界。                    |
| Oracle          | Oracle                                        | 标准判定器         | 能可靠判断答案或最终状态是否正确的程序/标注。                |
| Scorer          | Scorer                                        | 打分器           | 将输出转成数值分数的组件。                          |
| Judge           | Judge                                         | 裁判模型/评审者      | 用模型或人类判断开放式输出质量。                       |
| LLM-as-a-Judge  | LLM as a Judge                                | 大模型裁判         | 用 LLM 给答案、引用或轨迹评分。                     |
| HELM            | Holistic Evaluation of Language Models        | 语言模型整体评测      | Stanford CRFM 的综合评测框架。                 |
| VHELM           | Vision Holistic Evaluation of Language Models | 视觉语言模型整体评测    | HELM 思路扩展到 VLM 的评测。                    |
| MMLU            | Massive Multitask Language Understanding      | 大规模多任务语言理解基准  | 常见知识和推理评测。                             |
| MRR             | Mean Reciprocal Rank                          | 平均倒数排名        | 检索排序指标。                                |
| F1              | F1 Score                                      | F1 分数         | precision 和 recall 的调和平均。              |
| SWE-bench       | Software Engineering Benchmark                | 软件工程基准        | 真实 GitHub issue 修复任务。                  |
| TAU-bench       | Tool-Agent-User Benchmark                     | 工具-智能体-用户交互基准 | 业务工具调用和用户交互任务。                         |
| Trace           | Trace                                         | 轨迹日志          | 记录 prompt、tool call、observation、输出和分数。 |
| Trajectory      | Trajectory                                    | 执行轨迹          | agent 从开始到结束的动作序列。                     |
|                 |                                               |               |                                        |

| 符号/缩写           | English                | 中文          | 含义                        |
|-----------------|------------------------|-------------|---------------------------|
| Replay          | Replay                 | 回放          | 用保存的输入、状态和工具结果复现实验。       |
| pass@k          | Pass at k              | k 次通过率      | 采样 k 次至少一次成功的概率指标。        |
| Contamination   | Data Contamination     | 数据污染        | 测试集进入训练数据或 prompt 导致分数虚高。 |
| Decontamination | Decontamination        | 去污染         | 检查并移除训练/评测重叠的过程。          |
| CI              | Continuous Integration | 持续集成        | 代码变更后自动运行测试和评测的工程流程。      |
| $M$             | Model                  | 模型          | 被评测的基础模型或系统。              |
| $T$             | Task Set               | 任务集合        | benchmark 中的任务样本集合。       |
| $H$             | Harness                | 评测框架        | 执行评测的系统层。                 |
| $s_i$           | Score                  | 第 $i$ 个样本分数 | 单个任务的评分。                  |

## 本章目标

- 理解 benchmark、eval、harness、leaderboard 的区别。
- 能解释为什么 2026 年要报告 model + harness + scaffold，而不是只报 model 名。
- 能设计 LLM、RAG、coding agent、VLM 的评测 harness。
- 能识别 benchmark 污染、工具预算不公平、LLM judge 偏差、pass@k 滥用。
- 能把 eval 接入研发闭环，而不是只跑一次排行榜。

## Harness 是什么

Harness 本质上是“把评测跑起来并保证可复现”的系统层。

它通常负责：

- 读数据集和版本。
- 构造 prompt 或工具环境。
- 调用模型/API。
- 控制 temperature、top-p、seed、max tokens、thinking budget。
- 管理工具、权限、sandbox、timeout。
- 解析输出。
- 调用 scorer、oracle 或 judge。
- 保存 trace、日志、成本和错误。
- 生成报告。

面试表达：

Benchmark 是题，metric 是怎么算分，harness 是把题以固定协议喂给模型并记录结果的执行系统。对 agent 来说，harness 还包含工具、状态、权限、恢复和 trace，所以分数不能只归因于 base model。

## Benchmark、Harness、Scaffold 的区别

| 概念          | English     | 中文      | 关注点                                             |
|-------------|-------------|---------|-------------------------------------------------|
| Benchmark   | Benchmark   | 基准      | 任务集合、标准答案、指标。                                   |
| Harness     | Harness     | 评测/执行框架 | 如何执行任务、调用模型、打分、记录。                              |
| Scaffold    | Scaffold    | 外部脚手架   | agent 的 planner、memory、tools、verifier、retry 逻辑。 |
| Leaderboard | Leaderboard | 排行榜     | 按某协议汇总比较分数。                                     |
| Protocol    | Protocol    | 协议      | 是否允许工具、预算、采样次数、prompt 格式。                       |

一个模型的分数可以抽象成：

$$Score = f(M, H, T, P, B)$$

其中  $M$  是模型， $H$  是 harness， $T$  是任务集合， $P$  是 prompt/protocol， $B$  是预算。只说“某模型在某榜单多少分”往往信息不足。

## LM Evaluation Harness

EleutherAI 的 LM Evaluation Harness 是经典 model eval harness。它把很多文本 benchmark 统一到同一套接口里。

核心组件：

- model adapter：Hugging Face、vLLM、SGLang、API model。
- task config：数据集、prompt、few-shot、metric。
- runner：批量执行。
- output parser：解析模型输出。
- metric：accuracy、exact match、F1、perplexity 等。

适合：

- 基础语言理解。
- few-shot / zero-shot benchmark。
- 开源模型横向比较。
- 回归测试某次训练或微调是否退化。

局限：

- 很多任务是静态文本，不覆盖工具使用。
- 对 reasoning model，要处理 hidden CoT / think\_end\_token。
- 对 agentic 系统，单轮 harness 不够。

## OpenAI Evals 与自定义 Eval

OpenAI Evals 代表另一类思路：把 eval 当成产品和模型迭代的一部分。

典型结构：

1. 样本：输入、期望行为、评分标准。
2. Completion function：调用某个模型或系统。
3. Eval class：执行样本并收集输出。
4. Scorer：程序打分或 LLM-as-a-judge。
5. Report：聚合错误类型和样例。

面试重点：

生产 eval 不是只跑 MMLU，而是把真实用户失败样本、红队样本、权限边界样本、格式约束样本持续加入回归集。

## Agent Harness

Agent harness 比普通 model harness 多很多东西。

| 模块              | English         | 中文     | 作用                                |
|-----------------|-----------------|--------|-----------------------------------|
| Context Manager | Context Manager | 上下文管理器 | 决定给模型看哪些历史、文件和工具结果。               |
| Tool Runtime    | Tool Runtime    | 工具运行时  | 执行 shell、browser、database、editor。 |
| State Store     | State Store     | 状态存储   | 保存任务进度、文件 diff、memory。            |
| Permission Gate | Permission Gate | 权限门    | 控制写操作、网络、支付、删除等风险动作。              |
| Recovery Policy | Recovery Policy | 恢复策略   | 工具失败、超时、循环时如何处理。                  |
| Trace Logger    | Trace Logger    | 轨迹日志   | 记录每步动作和观察。                        |
| Validator       | Validator       | 验证器    | 检查最终 artifact、测试结果、业务状态。          |

Harness-Bench 这类研究强调：同一个 base model 在不同 harness 下可能表现差很多。因此报告 agent 能力时要说明：

- 模型版本。
- harness 版本。
- 工具集合。
- 上下文策略。
- 是否允许并行尝试。
- 时间和 token 预算。
- 是否有 reviewer/verifier。
- 最终如何判定成功。

## Coding Agent Harness

Coding agent 的 harness 通常包含：

1. 仓库快照：固定 commit。
2. Issue 描述：用户需求或真实 bug。
3. Sandbox：隔离执行代码。
4. Tool set：搜索、编辑、测试、lint、类型检查。
5. Patch capture：记录最终 diff。
6. Hidden tests：避免只拟合公开测试。
7. Validator：运行测试或人工验证。
8. Trace：记录每次命令、文件读取和修改。

评测指标：

- pass@1。
- pass@k。
- resolved rate。
- regression rate。
- tool error rate。
- average cost。
- time-to-resolution。
- patch size。

面试表达：

SWE-bench 分数不只是模型能力，还取决于 scaffold、工具、测试预算、重试策略和 patch 验证方式。比较 coding agent 时必须看 protocol。

## RAG Harness

RAG harness 需要同时固定 corpus、query、权限、gold evidence 和 judge。

最小结构：

- corpus version：文档库版本。
- index version：chunking、embedding、reranker 版本。

- query set：用户问题集合。
- gold evidence：标准证据块。
- expected answer：标准答案或评分 rubrics。
- permission scope：每个 query 允许访问哪些文档。
- scorer：retrieval scorer、generation scorer、citation scorer。

RAG harness 输出不应该只有 answer accuracy，还要有：

- Recall@k。
- MRR。
- citation precision。
- unsupported claim rate。
- refusal precision / recall。
- latency。
- cost。
- permission violation rate。

## LLM-as-a-Judge 怎么用

---

LLM-as-a-Judge 适合开放式答案，但不能裸用。

要注意：

- 先用人工样本校准 judge。
- prompt 里明确评分 rubrics。
- 使用 pairwise comparison 通常比绝对打分更稳定。
- 对 judge 本身做版本固定。
- 对安全和权限问题优先用规则或 oracle。
- 记录 judge rationale，但不要把 rationale 当真值。

常见问题：

- position bias：更偏好第一个答案。
- verbosity bias：更偏好长答案。
- self-preference：偏好同系列模型输出。
- rubric drift：评分标准不稳定。
- evidence blindness：没有认真核对引用。

## 污染、泄漏与可比性

---

2026 年 benchmark 最大的问题之一是可比性。

常见风险：

- test contamination：测试集进入预训练或微调数据。
- prompt leakage：评测 prompt 在网上公开并被训练。
- overfitting leaderboard：专门优化公开榜。
- hidden scaffold：不同模型使用了不同外部工具或预算。

- pass@k abuse: 用大量采样把分数堆高, 却不报告成本。
- benchmark saturation: 题目太简单, 区分不了前沿模型。

报告结果时至少说明:

1. 模型版本。
2. harness 版本。
3. benchmark 版本。
4. prompt 模板。
5. decoding 参数。
6. tool access。
7. thinking budget。
8. retries / pass@k。
9. 成本和延迟。
0. 是否做 decontamination。

## Eval 研发闭环

一个成熟团队不会只在发布前跑一次评测, 而是建立闭环:

线上失败样本 → 标注/归因 → 加入 eval set → 修模型/修系统 → CI 回归 → 灰度监控

评测集应该分层:

- smoke eval: 几十条, 提交前快速跑。
- regression eval: 几百到几千条, 覆盖核心场景。
- red-team eval: 安全、越权、prompt injection。
- canary eval: 新模型或新 prompt 灰度前跑。
- online eval: 真实流量抽检和人工反馈。

面试表达:

Eval 的价值不是得一个分数, 而是形成 failure taxonomy 和回归闭环。每次线上事故或人工纠错都应该沉淀成可复现 eval。

## 面试高频问题

### 1. Harness 和 benchmark 有什么区别?

Benchmark 是题和指标, harness 是执行系统。Harness 决定 prompt、工具、预算、解析、打分、日志和复现方式。

### 2. 为什么 agent 要报告 model-harness 组合?

因为 agent 能力强依赖工具、context management、retry、verifier、sandbox 和权限策略。同一模型换 harness, 成功率和失败模式都可能变。



### 3. 怎么设计一个 RAG eval harness?

固定 corpus/index/query/gold evidence/permission scope，分别评估 retrieval、rerank、generation、citation、refusal、latency、cost 和越权率。

### 4. LLM-as-a-Judge 靠谱吗?

可以用于趋势和开放式评测，但要用人工样本校准，固定 judge 版本，控制位置偏差和冗长偏差；高风险结论要用规则、oracle 或人工复核。

### 5. 为什么排行榜分数不能直接横比?

因为 prompt、decoding、thinking budget、tool access、scaffold、pass@k 和测试污染都可能不同。面试里要先问 protocol，再看分数。

## 本章 References

---

- [EleutherAI LM Evaluation Harness](#)
- [OpenAI Evals](#)
- [HELM: Holistic Evaluation of Language Models](#)
- [VHELM: A Holistic Evaluation of Vision Language Models](#)
- [Harness-Bench: Measuring Harness Effects across Models in Realistic Agent Workflows](#)
- [SWE-bench: Can Language Models Resolve Real-World GitHub Issues?](#)
- [TAU-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)