

第 13 章：Eval Harness、Benchmark 与可复现评测

本章符号说明

符号/缩写	English	中文	含义
Eval	Evaluation	评测	对模型或系统能力、风险和成本的测量。
LLM	Large Language Model	大语言模型	被评测的语言模型或系统核心。
LM	Language Model	语言模型	LM Evaluation Harness 名称中的缩写。
VLM	Vision-Language Model	视觉语言模型	同时处理视觉和语言输入的模型。
RAG	Retrieval-Augmented Generation	检索增强生成	需要单独设计 retrieval、generation、citation 评测的系统。
API	Application Programming Interface	应用程序编程接口	模型或工具服务的调用接口。
Harness	Harness	评测/执行框架	管理数据、prompt、模型调用、工具、环境、打分和记录的系统层。
Eval Harness	Evaluation Harness	评测框架	把 benchmark 跑成可复现实验的执行框架。
Agent Harness	Agent Harness	智能体执行框架	管理 agent 上下文、工具、状态、权限、trace 和恢复的系统层。
Benchmark	Benchmark	基准测试	固定任务集合和指标，用于比较模型或系统。
Leaderboard	Leaderboard	排行榜	汇总 benchmark 分数的公开排名。
Protocol	Evaluation Protocol	评测协议	规定 prompt、采样、工具、预算、指标和报告方式。
Model Adapter	Model Adapter	模型适配器	把不同模型/API 统一成 harness 可调用接口。
Task Adapter	Task Adapter	任务适配器	把数据样本转成 prompt、工具环境和期望输出。

符号/缩写	English	中文	含义
Dataset Adapter	Dataset Adapter	数据集适配器	读取、过滤、切分和版本化数据集。
Prompt Template	Prompt Template	提示模板	评测时固定的输入格式。
Runner	Runner	运行器	批量执行模型调用或 agent 任务的组件。
Sandbox	Sandbox	沙箱	隔离文件系统、网络和外部副作用的环境。
Environment	Environment	环境	agent 可以观察和行动的任务世界。
Oracle	Oracle	标准判定器	能可靠判断答案或最终状态是否正确的程序/标注。
Scorer	Scorer	打分器	将输出转成数值分数的组件。
Judge	Judge	裁判模型/评审者	用模型或人类判断开放式输出质量。
LLM-as-a-Judge	LLM as a Judge	大模型裁判	用 LLM 给答案、引用或轨迹评分。
HELM	Holistic Evaluation of Language Models	语言模型整体评测	Stanford CRFM 的综合评测框架。
VHELM	Vision Holistic Evaluation of Language Models	视觉语言模型整体评测	HELM 思路扩展到 VLM 的评测。
MMLU	Massive Multitask Language Understanding	大规模多任务语言理解基准	常见知识和推理评测。
MRR	Mean Reciprocal Rank	平均倒数排名	检索排序指标。
F1	F1 Score	F1 分数	precision 和 recall 的调和平均。
SWE-bench	Software Engineering Benchmark	软件工程基准	真实 GitHub issue 修复任务。
TAU-bench	Tool-Agent-User Benchmark	工具-智能体-用户交互基准	业务工具调用和用户交互任务。
Trace	Trace	轨迹日志	记录 prompt、tool call、observation、输出和分数。
Trajectory	Trajectory	执行轨迹	agent 从开始到结束的动作序列。

符号/缩写	English	中文	含义
Replay	Replay	回放	用保存的输入、状态和工具结果复现实验。
pass@k	Pass at k	k 次通过率	采样 k 次至少一次成功的概率指标。
Contamination	Data Contamination	数据污染	测试集进入训练数据或 prompt 导致分数虚高。
Decontamination	Decontamination	去污染	检查并移除训练/评测重叠的过程。
CI	Continuous Integration	持续集成	代码变更后自动运行测试和评测的工程流程。
M	Model	模型	被评测的基础模型或系统。
T	Task Set	任务集合	benchmark 中的任务样本集合。
H	Harness	评测框架	执行评测的系统层。
s_i	Score	第 i 个样本分数	单个任务的评分。

本章目标

- 理解 benchmark、eval、harness、leaderboard 的区别。
- 能解释为什么 2026 年要报告 model + harness + scaffold，而不是只报 model 名。
- 能设计 LLM、RAG、coding agent、VLM 的评测 harness。
- 能识别 benchmark 污染、工具预算不公平、LLM judge 偏差、pass@k 滥用。
- 能把 eval 接入研发闭环，而不是只跑一次排行榜。

Harness 是什么

Harness 本质上是“把评测跑起来并保证可复现”的系统层。

它通常负责：

- 读数据集和版本。
- 构造 prompt 或工具环境。
- 调用模型/API。
- 控制 temperature、top-p、seed、max tokens、thinking budget。
- 管理工具、权限、sandbox、timeout。
- 解析输出。
- 调用 scorer、oracle 或 judge。
- 保存 trace、日志、成本和错误。
- 生成报告。

面试表达：

Benchmark 是题，metric 是怎么算分，harness 是把题以固定协议喂给模型并记录结果的执行系统。对 agent 来说，harness 还包含工具、状态、权限、恢复和 trace，所以分数不能只归因于 base model。

Benchmark、Harness、Scaffold 的区别

概念	English	中文	关注点
Benchmark	Benchmark	基准	任务集合、标准答案、指标。
Harness	Harness	评测/执行框架	如何执行任务、调用模型、打分、记录。
Scaffold	Scaffold	外部脚手架	agent 的 planner、memory、tools、verifier、retry 逻辑。
Leaderboard	Leaderboard	排行榜	按某协议汇总比较分数。
Protocol	Protocol	协议	是否允许工具、预算、采样次数、prompt 格式。

一个模型的分数可以抽象成：

$$Score = f(M, H, T, P, B)$$

其中 M 是模型， H 是 harness， T 是任务集合， P 是 prompt/protocol， B 是预算。只说“某模型在某榜单多少分”往往信息不足。

LM Evaluation Harness

EleutherAI 的 LM Evaluation Harness 是经典 model eval harness。它把很多文本 benchmark 统一到同一套接口里。

核心组件：

- model adapter：Hugging Face、vLLM、SGLang、API model。
- task config：数据集、prompt、few-shot、metric。
- runner：批量执行。
- output parser：解析模型输出。
- metric：accuracy、exact match、F1、perplexity 等。

适合：

- 基础语言理解。
- few-shot / zero-shot benchmark。
- 开源模型横向比较。
- 回归测试某次训练或微调是否退化。

局限：

- 很多任务是静态文本，不覆盖工具使用。
- 对 reasoning model，要处理 hidden CoT / think_end_token。
- 对 agentic 系统，单轮 harness 不够。

OpenAI Evals 与自定义 Eval

OpenAI Evals 代表另一类思路：把 eval 当成产品和模型迭代的一部分。

典型结构：

1. 样本：输入、期望行为、评分标准。
2. Completion function：调用某个模型或系统。
3. Eval class：执行样本并收集输出。
4. Scorer：程序打分或 LLM-as-a-judge。
5. Report：聚合错误类型和样例。

面试重点：

生产 eval 不是只跑 MMLU，而是把真实用户失败样本、红队样本、权限边界样本、格式约束样本持续加入回归集。

Agent Harness

Agent harness 比普通 model harness 多很多东西。

模块	English	中文	作用
Context Manager	Context Manager	上下文管理器	决定给模型看哪些历史、文件和工具结果。
Tool Runtime	Tool Runtime	工具运行时	执行 shell、browser、database、editor。
State Store	State Store	状态存储	保存任务进度、文件 diff、memory。
Permission Gate	Permission Gate	权限门	控制写操作、网络、支付、删除等风险动作。
Recovery Policy	Recovery Policy	恢复策略	工具失败、超时、循环时如何处理。
Trace Logger	Trace Logger	轨迹日志	记录每步动作和观察。
Validator	Validator	验证器	检查最终 artifact、测试结果、业务状态。

Harness-Bench 这类研究强调：同一个 base model 在不同 harness 下可能表现差很多。因此报告 agent 能力时要说明：

- 模型版本。
- harness 版本。
- 工具集合。
- 上下文策略。
- 是否允许并行尝试。
- 时间和 token 预算。
- 是否有 reviewer/verifier。
- 最终如何判定成功。

Coding Agent Harness

Coding agent 的 harness 通常包含：

1. 仓库快照：固定 commit。
2. Issue 描述：用户需求或真实 bug。
3. Sandbox：隔离执行代码。
4. Tool set：搜索、编辑、测试、lint、类型检查。
5. Patch capture：记录最终 diff。
6. Hidden tests：避免只拟合公开测试。
7. Validator：运行测试或人工验证。
8. Trace：记录每次命令、文件读取和修改。

评测指标：

- pass@1。
- pass@k。
- resolved rate。
- regression rate。
- tool error rate。
- average cost。
- time-to-resolution。
- patch size。

面试表达：

SWE-bench 分数不只是模型能力，还取决于 scaffold、工具、测试预算、重试策略和 patch 验证方式。比较 coding agent 时必须看 protocol。

RAG Harness

RAG harness 需要同时固定 corpus、query、权限、gold evidence 和 judge。

最小结构：

- corpus version：文档库版本。
- index version：chunking、embedding、reranker 版本。

- query set：用户问题集合。
- gold evidence：标准证据块。
- expected answer：标准答案或评分 rubrics。
- permission scope：每个 query 允许访问哪些文档。
- scorer：retrieval scorer、generation scorer、citation scorer。

RAG harness 输出不应该只有 answer accuracy，还要有：

- Recall@k。
- MRR。
- citation precision。
- unsupported claim rate。
- refusal precision / recall。
- latency。
- cost。
- permission violation rate。

LLM-as-a-Judge 怎么用

LLM-as-a-Judge 适合开放式答案，但不能裸用。

要注意：

- 先用人工样本校准 judge。
- prompt 里明确评分 rubrics。
- 使用 pairwise comparison 通常比绝对打分更稳定。
- 对 judge 本身做版本固定。
- 对安全和权限问题优先用规则或 oracle。
- 记录 judge rationale，但不要把 rationale 当真值。

常见问题：

- position bias：更偏好第一个答案。
- verbosity bias：更偏好长答案。
- self-preference：偏好同系列模型输出。
- rubric drift：评分标准不稳定。
- evidence blindness：没有认真核对引用。

污染、泄漏与可比性

2026 年 benchmark 最大的问题之一是可比性。

常见风险：

- test contamination：测试集进入预训练或微调数据。
- prompt leakage：评测 prompt 在网上公开并被训练。
- overfitting leaderboard：专门优化公开榜。
- hidden scaffold：不同模型使用了不同外部工具或预算。

- pass@k abuse: 用大量采样把分数堆高, 却不报告成本。
- benchmark saturation: 题目太简单, 区分不了前沿模型。

报告结果时至少说明:

1. 模型版本。
2. harness 版本。
3. benchmark 版本。
4. prompt 模板。
5. decoding 参数。
6. tool access。
7. thinking budget。
8. retries / pass@k。
9. 成本和延迟。
0. 是否做 decontamination。

Eval 研发闭环

一个成熟团队不会只在发布前跑一次评测, 而是建立闭环:

线上失败样本 -> 标注/归因 -> 加入 eval set -> 修模型/修系统 -> CI 回归 -> 灰度监控

评测集应该分层:

- smoke eval: 几十条, 提交前快速跑。
- regression eval: 几百到几千条, 覆盖核心场景。
- red-team eval: 安全、越权、prompt injection。
- canary eval: 新模型或新 prompt 灰度前跑。
- online eval: 真实流量抽检和人工反馈。

面试表达:

Eval 的价值不是得一个分数, 而是形成 failure taxonomy 和回归闭环。每次线上事故或人工纠错都应该沉淀成可复现 eval。

面试高频问题

1. Harness 和 benchmark 有什么区别?

Benchmark 是题和指标, harness 是执行系统。Harness 决定 prompt、工具、预算、解析、打分、日志和复现方式。

2. 为什么 agent 要报告 model-harness 组合?

因为 agent 能力强依赖工具、context management、retry、verifier、sandbox 和权限策略。同一模型换 harness, 成功率和失败模式都可能变。

3. 怎么设计一个 RAG eval harness?

固定 corpus/index/query/gold evidence/permission scope，分别评估 retrieval、rerank、generation、citation、refusal、latency、cost 和越权率。

4. LLM-as-a-Judge 靠谱吗?

可以用于趋势和开放式评测，但要用人工样本校准，固定 judge 版本，控制位置偏差和冗长偏差；高风险结论要用规则、oracle 或人工复核。

5. 为什么排行榜分数不能直接横比?

因为 prompt、decoding、thinking budget、tool access、scaffold、pass@k 和测试污染都可能不同。面试里要先问 protocol，再看分数。

本章 References

- [EleutherAI LM Evaluation Harness](#)
- [OpenAI Evals](#)
- [HELM: Holistic Evaluation of Language Models](#)
- [VHELM: A Holistic Evaluation of Vision Language Models](#)
- [Harness-Bench: Measuring Harness Effects across Models in Realistic Agent Workflows](#)
- [SWE-bench: Can Language Models Resolve Real-World GitHub Issues?](#)
- [TAU-bench: A Benchmark for Tool-Agent-User Interaction in Real-World Domains](#)

[章节索引](#)

[← 上一章](#) [下一章 →](#)