

强化学习面试课程 Roadmap

这套笔记面向 AI（Artificial Intelligence，人工智能）算法工程师的强化学习入门与面试准备。目标不是把强化学习研究方向穷尽，而是系统掌握面试中最常被考察的概念、公式、算法区别、训练技巧和项目表达方式。

0.1 全局符号和缩写说明

阅读约定：每个章节还会在开头重复列出本章会用到的核心符号。一般来说，大写字母表示随机变量、函数或集合，小写字母表示一次采样到的具体取值；例如 S_t 是时刻 t 的状态随机变量， s 是某个具体状态。

注意符号会按上下文复用：例如 A 可以表示 action space（动作空间），而 $A_\pi(s,a)$ 可以表示 advantage function（优势函数）； $P(s'/s,a)$ 是 transition probability， $P(i)$ 则是采样概率。

本套笔记统一使用大写 $V_\pi(s)$ 和 $Q_\pi(s,a)$ 表示价值函数；有些教材会写成小写 $v_\pi(s)$ 、 $q_\pi(s,a)$ ，含义相同，只是记号风格不同。

符号/缩写	English	中文	含义
AI	Artificial Intelligence	人工智能	本课程面向 AI 算法工程师的面试准备。
RL	Reinforcement Learning	强化学习	agent 通过交互学习最大化长期 reward 的范式。
MDP	Markov Decision Process	马尔可夫决策过程	RL 最常见的数学建模。
DP	Dynamic Programming	动态规划	已知环境模型时用 Bellman backup 求解 MDP 的方法。
MC	Monte Carlo	蒙特卡洛	用完整 episode 的真实 return 估计价值。
TD	Temporal Difference	时序差分	用一步 reward 加下一状态估计值做 bootstrap 更新。
epsilon-greedy	Epsilon-greedy Policy	epsilon-greedy 策略 / epsilon 贪心策略	以 ϵ 概率随机探索，否则选择当前价值最大的动作。
behavior policy	Behavior Policy	行为策略	实际和环境交互、产生训练样本的策略。
target policy	Target Policy	目标策略	算法真正想评估或优化的策略。
on-policy	On-policy Learning	同策略学习	behavior policy 和 target policy 是同一个策略。
off-policy	Off-policy Learning	异策略学习	用 behavior policy 的数据学习另一个 target policy。
SARSA	State-Action-Reward-State-Action	状态-动作-奖励-状态-动作	使用实际下一动作更新的 TD control 算法。
REINFORCE	REINFORCE algorithm	REINFORCE 算法	最基础的 Monte Carlo policy gradient 算法。
DQN	Deep Q-Network	深度 Q 网络	用神经网络近似动作价值函数 $Q(s,a)$ 。
TRPO	Trust Region Policy Optimization	信赖域策略优化	通过 KL 约束限制策略更新幅度。

符号/缩写	English	中文	含义
PPO	Proximal Policy Optimization	近端策略优化	用 clipping objective 稳定策略更新。
SAC	Soft Actor-Critic	软 Actor-Critic	最大熵 actor-critic 算法。
DDPG	Deep Deterministic Policy Gradient	深度确定性策略梯度	连续动作空间的 actor-critic 算法，通常用异策略数据训练。
TD3	Twin Delayed DDPG	双延迟 DDPG	改进 DDPG 稳定性的连续控制算法。
A2C / A3C	Advantage Actor-Critic / Asynchronous Advantage Actor-Critic	优势 Actor-Critic / 异步优势 Actor-Critic	actor-critic 的同步和异步版本。
GAE	Generalized Advantage Estimation	广义优势估计	用 λ 平衡 advantage 估计的 bias 和 variance。
UCB	Upper Confidence Bound	置信上界	bandit 中基于不确定性 bonus 的探索方法。
RLHF	Reinforcement Learning from Human Feedback	基于人类反馈的强化学习	用人类偏好信号优化模型行为。
RM	Reward Model	奖励模型	RLHF 中根据偏好数据学习出的奖励模型。
S / S_t	State / State at time t	状态空间 / 时刻 t 的状态	S 常表示状态空间， S_t 表示状态随机变量。
A / A_t	Action / Action at time t	动作空间 / 时刻 t 的动作	A 常表示动作空间， A_t 表示动作随机变量。
R / R_{t+l}	Reward	奖励	R_{t+l} 表示执行 A_t 后收到的即时奖励。
G_t	Return	回报 / 累计折扣奖励	G_t 表示从时刻 t 开始的累计收益； G 是常用记号，不建议理解成固定英文缩写。
$P(s' s, a)$	Transition Probability	状态转移概率	在状态 s 执行动作 a 后转移到 s' 的概率。
$V_\pi(s)$	State-value Function	状态价值函数	策略 π 下状态 s 的期望 return。
$Q_\pi(s, a)$	Action-value Function	动作价值函数	策略 π 下，在 s 先执行 a 的期望 return； Q 可理解为 action quality。
$A_\pi(s, a)$	Advantage Function	优势函数	动作 a 相对状态平均价值的优势；这里的 A 不是 action space。
π	Policy	策略	从 state 到 action 或 action distribution 的映射。
γ	Discount Factor	折扣因子	控制未来 reward 的折扣强度。
θ / w	Parameters / Weights	参数 / 权重	神经网络或函数逼近器的可学习参数。
$J(\theta)$	Objective Function	优化目标函数	policy optimization 中要最大化的目标。
$L(\theta)$	Loss Function	损失函数	训练神经网络时要最小化的目标。

符号/缩写	English	中文	含义
$H(\pi)$	Entropy	熵	衡量策略随机性，常用于鼓励探索。
KL	Kullback-Leibler Divergence	KL 散度	衡量两个概率分布差异。

0.2 学习目标

学完后你应该能做到：

- 清楚解释强化学习和监督学习的区别。
- 熟练写出 MDP、return、value function、Bellman equation。
- 区分 DP、Monte Carlo、TD、SARSA、Q-learning。
- 解释 DQN 为什么需要 replay buffer 和 target network。
- 推导 policy gradient 的核心公式。
- 讲清 Actor-Critic、GAE、PPO、SAC 的动机。
- 理解 offline RL、imitation learning、RLHF 的基础问题。
- 准备一套可以在面试中讲清楚的 RL 项目。

0.3 全课程主线

这套课按“问题建模 -> 精确求解 -> 采样估计 -> 函数逼近 -> 策略优化 -> 进阶约束”的顺序组织。每章不是孤立算法，而是在回答上一个阶段留下的问题：

章节	主要问题	逻辑位置
第 1 章	RL 问题如何写成 MDP、return、value 和 Bellman 方程	建立统一语言
第 2 章	如果环境模型已知，怎样用 DP 精确做 evaluation 和 improvement	Bellman 方程的精确求解原型
第 3 章	如果模型未知，怎样用采样做 prediction 和 control	从 DP 过渡到 model-free tabular RL
第 4 章	学 Q 或 policy 时，数据从哪里来，如何平衡探索和利用	解释采样数据质量
第 5 章	表格法放不下真实状态空间时，怎样用函数逼近	进入 deep RL 的必要前提
第 6 章	Q-learning 加神经网络为什么会不稳，DQN 如何稳定它	value-based deep RL
第 7 章	不想通过 $\arg\max Q$ 选动作时，如何从 Policy Gradient 推到 REINFORCE、baseline 与 MC advantage	policy-based RL，不使用 TD Critic
第 8 章	如何把 MC baseline 变成 TD Critic，再推到 n-step、GAE 和 A2C/A3C	actor-critic 框架
第 9 章	policy 更新太大导致崩溃时，如何限制更新幅度	现代 on-policy 稳定训练
第 10 章	连续动作下无法枚举动作时，如何做 off-policy actor-critic	连续控制

章节	主要问题	逻辑位置
第 11 章	交互、模型、离线数据、人类反馈带来哪些新约束	高级 RL 与 LLM 对齐接口
第 12 章	面试中如何横向比较、推公式、讲项目	收束成可表达知识体系

0.4 推荐学习节奏

建议周期：6 到 8 周。

建议投入：每周 8 到 10 小时。

每章建议按这个顺序学习：

1. 先读核心概念。
2. 手写关键公式。
3. 用自己的话讲一遍算法直觉。
4. 回答本章面试高频问题。
5. 至少实现或阅读一个最小代码版本。
6. 独立完成章末练习，再点击展开参考答案核对推理过程。

0.5 推导阅读方式

RL 的公式不要直接背结论，建议按下面链路推：

1. 先写目标：agent 要最大化长期 return，而不是单步 reward。
2. 再拆递归：把 G_t 写成 $R_{t+1} + \gamma G_{t+1}$ ，自然得到 Bellman 思路。
3. 再区分期望和采样：Bellman 方程是期望形式，TD、SARSA、Q-learning 是用一次 transition 近似这个期望。
4. 再看函数逼近：DQN 把 tabular update 变成对 Bellman target 的监督回归。
5. 再看策略优化：policy gradient 用 log-derivative trick 处理“采样分布本身依赖参数”的问题；理论 Q_π 是 G_t 的条件期望，REINFORCE 用采样 G_t 估计它。
6. 再看方差控制：baseline 来自 action-independent control variate；取 $V_\pi(s)$ 后， $G_t - V_\pi(s_t)$ 是 advantage 的 Monte Carlo 估计。
7. 再引入 Critic：TD、n-step 和 GAE 用 bootstrap 换取更低方差与更快更新，这时才进入 Actor-Critic。
8. 最后看稳定化：target network、replay、PPO clipping、SAC entropy 分别处理不同算法中的移动目标、样本相关性、策略漂移和探索。

面试里如果一时忘公式，可以从这条链路往回推：目标是什么，target 是什么，target 为什么可靠，更新过大或估计不准会出什么问题。

0.6 新名词阅读约定

本套笔记后续按一个硬规则写：一个新名词第一次进入推导前，必须先说明它的英文、中文、解决什么问题，以及它和当前公式的关系。

读到算法段落时，建议先检查四件事：

1. 当前数据是谁采出来的，也就是 behavior policy。
2. 当前算法想学谁，也就是 target policy。
3. 当前 target 用的是完整 return、实际下一动作，还是 greedy max。
4. 因此它是 on-policy 还是 off-policy。

0.7 例子阅读方式

每章都补了“本章例子”或“典型例子”。读例子时不要只记场景名，要把它映射回四件事：

1. 状态是什么。
2. 动作是什么。
3. 奖励怎么定义。
4. 算法为什么适合这个场景。

例如 CartPole 不是“一个小游戏”，而是：

元素	例子
状态	小车位置、速度、杆角度、角速度。
动作	向左推或向右推。
奖励	杆保持不倒时每步 +1。
算法	离散动作、低维状态时可用 DQN 或 PPO。

面试时讲例子的目的不是展示你见过环境，而是证明你能把业务问题建模成 MDP，再解释为什么某个算法匹配这个 MDP。

0.8 章节目录

章节	文件	主题
第 1 章	01-rl-fundamentals-mdp-bellman	RL 基本设定、MDP、价值函数、Bellman 方程
第 2 章	02-dynamic-programming	Policy Evaluation、Policy Iteration、Value Iteration
第 3 章	03-monte-carlo-td-learning	Monte Carlo、TD、SARSA、Q-learning
第 4 章	04-exploration-bandit	探索与利用、Multi-Armed Bandit、UCB、Thompson Sampling
第 5 章	05-function-approximation-deadly-triad	函数逼近、稳定性、Deadly Triad
第 6 章	06-dqn-and-variants	DQN、Double DQN、Dueling DQN、Prioritized Replay
第 7 章	07-policy-gradient	Policy Gradient、REINFORCE、 Q_π 与 G_t 、baseline、MC advantage、混合动作策略
第 8 章	08-actor-critic-gae	从 MC baseline 到 TD Critic、n-step、GAE、A2C/A3C
第 9 章	09-ppo-trpo	TRPO、PPO、KL 约束、clipping objective
第 10 章	10-continuous-control-ddpg-td3-sac	DDPG、TD3、SAC、连续动作控制
第 11 章	11-model-based-offline-imitation-rlhf	Model-based RL、Offline RL、Imitation Learning、RLHF
第 12 章	12-interview-cheatsheet-projects	面试速查、横向对比、项目准备

0.9 面试复习优先级

如果时间有限，优先掌握：

1. MDP、Bellman 方程、V/Q 函数。

2. MC vs TD, SARSA vs Q-learning。
3. on-policy vs off-policy。
4. DQN 的 replay buffer、target network、Double DQN。
5. Policy Gradient 推导, baseline 为什么不引入 bias。
6. Actor-Critic 和 GAE。
7. PPO clipping objective。
8. SAC 的 entropy regularization。
9. offline RL 为什么难。
10. RLHF 的 PPO/RM/Preference data 基本流程。

0.10 推荐资料

- Sutton & Barto, Reinforcement Learning: An Introduction
- David Silver Reinforcement Learning Course
- OpenAI Spinning Up
- CleanRL single-file implementations
- Stable-Baselines3 文档和示例

0.11 面试表达模板

学习每个算法时, 都尝试用这个模板总结:

```
算法名:
解决的问题:
核心思想:
目标函数或更新公式:
on-policy/off-policy:
value-based/policy-based/actor-critic:
稳定训练技巧:
优点:
缺点:
常见面试追问:
```