

第 3 章：MC (Monte Carlo, 蒙特卡洛)、TD (Temporal Difference, 时序差分)、SARSA 与 Q-learning

本章符号说明

符号/缩写	English	中文	含义
MC	Monte Carlo	蒙特卡洛	用完整 episode 的真实 return 估计价值。
TD	Temporal Difference	时序差分	用 bootstrap target 在线更新价值估计。
SARSA	State-Action-Reward-State-Action	状态-动作-奖励-状态-动作	更新公式使用的五元组名称。
$S_t / A_t / R_{t+1}$	State / Action / Reward	状态 / 动作 / 奖励	一步交互中的随机变量。
G_t	Return	回报 / 累计折扣奖励	从时刻 t 到 episode 结束的累计收益。
$V(s)$	State-value Function	状态价值函数	状态 s 的长期价值估计。
$Q(s,a)$	Action-value Function	动作价值函数	状态 s 下动作 a 的长期价值估计。
δ_t	TD Error	时序差分误差	bootstrap target 和当前估计之间的差。
α	Learning Rate	学习率	控制每次更新幅度。
γ	Discount Factor	折扣因子	控制未来 reward 权重。
RL	Reinforcement Learning	强化学习	本章讨论 model-free RL 的估值和控制方法。
REINFORCE	REINFORCE algorithm	REINFORCE 算法	on-policy Monte Carlo policy gradient 算法。
DQN	Deep Q-Network	深度 Q 网络	off-policy value-based deep RL 算法。
DDPG	Deep Deterministic Policy Gradient	深度确定性策略梯度	连续动作空间的 off-policy actor-critic 算法。
TD3	Twin Delayed DDPG	双延迟 DDPG	DDPG 的稳定化改进。

符号/缩写	English	中文	含义
SAC	Soft Actor-Critic	软 Actor-Critic	最大熵 off-policy actor-critic 算法。
PPO	Proximal Policy Optimization	近端策略优化	on-policy actor-critic 算法。
A2C	Advantage Actor-Critic	优势 Actor-Critic	on-policy actor-critic 算法。

本章目标

本章进入 model-free RL。你需要掌握：

- Monte Carlo 方法。
- Temporal Difference Learning。
- MC 和 TD 的 bias/variance 区别。
- SARSA。
- Q-learning。
- on-policy 与 off-policy。

Model-free 的含义

Model-free 指的是不需要显式知道环境转移模型：

$$P(s' | s, a), R(s, a, s')$$

Agent 只通过和环境交互得到样本：

$$(s, a, r, s')$$

然后用这些样本估计价值函数或优化策略。

Monte Carlo 方法

Monte Carlo 方法用完整 episode 的实际 return 来估计价值。

对于状态价值：

$$V(s) \leftarrow \text{average of returns observed after visiting } s$$

增量形式：

$$V(s) \leftarrow V(s) + \alpha [G_t - V(s)]$$

其中 G_t 是从时间 t 到 episode 结束的真实累计 return。

特点：

- 不需要环境模型。
- 不需要 bootstrap。
- 必须等 episode 结束才能计算 return。
- 方差通常较大。
- 估计是无偏的，前提是采样足够充分。

First-visit MC：

每个 episode 中，一个状态第一次出现时才用它更新。

Every-visit MC：

每个 episode 中，一个状态每次出现都可以用来更新。

MC 的推理过程

MC 的出发点是价值函数定义：

$$V_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s]$$

这个式子里真正难的是期望。MC 的想法很朴素：

1. 我不知道这个期望的解析值。
2. 但我可以多跑很多条 episode。
3. 每次访问状态 s 后，都能观察到一个真实 return G_t 。
4. 多个 G_t 的平均值，就近似这个期望。

所以 tabular MC 更新写成：

$$V(s) \leftarrow V(s) + \alpha [G_t - V(s)]$$

这里 $G_t - V(s)$ 可以理解为“这次真实观察到的长期回报”和“当前估计”的差。更新不是一次替换成 G_t ，而是用学习率 α 做平滑平均。

为什么 MC 方差大？

- 同一个状态后面可能经历很长的随机轨迹。
- 后续每一步动作、转移、reward 都会影响 G_t 。
- 轨迹越长、随机性越强，return 波动越大。

但 MC 的好处是 target 不依赖当前价值函数估计，所以 bootstrap bias 小。

TD Learning

Temporal Difference Learning 结合了 Monte Carlo 和 Dynamic Programming 的思想。

TD(0) 更新：

$$V(S_t) \leftarrow V(S_t) + \alpha [R_{t+1} + \gamma V(S_{t+1}) - V(S_t)]$$

TD target：

$$R_{t+1} + \gamma V(S_{t+1})$$

TD error:

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$$

特点:

- 不需要环境模型。
- 不需要等 episode 结束。
- 使用 bootstrap, 用当前估计 $V(S_{t+1})$ 更新当前估计。
- 通常方差低于 MC, 但可能有 bias。

TD 的推理过程

TD 从 Bellman expectation 的紧凑形式来:

$$V_{\pi}(s) = \mathbb{E}_{\pi}[R_{t+1} + \gamma V_{\pi}(S_{t+1}) | S_t = s]$$

如果我们有环境模型, 可以像 DP 一样对所有 s' 求期望。但 model-free 场景下, 我们只有一次采样:

$(S_t, A_t, R_{t+1}, S_{t+1})$

于是把期望里的随机变量用这一次样本替代, 得到一步 bootstrap target:

$$R_{t+1} + \gamma V(S_{t+1})$$

再用“target 减当前估计”构造误差:

$$\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$$

最后更新:

$$V(S_t) \leftarrow V(S_t) + \alpha \delta_t$$

这就是 TD 的核心推理:

Bellman 方程给了期望 target; model-free 不能精确求期望, 就用采样 transition 做随机近似; 为了不等 episode 结束, 用下一状态当前价值估计 bootstrap。

MC vs TD

维度	Monte Carlo	TD
是否需要模型	不需要	不需要

维度	Monte Carlo	TD
是否需要完整 episode	需要	不需要
是否 bootstrap	否	是
目标	真实 return G_t	$r + \gamma V(s')$
方差	较高	较低
偏差	较低	有 bootstrap bias
适用场景	episodic task	episodic 或 continuing task

面试表达：

MC 用完整轨迹的真实 return 做 target，不 bootstrap，所以 bias 小但 variance 大。TD 用一步 reward 加下一状态的估计值做 target，能在线更新，variance 小，但因为 target 依赖当前估计，所以会引入 bias。

SARSA

SARSA 是 on-policy TD control 方法。名字来自一次更新用到的五元组：

$$(S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1})$$

更新公式：

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

关键点：

- A_{t+1} 是当前行为策略实际选择的动作。
- 如果行为策略是 epsilon-greedy，那么 SARSA 的 target 也包含探索动作的影响。
- 因此 SARSA 是 on-policy。

直觉：

SARSA 学的是“我按照当前这套带探索的策略行动，长期回报会是多少”。

SARSA 的 target 为什么是 $Q(s', a')$

对 action-value 来说，Bellman expectation 可以理解成：

$$Q_{\pi}(s, a) = \mathbb{E}[R_{t+1} + \gamma Q_{\pi}(S_{t+1}, A_{t+1})]$$

SARSA 在采样时真的执行了下一步动作 A_{t+1} 。如果当前行为策略是 epsilon-greedy，那么 A_{t+1} 可能是 greedy action，也可能是探索动作。

所以 SARSA 的 target 是：

$$R_{t+1} + \gamma Q(S_{t+1}, A_{t+1})$$

它把“探索可能造成的后果”也学进去。这就是为什么在 cliff walking 里 SARSA 更保守：它知道自己未来还可能因为 epsilon 探索而掉下去。

Q-learning

Q-learning 是 off-policy TD control 方法。

更新公式：

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

关键点：

- 行为时可以用 epsilon-greedy 探索。
- 更新 target 时直接用 $\max_a Q(s', a)$ 。
- 学习目标是 greedy policy 的价值，而不完全等于行为策略。
- 因此 Q-learning 是 off-policy。

直觉：

Q-learning 学的是“如果未来都选当前估计下最优的动作，长期回报会是多少”。

Q-learning 的 target 为什么用 max

Q-learning 对应的是 Bellman optimality 思路：

$$Q^*(s, a) = \mathbb{E}[R_{t+1} + \gamma \max_{a'} Q^*(S_{t+1}, a')]$$

model-free 场景下，把期望用一次 transition 近似，就得到 target：

$$R_{t+1} + \gamma \max_a Q(S_{t+1}, a')$$

这里要分清两件事：

- 行为时：可以用 epsilon-greedy 收集数据，保留探索。
- 学习时：target 假设未来执行 greedy action。

所以 Q-learning 是 off-policy。它不是在评估“实际带探索的行为策略”，而是在用探索数据学习一个 greedy target policy 的价值。

面试里可以这样推：

SARSA 从 Bellman expectation 来，下一动作就是行为策略实际采样的 a' ；Q-learning 从 Bellman optimality 来，下一动作取当前 Q 最大的动作。因此 SARSA on-policy，Q-learning off-policy。

SARSA vs Q-learning

维度	SARSA	Q-learning
策略类型	on-policy	off-policy
target	$r + \gamma Q(s', a')$	$r + \gamma \max_a Q(s', a)$
是否考虑探索动作影响	是	否
风格	更保守	更贪心
学习目标	当前行为策略	最优 greedy 策略

经典 cliff walking 例子：

- SARSA 会考虑 epsilon-greedy 探索可能掉下悬崖，因此倾向选择更安全路径。
- Q-learning 更新时假设未来总能选最优动作，因此更倾向学习贴近悬崖的最短路径。

On-policy vs Off-policy

On-policy：

学习和评估的是当前实际采样的行为策略。

$$\pi_{behavior} = \pi_{target}$$

例如：

- SARSA
- REINFORCE
- A2C
- PPO

Off-policy：

用一种行为策略收集数据，但学习另一种目标策略。

$$\pi_{behavior} \neq \pi_{target}$$

例如：

- Q-learning
- DQN
- DDPG

- TD3
- SAC

off-policy 的优势：

- 可以复用历史数据。
- sample efficiency 通常更高。
- 可以从 replay buffer 学习。

off-policy 的难点：

- 分布不匹配。
- 重要性采样或 value correction 可能带来高方差。
- 结合函数逼近和 bootstrap 时可能不稳定。

本章面试高频问题

1. MC 和 TD 的区别？

MC 用完整 episode 的真实 return 更新，不 bootstrap，bias 小但 variance 大。TD 用 $r + \gamma V(s')$ 这种一步 bootstrap target 更新，可以在线学习，variance 小但有 bias。

2. SARSA 和 Q-learning 的区别？

SARSA 是 on-policy，target 使用实际采样到的下一个动作 a' 。Q-learning 是 off-policy，target 使用 $\max_a Q(s', a)$ ，学习 greedy target policy。

3. 为什么 Q-learning 是 off-policy？

因为采样数据可以来自 epsilon-greedy 行为策略，但更新目标是假设下一步选择 greedy action 的价值，即 target policy 和 behavior policy 不同。

4. TD error 是什么？

TD error 是当前价值估计和 bootstrap target 之间的差：

$$\delta = r + \gamma V(s') - V(s)$$

它衡量当前估计需要被修正的方向和大小。

5. 为什么 TD 可以不等 episode 结束？

因为 TD target 只需要一步 reward 和下一状态的当前价值估计，不需要完整轨迹 return。

本章练习

1. 手写 SARSA 和 Q-learning 的更新公式。
2. 解释为什么 SARSA 在 cliff walking 中更保守。
3. 写一个 tabular Q-learning 的伪代码。
4. 用 bias/variance 角度比较 MC 和 TD。

