

第 4 章：探索与利用、Bandit、UCB（Upper Confidence Bound，置信上界）与 Thompson Sampling

4.1 本章符号说明

符号/缩写	English	中文	含义
UCB	Upper Confidence Bound	置信上界	用价值估计加不确定性 bonus 做探索。
K	Number of Arms	拉杆数量 / 动作数量	K-armed bandit 中候选动作的数量。
A_t	Action at time t	时刻 t 的动作	bandit 或 RL 中当前选择的动作。
R_t	Reward at time t	时刻 t 的奖励	本轮选择动作后获得的奖励。
$Q_t(a)$	Action-value Estimate	动作价值估计	到时刻 t 为止动作 a 的平均 reward 估计。
$N_t(a)$	Action Count	动作选择次数	到时刻 t 为止动作 a 被选过多少次。
ε	Exploration Probability	探索概率	epsilon-greedy 中随机选择动作的概率。
$P(a s)$	Action Sampling Probability	动作采样概率	softmax exploration 在状态 s 选择动作 a 的概率。
μ_a / μ^*	Mean Reward / Best Mean Reward	平均奖励 / 最优平均奖励	动作 a 或最优动作的期望奖励。
$Regret(T)$	Cumulative Regret	累计后悔值	到时间 T 为止因为没有总选最优动作损失的收益。
τ	Temperature	温度参数	softmax exploration 中控制分布平滑程度。
c	Exploration Coefficient	探索系数	UCB 中控制不确定性 bonus 强度的正数。
θ_a	Bernoulli Success Probability	Bernoulli 成功概率	Thompson Sampling 例子中动作 a 的未知真实点击率。
α_a / β_a	Beta Posterior Parameters	Beta 后验参数	分别累计动作 a 的成功和失败证据；不是学习率或熵系数。
RL	Reinforcement Learning	强化学习	探索与利用是 RL 的核心问题之一。
DQN	Deep Q-Network	深度 Q 网络	常用 epsilon-greedy 做探索的 value-based 算法。

4.2 本章目标

本章讨论强化学习中的 exploration-exploitation tradeoff。你需要掌握：

- 为什么需要探索，以及 exploration / exploitation 的矛盾。

- 基础采样策略：epsilon-greedy 和 softmax exploration。
- Bandit 为什么是研究探索的最小模型。
- Bandit 里的评价指标：regret。
- 利用不确定性的 bandit 采样策略：UCB 和 Thompson Sampling。
- 这些探索方法在完整 RL 里如何落到 behavior policy、NoisyNet 等机制上。

4.3 本章主线

第 3 章默认 agent 能持续拿到交互样本，但样本本身由策略决定。策略如果只选当前最优动作，可能永远发现不了更好动作；如果一直随机试，又会牺牲收益。

本章结构是：

1. 先定义 exploration-exploitation tradeoff。
2. 再讲只依赖当前价值估计的基础采样策略：epsilon-greedy 和 softmax。
3. 接着用 bandit 把探索问题单独抽出来，并引入 regret。
4. 然后讲 bandit 中利用不确定性的采样策略：UCB 和 Thompson Sampling。
5. 最后回到完整 RL，说明探索机制如何成为 behavior policy 或参数空间探索。

4.4 本章新增概念说明

先把本章会反复出现的探索名词说明清楚：

名词	中文	先记住什么
exploration	探索	尝试还不确定的动作，目的是发现潜在更优选择。
exploitation	利用	选择当前估计最好的动作，目的是获得已知收益。
epsilon-greedy	epsilon-greedy 策略	以 ϵ 概率随机探索，否则选择当前 Q 最大的动作。
greedy action	贪心动作	当前价值估计下最好的动作，即 $\arg \max_a Q(s,a)$ 。
softmax exploration	softmax 探索	按价值大小分配采样概率，价值越高越容易被选中。
temperature	温度参数	控制 softmax 分布平滑程度；温度高更随机，温度低更贪心。
bandit / arm	多臂老虎机 / 拉杆	只考虑动作和即时 reward、暂时不考虑状态转移的探索问题。
regret	后悔值	因为没总选最优动作而损失的累计收益。
UCB	置信上界	当前平均收益加不确定性 bonus，偏向探索不确定动作。
Thompson Sampling	Thompson 采样	从每个动作的后验分布采样，用概率匹配方式探索。
posterior	后验分布	看到历史数据后，对某个动作真实收益的概率估计。

名词	中文	先记住什么
NoisyNet	噪声网络	在网络参数中加入噪声，让探索发生在参数或策略层面。

4.5 探索问题的基本概念

4.5.1 探索与利用

强化学习中，agent 面临两个目标：

- exploitation：选择当前看起来最好的动作，最大化已知收益。
- exploration：尝试不确定的动作，发现潜在更好的选择。

如果只 exploitation，可能永远错过更优动作。

如果只 exploration，则无法稳定获得高收益。

面试表达：

Exploration-exploitation tradeoff 是 RL 的核心问题之一。Agent 需要在利用当前价值估计和探索未知动作之间平衡。探索不足会导致局部最优，探索过多会损害短期收益和训练稳定性。

这一节只是定义问题：agent 到底为什么不能一直选当前最优动作。下面的 epsilon-greedy、softmax、UCB、Thompson Sampling 才是不同的动作采样策略。

4.6 基础采样策略：只依赖当前价值估计

这一组方法只看当前 action-value estimate，不显式建模“这个估计有多不确定”。它们适合作为 RL 里的基础 behavior policy。

4.6.1 Epsilon-greedy

epsilon-greedy 是最常见的探索策略。

```
with probability epsilon:
    choose random action
otherwise:
    choose argmax_a Q(s, a)
```

优点：

- 简单。
- 容易实现。
- DQN 等算法常用。

缺点：

- 随机探索没有方向。
- 对所有非 greedy 动作一视同仁。
- 在大动作空间中效率较低。

常见工程做法：

epsilon starts high and decays over time

例如从 1.0 逐渐衰减到 0.05。

4.6.2 Softmax Exploration

softmax exploration 按照 action-value 的 softmax 概率采样动作：

$$P(a | s) = \exp(Q(s, a) / \tau) / \sum_b \exp(Q(s, b) / \tau)$$

其中 b 只是遍历全部候选动作的求和下标， $P(a|s)$ 是最终采样动作 a 的概率， τ 是 temperature：

- τ 大：分布更平，探索更多。
- τ 小：分布更尖，接近 greedy。

相比 epsilon-greedy，softmax 会更偏向价值较高的动作，而不是均匀随机探索。

缺点：

- 对 Q 值尺度敏感。
- 如果 Q 值估计不准，采样分布也会被误导。

4.7 Bandit 问题：把探索单独抽出来研究

Bandit 是研究 exploration-exploitation 的最小模型。先在 bandit 中理解“动作采样策略如何权衡收益和不确定性”，再回到完整 RL。

4.7.1 Multi-Armed Bandit

Bandit 是最简单的 sequential decision 问题：

- 只有动作，没有状态转移。
- 每个 action 对应一个未知 reward distribution。
- 目标是在不断试验中最大化累计 reward。

K-armed bandit：

```
choose action A_t in {1, ..., K}
receive reward R_t
```

它可以看成没有状态或只有单一状态的 RL 问题。

Bandit 在推荐系统、广告投放、A/B testing 中非常常见。

4.7.2 Bandit 和完整 RL 的关系

本章先讲 bandit，不是因为 bandit 比 RL 更重要，而是因为它把“探索”从复杂的状态转移里单独抽出来。

维度	Bandit	完整 RL
状态	通常没有状态，或只有单一状态	有状态 s
动作影响	主要影响当前 reward	同时影响当前 reward 和未来状态
学习目标	找到平均 reward 高的动作	找到长期 return 高的策略
探索难点	试哪个 arm	在什么状态试什么动作

所以 bandit 是完整 RL 的一个局部视角：先把“动作选择的不确定性”讲清楚，再回到有状态转移的长期决策问题。

4.7.3 Regret

Regret 衡量由于没有总是选择最优动作而损失的收益。

如果最优动作的期望奖励是 μ^* ，第 t 步选择动作的期望奖励是 μ_{a_t} ，则累计 regret：

$$Regret(T) = \sum_{t=1}^T (\mu^* - \mu_{a_t})$$

目标不是只最大化 reward，也可以表述为最小化 regret。

4.8 Bandit 采样策略：利用不确定性做探索

这一组策略不只是看当前平均收益，还会显式使用“不确定性”。UCB 用 confidence bonus 表达不确定性，Thompson Sampling 用 posterior sampling 表达不确定性。

4.8.1 UCB

Upper Confidence Bound，简称 UCB。

核心思想：

乐观面对不确定性。对不确定的动作给一个探索 bonus。

常见 UCB 形式：

$$A_t = \arg \max_a [Q_t(a) + c \sqrt{(\ln t / N_t(a))}]$$

其中：

- $Q_t(a)$ ：动作 a 当前平均 reward 估计。
- $N_t(a)$ ：动作 a 被选择次数。
- t ：总时间步。
- c ：控制探索强度。

解释：

- 如果动作被选得少， $N_t(a)$ 小，bonus 大。
- 如果动作被选得多，不确定性下降，bonus 变小。
- UCB 会系统性探索不确定动作，而不是随机探索。

平方根 bonus 不是凭经验随便拼出来的。对有界随机 reward，集中不等式会给出均值估计误差大致为 $\sqrt{(\log t / N_t(a))}$ 这一量级：样本数 $N_t(a)$ 增大时置信区间收窄，而总轮数 t 增大时，算法会以较慢速度重新检查长期没选的动作。不同 UCB 推导的常数会不同，但“经验均值 + 置信半径”的结构相同。实现时通常先把每个动作至少选一次，避免 $N_t(a)=0$ 时除零。

4.8.2 Thompson Sampling

Thompson Sampling 是一种 Bayesian exploration 方法。

流程：

1. 为每个动作维护 reward 分布参数的 posterior。
2. 每轮从每个动作的 posterior 中采样一个可能的参数。
3. 选择采样后看起来最优的动作。
4. 根据实际 reward 更新 posterior。

4.8.2.1 具体例子：Beta-Bernoulli 广告点击

假设有 3 个广告候选，reward 是二值点击：

```
click = 1
no click = 0
```

每个广告的真实点击率未知，记作 θ_a 。因为点击是 Bernoulli variable，所以可以给每个广告维护一个 Beta posterior：

$$\theta_a \sim \text{Beta}(\alpha_a, \beta_a)$$

初始化时，如果没有任何历史数据，可以用均匀先验：

$$\alpha_a=1, \beta_a=1$$

含义是：一开始不知道广告好坏，所有点击率都可能。

如果广告 a 被展示后：

- 用户点击了： $\alpha_a \leftarrow \alpha_a + 1$
- 用户没点击： $\beta_a \leftarrow \beta_a + 1$

因为 Beta 是 Bernoulli 的 conjugate prior，所以这个更新可以理解为：

```
alpha = 1 + click_count
beta = 1 + no_click_count
```

某一轮开始时，假设 posterior 是：

广告	历史点击 / 未点击	Posterior	后验均值
A	7 / 3	Beta(8, 4)	0.67
B	2 / 2	Beta(3, 3)	0.50
C	1 / 5	Beta(2, 6)	0.25

如果只看均值，会选择 A。但 Thompson Sampling 不直接选均值，而是每轮从每个 posterior 里采样一个可能点击率：

```
sample theta_A ~ Beta(8, 4) -> 0.62
sample theta_B ~ Beta(3, 3) -> 0.78
sample theta_C ~ Beta(2, 6) -> 0.20
```

这一轮采样结果里 B 最大，所以展示 B。

如果展示 B 后用户点击了：

```
Beta(3, 3) -> Beta(4, 3)
```

如果用户没点击：

```
Beta(3, 3) -> Beta(3, 4)
```

这个例子里，B 的后验均值低于 A，但因为 B 的历史样本少，posterior 更宽，偶尔会采样出很高的点击率，因此仍有机会被探索。A 的样本多，posterior 更窄，如果它确实好，就会更稳定地被选中。

伪代码：

```
for each arm a:
    alpha[a] = 1
    beta[a] = 1

for each round:
    for each arm a:
        theta[a] = sample_beta(alpha[a], beta[a])

    a_t = argmax_a theta[a]
    r_t = show(a_t)

    if r_t == 1:
        alpha[a_t] += 1
    else:
        beta[a_t] += 1
```

面试表达：

Thompson Sampling 不是固定比例随机探索，而是“按不确定性自然探索”。每个动作维护一个收益分布，每轮从分布采样后选最大。数据少的动作 posterior 宽，偶尔会采样出高值，从而获得探索机会；数据多且表现好的动作 posterior 窄，会稳定获得利用机会。

直觉：

一个动作的不确定性越大，它在采样中偶尔成为最优的概率越大，因此会自然获得探索机会。

优点：

- 探索非常自然。
- 在 bandit 问题中表现强。
- 常用于推荐、广告、实验分流。

缺点：

- 需要构造合适的概率模型。
- 在复杂深度 RL 中实现和建模成本更高。

4.9 完整 RL 中的探索落地

回到第 3 章的 SARSA 和 Q-learning，探索通常体现在 behavior policy 上。例如 Q-learning 可以用 epsilon-greedy 收集数据，再用 greedy target 做更新：

```
behavior policy: epsilon-greedy
target update:   max_a Q(s', a)
```

这说明探索机制和学习目标是两件事：

- 探索机制决定 agent 看到什么数据。

- 学习目标决定 value 或 policy 往哪里更新。

后面的 DQN、PPO、SAC 也都要处理探索，只是方式不同：

算法类型	常见探索方式
DQN	epsilon-greedy、NoisyNet
Policy Gradient / PPO	stochastic policy、entropy bonus
SAC	maximum entropy objective

4.9.1 NoisyNet 与参数空间探索

深度 RL 中还可以在参数空间探索。例如 NoisyNet 在网络参数中加入可学习噪声。

直觉：

- epsilon-greedy 是 action-level 随机。
- 参数空间噪声会让整个策略在一段时间内保持一致的探索模式。

这在需要 temporally coherent exploration 的任务中更合理。

4.10 本章例子：广告推荐里的探索

4.10.1 例子 1：Epsilon-greedy

假设有 3 个广告候选：

广告	当前点击率估计
A	4.0%
B	3.5%
C	1.0%

如果完全 exploitation，系统总是展示 A。但 C 的估计可能只是因为曝光少，不代表真实差。

epsilon-greedy 的做法：

- 95% 概率展示当前最优广告 A。
- 5% 概率随机探索 A/B/C。

这能避免过早把 B 或 C 判死。

4.10.2 例子 2：UCB

UCB 会给曝光少、不确定性高的广告更高 bonus。

直觉：

score = 当前平均收益 + 不确定性奖励

如果广告 C 曝光很少，即使平均点击率暂时低，也可能因为不确定性高被选中继续探索。

4.10.3 例子 3：Thompson Sampling

Thompson Sampling 会为每个广告维护一个后验分布，然后从分布里采样。

如果广告 A 数据多，后验分布窄；广告 C 数据少，后验分布宽。C 偶尔采样出很高的潜在点击率，就会获得探索机会。面试表达：

Epsilon-greedy 是固定比例随机探索；UCB 是乐观面对不确定性；Thompson Sampling 是按后验不确定性自然采样。推荐和广告场景里，探索机制直接影响冷启动和长期收益。

4.11 本章面试高频问题

4.11.1 为什么强化学习需要探索？

因为 agent 初始并不知道哪些动作长期收益最高。如果只选择当前估计最优的动作，可能因为早期估计错误而陷入局部最优。

4.11.2 epsilon-greedy 的缺点是什么？

探索是均匀随机的，没有利用不确定性信息，也不区分非 greedy 动作的潜在价值。在大动作空间中效率较低。

4.11.3 UCB 的核心思想是什么？

UCB 使用当前价值估计加上不确定性 bonus 选动作。被尝试较少的动作有更大 bonus，从而获得探索机会。

4.11.4 Thompson Sampling 和 UCB 的区别？

UCB 基于置信上界，显式构造 optimism bonus。Thompson Sampling 是 Bayesian 方法，从 posterior 采样参数，通过概率匹配自然平衡探索和利用。

4.11.5 Bandit 和完整 RL 的区别？

Bandit 没有复杂状态转移，动作只影响当前 reward。完整 RL 中动作会影响未来状态分布和长期 return。

4.12 本章练习

1. 写出 epsilon-greedy 的动作选择逻辑。
2. 解释 UCB 中 $\sqrt{\ln t / N(a)}$ 的直觉。
3. 用推荐系统举一个 bandit 的例子。
4. 比较 epsilon-greedy、UCB 和 Thompson Sampling。

▼ 参考答案（点击展开）

1. **Epsilon-greedy 逻辑**：生成 $u \sim \text{Uniform}(0,1)$ 。若 $u < \epsilon$ ，从全部动作中随机选一个；否则选择 $\arg \max_a Q(s,a)$ 。如果探索时也可能抽中 greedy action， K 个动作下 greedy action 的总概率是 $1 - \epsilon + \epsilon/K$ 。
2. **UCB bonus 直觉**： $N(a)$ 小表示动作尝试少、不确定性高，bonus 会变大；同一动作被反复尝试后， $N(a)$ 增长，bonus 会衰减。 $\ln t$ 缓慢增长，表示即使很久没选某个动作，随着总轮数增加仍会重新检查它，避免过早永久放弃。
3. **推荐系统例子**：把候选广告当作 arms，context 是用户画像和场景，action 是展示某个广告，reward 是点击或转化。系统既要多展示当前点击率高的广告，也要给新广告少量曝光来估计效果；若展示不改变用户长期状态，可先建模为 contextual bandit。
4. **三者比较**：epsilon-greedy 以固定概率做无差别随机探索，实现最简单但不利用不确定性；UCB 选择“均值 + 置信 bonus”最大的动作，属于确定性的 optimism in the face of uncertainty；Thompson Sampling 从每个动作的 posterior 采样后选最大值，属于概率匹配。UCB 和 Thompson Sampling 通常比固定随机探索更有针对性，但需要额外的不确定性估计或概率模型。