

第 4 章：探索与利用、Bandit、UCB（Upper Confidence Bound，置信上界）与 Thompson Sampling

4.1 本章符号说明

符号/缩写	English	中文	含义
UCB	Upper Confidence Bound	置信上界	用价值估计加不确定性 bonus 做探索。
K	Number of Arms	拉杆数量 / 动作数量	K-armed bandit 中候选动作的数量。
A_t	Action at time t	时刻 t 的动作	bandit 或 RL 中当前选择的动作。
R_t	Reward at time t	时刻 t 的奖励	本轮选择动作后获得的奖励。
$Q_t(a)$	Action-value Estimate	动作价值估计	到时刻 t 为止动作 a 的平均 reward 估计。
$N_t(a)$	Action Count	动作选择次数	到时刻 t 为止动作 a 被选过多少次。
μ_a / μ^*	Mean Reward / Best Mean Reward	平均奖励 / 最优平均奖励	动作 a 或最优动作的期望奖励。
$Regret(T)$	Cumulative Regret	累计后悔值	到时间 T 为止因为没有总选最优动作损失的收益。
τ	Temperature	温度参数	softmax exploration 中控制分布平滑程度。
RL	Reinforcement Learning	强化学习	探索与利用是 RL 的核心问题之一。
DQN	Deep Q-Network	深度 Q 网络	常用 epsilon-greedy 做探索的 value-based 算法。

4.2 本章目标

本章讨论强化学习中的 exploration-exploitation tradeoff。你需要掌握：

- 为什么需要探索。
- epsilon-greedy。
- softmax exploration。
- Multi-Armed Bandit。

- UCB。
- Thompson Sampling。
- regret。

4.3 本章主线

第 3 章默认 agent 能持续拿到交互样本，但样本本身由策略决定。策略如果只选当前最优动作，可能永远发现不了更好动作；如果一直随机试，又会牺牲收益。本章把探索问题抽出来，先在 bandit 里研究最小版本，再把 epsilon-greedy、UCB、Thompson Sampling 的思想带回 RL。

4.4 本章新增概念说明

先把本章会反复出现的探索名词说明清楚：

名词	中文	先记住什么
exploration	探索	尝试还不确定的动作，目的是发现潜在更优选择。
exploitation	利用	选择当前估计最好的动作，目的是获得已知收益。
epsilon-greedy	epsilon-greedy 策略	以 ϵ 概率随机探索，否则选择当前 Q 最大的动作。
greedy action	贪心动作	当前价值估计下最好的动作，即 $\operatorname{argmax}_a Q(s,a)$ 。
softmax exploration	softmax 探索	按价值大小分配采样概率，价值越高越容易被选中。
temperature	温度参数	控制 softmax 分布平滑程度；温度高更随机，温度低更贪心。
bandit / arm	多臂老虎机 / 拉杆	只考虑动作和即时 reward、暂时不考虑状态转移的探索问题。
regret	后悔值	因为没总选最优动作而损失的累计收益。
UCB	置信上界	当前平均收益加不确定性 bonus，偏向探索不确定动作。
Thompson Sampling	Thompson 采样	从每个动作的后验分布采样，用概率匹配方式探索。
posterior	后验分布	看到历史数据后，对某个动作真实收益的概率估计。
NoisyNet	噪声网络	在网络参数中加入噪声，让探索发生在参数或策略层面。

4.5 探索与利用

强化学习中，agent 面临两个目标：

- exploitation：选择当前看起来最好的动作，最大化已知收益。
- exploration：尝试不确定的动作，发现潜在更好的选择。

如果只 exploitation，可能永远错过更优动作。

如果只 exploration，则无法稳定获得高收益。

面试表达：

Exploration-exploitation tradeoff 是 RL 的核心问题之一。Agent 需要在利用当前价值估计和探索未知动作之间平衡。探索不足会导致局部最优，探索过多会损害短期收益和训练稳定性。

4.6 Epsilon-greedy

epsilon-greedy 是最常见的探索策略。

```
with probability epsilon:
    choose random action
otherwise:
    choose argmax_a Q(s, a)
```

优点：

- 简单。
- 容易实现。
- DQN 等算法常用。

缺点：

- 随机探索没有方向。
- 对所有非 greedy 动作一视同仁。
- 在大动作空间中效率较低。

常见工程做法：

```
epsilon starts high and decays over time
```

例如从 1.0 逐渐衰减到 0.05。

4.7 Softmax Exploration

softmax exploration 按照 action-value 的 softmax 概率采样动作：

$$P(a | s) = \exp(Q(s, a) / \tau) / \sum_b \exp(Q(s, b) / \tau)$$

τ 是 temperature:

- τ 大: 分布更平, 探索更多。
- τ 小: 分布更尖, 接近 greedy。

相比 epsilon-greedy, softmax 会更偏向价值较高的动作, 而不是均匀随机探索。

缺点:

- 对 Q 值尺度敏感。
- 如果 Q 值估计不准, 采样分布也会被误导。

4.8 Multi-Armed Bandit

Bandit 是最简单的 sequential decision 问题:

- 只有动作, 没有状态转移。
- 每个 action 对应一个未知 reward distribution。
- 目标是在不断试验中最大化累计 reward。

K-armed bandit:

```
choose action A_t in {1, ..., K}
receive reward R_t
```

它可以看成没有状态或只有单一状态的 RL 问题。

Bandit 在推荐系统、广告投放、A/B testing 中非常常见。

4.9 Bandit 和完整 RL 的关系

本章先讲 bandit, 不是因为 bandit 比 RL 更重要, 而是因为它把“探索”从复杂的状态转移里单独抽出来。

维度	Bandit	完整 RL
状态	通常没有状态, 或只有单一状态	有状态 s
动作影响	主要影响当前 reward	同时影响当前 reward 和未来状态
学习目标	找到平均 reward 高的动作	找到长期 return 高的策略
探索难点	试哪个 arm	在什么状态试什么动作

所以 bandit 是完整 RL 的一个局部视角: 先把“动作选择的不确定性”讲清楚, 再回到有状态转移的长期决策问题。

4.10 Regret

Regret 衡量由于没有总是选择最优动作而损失的收益。

如果最优动作的期望奖励是 μ^* , 第 t 步选择动作的期望奖励是 μ_{a_t} , 则累计 regret:

$$\text{Regret}(T) = \sum_{t=1}^T (\mu^* - \mu_{a_t})$$

目标不是只最大化 reward，也可以表述为最小化 regret。

4.11 UCB

Upper Confidence Bound，简称 UCB。

核心思想：

乐观面对不确定性。对不确定的动作给一个探索 bonus。

常见 UCB 形式：

$$A_t = \operatorname{argmax}_a [Q_t(a) + c \sqrt{(\ln t / N_t(a))}]$$

其中：

- $Q_t(a)$ ：动作 a 当前平均 reward 估计。
- $N_t(a)$ ：动作 a 被选择次数。
- t ：总时间步。
- c ：控制探索强度。

解释：

- 如果动作被选得少， $N_t(a)$ 小，bonus 大。
- 如果动作被选得多，不确定性下降，bonus 变小。
- UCB 会系统性探索不确定动作，而不是随机探索。

4.12 Thompson Sampling

Thompson Sampling 是一种 Bayesian exploration 方法。

流程：

1. 为每个动作维护 reward 分布参数的 posterior。
2. 每轮从每个动作的 posterior 中采样一个可能的参数。
3. 选择采样后看起来最优的动作。
4. 根据实际 reward 更新 posterior。

直觉：

一个动作的不确定性越大，它在采样中偶尔成为最优的概率越大，因此会自然获得探索机会。

优点：

- 探索非常自然。
- 在 bandit 问题中表现强。
- 常用于推荐、广告、实验分流。

缺点：

- 需要构造合适的概率模型。
- 在复杂深度 RL 中实现和建模成本更高。

4.13 探索方法在完整 RL 中怎么落地

回到第 3 章的 SARSA 和 Q-learning，探索通常体现在 behavior policy 上。例如 Q-learning 可以用 epsilon-greedy 收集数据，再用 greedy target 做更新：

```
behavior policy: epsilon-greedy
target update:  max_a Q(s', a)
```

这说明探索机制和学习目标是两件事：

- 探索机制决定 agent 看到什么数据。
- 学习目标决定 value 或 policy 往哪里更新。

后面的 DQN、PPO、SAC 也都要处理探索，只是方式不同：

算法类型	常见探索方式
DQN	epsilon-greedy、NoisyNet
Policy Gradient / PPO	stochastic policy、entropy bonus
SAC	maximum entropy objective

4.14 NoisyNet 与参数空间探索

深度 RL 中还可以在参数空间探索。例如 NoisyNet 在网络参数中加入可学习噪声。

直觉：

- epsilon-greedy 是 action-level 随机。
- 参数空间噪声会让整个策略在一段时间内保持一致的探索模式。

这在需要 temporally coherent exploration 的任务中更合理。

4.15 本章例子：广告推荐里的探索

4.15.1 例子 1：Epsilon-greedy

假设有 3 个广告候选：

广告	当前点击率估计
A	4.0%
B	3.5%

广告	当前点击率估计
C	1.0%

如果完全 exploitation，系统总是展示 A。但 C 的估计可能只是因为曝光少，不代表真实差。

epsilon-greedy 的做法：

- 95% 概率展示当前最优广告 A。
- 5% 概率随机探索 A/B/C。

这能避免过早把 B 或 C 判死。

4.15.2 例子 2：UCB

UCB 会给曝光少、不确定性高的广告更高 bonus。

直觉：

`score = 当前平均收益 + 不确定性奖励`

如果广告 C 曝光很少，即使平均点击率暂时低，也可能因为不确定性高被选中继续探索。

4.15.3 例子 3：Thompson Sampling

Thompson Sampling 会为每个广告维护一个后验分布，然后从分布里采样。

如果广告 A 数据多，后验分布窄；广告 C 数据少，后验分布宽。C 偶尔采样出很高的潜在点击率，就会获得探索机会。

面试表达：

Epsilon-greedy 是固定比例随机探索；UCB 是乐观面对不确定性；Thompson Sampling 是按后验不确定性自然采样。推荐和广告场景里，探索机制直接影响冷启动和长期收益。

4.16 本章面试高频问题

4.16.1 为什么强化学习需要探索？

因为 agent 初始并不知道哪些动作长期收益最高。如果只选择当前估计最优的动作，可能因为早期估计错误而陷入局部最优。

4.16.2 epsilon-greedy 的缺点是什么？

探索是均匀随机的，没有利用不确定性信息，也不区分非 greedy 动作的潜在价值。在大动作空间中效率较低。

4.16.3 UCB 的核心思想是什么？

UCB 使用当前价值估计加上不确定性 bonus 选动作。被尝试较少的动作有更大 bonus，从而获得探索机会。

4.16.4 Thompson Sampling 和 UCB 的区别?

UCB 基于置信上界，显式构造 optimism bonus。Thompson Sampling 是 Bayesian 方法，从 posterior 采样参数，通过概率匹配自然平衡探索和利用。

4.16.5 Bandit 和完整 RL 的区别?

Bandit 没有复杂状态转移，动作只影响当前 reward。完整 RL 中动作会影响未来状态分布和长期 return。

4.17 本章练习

1. 写出 epsilon-greedy 的动作选择逻辑。
2. 解释 UCB 中 $\sqrt{(\ln t) / N(a)}$ 的直觉。
3. 用推荐系统举一个 bandit 的例子。
4. 比较 epsilon-greedy、UCB 和 Thompson Sampling。

[章节索引](#)

[< 上一章](#) [下一章 >](#)
