

第 4 章：探索与利用、Bandit、UCB（Upper Confidence Bound，置信上界）与 Thompson Sampling

4.1 本章符号说明

符号/缩写	English	中文	含义
UCB	Upper Confidence Bound	置信上界	用价值估计加不确定性 bonus 做探索。
K	Number of Arms	拉杆数量 / 动作数量	K-armed bandit 中候选动作的数量。
A_t	Action at time t	时刻 t 的动作	bandit 或 RL 中当前选择的动作。
R_t	Reward at time t	时刻 t 的奖励	本轮选择动作后获得的奖励。
$Q_t(a)$	Action-value Estimate	动作价值估计	到时刻 t 为止动作 a 的平均 reward 估计。
$N_t(a)$	Action Count	动作选择次数	到时刻 t 为止动作 a 被选过多少次。
$\mu_a \mid \mu^*$	Mean Reward / Best Mean Reward	平均奖励 / 最优平均奖励	动作 a 或最优动作的期望奖励。
$Regret(T)$	Cumulative Regret	累计后悔值	到时间 T 为止因为没有总选最优动作损失的收益。
τ	Temperature	温度参数	softmax exploration 中控制分布平滑程度。
RL	Reinforcement Learning	强化学习	探索与利用是 RL 的核心问题之一。
DQN	Deep Q-Network	深度 Q 网络	常用 epsilon-greedy 做探索的 value-based 算法。

4.2 本章目标

本章讨论强化学习中的 exploration-exploitation tradeoff。你需要掌握：

- 为什么需要探索，以及 exploration / exploitation 的矛盾。
- 基础采样策略：epsilon-greedy 和 softmax exploration。
- Bandit 为什么是研究探索的最小模型。
- Bandit 里的评价指标：regret。
- 利用不确定性的 bandit 采样策略：UCB 和 Thompson Sampling。
- 这些探索方法在完整 RL 里如何落到 behavior policy、NoisyNet 等机制上。

4.3 本章主线

第 3 章默认 agent 能持续拿到交互样本，但样本本身由策略决定。策略如果只选当前最优动作，可能永远发现不了更好动作；如果一直随机试，又会牺牲收益。

本章结构是：

1. 先定义 exploration-exploitation tradeoff。

2. 再讲只依赖当前价值估计的基础采样策略：epsilon-greedy 和 softmax。
3. 接着用 bandit 把探索问题单独抽出来，并引入 regret。
4. 然后讲 bandit 中利用不确定性的采样策略：UCB 和 Thompson Sampling。
5. 最后回到完整 RL，说明探索机制如何成为 behavior policy 或参数空间探索。

4.4 本章新增概念说明

先把本章会反复出现的探索名词说明清楚：

名词	中文	先记住什么
exploration	探索	尝试还不确定的动作，目的是发现潜在更优选择。
exploitation	利用	选择当前估计最好的动作，目的是获得已知收益。
epsilon-greedy	epsilon-greedy 策略	以 ϵ 概率随机探索，否则选择当前 Q 最大的动作。
greedy action	贪心动作	当前价值估计下最好的动作，即 $\arg \max_a Q(s,a)$ 。
softmax exploration	softmax 探索	按价值大小分配采样概率，价值越高越容易被选中。
temperature	温度参数	控制 softmax 分布平滑程度；温度高更随机，温度低更贪心。
bandit / arm	多臂老虎机 / 拉杆	只考虑动作和即时 reward、暂时不考虑状态转移的探索问题。
regret	后悔值	因为没总选最优动作而损失的累计收益。
UCB	置信上界	当前平均收益加不确定性 bonus，偏向探索不确定动作。
Thompson Sampling	Thompson 采样	从每个动作的后验分布采样，用概率匹配方式探索。
posterior	后验分布	看到历史数据后，对某个动作真实收益的概率估计。
NoisyNet	噪声网络	在网络参数中加入噪声，让探索发生在参数或策略层面。

4.5 探索问题的基本概念

4.5.1 探索与利用

强化学习中，agent 面临两个目标：

- exploitation：选择当前看起来最好的动作，最大化已知收益。
- exploration：尝试不确定的动作，发现潜在更好的选择。

如果只 exploitation，可能永远错过更优动作。

如果只 exploration，则无法稳定获得高收益。

面试表达：

Exploration-exploitation tradeoff 是 RL 的核心问题之一。Agent 需要在利用当前价值估计和探索未知动作之间平衡。探索不足会导致局部最优，探索过多会损害短期收益和训练稳定性。

这一节只是定义问题：agent 到底为什么不能一直选当前最优动作。下面的 epsilon-greedy、softmax、UCB、Thompson Sampling 才是不同的动作采样策略。

4.6 基础采样策略：只依赖当前价值估计

这一组方法只看当前 action-value estimate，不显式建模“这个估计有多不确定”。它们适合作为 RL 里的基础 behavior policy。

4.6.1 Epsilon-greedy

epsilon-greedy 是最常见的探索策略。

```
with probability epsilon:
    choose random action
otherwise:
    choose argmax_a Q(s, a)
```

优点：

- 简单。
- 容易实现。
- DQN 等算法常用。

缺点：

- 随机探索没有方向。
- 对所有非 greedy 动作一视同仁。
- 在大动作空间中效率较低。

常见工程做法：

```
epsilon starts high and decays over time
```

例如从 1.0 逐渐衰减到 0.05。

4.6.2 Softmax Exploration

softmax exploration 按照 action-value 的 softmax 概率采样动作：

$$P(a | s) = \exp(Q(s, a) / \tau) / \sum_b \exp(Q(s, b) / \tau)$$

τ 是 temperature：

- τ 大：分布更平，探索更多。
- τ 小：分布更尖，接近 greedy。

相比 epsilon-greedy，softmax 会更偏向价值较高的动作，而不是均匀随机探索。

缺点：

- 对 Q 值尺度敏感。
- 如果 Q 值估计不准，采样分布也会被误导。

4.7 Bandit 问题：把探索单独抽出来研究

Bandit 是研究 exploration-exploitation 的最小模型。先在 bandit 中理解“动作采样策略如何权衡收益和不确定性”，再回到完整 RL。

4.7.1 Multi-Armed Bandit

Bandit 是最简单的 sequential decision 问题：

- 只有动作，没有状态转移。
- 每个 action 对应一个未知 reward distribution。
- 目标是在不断试验中最大化累计 reward。

K-armed bandit：

```
choose action A_t in {1, ..., K}
receive reward R_t
```

它可以看成没有状态或只有单一状态的 RL 问题。

Bandit 在推荐系统、广告投放、A/B testing 中非常常见。

4.7.2 Bandit 和完整 RL 的关系

本章先讲 bandit，不是因为 bandit 比 RL 更重要，而是因为它把“探索”从复杂的状态转移里单独抽出来。

维度	Bandit	完整 RL
状态	通常没有状态，或只有单一状态	有状态 s
动作影响	主要影响当前 reward	同时影响当前 reward 和未来状态
学习目标	找到平均 reward 高的动作	找到长期 return 高的策略
探索难点	试哪个 arm	在什么状态试什么动作

所以 bandit 是完整 RL 的一个局部视角：先把“动作选择的不确定性”讲清楚，再回到有状态转移的长期决策问题。

4.7.3 Regret

Regret 衡量由于没有总是选择最优动作而损失的收益。

如果最优动作的期望奖励是 μ^* ，第 t 步选择动作的期望奖励是 μ_{a_t} ，则累计 regret：

$$Regret(T) = \sum_{t=1}^T (\mu^* - \mu_{a_t})$$

目标不是只最大化 reward，也可以表述为最小化 regret。

4.8 Bandit 采样策略：利用不确定性做探索

这一组策略不只是看当前平均收益，还会显式使用“不确定性”。UCB 用 confidence bonus 表达不确定性，Thompson Sampling 用 posterior sampling 表达不确定性。

4.8.1 UCB

Upper Confidence Bound, 简称 UCB。

核心思想：

乐观面对不确定性。对不确定的动作给一个探索 bonus。

常见 UCB 形式：

$$A_t = \arg \max_a [Q_t(a) + c \sqrt{(\ln t / N_t(a))}]$$

其中：

- $Q_t(a)$: 动作 a 当前平均 reward 估计。
- $N_t(a)$: 动作 a 被选择次数。
- t : 总时间步。
- c : 控制探索强度。

解释：

- 如果动作被选得少, $N_t(a)$ 小, bonus 大。
- 如果动作被选得多, 不确定性下降, bonus 变小。
- UCB 会系统性探索不确定动作, 而不是随机探索。

4.8.2 Thompson Sampling

Thompson Sampling 是一种 Bayesian exploration 方法。

流程：

1. 为每个动作维护 reward 分布参数的 posterior。
2. 每轮从每个动作的 posterior 中采样一个可能的参数。
3. 选择采样后看起来最优的动作。
4. 根据实际 reward 更新 posterior。

4.8.2.1 具体例子：Beta-Bernoulli 广告点击

假设有 3 个广告候选, reward 是二值点击：

```
click = 1
no click = 0
```

每个广告的真实点击率未知, 记作 θ_a 。因为点击是 Bernoulli variable, 所以可以给每个广告维护一个 Beta posterior：

$$\theta_a \sim \text{Beta}(\alpha_a, \beta_a)$$

初始化时, 如果没有任何历史数据, 可以用均匀先验：

$$\alpha_a=1, \beta_a=1$$

含义是：一开始不知道广告好坏, 所有点击率都可能。

如果广告 a 被展示后：

- 用户点击了: $\alpha_a \leftarrow \alpha_a + 1$
- 用户没点击: $\beta_a \leftarrow \beta_a + 1$

因为 Beta 是 Bernoulli 的 conjugate prior，所以这个更新可以理解为：

```
alpha = 1 + click_count
beta  = 1 + no_click_count
```

某一轮开始时，假设 posterior 是：

广告	历史点击 / 未点击	Posterior	后验均值
A	7 / 3	Beta(8, 4)	0.67
B	2 / 2	Beta(3, 3)	0.50
C	1 / 5	Beta(2, 6)	0.25

如果只看均值，会选择 A。但 Thompson Sampling 不直接选均值，而是每轮从每个 posterior 里采样一个可能点击率：

```
sample theta_A ~ Beta(8, 4)  -> 0.62
sample theta_B ~ Beta(3, 3)  -> 0.78
sample theta_C ~ Beta(2, 6)  -> 0.20
```

这一轮采样结果里 B 最大，所以展示 B。

如果展示 B 后用户点击了：

```
Beta(3, 3) -> Beta(4, 3)
```

如果用户没点击：

```
Beta(3, 3) -> Beta(3, 4)
```

这个例子里，B 的后验均值低于 A，但因为 B 的历史样本少，posterior 更宽，偶尔会采样出很高的点击率，因此仍有机会被探索。A 的样本多，posterior 更窄，如果它确实好，就会更稳定地被选中。

伪代码：

```
for each arm a:
    alpha[a] = 1
    beta[a] = 1

for each round:
    for each arm a:
        theta[a] = sample_beta(alpha[a], beta[a])

    a_t = argmax_a theta[a]
    r_t = show(a_t)

    if r_t == 1:
        alpha[a_t] += 1
    else:
        beta[a_t] += 1
```

面试表达：

Thompson Sampling 不是固定比例随机探索，而是“按不确定性自然探索”。每个动作维护一个收益分布，每轮从分布采样后选最大。数据少的动作 posterior 宽，偶尔会采样出高值，从而获得探索机会；数据多且表现好的动作 posterior 窄，会稳定获得利用机会。

直觉：

一个动作的不确定性越大，它在采样中偶尔成为最优的概率越大，因此会自然获得探索机会。

优点：

- 探索非常自然。
- 在 bandit 问题中表现强。
- 常用于推荐、广告、实验分流。

缺点：

- 需要构造合适的概率模型。
- 在复杂深度 RL 中实现和建模成本更高。

4.9 完整 RL 中的探索落地

回到第 3 章的 SARSA 和 Q-learning，探索通常体现在 behavior policy 上。例如 Q-learning 可以用 epsilon-greedy 收集数据，再用 greedy target 做更新：

```
behavior policy: epsilon-greedy
target update:  max_a Q(s', a)
```

这说明探索机制和学习目标是两件事：

- 探索机制决定 agent 看到什么数据。
- 学习目标决定 value 或 policy 往哪里更新。

后面的 DQN、PPO、SAC 也都要处理探索，只是方式不同：

算法类型	常见探索方式
DQN	epsilon-greedy、NoisyNet
Policy Gradient / PPO	stochastic policy、entropy bonus
SAC	maximum entropy objective

4.9.1 NoisyNet 与参数空间探索

深度 RL 中还可以在参数空间探索。例如 NoisyNet 在网络参数中加入可学习噪声。

直觉：

- epsilon-greedy 是 action-level 随机。
- 参数空间噪声会让整个策略在一段时间内保持一致的探索模式。

这在需要 temporally coherent exploration 的任务中更合理。

4.10 本章例子：广告推荐里的探索

4.10.1 例子 1：Epsilon-greedy

假设有 3 个广告候选：

广告	当前点击率估计
A	4.0%
B	3.5%
C	1.0%

如果完全 exploitation，系统总是展示 A。但 C 的估计可能只是因为曝光少，不代表真实差。

epsilon-greedy 的做法：

- 95% 概率展示当前最优广告 A。
- 5% 概率随机探索 A/B/C。

这能避免过早把 B 或 C 判死。

4.10.2 例子 2：UCB

UCB 会给曝光少、不确定性高的广告更高 bonus。

直觉：

```
score = 当前平均收益 + 不确定性奖励
```

如果广告 C 曝光很少，即使平均点击率暂时低，也可能因为不确定性高被选中继续探索。

4.10.3 例子 3：Thompson Sampling

Thompson Sampling 会为每个广告维护一个后验分布，然后从分布里采样。

如果广告 A 数据多，后验分布窄；广告 C 数据少，后验分布宽。C 偶尔采样出很高的潜在点击率，就会获得探索机会。

面试表达：

Epsilon-greedy 是固定比例随机探索；UCB 是乐观面对不确定性；Thompson Sampling 是按后验不确定性自然采样。推荐和广告场景里，探索机制直接影响冷启动和长期收益。

4.11 本章面试高频问题

4.11.1 为什么强化学习需要探索？

因为 agent 初始并不知道哪些动作长期收益最高。如果只选择当前估计最优的动作，可能因为早期估计错误而陷入局部最优。

4.11.2 epsilon-greedy 的缺点是什么？

探索是均匀随机的，没有利用不确定性信息，也不区分非 greedy 动作的潜在价值。在大动作空间中效率较低。

4.11.3 UCB 的核心思想是什么？

UCB 使用当前价值估计加上不确定性 bonus 选动作。被尝试较少的动作有更大 bonus，从而获得探索机会。

4.11.4 Thompson Sampling 和 UCB 的区别？

UCB 基于置信上界，显式构造 optimism bonus。Thompson Sampling 是 Bayesian 方法，从 posterior 采样参数，通过概率匹配自然平衡探索和利用。

4.11.5 Bandit 和完整 RL 的区别？

Bandit 没有复杂状态转移，动作只影响当前 reward。完整 RL 中动作会影响未来状态分布和长期 return。

4.12 本章练习

1. 写出 epsilon-greedy 的动作选择逻辑。
2. 解释 UCB 中 $\sqrt{\ln t / N(a)}$ 的直觉。
3. 用推荐系统举一个 bandit 的例子。
4. 比较 epsilon-greedy、UCB 和 Thompson Sampling。

▼ 参考答案 (点击展开)

1. **Epsilon-greedy 逻辑**：生成 $u \sim \text{Uniform}(0, 1)$ 。若 $u < \epsilon$ ，从全部动作中随机选一个；否则选择 $\arg \max_a Q(s, a)$ 。如果探索时也可能抽中 greedy action， K 个动作下 greedy action 的总概率是 $1 - \epsilon + \epsilon/K$ 。
2. **UCB bonus 直觉**： $N(a)$ 小表示动作尝试少、不确定性高，bonus 会变大；同一动作被反复尝试后， $N(a)$ 增长，bonus 会衰减。 $\ln t$ 缓慢增长，表示即使很久没选某个动作，随着总轮数增加仍会重新检查它，避免过早永久放弃。
3. **推荐系统例子**：把候选广告当作 arms，context 是用户画像和场景，action 是展示某个广告，reward 是点击或转化。系统既要多展示当前点击率高的广告，也要给新广告少量曝光来估计效果；若展示不改变用户长期状态，可先建模为 contextual bandit。
4. **三者比较**：epsilon-greedy 以固定概率做无差别随机探索，实现最简单但不利用不确定性；UCB 选择“均值 + 置信 bonus”最大的动作，属于确定性的 optimism in the face of uncertainty；Thompson Sampling 从每个动作的 posterior 采样后选最大值，属于概率匹配。UCB 和 Thompson Sampling 通常比固定随机探索更有针对性，但需要额外的不确定性估计或概率模型。