

第 4 章：探索与利用、Bandit、UCB（Upper Confidence Bound，置信上界）与 Thompson Sampling

本章符号说明

符号/缩写	English	中文	含义
UCB	Upper Confidence Bound	置信上界	用价值估计加不确定性 bonus 做探索。
K	Number of Arms	拉杆数量 / 动作数量	K-armed bandit 中候选动作的数量。
A_t	Action at time t	时刻 t 的动作	bandit 或 RL 中当前选择的动作。
R_t	Reward at time t	时刻 t 的奖励	本轮选择动作后获得的奖励。
$Q_t(a)$	Action-value Estimate	动作价值估计	到时刻 t 为止动作 a 的平均 reward 估计。
$N_t(a)$	Action Count	动作选择次数	到时刻 t 为止动作 a 被选过多少次。
μ_a / μ^*	Mean Reward / Best Mean Reward	平均奖励 / 最优平均奖励	动作 a 或最优动作的期望奖励。
$Regret(T)$	Cumulative Regret	累计后悔值	到时间 T 为止因为没有总选最优动作损失的收益。
τ	Temperature	温度参数	softmax exploration 中控制分布平滑程度。
RL	Reinforcement Learning	强化学习	探索与利用是 RL 的核心问题之一。
DQN	Deep Q-Network	深度 Q 网络	常用 epsilon-greedy 做探索的 value-based 算法。

本章目标

本章讨论强化学习中的 exploration-exploitation tradeoff。你需要掌握：

- 为什么需要探索。
- epsilon-greedy。
- softmax exploration。
- Multi-Armed Bandit。

- UCB。
- Thompson Sampling。
- regret。

本章主线

第 3 章默认 agent 能持续拿到交互样本，但样本本身由策略决定。策略如果只选当前最优动作，可能永远发现不了更好动作；如果一直随机试，又会牺牲收益。本章把探索问题抽出来，先在 bandit 里研究最小版本，再把 epsilon-greedy、UCB、Thompson Sampling 的思想带回 RL。

探索与利用

强化学习中，agent 面临两个目标：

- exploitation：选择当前看起来最好的动作，最大化已知收益。
- exploration：尝试不确定的动作，发现潜在更好的选择。

如果只 exploitation，可能永远错过更优动作。

如果只 exploration，则无法稳定获得高收益。

面试表达：

Exploration-exploitation tradeoff 是 RL 的核心问题之一。Agent 需要在利用当前价值估计和探索未知动作之间平衡。探索不足会导致局部最优，探索过多会损害短期收益和训练稳定性。

Epsilon-greedy

epsilon-greedy 是最常见的探索策略。

```
with probability epsilon:
    choose random action
otherwise:
    choose argmax_a Q(s, a)
```

优点：

- 简单。
- 容易实现。
- DQN 等算法常用。

缺点：

- 随机探索没有方向。
- 对所有非 greedy 动作一视同仁。
- 在大动作空间中效率较低。

常见工程做法：

```
epsilon starts high and decays over time
```

例如从 1.0 逐渐衰减到 0.05。

Softmax Exploration

softmax exploration 按照 action-value 的 softmax 概率采样动作：

$$P(a | s) = \exp(Q(s,a) / \tau) / \sum_b \exp(Q(s,b) / \tau)$$

τ 是 temperature：

- τ 大：分布更平，探索更多。
- τ 小：分布更尖，接近 greedy。

相比 epsilon-greedy，softmax 会更偏向价值较高的动作，而不是均匀随机探索。

缺点：

- 对 Q 值尺度敏感。
- 如果 Q 值估计不准，采样分布也会被误导。

Multi-Armed Bandit

Bandit 是最简单的 sequential decision 问题：

- 只有动作，没有状态转移。
- 每个 action 对应一个未知 reward distribution。
- 目标是在不断试验中最大化累计 reward。

K-armed bandit：

```
choose action A_t in {1, ..., K}
receive reward R_t
```

它可以看成没有状态或只有单一状态的 RL 问题。

Bandit 在推荐系统、广告投放、A/B testing 中非常常见。

Bandit 和完整 RL 的关系

本章先讲 bandit，不是因为 bandit 比 RL 更重要，而是因为它把“探索”从复杂的状态转移里单独抽出来。

维度	Bandit	完整 RL
状态	通常没有状态，或只有单一状态	有状态 s
动作影响	主要影响当前 reward	同时影响当前 reward 和未来状态

维度	Bandit	完整 RL
学习目标	找到平均 reward 高的动作	找到长期 return 高的策略
探索难点	试哪个 arm	在什么状态试什么动作

所以 bandit 是完整 RL 的一个局部视角：先把“动作选择的不确定性”讲清楚，再回到有状态转移的长期决策问题。

Regret

Regret 衡量由于没有总是选择最优动作而损失的收益。

如果最优动作的期望奖励是 μ^* ，第 t 步选择动作的期望奖励是 μ_{a_t} ，则累计 regret：

$$\text{Regret}(T) = \sum_{t=1}^T (\mu^* - \mu_{a_t})$$

目标不是只最大化 reward，也可以表述为最小化 regret。

UCB

Upper Confidence Bound，简称 UCB。

核心思想：

乐观面对不确定性。对不确定的动作给一个探索 bonus。

常见 UCB 形式：

$$A_t = \operatorname{argmax}_a [Q_t(a) + c \sqrt{(\ln t / N_t(a))}]$$

其中：

- $Q_t(a)$ ：动作 a 当前平均 reward 估计。
- $N_t(a)$ ：动作 a 被选择次数。
- t ：总时间步。
- c ：控制探索强度。

解释：

- 如果动作被选得少， $N_t(a)$ 小，bonus 大。
- 如果动作被选得多，不确定性下降，bonus 变小。
- UCB 会系统性探索不确定动作，而不是随机探索。

Thompson Sampling

Thompson Sampling 是一种 Bayesian exploration 方法。

流程：

- 1. 为每个动作维护 reward 分布参数的 posterior。
- 2. 每轮从每个动作的 posterior 中采样一个可能的参数。
- 3. 选择采样后看起来最优的动作。
- 4. 根据实际 reward 更新 posterior。

直觉：

一个动作的不确定性越大，它在采样中偶尔成为最优的概率越大，因此会自然获得探索机会。

优点：

- 探索非常自然。
- 在 bandit 问题中表现强。
- 常用于推荐、广告、实验分流。

缺点：

- 需要构造合适的概率模型。
- 在复杂深度 RL 中实现和建模成本更高。

探索方法在完整 RL 中怎么落地

回到第 3 章的 SARSA 和 Q-learning，探索通常体现在 behavior policy 上。例如 Q-learning 可以用 epsilon-greedy 收集数据，再用 greedy target 做更新：

```
behavior policy: epsilon-greedy
target update:  max_a Q(s', a)
```

这说明探索机制和学习目标是两件事：

- 探索机制决定 agent 看到什么数据。
- 学习目标决定 value 或 policy 往哪里更新。

后面的 DQN、PPO、SAC 也都要处理探索，只是方式不同：

算法类型	常见探索方式
DQN	epsilon-greedy、NoisyNet
Policy Gradient / PPO	stochastic policy、entropy bonus
SAC	maximum entropy objective

NoisyNet 与参数空间探索

深度 RL 中还可以在参数空间探索。例如 NoisyNet 在网络参数中加入可学习噪声。

直觉：

- epsilon-greedy 是 action-level 随机。
- 参数空间噪声会让整个策略在一段时间内保持一致的探索模式。

这在需要 temporally coherent exploration 的任务中更合理。

本章例子：广告推荐里的探索

例子 1：Epsilon-greedy

假设有 3 个广告候选：

广告	当前点击率估计
A	4.0%
B	3.5%
C	1.0%

如果完全 exploitation，系统总是展示 A。但 C 的估计可能只是因为曝光少，不代表真实差。

epsilon-greedy 的做法：

- 95% 概率展示当前最优广告 A。
- 5% 概率随机探索 A/B/C。

这能避免过早把 B 或 C 判死。

例子 2：UCB

UCB 会给曝光少、不确定性高的广告更高 bonus。

直觉：

$\text{score} = \text{当前平均收益} + \text{不确定性奖励}$

如果广告 C 曝光很少，即使平均点击率暂时低，也可能因为不确定性高被选中继续探索。

例子 3：Thompson Sampling

Thompson Sampling 会为每个广告维护一个后验分布，然后从分布里采样。

如果广告 A 数据多，后验分布窄；广告 C 数据少，后验分布宽。C 偶尔采样出很高的潜在点击率，就会获得探索机会。

面试表达：

Epsilon-greedy 是固定比例随机探索；UCB 是乐观面对不确定性；Thompson Sampling 是按后验不确定性自然采样。推荐和广告场景里，探索机制直接影响冷启动和长期收益。

本章面试高频问题

1. 为什么强化学习需要探索？

因为 agent 初始并不知道哪些动作长期收益最高。如果只选择当前估计最优的动作，可能因为早期估计错误而陷入局部最优。

2. epsilon-greedy 的缺点是什么？

探索是均匀随机的，没有利用不确定性信息，也不区分非 greedy 动作的潜在价值。在大动作空间中效率较低。

3. UCB 的核心思想是什么？

UCB 使用当前价值估计加上不确定性 bonus 选动作。被尝试较少的动作有更大 bonus，从而获得探索机会。

4. Thompson Sampling 和 UCB 的区别？

UCB 基于置信上界，显式构造 optimism bonus。Thompson Sampling 是 Bayesian 方法，从 posterior 采样参数，通过概率匹配自然平衡探索和利用。

5. Bandit 和完整 RL 的区别？

Bandit 没有复杂状态转移，动作只影响当前 reward。完整 RL 中动作会影响未来状态分布和长期 return。

本章练习

1. 写出 epsilon-greedy 的动作选择逻辑。
2. 解释 UCB 中 $\sqrt{(\ln t) / N(a)}$ 的直觉。
3. 用推荐系统举一个 bandit 的例子。
4. 比较 epsilon-greedy、UCB 和 Thompson Sampling。

[章节索引](#)

[← 上一章](#) [下一章 →](#)