

第 5 章：函数逼近、稳定性与 Deadly Triad

5.1 本章符号说明

符号/缩写	English	中文	含义
$V(s)$	State-value Function	状态价值函数	状态 s 的长期价值。
$Q(s,a)$	Action-value Function	动作价值函数	状态-动作对 (s,a) 的长期价值。
$\pi(a \mid s)$	Policy	策略	状态 s 下选择动作 a 的概率。
$\theta \mid w$	Parameters / Weights	参数 / 权重	策略网络或价值网络的可学习参数。
w^-	Target Network Weights	目标网络权重	从在线权重 w 延迟同步或软更新得到的参数。
y	Target	训练目标值	Bellman target，用来监督当前估计。
$L(w)$	Loss Function	损失函数	训练价值网络时最小化的目标。
(s,a,r,s',d)	Transition Tuple	转移样本五元组	当前状态、动作、即时奖励、下一状态和终止指示量；代码常把 d 写成 <code>done</code> 。
$d \mid \text{done}$	Terminal Indicator	终止指示量	$d=1$ 表示该转移到达真正终止状态， $d=0$ 表示仍可从 s' bootstrap。
γ	Discount Factor	折扣因子	控制 Bellman target 中未来价值的权重。
$d_\mu(s,a)$	Behavior Distribution	行为分布	行为策略 μ 与环境交互后在状态-动作对上的访问分布。
μ	Behavior Policy	行为策略	实际产生训练数据的策略；可与目标策略 π 不同。
τ_{soft}	Soft-update Rate	软更新系数	控制目标网络每次从在线网络吸收多少新参数，通常远小于 1。
behavior policy	Behavior Policy	行为策略	实际收集训练数据的策略。
target policy	Target Policy	目标策略	当前算法想学习或优化的策略。
on-policy	On-policy Learning	同策略学习	数据来自当前正在学习的策略。
off-policy	Off-policy Learning	异策略学习	用一个策略的数据学习另一个策略。
DQN	Deep Q-Network	深度 Q 网络	用神经网络近似 $Q(s,a)$ 的 value-based 算法。
TD	Temporal Difference	时序差分	用一步 reward 和下一状态估计构造 target 的方法。
RL	Reinforcement Learning	强化学习	本章讨论 RL 从表格方法进入函数逼近后的稳定性问题。

符号/缩写	English	中文	含义
LLM	Large Language Model	大语言模型	文中作为高维状态或复杂序列系统的例子。

5.2 本章目标

本章从表格型 RL 过渡到深度强化学习。你需要掌握：

- 为什么需要函数逼近。
- 线性函数逼近和神经网络逼近。
- value function approximation。
- bootstrapping 的影响。
- off-policy learning 的分布问题。
- Deadly Triad。

5.3 本章主线

前面几章默认可以为每个状态或状态-动作对存一个表格值。真实任务里状态空间通常巨大或连续，所以必须用参数化函数近似 $V(s)$ 、 $Q(s,a)$ 或 $\pi(a|s)$ 。本章先建立函数逼近的训练形式，再解释为什么 bootstrapping、off-policy learning 和 function approximation 同时出现时会带来稳定性问题。

5.4 本章新增概念说明

本章开始进入 deep RL，先把稳定性相关名词放在一起：

名词	中文	先记住什么
function approximation	函数逼近	用参数化模型近似 $V(s)$ 、 $Q(s,a)$ 或 $\pi(a s)$ ，不再为每个状态单独建表。
value function approximation	价值函数逼近	用模型预测价值函数，例如 $Q(s,a;w)$ 。
bootstrapping	自举	target 里用了模型当前自己的估计，例如 $r+\gamma V(s')$ 。
off-policy distribution shift	异策略分布偏移	数据来自一个策略，学习目标却是另一个策略，导致训练分布和目标分布不一致。
Deadly Triad	致命三角	function approximation、bootstrapping、off-policy 同时出现时，训练容易不稳定。
replay buffer	经验回放池	存历史 transition，训练时随机采样，打破连续样本相关性。
target network	目标网络	滞后更新的网络，用来让 Bellman target 更稳定。
overestimation bias	过估计偏差	max 操作容易选择被噪声高估的动作，导致 Q 值偏高。
reward clipping / gradient clipping	奖励截断 / 梯度截断	工程稳定化技巧，用来限制训练信号或梯度过大。

5.5 函数逼近为什么出现

5.5.1 为什么需要函数逼近

表格型方法为每个状态或状态动作对存一个值：

$$V(s)$$

$$Q(s, a)$$

但真实任务中状态空间可能极大，甚至连续：

- 图像输入。
- 机器人连续状态。
- 推荐系统用户特征。
- LLM 对话状态。

这时无法为每个状态单独建表，需要用参数化函数近似价值函数或策略。

例如：

$$V(s) \approx V(s; w)$$

$$Q(s, a) \approx Q(s, a; w)$$

$$\pi(a | s) \approx \pi(a | s; \theta)$$

5.5.2 Value Function Approximation

用神经网络近似 Q 函数：

$$Q(s, a; w)$$

训练目标通常来自 Bellman target。

例如 DQN 中：

$$y = r + \gamma \max_{a'} Q(s', a'; w^-)$$

损失：

$$L(w) = \mathbb{E}[(y - Q(s, a; w))^2]$$

其中 w^- 是 target network 参数。

5.5.3 函数逼近的好处

- 可以处理高维状态。
- 可以泛化到没见过的状态。
- 可以结合深度学习特征提取能力。
- 能用于图像、文本、连续控制等任务。

5.5.4 函数逼近的风险

表格型方法中，不同状态动作对的值相互独立。

函数逼近中，共享参数会导致一个样本更新影响许多状态动作对的估计。

这带来几个问题：

- 训练目标非平稳。
- 样本之间高度相关。
- 误差可能通过 bootstrap 扩散。
- 价值函数可能过估计或发散。

5.6 不稳定来源：Deadly Triad

5.6.1 Bootstrapping

Bootstrapping 指 target 中包含当前模型自己的估计。

例如 TD target:

$$r + \gamma V(s')$$

Q-learning target:

$$r + \gamma \max_{a'} Q(s', a')$$

它的优点:

- 可以在线更新。
- 不需要完整 episode。
- sample efficiency 较高。

它的风险:

- target 依赖当前估计。
- 估计错误会被继续传播。
- 函数逼近下更容易放大不稳定性。

5.6.2 Off-policy Distribution Shift

off-policy 学习中, 数据来自 behavior policy, 但学习目标是 target policy。

data distribution: $d_{\mu}(s, a)$

target policy: π

如果 behavior policy 产生的数据分布和 target policy 需要的数据分布差异很大, 模型可能会在没数据覆盖的状态动作上产生错误估计。

这种问题在 offline RL 中尤其严重。

5.6.3 Deadly Triad

Deadly Triad 指三个因素同时出现时, RL 训练可能不稳定甚至发散:

1. Function approximation。
2. Bootstrapping。
3. Off-policy learning。

为什么危险?

- 函数逼近会让误差泛化到其他状态。
- bootstrapping 会用当前估计构造 target, 错误会自我强化。
- off-policy 会带来数据分布和学习目标不一致。

DQN 同时包含这三个因素，因此需要额外稳定技巧：

- replay buffer 打破样本相关性。
- target network 稳定 bootstrap target。
- reward clipping。
- gradient clipping。
- Double DQN 降低 overestimation bias。

5.7 DQN 稳定化思想

5.7.1 从 Deadly Triad 到 DQN 稳定化

下面的 replay buffer 和 target network 不应该理解成孤立技巧，而是第 6 章 DQN 的铺垫。逻辑是：

```
Q-learning + neural network
-> function approximation
-> bootstrap target
-> off-policy replay data
-> Deadly Triad risk
-> replay buffer / target network / Double DQN
```

所以第 5 章先解释“不稳定从哪里来”，第 6 章再系统讲“DQN 如何把这些稳定化设计组合成算法”。

5.7.2 Experience Replay 的稳定作用

Replay buffer 存储历史 transition：

```
(s, a, r, s', done)
```

五个字段依次是当前状态 s 、已执行动作 a 、即时奖励 r 、下一状态 s' 和终止标记 `done`。下文用数学符号 $d \in \{0, 1\}$ 表示 `done`； $d=1$ 时表示没有可继续估计的未来回报。

训练时从 buffer 中随机采样 mini-batch。

好处：

- 打破连续样本相关性。
- 提高样本利用率。
- 让数据分布更平滑。

限制：

- 数据可能 stale。
- 对 on-policy 算法不天然适用。
- 分布偏移仍然存在。

5.7.3 Target Network 的稳定作用

如果 target 和 online prediction 使用同一个网络，带终止掩码的 target 是：

$$y = r + \gamma(1-d) \max_{a'} Q(s', a'; w)$$

那么模型参数一更新，target 也立刻变化，训练目标非常不稳定。

Target network 使用滞后的参数 w^- ：

$$y = r + \gamma(1-d) \max_{a'} Q(s', a'; w^-)$$

每隔一段时间同步：

$$w^- \leftarrow w$$

或者软更新：

$$w^- \leftarrow \tau_{soft} w + (1 - \tau_{soft}) w^-$$

Target network 刻意使用“稍旧”的估计，因此确实引入了滞后；它并不是更接近真值的教师。这里交换的是**短期准确性与优化稳定性**：online network 先追逐一段时间内相对固定的 Bellman target，再周期性或缓慢刷新 target。只要 target 持续跟随 online network，奖励和终止边界仍会逐步传播；更新过快会重新变成移动目标，更新过慢则会学习迟钝。

软更新也可以改写成 $w^- \leftarrow w^- + \tau_{soft}(w - w^-)$ ，即 target 参数每次只向 online 参数移动一小段。它是参数插值，不是由 target network 自己反向传播学习。

5.8 本章例子：为什么表格法不够

5.8.1 例子 1：Atari 像素输入

Atari 游戏状态是一张图片。如果用表格法，每一种像素组合都对应一个状态，状态数量几乎无限。

函数逼近的做法是：

输入：游戏画面
神经网络：CNN / encoder
输出：每个动作的 Q 值

这样模型可以泛化。例如两个画面只差几个像素，但局面本质相似，网络可以给出相近价值。

5.8.2 例子 2：推荐系统高维状态

推荐系统状态可能包含：

- 用户画像。
- 最近点击序列。
- 商品特征。
- 时间、地点、设备。

这些状态无法枚举。函数逼近可以把高维特征映射到价值或策略：

$$Q(s, a; \theta)$$

5.8.3 例子 3：Deadly Triad 为什么危险

假设用 DQN 训练一个推荐策略：

- function approximation：用神经网络估计 Q。
- bootstrapping：target 里有 $\max_a Q(s', a)$ 。
- off-policy：数据来自旧策略或 replay buffer。

如果新策略常推荐训练数据里很少出现的内容，Q 网络可能对这些动作过度乐观；bootstrap 又会把这种高估继续传播，训练就可能发散。

面试表达：

Deadly Triad 的危险不是三个词各自危险，而是它们叠加后，错误估计会通过 bootstrap 在 off-policy 分布外被不断放大。

5.9 本章面试高频问题

5.9.1 为什么表格型 RL 不够用？

因为真实任务的状态空间通常很大或连续，无法为每个状态动作对单独存一个值。函数逼近可以泛化到未见状态，并处理高维输入。

5.9.2 什么是 Deadly Triad？

Function approximation、bootstrapping 和 off-policy learning 三者同时出现时，强化学习训练容易不稳定甚至发散。

5.9.3 为什么神经网络加 Q-learning 会不稳定？

Q-learning 使用 bootstrap target，target 又依赖当前估计。神经网络共享参数，一个样本更新会影响大量状态动作估计。再加上 off-policy 数据分布偏移，误差可能被放大。

5.9.4 replay buffer 解决什么问题？

它通过随机采样历史 transition，打破连续样本相关性，提高样本利用率，并让训练数据分布更平滑。

5.9.5 target network 解决什么问题？

它让 Bellman target 在一段时间内保持相对稳定，避免 online network 更新时 target 也同步剧烈变化。

5.10 本章练习

1. 用自己的话解释 bootstrapping。
2. 画出 DQN 中 online network 和 target network 的关系。
3. 解释为什么 off-policy + function approximation 容易出问题。
4. 总结 DQN 针对 Deadly Triad 做了哪些稳定化设计。

▼ 参考答案（点击展开）

1. **Bootstrapping**：更新 target 中含有当前价值估计本身，例如 TD target $r + \gamma V(s')$ 或 Q-learning target $r + \gamma \max_a Q(s', a')$ 。它能在 episode 结束前更新，但错误估计也可能被反复传递和放大。
2. **Online/target network 关系**：

```

transition batch
  |
  +----- periodically copy / soft update -----> target Q(s', a'; theta-)
  |
  v
online Q(s, a; theta) <--- optimize loss ---+--- target Q(s', a'; theta-)
  |                                     |
  +----- current prediction -----> +--- Bellman target y

```

梯度只更新 online network 的 θ ；target network 的 θ 通过周期性 hard update 或缓慢 soft update 获得。

3. **为什么容易不稳定**：off-policy 数据分布和当前 target policy 想访问的分布不一致；function approximation 又让一次参数更新同时改变许多状态的预测；如果 target 还通过 bootstrapping 依赖这些预测，分布外误差就可能被传播，甚至形成发散反馈。

4. **DQN 的稳定化设计**：replay buffer 随机化并复用历史样本，缓解连续样本相关性；target network 让 bootstrap target 在一段时间内固定；Huber loss、reward clipping、gradient clipping 可限制异常更新；Double DQN 缓解 max 导致的过估计。它们降低风险，但不代表从理论上彻底消除了 Deadly Triad。