

第 8 章：Actor-Critic、A2C (Advantage Actor-Critic, 优势 Actor-Critic)、A3C (Asynchronous Advantage Actor-Critic, 异步优势 Actor-Critic) 与 GAE (Generalized Advantage Estimation, 广义优势估计)

本章符号说明

符号/缩写	English	中文	含义
A2C	Advantage Actor-Critic	优势 Actor-Critic	同步采样和更新的 actor-critic 方法。
A3C	Asynchronous Advantage Actor-Critic	异步优势 Actor-Critic	多 worker 异步更新的 actor-critic 方法。
GAE	Generalized Advantage Estimation	广义优势估计	用 λ 在 TD 和 MC advantage 之间折中。
$\pi_{\theta}(a s)$	Actor Policy	Actor 策略	actor 网络输出的动作分布。
$V_w(s)$	Critic Value Function	Critic 状态价值函数	critic 网络对状态价值的估计。
$Q_w(s,a)$	Critic Action-value Function	Critic 动作价值函数	critic 网络对状态-动作价值的估计。
$J(\theta)$	Policy Objective	策略目标函数	actor 要最大化的目标。
δ_t	TD Error	时序差分误差	可作为一步 advantage 估计。
A_t	Advantage Estimate	优势估计	策略更新时衡量动作好坏的信号。
L_{policy} / L_{value}	Policy Loss / Value Loss	策略损失 / 价值损失	actor 和 critic 的训练损失。
$R_t^{(n)}$	n-step Return	n 步回报	n-step bootstrap target。
λ	GAE Lambda	GAE 衰减参数	控制 bias 和 variance 的折中。
TD	Temporal Difference	时序差分	critic 常用 TD error 做估计。
MC	Monte Carlo	蒙特卡洛	GAE 的另一端近似完整 return。
REINFORCE	REINFORCE algorithm	REINFORCE 算法	Actor-Critic 要改进的高方差 policy gradient 基线。

符号/缩写	English	中文	含义
PPO	Proximal Policy Optimization	近端策略优化	常结合 GAE 使用的策略优化算法。

本章目标

本章学习 Actor-Critic 框架。你需要掌握：

- actor 和 critic 的职责。
- Actor-Critic 如何结合 policy gradient 和 value learning。
- TD error 如何作为 advantage 估计。
- A2C 和 A3C。
- Generalized Advantage Estimation。

Actor-Critic 基本思想

Actor-Critic 有两个部分：

- Actor：策略网络 $\pi_{\theta}(a|s)$ ，负责选动作。
- Critic：价值网络 $V_w(s)$ 或 $Q_w(s,a)$ ，负责评估动作或状态。

Actor 用 critic 提供的学习信号更新策略：

$$\begin{aligned} & \nabla_{\theta} J(\theta) \\ &= \mathbb{E}[\nabla \log \pi_{\theta}(a|s) A(s,a)] \end{aligned}$$

Critic 学习价值函数：

$$V_w(s) \approx V_{\pi}(s)$$

直觉：

Actor 负责做决策，critic 负责评价决策质量。Critic 降低了纯 Monte Carlo policy gradient 的方差，让策略更新更稳定。

TD Error 作为 Advantage

TD error：

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

它可以看成一步 advantage 的估计：

$$A(s_t, a_t) \approx \delta_t$$

直觉：

- 如果实际 reward 加下一状态价值高于当前价值估计，说明这个动作比预期好。
- 如果低于当前价值估计，说明这个动作比预期差。

Actor 更新：

$$\theta \leftarrow \theta + \alpha \nabla \log \pi_{\theta}(a_t | s_t) \delta_t$$

Critic 更新：

$$w \leftarrow w - \beta \nabla (r_t + \gamma V_w(s_{t+1}) - V_w(s_t))^2$$

为什么 TD Error 可以近似 Advantage

Advantage 的定义是：

$$A_{\pi}(s_t, a_t) = Q_{\pi}(s_t, a_t) - V_{\pi}(s_t)$$

而动作价值可以拆成“一步 reward + 下一状态价值”：

$$Q_{\pi}(s_t, a_t) = \mathbb{E}[r_t + \gamma V_{\pi}(s_{t+1})]$$

把它代入 advantage：

$$A_{\pi}(s_t, a_t) = \mathbb{E}[r_t + \gamma V_{\pi}(s_{t+1}) - V_{\pi}(s_t)]$$

如果用一次采样近似这个期望，就得到：

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

所以 TD error 不是随便定义的误差，它正是“一步采样下的 advantage 估计”。

面试里可以这样讲：

如果执行动作后得到的 reward 加下一状态价值超过当前状态价值，说明这个动作比平均动作好，advantage 为正；反之说明动作低于预期，advantage 为负。

Actor-Critic vs REINFORCE

维度	REINFORCE	Actor-Critic
策略更新信号	Monte Carlo return	critic 估计的 advantage
是否 bootstrap	否	通常是
方差	高	较低

维度	REINFORCE	Actor-Critic
bias	较低	有 critic bias
是否能在线更新	通常需要 episode 结束	可以在线或 n-step 更新
sample efficiency	较低	更高

面试表达：

Actor-Critic 用 critic 估计 value 或 advantage，降低 policy gradient 的方差，并允许 TD 式在线更新。但 critic 是函数逼近模型，因此会引入估计 bias。

A2C

A2C 是 Advantage Actor-Critic。

目标通常包含三部分：

1. Policy loss。
2. Value loss。
3. Entropy bonus。

Policy loss：

$$L_{policy} = - \log \pi_{\theta}(a_t | s_t) A_t$$

Value loss：

$$L_{value} = (R_t - V_w(s_t))^2$$

Entropy bonus：

$$L_{entropy} = - \beta H(\pi_{\theta}(\cdot | s_t))$$

整体最小化：

$$L = L_{policy} + c_v L_{value} + L_{entropy}$$

注意符号：很多实现中是最小化 loss，因此 policy gradient 的最大化目标会写成负号。

A3C

A3C 是 Asynchronous Advantage Actor-Critic。

核心思想：

- 多个 worker 并行和环境交互。

- 每个 worker 异步更新共享全局网络。
- 不同 worker 产生的数据降低样本相关性。

A3C 在 replay buffer 不常用的 on-policy 场景中, 通过并行采样改善数据多样性。

A2C 可以看作 A3C 的同步版本:

- A3C: asynchronous。
- A2C: synchronous, 多个环境同步采样后统一更新。

N-step Return

一步 TD target:

$$R_t^{(1)} = r_t + \gamma V(s_{t+1})$$

n-step return:

$$R_t^{(n)} = r_t + \gamma r_{t+1} + \dots + \gamma^{n-1} r_{t+n-1} + \gamma^n V(s_{t+n})$$

n-step return 在 MC 和 TD 之间折中:

- n 小: bias 较大, variance 较小。
- n 大: bias 较小, variance 较大。

Generalized Advantage Estimation

GAE 用一个参数 λ 在不同步数的 advantage 估计之间折中。

TD residual:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

GAE:

$$A_t^{GAE(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

直觉:

- $\lambda = 0$: 接近一步 TD, bias 大、variance 小。
- $\lambda = 1$: 接近 Monte Carlo, bias 小、variance 大。
- 实践中常用 $\lambda = 0.95$ 。

PPO 中经常使用 GAE 估计 advantage。

GAE 的推理过程

一步 TD error 方差小，但依赖 critic，bias 可能大。完整 Monte Carlo return bias 小，但方差大。GAE 的想法是：不要只选一个步数，而是把不同步数的 TD residual 加权平均。

从一步 TD residual 开始：

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

如果下一步也持续“比预期好”，那么 δ_{t+1} 也应该影响当前动作的评价，只是影响要打折：

$$\delta_t + \gamma \lambda \delta_{t+1}$$

继续往后累加，就得到：

$$A_t^{GAE} = \delta_t + \gamma \lambda \delta_{t+1} + (\gamma \lambda)^2 \delta_{t+2} + \dots$$

也就是：

$$A_t^{GAE} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

这里 γ 是时间折扣， λ 是“愿意看多远的误差信号”：

- λ 小：更相信短期 bootstrap，更新稳但 bias 大。
- λ 大：更接近长回报，bias 小但 variance 大。

实践里 PPO 常用 $\lambda=0.95$ ，是因为它通常在稳定性和学习信号之间比较均衡。

Shared Network vs Separate Network

Actor 和 critic 可以：

- 共享一部分 backbone，分别输出 policy head 和 value head。
- 完全分离成两个网络。

共享 backbone 的优点：

- 参数更少。
- 表征可以复用。

风险：

- policy loss 和 value loss 的梯度可能相互干扰。
- 需要调节 value loss coefficient。

本章面试高频问题

1. Actor-Critic 中 actor 和 critic 分别做什么？

Actor 学习策略并负责选动作。Critic 学习价值函数，用来评价 actor 的动作，并为 policy gradient 提供低方差的 advantage 估计。

2. Actor-Critic 相比 REINFORCE 的优势?

Actor-Critic 用 critic 的 value estimate 替代完整 Monte Carlo return, 降低方差, 并支持在线或 n-step 更新, sample efficiency 更高。

3. TD error 为什么可以作为 advantage?

TD error 衡量执行动作后的一步结果是否比当前价值估计更好。如果 $r + \gamma V(s') > V(s)$, 说明动作带来的结果超出预期, 可以增加其概率。

4. A2C 和 A3C 的区别?

A3C 使用多个 worker 异步更新全局网络。A2C 是同步版本, 多个环境同步采样后统一更新, 工程上更稳定、易并行。

5. GAE 解决什么问题?

GAE 在 bias 和 variance 之间做平滑折中, 通过 λ 控制 advantage 估计更接近一步 TD 还是 Monte Carlo return。

本章练习

1. 写出 Actor-Critic 的 actor loss 和 critic loss。
2. 解释 TD error 和 advantage 的关系。
3. 推导 n-step return。
4. 说明 GAE 中 λ 的作用。

[章节索引](#)

[← 上一章](#) [下一章 →](#)