

第 8 章：Actor-Critic、A2C (Advantage Actor-Critic, 优势 Actor-Critic)、A3C (Asynchronous Advantage Actor-Critic, 异步优势 Actor-Critic) 与 GAE (Generalized Advantage Estimation, 广义优势估计)

8.1 本章符号说明

符号/缩写	English	中文	含义
A2C	Advantage Actor-Critic	优势 Actor-Critic	同步采样和更新的 actor-critic 方法。
A3C	Asynchronous Advantage Actor-Critic	异步优势 Actor-Critic	多 worker 异步更新的 actor-critic 方法。
GAE	Generalized Advantage Estimation	广义优势估计	用 λ 在 TD 和 MC advantage 之间折中。
$\pi_{\theta}(a \mid s)$	Actor Policy	Actor 策略	actor 网络输出的动作分布。
$V_w(s)$	Critic Value Function	Critic 状态价值函数	critic 网络对状态价值的估计。
$Q_w(s,a)$	Critic Action-value Function	Critic 动作价值函数	critic 网络对状态-动作价值的估计。
$V_{\pi}(s) \mid Q_{\pi}(s,a)$	True Value Functions under π	策略 π 下的真实价值函数	推导 advantage 时使用的理论状态价值与动作价值。
$A_{\pi}(s,a)$	Advantage Function	优势函数	策略 π 下动作价值相对状态价值的差, 即 $Q_{\pi}(s,a)-V_{\pi}(s)$ 。
$J(\theta)$	Policy Objective	策略目标函数	actor 要最大化的目标。
δ_t	TD Error	时序差分误差	可作为一步 advantage 估计。
A_t	Advantage Estimate	优势估计	策略更新时衡量动作好坏的信号。
$L_{policy} \mid L_{value}$	Policy Loss / Value Loss	策略损失 / 价值损失	actor 和 critic 的训练损失。
V_t^{target}	Value Target	价值目标	用 return 或 bootstrap 构造、用于训练 critic 的监督目标。上标 target 用来区别当前预测 $V_w(s_t)$ 。
$R_t^{(n)}$	n-step Return	n 步回报	n-step bootstrap target。
γ	Discount Factor	折扣因子	控制未来 reward 和 value 的权重。
λ	GAE Lambda	GAE 衰减参数	控制 bias 和 variance 的折中。
$\alpha_{\pi} \mid \alpha_V$	Actor / Critic Learning Rate	Actor / Critic 学习率	分别控制策略参数 θ 和价值参数 w 的更新步长。
β_H	Entropy Coefficient	熵系数	控制 entropy bonus 的强度。

符号/缩写	English	中文	含义
c_v	Value-loss Coefficient	价值损失系数	控制 value loss 在总 loss 中的权重。
on-policy	On-policy Learning	同策略学习	数据来自当前正在更新的策略。
TD	Temporal Difference	时序差分	critic 常用 TD error 做估计。
MC	Monte Carlo	蒙特卡洛	GAE 的另一端近似完整 return。
REINFORCE	REINFORCE algorithm	REINFORCE 算法	Actor-Critic 要改进的高方差 policy gradient 基线。
PPO	Proximal Policy Optimization	近端策略优化	常结合 GAE 使用的策略优化算法。

8.2 本章目标

本章学习 Actor-Critic 框架。你需要掌握：

- actor 和 critic 的职责。
- Actor-Critic 如何结合 policy gradient 和 value learning。
- TD error 如何作为 advantage 估计。
- A2C 和 A3C。
- Generalized Advantage Estimation。

8.3 本章主线

第 7 章的纯 policy gradient 可以直接优化策略，但 Monte Carlo return 方差高。第 3 章的 TD value learning 方差低但主要解决估值。本章把两者合并：actor 负责更新策略，critic 负责估计 value 或 advantage。GAE 则进一步在 MC 和 TD 之间调节 bias/variance。

8.4 本章新增概念说明

Actor-Critic 的词容易混在一起，先按角色定义：

名词	中文	先记住什么
actor	行动者 / 策略网络	负责输出动作或动作分布。
critic	评价者 / 价值网络	负责估计 $V(s)$ 、 $Q(s,a)$ 或 advantage，给 actor 提供学习信号。
actor-critic	Actor-Critic 框架	actor 学策略，critic 学价值，用 critic 降低 policy gradient 方差。
TD error	时序差分误差	一步 target 和当前价值估计的差，可近似 advantage。
A2C	Advantage Actor-Critic	同步采样和更新的 actor-critic 方法。
A3C	Asynchronous Advantage Actor-Critic	多 worker 异步采样和更新的 actor-critic 方法。
n-step return	n 步回报	用未来 n 步真实 reward 加 bootstrap target 构造学习信号。

名词	中文	先记住什么
GAE	广义优势估计	把多个步数的 TD residual 加权平均，平衡 bias 和 variance。
shared network / separate network	共享网络 / 分离网络	actor 和 critic 共用一部分网络，或各自用独立网络。
stop gradient	停止梯度	计算 actor loss 时把 advantage 当作固定学习信号，不让 actor 的梯度反向修改 advantage 的构造过程。

8.5 Actor-Critic 基础

8.5.1 Actor-Critic 基本思想

Actor-Critic 有两个部分：

- Actor：策略网络 $\pi_{\theta}(a|s)$ ，负责选动作。
- Critic：价值网络 $V_w(s)$ 或 $Q_w(s,a)$ ，负责评估动作或状态。

Actor 用 critic 提供的学习信号更新策略：

$$\begin{aligned} & \nabla_{\theta} J(\theta) \\ &= \mathbb{E}[\nabla \log \pi_{\theta}(a|s) A_{\pi}(s,a)] \end{aligned}$$

Critic 学习价值函数：

$$V_w(s) \approx V_{\pi}(s)$$

直觉：

Actor 负责做决策，critic 负责评价决策质量。Critic 降低了纯 Monte Carlo policy gradient 的方差，让策略更新更稳定。

8.5.2 TD Error 作为 Advantage

TD error：

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

它可以看成一步 advantage 的估计：

$$A(s_t, a_t) \approx \delta_t$$

直觉：

- 如果实际 reward 加下一状态价值高于当前价值估计，说明这个动作比预期好。
- 如果低于当前价值估计，说明这个动作比预期差。

Actor 更新：

$$\theta \leftarrow \theta + \alpha_{\pi} \nabla \log \pi_{\theta}(a_t | s_t) \delta_t$$

Critic 更新：

$$w \leftarrow w - \alpha_V \nabla (r_t + \gamma V_w(s_{t+1}) - V_w(s_t))^2$$

8.5.3 为什么 TD Error 可以近似 Advantage

Advantage 的定义是：

$$A_{\pi}(s_t, a_t) = Q_{\pi}(s_t, a_t) - V_{\pi}(s_t)$$

而动作价值可以拆成“一步 reward + 下一状态价值”：

$$Q_{\pi}(s_t, a_t) = \mathbb{E}[r_t + \gamma V_{\pi}(s_{t+1})]$$

把它代入 advantage：

$$A_{\pi}(s_t, a_t) = \mathbb{E}[r_t + \gamma V_{\pi}(s_{t+1}) - V_{\pi}(s_t)]$$

如果用一次采样近似这个期望，就得到：

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

所以 TD error 不是随便定义的误差，它正是“一步采样下的 advantage 估计”。

面试里可以这样讲：

如果执行动作后得到的 reward 加下一状态价值超过当前状态价值，说明这个动作比平均动作好，advantage 为正；反之说明动作低于预期，advantage 为负。

8.5.4 Actor-Critic vs REINFORCE

维度	REINFORCE	Actor-Critic
策略更新信号	Monte Carlo return	critic 估计的 advantage
是否 bootstrap	否	通常是
方差	高	较低
bias	较低	有 critic bias
是否能在线更新	通常需要 episode 结束	可以在线或 n-step 更新
sample efficiency	较低	更高

面试表达：

Actor-Critic 用 critic 估计 value 或 advantage，降低 policy gradient 的方差，并允许 TD 式在线更新。但 critic 是函数逼近模型，因此会引入估计 bias。

8.6 A2C / A3C：Actor-Critic 的采样组织方式

8.6.1 A2C

A2C 是 Advantage Actor-Critic。

目标通常包含三部分：

1. Policy loss。
2. Value loss。
3. Entropy bonus。

Policy loss：

$$L_{policy} = -\log \pi_{\theta}(a_t | s_t) A_t$$

Value loss：

$$L_{value} = (V_t^{target} - V_w(s_t))^2$$

Entropy bonus：

$$L_{entropy} = -\beta_H H(\pi_{\theta}(\cdot | s_t))$$

整体最小化：

$$L = L_{policy} + c_v L_{value} + L_{entropy}$$

注意符号：很多实现中是最小化 loss，因此 policy gradient 的最大化目标会写成负号。

8.6.2 A3C

A3C 是 Asynchronous Advantage Actor-Critic。

核心思想：

- 多个 worker 并行和环境交互。
- 每个 worker 异步更新共享全局网络。
- 不同 worker 产生的数据降低样本相关性。

A3C 在 replay buffer 不常用的 on-policy 场景中，通过并行采样改善数据多样性。这里 on-policy 指数据来自当前正在更新的策略，因此不能像 DQN 那样随意复用很旧的数据。

A2C 可以看作 A3C 的同步版本：

- A3C：asynchronous。
- A2C：synchronous，多个环境同步采样后统一更新。

8.7 多步回报与 GAE

8.7.1 N-step Return

一步 TD target：

$$R_t^{(1)} = r_t + \gamma V(s_{t+1})$$

n-step return:

$$R_t^{(n)} = r_t + \gamma r_{t+1} + \dots + \gamma^{n-1} r_{t+n-1} + \gamma^n V(s_{t+n})$$

n-step return 在 MC 和 TD 之间折中:

- n 小: bias 较大, variance 较小。
- n 大: bias 较小, variance 较大。

8.7.2 Generalized Advantage Estimation

GAE 用一个参数 λ 在不同步数的 advantage 估计之间折中。

TD residual:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

GAE:

$$A_t^{GAE(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

直觉:

- $\lambda = 0$: 接近一步 TD, bias 大、variance 小。
- $\lambda = 1$: 接近 Monte Carlo, bias 小、variance 大。
- 实践中常用 $\lambda = 0.95$ 。

PPO 中经常使用 GAE 估计 advantage。

8.7.3 GAE 的推理过程

一步 TD error 方差小, 但依赖 critic, bias 可能大。完整 Monte Carlo return bias 小, 但方差大。GAE 的想法是: 不要只选一个步数, 而是把不同步数的 TD residual 加权平均。

从一步 TD residual 开始:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

如果下一步也持续“比预期好”, 那么 δ_{t+1} 也应该影响当前动作的评价, 只是影响要打折:

$$\delta_t + \gamma \lambda \delta_{t+1}$$

继续往后累加, 就得到:

$$A_t^{GAE} = \delta_t + \gamma \lambda \delta_{t+1} + (\gamma \lambda)^2 \delta_{t+2} + \dots$$

也就是:

$$A_t^{GAE} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$$

这里 γ 是时间折扣, λ 是“愿意看多远的误差信号”:

- λ 小: 更相信短期 bootstrap, 更新稳但 bias 大。

- λ 大: 更接近长回报, bias 小但 variance 大。

实践里 PPO 常用 $\lambda=0.95$, 是因为它通常在稳定性和学习信号之间比较均衡。

8.8 Actor-Critic 网络结构选择

8.8.1 Shared Network vs Separate Network

Actor 和 critic 可以:

- 共享一部分 backbone, 分别输出 policy head 和 value head。
- 完全分离成两个网络。

共享 backbone 的优点:

- 参数更少。
- 表征可以复用。

风险:

- policy loss 和 value loss 的梯度可能相互干扰。
- 需要调节 value loss coefficient。

8.9 本章例子: Actor 和 Critic 分工

8.9.1 例子 1: 游戏 agent

在一个游戏中:

- Actor 负责选择动作, 例如移动、攻击、防御。
- Critic 负责评价当前局面值多少钱。

如果 Actor 做了一个动作后, Critic 发现:

$$r + \gamma V(s') - V(s) > 0$$

说明这步结果比预期好, Actor 应该增加这个动作在该状态下的概率。

如果 TD error 小于 0, 则说明这步比预期差, Actor 应该降低该动作概率。

8.9.2 例子 2: A2C 和 REINFORCE 对比

REINFORCE 要等一整局结束, 用完整 G_t 更新策略。A2C 用 critic 提供一步或多步 target, 可以更早更新。

REINFORCE target: G_t
A2C target: $r + \gamma V(s')$

所以 A2C 通常方差更低, 但 critic 不准时会带来 bias。

8.9.3 例子 3: GAE 的直觉

如果只用一步 TD error, 更新稳定但可能短视。

如果用完整 return, 信息完整但方差大。

GAE 用 λ 在中间插值:

- λ 接近 0: 更像一步 TD。

- λ 接近 1: 更像 Monte Carlo。

面试表达:

Actor-Critic 可以理解成 policy gradient 加一个会估值的助手。Critic 不直接决定动作, 而是告诉 Actor 这次动作比预期好还是差。

8.10 本章面试高频问题

8.10.1 Actor-Critic 中 actor 和 critic 分别做什么?

Actor 学习策略并负责选动作。Critic 学习价值函数, 用来评价 actor 的动作, 并为 policy gradient 提供低方差的 advantage 估计。

8.10.2 Actor-Critic 相比 REINFORCE 的优势?

Actor-Critic 用 critic 的 value estimate 替代完整 Monte Carlo return, 降低方差, 并支持在线或 n-step 更新, sample efficiency 更高。

8.10.3 TD error 为什么可以作为 advantage?

TD error 衡量执行动作后的一步结果是否比当前价值估计更好。如果 $r + \gamma V(s') > V(s)$, 说明动作带来的结果超出预期, 可以增加其概率。

8.10.4 A2C 和 A3C 的区别?

A3C 使用多个 worker 异步更新全局网络。A2C 是同步版本, 多个环境同步采样后统一更新, 工程上更稳定、易并行。

8.10.5 GAE 解决什么问题?

GAE 在 bias 和 variance 之间做平滑折中, 通过 λ 控制 advantage 估计更接近一步 TD 还是 Monte Carlo return。

8.11 本章练习

1. 写出 Actor-Critic 的 actor loss 和 critic loss。
2. 解释 TD error 和 advantage 的关系。
3. 推导 n-step return。
4. 说明 GAE 中 λ 的作用。

▼ 参考答案 (点击展开)

1. **Actor 和 critic loss:** 一种常见写法是 $L_{actor} = -\mathbb{E}[\log \pi_{\theta}(a_t | s_t) A_t]$, $L_{critic} = \mathbb{E}[(V_w(s_t) - V_t^{target})^2]$ 。工程上常组合为 $L = L_{actor} + c_v L_{critic} - \beta_H H(\pi_{\theta}(\cdot | s_t))$; 计算 actor loss 时通常对 A_t stop gradient。
2. **TD error 与 advantage:** $\delta_t = r_t + \gamma V_{\pi}(s_{t+1}) - V_{\pi}(s_t)$ 。给定 (s_t, a_t) 取条件期望后, $\mathbb{E}[\delta_t | s_t, a_t] = Q_{\pi}(s_t, a_t) - V_{\pi}(s_t) = A_{\pi}(s_t, a_t)$ 。所以单步 TD error 是 advantage 的有噪声样本估计。
3. **N-step return:** 连续展开 return 递归 n 次, 得到 $G_t^{(n)} = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots + \gamma^{n-1} r_{t+n-1} + \gamma^n V(s_{t+n})$ 。若在 n 步内终止, 则终止后的 bootstrap value 为 0。
4. **λ 的作用:** GAE 使用 $A_t^{GAE(\gamma, \lambda)} = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}$ 。 λ 小时更接近一步 TD, bias 较大但 variance 较小; λ 接近 1 时更接近长回报, bias 较小但 variance 较大。它是 bias-variance tradeoff 的旋钮。