

第 9 章：TRPO (Trust Region Policy Optimization, 信赖域策略优化)、PPO (Proximal Policy Optimization, 近端策略优化) 与策略更新约束

本章符号说明

符号/缩写	English	中文	含义
TRPO	Trust Region Policy Optimization	信赖域策略优化	用 KL 约束限制策略更新幅度。
PPO	Proximal Policy Optimization	近端策略优化	用 clipping objective 近似限制策略更新幅度。
KL	Kullback-Leibler Divergence	KL 散度	衡量新旧策略分布差异。
θ / θ_{old}	New / Old Policy Parameters	新 / 旧策略参数	当前要优化的策略参数和采样数据时的旧参数。
$r_t(\theta)$	Probability Ratio	概率比	新策略和旧策略对同一动作的概率比。
A_t	Advantage Estimate	优势估计	判断当前动作应提高还是降低概率的信号。
$L^{CLIP}(\theta)$	Clipped Objective	截断目标函数	PPO 用来限制策略更新的 surrogate objective。
ϵ	Clipping Range	截断范围	PPO 中控制 ratio 允许变化范围的超参数。
L_{policy} / L_{value}	Policy Loss / Value Loss	策略损失 / 价值损失	PPO 总 loss 的两个主要部分。
$H(\pi)$	Entropy	熵	鼓励策略保持探索的正则项。
behavior policy	Behavior Policy	行为策略	产生当前 rollout 数据的旧策略。
target policy	Target Policy	目标策略	当前正在优化的新策略。
on-policy	On-policy Learning	同策略学习	主要用当前策略或近似当前策略采样的数据更新。

符号/缩写	English	中文	含义
off-policy	Off-policy Learning	异策略学习	用其他策略产生的数据学习目标策略。
CLIP	Clipped Objective Label	截断目标标记	L^{CLIP} 中的上标, 表示 PPO 的 clipped surrogate objective。
GAE	Generalized Advantage Estimation	广义优势估计	PPO 中常用的 advantage 估计方法。
DQN	Deep Q-Network	深度 Q 网络	PPO 对比中的 value-based deep RL 算法。
RL / RLHF	Reinforcement Learning / Reinforcement Learning from Human Feedback	强化学习 / 基于人类反馈的强化学习	PPO 既用于 RL, 也常出现在 RLHF 流程中。

本章目标

本章学习现代 on-policy deep RL 中最常用的一类算法。你需要掌握：

- 为什么 policy gradient 需要限制更新步长。
- importance sampling ratio。
- TRPO 的 trust region 思想。
- PPO clipping objective。
- PPO 的训练细节。
- PPO 的优缺点。

本章主线

Actor-Critic 解决了 policy gradient 高方差问题，但策略更新仍可能一步走太大，导致新策略和采样数据对应的旧策略差异过大。本章专门处理“更新幅度控制”：TRPO 用 trust region 和 KL 约束，PPO 用 clipping objective 做更易实现的近似。

为什么要限制策略更新

Policy Gradient 直接更新策略参数：

$$\theta \leftarrow \theta + \alpha \nabla J(\theta)$$

但策略优化很敏感。如果一次更新太大，新的 policy 和采样数据对应的旧 policy 差异过大，可能导致性能崩掉。

原因：

- on-policy 数据只对采样它的旧策略可靠。
- 策略变化太大时，旧数据不能准确估计新策略表现。

- neural policy 的参数小变化可能导致动作分布大变化。

因此 TRPO/PPO 都试图限制新旧策略距离。

Importance Sampling Ratio

PPO/TRPO 常用 ratio:

$$r_t(\theta) = \pi_{\theta}(a_t | s_t) / \pi_{\theta_{old}}(a_t | s_t)$$

它表示在同一个 (s_t, a_t) 上, 新策略相对于旧策略的概率变化。

Policy objective 可写成:

$$L(\theta) = \mathbb{E}[r_t(\theta) A_t]$$

如果 $A_t > 0$, 希望增加该动作概率, 即增大 ratio。

如果 $A_t < 0$, 希望降低该动作概率, 即减小 ratio。

Ratio 从哪里来

PPO 的数据是旧策略 $\pi_{\theta_{old}}$ 采样出来的, 但我们想评估新策略 π_{θ} 。如果完全重新采样, 成本很高; 如果直接把旧数据当新数据, 又会有分布偏差。

importance sampling 的基本想法是:

$$\mathbb{E}_{a \sim \pi_{\theta}}[f(a)] = \mathbb{E}_{a \sim \pi_{old}}[\pi_{\theta}(a | s) / \pi_{old}(a | s) f(a)]$$

所以出现 ratio:

$$r_t(\theta) = \pi_{\theta}(a_t | s_t) / \pi_{\theta_{old}}(a_t | s_t)$$

它把“旧策略采到的动作”校正成“新策略下这个动作有多可能”。但 ratio 如果太大或太小, 说明新旧策略差异太大, 旧数据对新策略的估计就不可靠。这就是后面 clipping 的动机。

TRPO

TRPO 是 Trust Region Policy Optimization。

它希望在提升 surrogate objective 的同时, 限制新旧策略的 KL divergence:

$$\begin{aligned} & \max_{\theta} \mathbb{E}[r_t(\theta) A_t] \\ & \text{subject to } \mathbb{E}[KL(\pi_{old}(\cdot | s_t) \parallel \pi_{\theta}(\cdot | s_t))] \leq \delta \end{aligned}$$

核心思想:

每次策略更新不能离旧策略太远, 保证更新在 trust region 内。

优点：

- 理论上更稳定。
- 避免灾难性大步更新。

缺点：

- 实现复杂。
- 需要二阶近似、conjugate gradient、line search。
- 工程成本较高。

PPO

PPO 是 Proximal Policy Optimization。它保留了限制策略更新幅度的思想，但实现更简单。

PPO clipped objective：

$$\begin{aligned} L^{CLIP}(\theta) \\ = \mathbb{E}[\min(r_t(\theta) A_p, \\ clip(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon) A_p)] \end{aligned}$$

其中：

$$r_t(\theta) = \pi_{\theta}(a_t | s_t) / \pi_{\theta_{old}}(a_t | s_t)$$

ε 常用 0.1 或 0.2。

PPO Clipping 直觉

当 $A_t > 0$ ：

- 增大动作概率是好事。
- 但 ratio 超过 $1 + \varepsilon$ 后，收益被截断。
- 防止过度增加该动作概率。

当 $A_t < 0$ ：

- 降低动作概率是好事。
- 但 ratio 低于 $1 - \varepsilon$ 后，收益被截断。
- 防止过度降低该动作概率。

一句话：

PPO clipping 允许策略朝 advantage 指示的方向更新，但限制更新幅度，避免新旧策略差异过大。

Clipping 分情况推理

PPO 的 min 不是为了让公式复杂，而是为了“好方向可以走，但不要走太猛”。

情况 1: $A_t > 0$

动作比平均水平好，应该提高它的概率。未截断目标是：

$$r_t A_t$$

当 r_t 从 1 增大时，目标变大，表示鼓励新策略更常选这个动作。但如果 $r_t > 1 + \epsilon$ ，说明概率已经提高太多。此时 clipped 项固定在：

$$(1 + \epsilon) A_t$$

再提高概率也不会得到更多收益，梯度被压住。

情况 2: $A_t < 0$

动作比平均水平差，应该降低它的概率。因为 A_t 是负数，减小 r_t 会让 $r_t A_t$ 变大，看起来是好事。但如果 $r_t < 1 - \epsilon$ ，说明概率已经降低太多。clipped 项固定在：

$$(1 - \epsilon) A_t$$

PPO 取 min，会阻止继续通过过度降低概率来“刷目标”。

因此 clipped objective 同时限制两种过度更新：

- 好动作概率不能一下子加太多。
- 坏动作概率不能一下子降太多。

这就是 PPO 比普通 policy gradient 更稳的核心。

PPO Loss 组成

常见 PPO 总 loss：

$$L = L_{policy} + c_v L_{value} - c_e Entropy$$

如果按最小化写：

$$L_{policy} = - \mathbb{E}[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$

Value loss：

$$L_{value} = \mathbb{E}[(V(s_t) - R_t)^2]$$

Entropy bonus：

$$Entropy = \mathbb{E}[H(\pi(\cdot | s_t))]$$

实际实现中还可能有的：

- advantage normalization。

- value clipping。
- gradient clipping。
- target KL early stopping。
- learning rate annealing。

PPO 训练流程

```
for each iteration:
    collect rollout using pi_old
    compute returns and advantages, often with GAE
    for several epochs:
        shuffle rollout data
        split into minibatches
        update policy with clipped objective
        update value function
    set pi_old <- current policy
```

注意：

PPO 是 on-policy，但它会对同一批 rollout 做多个 epoch 的 minibatch 更新。clipping 机制就是为了让这种有限复用不至于让策略偏离太远。

PPO 一轮训练的推理顺序

从实现角度，PPO 一轮迭代可以按下面理解：

1. 用当前策略采样 rollout，此时这份数据绑定的是 π_{old} 。
2. 用 reward 和 critic 计算 return。
3. 用 GAE 计算 advantage，得到每个动作“比平均水平好多少”。
4. 保存旧策略对已采样动作的 log probability。
5. 更新时重新计算新策略 log probability。
6. 用新旧 log probability 的差得到 ratio。
7. 用 clipped objective 更新 actor。
8. 用 return target 更新 critic。
9. 用 entropy bonus 防止策略过早塌缩。

这里最关键的是第 4 到第 7 步：PPO 不是只看当前策略输出，而是一直比较“新策略相对采样时旧策略改了多少”。

PPO 为什么常用

优点：

- 实现比 TRPO 简单。
- 稳定性好。
- 对超参数相对不那么敏感。

- 离散和连续动作都能用。
- 成为很多 RLHF 早期流程中的常见选择。

缺点：

- on-policy, sample efficiency 不如 off-policy 方法。
- 需要大量环境交互。
- 对 reward scaling、advantage normalization 仍然敏感。
- clipping 不是严格 trust region, 仍可能出现不稳定。

PPO vs DQN

维度	DQN	PPO
类型	value-based	policy-based / actor-critic
动作空间	离散	离散和连续
策略	由 Q argmax 导出	直接学习 policy
数据使用	off-policy	on-policy
样本效率	较高	较低
稳定性	需要 replay 和 target network	clipping + GAE 较稳定

本章例子：PPO clipping 怎么工作

假设某个动作在旧策略下概率是 0.20, 新策略下概率是 0.26。

importance ratio 是：

$$r_t = 0.26 / 0.20 = 1.3$$

如果 $\epsilon = 0.2$, 允许范围是：

$$[0.8, 1.2]$$

Advantage 为正

如果 $A_t > 0$, 说明这个动作比预期好, 应该提高概率。但 ratio 已经到 1.3, 超过 1.2, PPO 会把收益截断在 1.2, 防止策略一步变太多。

Advantage 为负

如果 $A_t < 0$, 说明这个动作不好, 应该降低概率。但如果新策略把概率降得过猛, ratio 低于 0.8, 也会被 clip。

RLHF 例子

在 RLHF 里, 策略是语言模型, 动作可以理解成生成 token。PPO 更新时：

- reward model 给回答打分。
- critic 估计 value。
- advantage 判断这段输出比预期好还是差。
- KL 或 clipping 防止模型偏离参考模型太远。

面试表达：

PPO 的例子要讲清楚 ratio。它不是禁止策略更新，而是限制同一批数据上新旧策略概率比变化过大，避免 policy gradient 一步把策略推崩。

本章面试高频问题

1. PPO 解决了什么问题？

PPO 解决普通 policy gradient 更新过大导致策略崩掉的问题。它通过 clipping objective 限制新旧策略概率比的变化，使策略更新更稳定。

2. PPO 的 ratio 是什么？

$$r_t(\theta) = \pi_{\theta}(a_t | s_t) / \pi_{old}(a_t | s_t)$$

它衡量新策略相对于采样数据的旧策略，对同一动作概率改变了多少。

3. PPO clipping objective 的直觉？

如果 advantage 为正，允许提高动作概率，但超过 $1 + \epsilon$ 后不再给额外收益。如果 advantage 为负，允许降低动作概率，但低于 $1 - \epsilon$ 后不再给额外收益。

4. PPO 和 TRPO 的区别？

TRPO 通过 KL constraint 显式限制策略更新，理论更严谨但实现复杂。PPO 用 clipping 或 KL penalty 近似 trust region 思想，实现简单，工程上更常用。

5. PPO 是 on-policy 还是 off-policy？

PPO 通常是 on-policy。虽然它会对同一批 rollout 做多个 epoch 更新，但数据仍来自当前旧策略，且通过 ratio 和 clipping 控制偏移。

本章练习

1. 手写 PPO clipped objective。
2. 分别解释 $A_t > 0$ 和 $A_t < 0$ 时 clipping 的效果。
3. 对比 TRPO 和 PPO。
4. 说明 PPO 中 GAE、entropy bonus、advantage normalization 的作用。

[章节索引](#)

[← 上一章](#) [下一章 →](#)