

第 10 章：连续控制、DDPG (Deep Deterministic Policy Gradient, 深度确定性策略梯度)、TD3 (Twin Delayed DDPG, 双延迟 DDPG) 与 SAC (Soft Actor-Critic, 软 Actor-Critic)

10.1 本章符号说明

符号/缩写	English	中文	含义
DDPG	Deep Deterministic Policy Gradient	深度确定性策略梯度	连续动作空间的 off-policy actor-critic 算法。
TD3	Twin Delayed DDPG	双延迟 DDPG	用双 Q、延迟 actor 更新和 target smoothing 改进 DDPG。
SAC	Soft Actor-Critic	软 Actor-Critic	最大熵 off-policy actor-critic 算法。
$S_t / A_t / R_{t+1}$	State / Action / Reward Random Variable	状态 / 动作 / 奖励随机变量	时刻 t 的状态、动作和执行动作后收到的奖励。
$Q_w(s,a)$	Critic Action-value Function	Critic 动作价值函数	参数 w 下的 Q 估计。
$\mu_\theta(s)$	Deterministic Actor	确定性 actor	DDPG/TD3 中 actor 输出的连续动作。
$\pi_\theta(a s)$	Stochastic Actor	随机 actor	SAC 中 actor 输出的动作分布。
K_t / U_t	Discrete Type / Continuous Parameter	离散类型 / 连续参数	混合动作中时刻 t 的离散选择和连续参数随机变量。
$\pi_{\theta_d} / \pi_{\theta_c}$	Discrete / Continuous Policy Head	离散 / 连续策略分支	混合 Actor 中分别输出 categorical choice 和 conditional continuous distribution 的分支。
$\hat{A}_t$	Advantage Estimate	优势估计	On-policy 混合 Actor-Critic 更新整个联合动作时使用的相对价值信号。
w^- / θ^-	Target Critic / Actor Parameters	目标 critic / actor 参数	从在线参数滞后更新得到、用于构造稳定 target 的参数；上标 - 表示 target network。
Q_i^- / μ^-	Target Critic / Target Actor	目标 Q 网络 / 目标 actor	TD3/SAC 中的 target 网络简写； i 是 twin critic 的编号。
(s,a,r,s',d)	Transition Tuple	转移样本五元组	replay buffer 中的当前状态、动作、奖励、下一状态和终止指示量。
d / done	Terminal Indicator	终止指示量	$d=1$ 时没有后续价值, $d=0$ 时可以从 s' bootstrap。
D	Replay-buffer Distribution	回放数据分布	公式 $s \sim D$ 表示从 replay buffer 的样本状态中取期望。

符号/缩写	English	中文	含义
γ	Discount Factor	折扣因子	控制下一状态 soft value 或 Q value 的权重。
y	Bellman Target	Bellman 目标	critic 训练时的目标值。
$J(\theta)$	Actor Objective	Actor 目标函数	actor 要最大化或等价最小化的目标。
Q_1 / Q_2	Twin Q Networks	双 Q 网络	TD3/SAC 中用于缓解过估计的两个 critic。
$H(\pi)$	Entropy	熵	SAC 目标中鼓励策略随机性的项。
α	Temperature	温度系数	SAC 中 reward 和 entropy 的权衡参数。
ϵ_t	Exploration Noise	探索噪声	DDPG/TD3 与环境交互时加到确定性动作上的噪声。
ϵ_{clip}	Clipped Target Noise	截断目标噪声	TD3 构造 target action 时加入并限制幅度的平滑噪声；不是 PPO 的 clipping range。
off-policy	Off-policy Learning	异策略学习	可以用 replay buffer 中旧策略产生的数据更新当前策略。
target policy smoothing	Target Policy Smoothing	目标策略平滑	TD3 中给 target action 加噪声，避免 critic 学到尖锐错误峰值。
DQN	Deep Q-Network	深度 Q 网络	离散动作空间的 value-based 算法，本章用它引出连续动作困难。

10.2 本章目标

本章学习连续动作空间中的经典 off-policy actor-critic 算法。你需要掌握：

- 连续动作为什么不适合普通 DQN。
- DDPG。
- TD3。
- SAC。
- entropy regularization。
- deterministic policy vs stochastic policy。

10.3 本章主线

第 6 章的 DQN 依赖离散动作枚举，第 9 章的 PPO 是 on-policy，样本效率相对低。连续控制通常既需要 actor 直接输出连续动作，又希望 off-policy 复用 replay buffer。本章围绕这个目标讲 DDPG、TD3、SAC：它们都是连续动作下的 off-policy actor-critic，只是稳定性和探索处理不同。

10.4 本章新增概念说明

连续控制章节的核心是“动作不能枚举”，相关名词先放这里：

名词	中文	先记住什么
continuous action	连续动作	动作是连续数值，例如力矩、速度、角度，不能像 DQN 那样枚举。
deterministic actor	确定性 actor	输入状态后直接输出一个连续动作。
stochastic actor	随机 actor	输出动作分布，再从分布中采样动作。
critic	评价网络	估计 $Q(s,a)$ ，告诉 actor 哪些动作价值高。
DDPG	深度确定性策略梯度	用 deterministic actor 处理连续动作的 off-policy actor-critic。
TD3	双延迟 DDPG	通过双 Q、延迟 actor 更新、target policy smoothing 稳定 DDPG。
SAC	软 Actor-Critic	用最大熵目标训练 stochastic actor，探索更稳定。
exploration noise	探索噪声	DDPG/TD3 中加到动作上的噪声，用来探索连续动作空间。
target actor / target critic	目标 actor / 目标 critic	滞后更新的 actor/critic，用来构造更稳定的 target。
clipped double Q	截断双 Q	两个 critic 取较小值，缓解过估计。
delayed policy update	延迟策略更新	critic 多更新几次后再更新 actor，让评价更可靠。
target policy smoothing	目标策略平滑	给 target action 加小噪声，让 critic 不过拟合尖锐 Q 峰值。
maximum entropy objective	最大熵目标	同时最大化 reward 和策略熵，让策略保持探索。

10.5 连续动作问题和 Actor 思路

10.5.1 连续动作空间的挑战

DQN 需要计算：

$$\max_a Q(s', a)$$

如果动作空间是离散且规模不大，可以枚举所有动作。
但连续动作空间无法枚举，例如机器人控制中的力矩、速度、角度。

因此需要直接学习一个 actor 输出动作：

$$a = \mu_\theta(s)$$

或者输出动作分布：

$$a \sim \pi_\theta(\cdot | s)$$

10.5.2 从 DQN 到 Actor 的推理过程

DQN 在离散动作中可以做：

$$a^* = \arg \max_a Q(s, a)$$

连续动作下，这个 maximization 本身就是一个困难优化问题。如果每次决策都在动作空间里搜索最大 Q，代价很高，也不稳定。

DDPG/TD3/SAC 的思路是额外训练一个 actor，让 actor 学会直接输出“critic 认为高价值”的动作：

```
critic: 评价 Q(s, a)
actor: 产生让 Q(s, a) 尽量大的动作
```

所以连续控制里的 actor 不是装饰，它是在替代 DQN 中对动作的显式枚举或 argmax。

10.5.3 混合动作为什么不能直接套纯 DDPG、TD3 或 SAC

第 7 章定义过混合动作：

$$A_t = (K_t, U_t)$$

其中 K_t 是离散类型， U_t 是该类型下的连续参数。例如：

```
K_t = {等待, 买入, 卖出}
U_t = [价格, 数量]
```

纯 DDPG/TD3 的 Actor 假设整个动作都是可微连续向量：

$$A_t = \mu_\theta(S_t)$$

它依赖 Critic 对动作的梯度：

$$\nabla_a Q(s, a)$$

但 categorical sample 或离散 $\arg \max$ 对离散类型 K_t 不可按同样方式直接求导。因此不能让 DDPG 输出一个连续数再四舍五入成动作类型：环境执行的是离散结果，而 Actor/Critic 反传所假设的动作还是原连续数，两者优化语义不一致。

纯连续 SAC 也通常假设可从连续分布重参数化采样。混合动作需要显式拆成：

$$\pi_\theta(k, u | s) = \pi_{\theta_d}(k | s) \pi_{\theta_c}(u | s, k)$$

相应 Critic 可以写成：

$$Q_w(s, k, u)$$

常见处理路线：

1. **On-policy 联合策略**：使用 A2C/PPO 一类 score-function gradient，Actor loss 同时包含 categorical 和 conditional continuous log probability。
2. **混合 SAC 变体**：离散类型较少时，对 k 枚举或取期望；每个 k 再对条件连续参数 u 采样并计算 soft Q。
3. **参数化动作方法**：离散分支选择动作类型，连续分支只输出被选类型需要的参数，Critic 对 (s, k, u) 联合估值。

以 joint Actor-Critic 为例：

$$L_{actor} = -\mathbb{E}[(\log \pi_{\theta_d}(K_t | S_t) + \log \pi_{\theta_c}(U_t | S_t, K_t)) \hat{A}_t]$$

这里有三个实现边界：

- 只训练实际被选中的 K_t 所对应的连续参数分支。
- 不同离散类型的连续参数维度和合法范围要分别 mask。
- categorical entropy 与 continuous entropy 尺度不同，需要分别监控或加权。

所以本章后续 DDPG、TD3、SAC 的标准公式都默认 **纯连续动作空间**。遇到离散加连续的混合空间时，应先写清联合动作分解，再选择或改造算法，不能只说“Actor 可以输出连续动作”就结束。

10.6 DDPG：确定性 Actor-Critic

10.6.1 DDPG

DDPG 是 Deep Deterministic Policy Gradient。

它适用于连续动作空间，是 off-policy actor-critic。

组件：

- Actor：确定性策略 $\mu_{\theta}(s)$ 。
- Critic：动作价值函数 $Q_w(s, a)$ 。
- Replay buffer。
- Target actor。
- Target critic。

Critic target：

$$y = r + \gamma(1-d) Q_w(s', \mu_{\theta}(s'))$$

这里 d 是 replay transition 的终止指示量： $d=1$ 时 target 只剩即时奖励 r ； $d=0$ 时才加入下一状态的 bootstrap value。

Critic loss：

$$L(w) = \mathbb{E}[(Q_w(s, a) - y)^2]$$

Actor objective：

$$J(\theta) = \mathbb{E}[Q_w(s, \mu_{\theta}(s))]$$

Actor 更新：

$$\begin{aligned} \nabla_{\theta} J \\ = \mathbb{E}[\nabla_a Q_w(s, a)|_{a=\mu_{\theta}(s)} \nabla_{\theta} \mu_{\theta}(s)] \end{aligned}$$

这个梯度来自 chain rule。目标是让：

$$J(\theta) = Q_w(s, \mu_{\theta}(s))$$

变大。参数 θ 先影响 actor 输出的动作 $\mu_{\theta}(s)$ ，动作再影响 critic 给出的 $Q_w(s, a)$ 。所以更新方向分两段：

- $\nabla_a Q_w(s, a)$: critic 告诉 actor, 动作往哪个方向改能提高 Q。
- $\nabla_{\theta} \mu_{\theta}(s)$: actor 告诉参数, 怎么改参数能让动作往那个方向移动。

面试表达:

DDPG 用 critic 对连续动作求梯度, 再通过 actor 反传到策略参数, 相当于用 actor 学一个可微的 argmax。

这里和 PPO 的旧动作 importance ratio 不同。DDPG 更新 Actor 时, 从 replay buffer 取的是状态 s , 但送入 Critic 的动作不是数据里保存的旧动作 a , 而是当前 Actor 重新生成的 $\mu_{\theta}(s)$ 。Critic 提供这个当前动作附近的可微 Q 曲面, 梯度直接穿过 $Q_w(s, \mu_{\theta}(s))$ 回到 Actor; 更新 Actor 时固定 Critic 参数 w , 但保留 Q 对动作输入的梯度。Off-policy Deterministic Policy Gradient (异策略确定性策略梯度) 定理允许在 behavior policy 的状态分布下定义并优化这一目标, 因此不需要对历史动作写 score-function ratio; 前提仍是 replay 数据对相关状态和动作区域有足够覆盖, 否则 Critic 的梯度同样不可靠。

探索:

DDPG 的策略是 deterministic, 因此训练时通常给动作加噪声:

$$a_t = \mu_{\theta}(s_t) + \epsilon_t$$

10.6.2 DDPG 的问题

DDPG 比较脆弱, 常见问题:

- Q 值过估计。
- 对超参数敏感。
- exploration noise 难调。
- actor 可能利用 critic 的错误高估。
- 训练容易不稳定。

TD3 就是针对 DDPG 的几个问题做改进。

10.7 TD3: 修正 DDPG 的过估计和不稳定

10.7.1 TD3

TD3 是 Twin Delayed DDPG。

核心改进:

1. Clipped Double Q-learning。
2. Delayed policy update。
3. Target policy smoothing。

10.7.1.1 Clipped Double Q-learning

TD3 学两个 critic:

$$Q_1(s, a), Q_2(s, a)$$

target 使用两者较小值:

$$y = r + \gamma(1-d) \min_i Q_i^-(s', a')$$

这样可以缓解 overestimation bias。

10.7.1.2 Delayed Policy Update

Critic 更新多次后, actor 再更新一次。

直觉:

critic 估计更可靠后, 再用它指导 actor, 减少 actor 被错误 Q 值带偏。

10.7.1.3 Target Policy Smoothing

target action 加入 clipped noise:

$$a' = \mu^-(s') + \epsilon_{clip}$$

这里 ϵ_{clip} 通常由零均值高斯噪声截断得到, a' 还会再限制到环境合法动作范围; 然后用 a' 计算 target。

直觉:

让 critic 不要对动作空间中的尖锐错误峰值过拟合, 使 Q 函数更平滑。

它不要和 DDPG/TD3 收集数据时的 exploration noise 混为一谈: exploration noise 加在当前 Actor 的环境动作上, 目的是访问更多状态动作; target smoothing noise 只在训练时构造下一状态 target action, 目的是让 Critic 不依赖一个孤立尖峰。两者出现位置和职责不同。

10.7.2 TD3 三个改进的共同逻辑

TD3 的三个 trick 都围绕同一个问题: actor 很容易利用 critic 的错误。

改进	解决的问题	推理
双 Q 取最小	Q 过估计	如果一个 critic 偶然高估, 取 min 可以更保守。
延迟 actor 更新	actor 跟着错误 critic 跑	先多训几步 critic, 让评价器更靠谱, 再更新 actor。
target smoothing	critic 对尖锐动作峰值过拟合	target 动作附近加噪声, 让 Q 在局部更平滑。

一句话:

TD3 不是三个孤立技巧, 而是在防止 deterministic actor 钻 critic 估计误差的空子。

10.8 SAC: 最大熵 Actor-Critic

10.8.1 SAC

SAC 是 Soft Actor-Critic, 是现代连续控制中非常常用的算法。

核心思想:

最大化 reward 的同时最大化策略 entropy。

目标:

$$\mathbb{E}[\sum_t \gamma^t (r_t + \alpha H(\pi(.|s_t)))]$$

或者写成：

$$\mathbb{E}[\sum_t \gamma^t (r_t - \alpha \log \pi(a_t|s_t))]$$

其中 α 是 temperature, 控制 entropy 权重。

10.8.2 SAC 的组件

SAC 通常包含：

- Stochastic actor: $\pi_\theta(a|s)$ 。
- 两个 Q network: Q_1, Q_2 。
- target Q networks。
- replay buffer。
- temperature parameter α 。

Soft Q target:

$$y = r + \gamma(1-d) [\min_i Q_i(s', a') - \alpha \log \pi(a'|s')]$$

其中：

$$a' \sim \pi_\theta(\cdot|s')$$

上面的 a' 用来构造 Critic target; 更新 Critic 时, 整个 target y 都停止梯度, 不会顺便更新 Actor。Actor 由下面单独的 Actor objective 更新, 而其中的连续动作采样需要一条可微路径。常见 Gaussian Actor 使用 Reparameterization Trick (重参数化技巧):

$$\varepsilon \sim N(0, I), u = \mu_\theta(s) + \sigma_\theta(s) \odot \varepsilon, a = \tanh(u)$$

N 表示 Normal Distribution (正态分布), I 是 Identity Matrix (单位矩阵), 所以 ε 是各维独立的标准正态辅助噪声。随机性被放进与 θ 无关的 ε , 而 a 成为参数的可微函数, 所以 Actor loss 的梯度可以沿 $Q(s, a)$ 对动作的梯度回传到 θ 。这与第 7 章对离散采样使用的 score-function gradient 是两条不同的求导路径; $\tanh$ 后的 log density 还要包含变量变换校正。

Actor objective:

$$J_\pi(\theta) = \mathbb{E}[\alpha \log \pi_\theta(a|s) - \min_i Q_i(s, a)]$$

最小化这个 loss 等价于选择高 Q 且高 entropy 的动作分布。

10.8.3 SAC Soft Target 的推理过程

普通 Bellman target 是:

$$y = r + \gamma Q(s', a')$$

SAC 的目标不是只最大化 reward, 而是最大化 reward 加 entropy。对某个动作来说, entropy 项可以写成:

$$-\alpha \log \pi(a'|s')$$

所以 soft value 可以理解为:

$$Q(s', a') - \alpha \log \pi(a'|s')$$

代回 Bellman target, 就得到:

$$y=r+\gamma(1-d)[\min_i Q_i^-(s',a')-alog\pi(a'|s')]$$

为什么 actor loss 是:

$$J_{\pi}(\theta)=\mathbb{E}[alog\pi_{\theta}(a|s)-\min_i Q_i(s,a)]$$

因为实现里通常最小化 loss。最小化这个式子等价于:

- 最大化 Q: 让动作回报高。
- 最大化 entropy: 不是逐点把某个 $\log\pi(a|s)$ 压低, 而是利用 $H(\pi(\cdot|s))=-\mathbb{E}_{a\sim\pi}[\log\pi(a|s)]$ 。因此在分布期望上, 最小化 $\mathbb{E}[alog\pi]$ 等价于最大化熵; 连续分布的 density 甚至可能大于 1, 不能只靠单个 log density 的正负判断。

面试里可以说:

SAC 把探索写进目标函数, 而不是只靠外加噪声。Soft target 中的 $-alog\pi$ 会奖励更高熵的动作分布, 因此策略既追求高 Q, 也保持足够随机性。

10.8.4 Entropy Regularization 的意义

SAC 不只是把 entropy 当作训练 trick, 而是把它放进目标函数。

好处:

- 鼓励探索。
- 避免策略过早确定。
- 对多模态最优策略更友好。
- 训练通常比 DDPG/TD3 更稳定。

α 控制探索程度:

- α 大: 更重视 entropy, 策略更随机。
- α 小: 更重视 reward, 策略更确定。

现代 SAC 常自动调节 α , 让策略 entropy 接近 target entropy。

10.9 连续控制算法对比和选型

10.9.1 DDPG vs TD3 vs SAC

维度	DDPG	TD3	SAC
策略	deterministic	deterministic	stochastic
数据	off-policy	off-policy	off-policy
critic	单 Q	双 Q	双 Q
探索	外加噪声	外加噪声	entropy 驱动
稳定性	较弱	比 DDPG 强	通常更强
适用	连续控制	连续控制	连续控制、鲁棒训练

10.9.2 本章例子：连续控制怎么选算法

10.9.2.1 例子 1：机械臂控制

机械臂每个关节输出连续力矩：

```
a = [torque_shoulder, torque_elbow, torque_wrist]
```

DQN 不适合，因为动作不是离散的。DDPG、TD3、SAC 可以直接输出连续动作。

10.9.2.2 例子 2：DDPG 的问题

如果 critic 对某个连续动作附近估值过高，actor 会被 critic 引导到这个错误高值区域。

这就是 DDPG 容易不稳定的原因：

critic 估错 → actor 追错 → 数据分布变差 → critic 更难学准

10.9.2.3 例子 3：TD3 怎么修

TD3 用两个 critic：

$$\min(Q_1, Q_2)$$

如果一个 critic 过高估计，另一个没那么高，取 min 可以降低过估计传播。

10.9.2.4 例子 4：SAC 为什么适合探索

如果机器人需要学会走路，早期策略不能太确定，否则很容易卡在局部动作模式。SAC 的 entropy 项鼓励策略保持随机性：

既要拿高 reward，也要保持足够探索

面试表达：

DDPG、TD3、SAC 都处理连续动作。DDPG 是基础 actor-critic，TD3 主要修过估计和不稳定，SAC 用最大熵目标把探索写进优化目标。

10.10 本章面试高频问题

10.10.1 为什么 DQN 不适合连续动作？

DQN 需要对动作枚举并取 $\max_a Q(s,a)$ 。连续动作空间无法枚举，直接求 argmax 也通常很难，因此需要 actor 直接输出连续动作。

10.10.2 DDPG 的核心是什么？

DDPG 是连续动作空间下的 off-policy actor-critic。Actor 输出确定性动作，critic 评估 $Q(s,a)$ ，actor 通过最大化 critic 给出的 Q 值来更新。

10.10.3 TD3 相比 DDPG 做了哪些改进？

TD3 使用双 critic 取最小值缓解过估计，延迟 actor 更新提高稳定性，并使用 target policy smoothing 平滑 Q 函数。

10.10.4 SAC 为什么稳定？

SAC 使用最大熵目标, 鼓励高 reward 和高 entropy 的策略; 同时使用双 Q 网络、target network 和 replay buffer。Entropy regularization 带来更好的探索和鲁棒性。

10.10.5 SAC 中 α 是什么?

α 是 entropy temperature, 控制 reward 和 entropy 的权衡。 α 越大, 策略越随机、探索越强; α 越小, 策略越偏向最大化 reward。

10.11 本章练习

1. 写出 DDPG critic target 和 actor objective。
2. 解释 TD3 的三个 trick。
3. 写出 SAC soft Q target。
4. 对比 deterministic policy 和 stochastic policy。

▼ 参考答案 (点击展开)

1. **DDPG 目标**: critic target 为 $y=r+\gamma(1-d)Q_w(s',\mu_\theta(s'))$, critic 最小化 $\mathbb{E}[(Q_w(s,a)-y)^2]$; actor 最大化 $J(\theta)=\mathbb{E}_{s\sim D}[Q_w(s,\mu_\theta(s))]$, 等价地最小化其负值。 w,θ 是 target network 参数, d 是 terminal indicator。
2. **TD3 三个 trick**: Clipped Double Q-learning 取两个 target critic 的较小值, 缓解过估计; Delayed Policy Update 降低 actor 和 target network 的更新频率, 让 critic 先学稳; Target Policy Smoothing 在 target action 上加截断噪声, 抑制 policy 利用狭窄的 Q 函数错误峰值。
3. **SAC soft Q target**: $y=r+\gamma(1-d)[\min_{i=1,2}Q_i(s',a')-a\log\pi_\theta(a'/s')]$, 其中 $a'\sim\pi_\theta(\cdot/s')$ 。减去 $a\log\pi$ 等价于加入 entropy reward。
4. **确定性 vs 随机策略**: deterministic policy 对每个 state 输出单一 action, 执行高效, DDPG/TD3 通常另外加 exploration noise; stochastic policy 输出 action distribution, 自带探索并能表示多峰或不确定行为, SAC/PPO 属于这一类, 但需要处理采样和 log-probability。确定性策略适合动作输出稳定的控制, 随机策略在探索和鲁棒性上通常更自然。