

# 第 10 章：连续控制、DDPG (Deep Deterministic Policy Gradient, 深度确定性策略梯度)、TD3 (Twin Delayed DDPG, 双延迟 DDPG) 与 SAC (Soft Actor-Critic, 软 Actor-Critic)

## 本章符号说明

| 符号/缩写                  | English                            | 中文             | 含义                                          |
|------------------------|------------------------------------|----------------|---------------------------------------------|
| DDPG                   | Deep Deterministic Policy Gradient | 深度确定性策略梯度      | 连续动作空间的 off-policy actor-critic 算法。         |
| TD3                    | Twin Delayed DDPG                  | 双延迟 DDPG       | 用双 Q、延迟 actor 更新和 target smoothing 改进 DDPG。 |
| SAC                    | Soft Actor-Critic                  | 软 Actor-Critic | 最大熵 off-policy actor-critic 算法。             |
| $Q_w(s,a)$             | Critic Action-value Function       | Critic 动作价值函数  | 参数 $w$ 下的 Q 估计。                             |
| $\mu_\theta(s)$        | Deterministic Actor                | 确定性 actor      | DDPG/TD3 中 actor 输出的连续动作。                   |
| $\pi_\theta(a \mid s)$ | Stochastic Actor                   | 随机 actor       | SAC 中 actor 输出的动作分布。                        |
| $y$                    | Bellman Target                     | Bellman 目标     | critic 训练时的目标值。                             |
| $J(\theta)$            | Actor Objective                    | Actor 目标函数     | actor 要最大化或等价最小化的目标。                        |
| $Q_1 / Q_2$            | Twin Q Networks                    | 双 Q 网络         | TD3/SAC 中用于缓解过估计的两个 critic。                 |
| $H(\pi)$               | Entropy                            | 熵              | SAC 目标中鼓励策略随机性的项。                           |
| $\alpha$               | Temperature                        | 温度系数           | SAC 中 reward 和 entropy 的权衡参数。               |
| DQN                    | Deep Q-Network                     | 深度 Q 网络        | 离散动作空间的 value-based 算法，本章用它引出连续动作困难。        |

## 本章目标

本章学习连续动作空间中的经典 off-policy actor-critic 算法。你需要掌握：

- 连续动作为什么不适合普通 DQN。
- DDPG。
- TD3。
- SAC。
- entropy regularization。
- deterministic policy vs stochastic policy。

## 连续动作空间的挑战

DQN 需要计算：

$$\max_a Q(s', a)$$

如果动作空间是离散且规模不大，可以枚举所有动作。

但连续动作空间无法枚举，例如机器人控制中的力矩、速度、角度。

因此需要直接学习一个 actor 输出动作：

$$a = \mu_{\theta}(s)$$

或者输出动作分布：

$$a \sim \pi_{\theta}(\cdot | s)$$

## 从 DQN 到 Actor 的推理过程

DQN 在离散动作中可以做：

$$a^* = \operatorname{argmax}_a Q(s, a)$$

连续动作下，这个 maximization 本身就是一个困难优化问题。如果每次决策都在动作空间里搜索最大 Q，代价很高，也不稳定。

DDPG/TD3/SAC 的思路是额外训练一个 actor，让 actor 学会直接输出“critic 认为高价值”的动作：

```
critic: 评价 Q(s, a)
actor: 产生让 Q(s, a) 尽量大的动作
```

所以连续控制里的 actor 不是装饰，它是在替代 DQN 中对动作的显式枚举或 argmax。

## DDPG

DDPG 是 Deep Deterministic Policy Gradient。

它适用于连续动作空间，是 off-policy actor-critic。

组件：

- Actor：确定性策略  $\mu_\theta(s)$ 。
- Critic：动作价值函数  $Q_w(s,a)$ 。
- Replay buffer。
- Target actor。
- Target critic。

Critic target：

$$y = r + \gamma Q_w(s', \mu_\theta(s'))$$

Critic loss：

$$L(w) = \mathbb{E}[(Q_w(s,a) - y)^2]$$

Actor objective：

$$J(\theta) = \mathbb{E}[Q_w(s, \mu_\theta(s))]$$

Actor 更新：

$$\begin{aligned} \nabla_\theta J \\ = \mathbb{E}[\nabla_a Q_w(s,a)|_{a=\mu_\theta(s)} \nabla_\theta \mu_\theta(s)] \end{aligned}$$

这个梯度来自 chain rule。目标是让：

$$J(\theta) = Q_w(s, \mu_\theta(s))$$

变大。参数  $\theta$  先影响 actor 输出的动作  $\mu_\theta(s)$ ，动作再影响 critic 给出的  $Q_w(s,a)$ 。所以更新方向分两段：

- $\nabla_a Q_w(s,a)$ ：critic 告诉 actor，动作往哪个方向改能提高 Q。
- $\nabla_\theta \mu_\theta(s)$ ：actor 告诉参数，怎么改参数能让动作往那个方向移动。

面试表达：

DDPG 用 critic 对连续动作求梯度，再通过 actor 反传到策略参数，相当于用 actor 学一个可微的 argmax。

探索：

DDPG 的策略是 deterministic，因此训练时通常给动作加噪声：

$$a_t = \mu_\theta(s_t) + \varepsilon_t$$

## DDPG 的问题

DDPG 比较脆弱，常见问题：

- Q 值过估计。
- 对超参数敏感。
- exploration noise 难调。
- actor 可能利用 critic 的错误高估。
- 训练容易不稳定。

TD3 就是针对 DDPG 的几个问题做改进。

## TD3

TD3 是 Twin Delayed DDPG。

核心改进：

1. Clipped Double Q-learning。
2. Delayed policy update。
3. Target policy smoothing。

### Clipped Double Q-learning

TD3 学两个 critic：

$$Q_1(s, a), Q_2(s, a)$$

target 使用两者较小值：

$$y = r + \gamma \min_i Q_i^-(s', a')$$

这样可以缓解 overestimation bias。

### Delayed Policy Update

Critic 更新多次后，actor 再更新一次。

直觉：

critic 估计更可靠后，再用它指导 actor，减少 actor 被错误 Q 值带偏。

### Target Policy Smoothing

target action 加入 clipped noise：

$$a' = \mu^-(s') + \epsilon_{clip}$$

再用  $a'$  计算 target。

直觉：

让 critic 不要对动作空间中的尖锐错误峰值过拟合，使 Q 函数更平滑。

## TD3 三个改进的共同逻辑

TD3 的三个 trick 都围绕同一个问题：actor 很容易利用 critic 的错误。

| 改进               | 解决的问题               | 推理                              |
|------------------|---------------------|---------------------------------|
| 双 Q 取最小          | Q 过估计               | 如果一个 critic 偶然高估，取 min 可以更保守。   |
| 延迟 actor 更新      | actor 跟着错误 critic 跑 | 先多训几步 critic，让评价器更靠谱，再更新 actor。 |
| target smoothing | critic 对尖锐动作峰值过拟合   | target 动作附近加噪声，让 Q 在局部更平滑。      |

一句话：

TD3 不是三个孤立技巧，而是在防止 deterministic actor 钻 critic 估计误差的空子。

## SAC

SAC 是 Soft Actor-Critic，是现代连续控制中非常常用的算法。

核心思想：

最大化 reward 的同时最大化策略 entropy。

目标：

$$\mathbb{E}[\sum_t \gamma^t (r_t + \alpha H(\pi(.|s_t)))]$$

或者写成：

$$\mathbb{E}[\sum_t \gamma^t (r_t - \alpha \log \pi(a_t|s_t))]$$

其中  $\alpha$  是 temperature，控制 entropy 权重。

## SAC 的组件

SAC 通常包含：

- Stochastic actor:  $\pi_\theta(a|s)$ 。
- 两个 Q network:  $Q_1, Q_2$ 。
- target Q networks。
- replay buffer。
- temperature parameter  $\alpha$ 。

Soft Q target:

$$y = r + \gamma [\min_i Q_i^-(s', a') - \alpha \log \pi(a'|s')]$$

其中:

$$a' \sim \pi_\theta(.|s')$$

Actor objective:

$$J_\pi(\theta) = \mathbb{E}[\alpha \log \pi_\theta(a|s) - \min_i Q_i(s, a)]$$

最小化这个 loss 等价于选择高 Q 且高 entropy 的动作分布。

## SAC Soft Target 的推理过程

普通 Bellman target 是:

$$y = r + \gamma Q(s', a')$$

SAC 的目标不是只最大化 reward, 而是最大化 reward 加 entropy。对某个动作来说, entropy 项可以写成:

$$-\alpha \log \pi(a'|s')$$

所以 soft value 可以理解为:

$$Q(s', a') - \alpha \log \pi(a'|s')$$

代回 Bellman target, 就得到:

$$y = r + \gamma [\min_i Q_i^-(s', a') - \alpha \log \pi(a'|s')]$$

为什么 actor loss 是:

$$J_\pi(\theta) = \mathbb{E}[\alpha \log \pi_\theta(a|s) - \min_i Q_i(s, a)]$$

因为实现里通常最小化 loss。最小化这个式子等价于:

- 最大化 Q: 让动作回报高。
- 最大化 entropy: 因为最小化  $\log \pi$  倾向避免策略过度确定。

面试里可以说:

SAC 把探索写进目标函数, 而不是只靠外加噪声。Soft target 中的  $-\alpha \log \pi$  会奖励更高熵的动作分布, 因此策略既追求高 Q, 也保持足够随机性。

# Entropy Regularization 的意义

SAC 不只是把 entropy 当作训练 trick，而是把它放进目标函数。

好处：

- 鼓励探索。
- 避免策略过早确定。
- 对多模态最优策略更友好。
- 训练通常比 DDPG/TD3 更稳定。

$\alpha$  控制探索程度：

- $\alpha$  大：更重视 entropy，策略更随机。
- $\alpha$  小：更重视 reward，策略更确定。

现代 SAC 常自动调节  $\alpha$ ，让策略 entropy 接近 target entropy。

## DDPG vs TD3 vs SAC

| 维度     | DDPG          | TD3           | SAC        |
|--------|---------------|---------------|------------|
| 策略     | deterministic | deterministic | stochastic |
| 数据     | off-policy    | off-policy    | off-policy |
| critic | 单 Q           | 双 Q           | 双 Q        |
| 探索     | 外加噪声          | 外加噪声          | entropy 驱动 |
| 稳定性    | 较弱            | 比 DDPG 强      | 通常更强       |
| 适用     | 连续控制          | 连续控制          | 连续控制、鲁棒训练  |

## 本章面试高频问题

### 1. 为什么 DQN 不适合连续动作？

DQN 需要对动作枚举并取  $\max_a Q(s,a)$ 。连续动作空间无法枚举，直接求 argmax 也通常很难，因此需要 actor 直接输出连续动作。

### 2. DDPG 的核心是什么？

DDPG 是连续动作空间下的 off-policy actor-critic。Actor 输出确定性动作，critic 评估  $Q(s,a)$ ，actor 通过最大化 critic 给出的 Q 值来更新。

### 3. TD3 相比 DDPG 做了哪些改进？

TD3 使用双 critic 取最小值缓解过估计，延迟 actor 更新提高稳定性，并使用 target policy smoothing 平滑 Q 函数。

### 4. SAC 为什么稳定？

SAC 使用最大熵目标，鼓励高 reward 和高 entropy 的策略；同时使用双 Q 网络、target network 和 replay buffer。Entropy regularization 带来更好的探索和鲁棒性。

## 5. SAC 中 $\alpha$ 是什么？

$\alpha$  是 entropy temperature，控制 reward 和 entropy 的权衡。 $\alpha$  越大，策略越随机、探索越强； $\alpha$  越小，策略越偏向最大化 reward。

## 本章练习

---

1. 写出 DDPG critic target 和 actor objective。
2. 解释 TD3 的三个 trick。
3. 写出 SAC soft Q target。
4. 对比 deterministic policy 和 stochastic policy。

[章节索引](#)

[← 上一章](#) [下一章 →](#)

---