

第 10 章：从 DDPG 到 TD3 与 SAC：连续动作的 Off-policy Actor-Critic

10.1 本章符号说明

符号/缩写	English	中文	本章中的具体含义
DPG	Deterministic Policy Gradient	确定性策略梯度	对确定性策略的期望 Q 值直接求梯度。
DDPG	Deep Deterministic Policy Gradient	深度确定性策略梯度	用神经网络、Replay Buffer 和 Target Network 实现 DPG。
TD3	Twin Delayed DDPG	双延迟 DDPG	用双 Critic、延迟 Actor 更新和 Target Policy Smoothing 修正 DDPG。
SAC	Soft Actor-Critic	软 Actor-Critic	最大化 Reward 与 Entropy 的 Off-policy 随机 Actor-Critic。
DQN	Deep Q-Network	深度 Q 网络	依赖离散动作枚举的价值算法，本章用作连续动作问题的对照。
PPO	Proximal Policy Optimization	近端策略优化	可通过联合 Log Probability 处理混合动作的 On-policy 方法。
$S_t A_t R_{t+1}$	State, Action, Reward Random Variable	状态、动作、奖励随机变量	时刻 t 的随机状态、动作，以及执行后得到的奖励。
s, a, r, s'	State, Action, Reward Realization	状态、动作、奖励的样本值	Replay Buffer 某条 Transition 中的具体数值。
d / done	Terminal Indicator	真终止指示量	$d=1$ 表示轨迹真正终止，Target 不再 Bootstrap；时间上限截断通常不能直接当作真终止。
D	Replay Buffer	经验回放池	存储旧策略产生的 (s, a, r, s', d) ，供 Off-policy 更新复用。
$\mu_\theta(s)$	Deterministic Actor	确定性 Actor	参数 θ 的网络，在状态 s 直接输出一个连续动作。
$\pi_\theta(a s)$	Stochastic Actor	随机 Actor	参数 θ 的策略分布；SAC 从中采样动作。
$Q_{w_i}(s, a)$	Action-value Critic	动作价值 Critic	参数 w_i 的第 i 个 Q 网络，估计动作的长期价值。
$\bar{\theta}, \bar{w}_i$	Target-network Parameters	目标网络参数	在线参数的慢速副本，只用于构造较稳定的 Bellman Target。
y	Bellman Target	Bellman 训练目标	Critic 回归时希望 $Q(s, a)$ 接近的标量。
γ	Discount Factor	折扣因子	下一状态价值在 Target 中的权重。
η_Q, η_π	Critic / Actor Learning Rate	Critic / Actor 学习率	两类网络各自的优化步长。

符号/缩写	English	中文	本章中的具体含义
τ	Polyak Update Rate	Polyak 软更新系数	目标参数每次向在线参数移动的比例，通常远小于 1。
ζ_t	Exploration Noise	交互探索噪声	DDPG/TD3 收集真实数据时加到 Actor 动作上的噪声。
ε	Target Smoothing Noise	Target 平滑噪声	TD3 构造下一状态 Target Action 时加入的截断噪声。
α	Entropy Temperature	熵温度系数	SAC 中平衡 Reward 与 Entropy 的正数。
$H(\pi)$	Policy Entropy	策略熵	策略分布的随机程度。
ε	Reparameterization Noise	重参数化辅助噪声	SAC 中与网络参数无关的标准正态噪声。
I	Identity Matrix	单位矩阵	$\varepsilon \sim \mathcal{N}(0, I)$ 的协方差矩阵。
$\odot$	Element-wise Product	逐元素乘法	均值、标准差与噪声按动作维度相乘。

后文统一假设动作空间是有界连续向量。混合离散与连续动作放在 10.9 单独讨论。

10.2 本章目标

学完本章，你应该能回答四个连续问题：

1. 连续动作为什么不能直接照搬 DQN（Deep Q-Network，深度 Q 网络）的 $\max_a Q(s, a)$ ？
2. DDPG 怎样让 Actor 学成一个可微的近似 $\arg \max$ ？
3. TD3 的三个改进为什么都在防止 Actor 利用 Critic 的误差？
4. SAC 怎样从最大熵目标得到 Soft Bellman Target 和 Actor Loss？

10.3 本章主线

连续动作不能枚举

- > 训练 Actor 直接输出高 Q 动作
- > DDPG：确定性 Actor + 单 Critic + Replay
- > Actor 会追逐 Critic 的虚假尖峰
- > TD3：双 Critic + 延迟更新 + Target 平滑
- > 外加动作噪声仍然是人为探索机制
- > SAC：随机 Actor + 最大熵目标 + 双 Critic

三种算法不是互不相关的公式集合。DDPG 给出最基本的连续 Off-policy Actor-Critic；TD3修复它的价值估计问题；SAC进一步把探索写进优化目标。

10.4 从离散 Argmax 到连续 Actor

10.4.1 DQN 卡在哪里

离散动作 DQN 可以逐个计算 Q 值：

$$a^*(s) = \arg \max_{a \in A} Q(s, a)$$

若动作是机械臂的 7 维关节力矩，每一维都连续，动作组合不可枚举。每个环境步都重新对 a 做数值优化也昂贵且不稳定。

连续控制因此增加一个 Actor：

$$a = \mu_{\theta}(s)$$

Critic 仍然回答“动作有多好”，Actor 学习“怎样一次前向就给出高价值动作”。可以把 Actor 理解为被训练出来的、摊销后的 $\arg \max$ 求解器。

10.4.2 Actor 和 Critic 的职责必须分开

模块	输入	输出	学习信号
Critic	(s, a)	$Q_w(s, a)$	Bellman Target y
Actor	s	动作 $\mu_{\theta}(s)$ 或分布 $\pi_{\theta}(\cdot s)$	Critic 对当前动作的评价

Critic 不是最终决策器；Actor 也不能凭空知道动作好坏。两者相互依赖，因此 Critic 的估值误差会直接影响 Actor。

10.5 DDPG：最基本的连续 Off-policy 闭环

10.5.1 为什么要有四个网络

DDPG 包含在线 Actor μ_{θ} 、在线 Critic Q_w ，以及它们的慢速副本 $\mu_{bar \theta}$ 、 $Q_{bar w}$ 。

- 在线网络负责学习。
- 目标网络只负责构造 Target。
- Replay Buffer 复用历史 Transition，因此算法是 Off-policy（异策略）：采样数据的旧行为策略可以不同于正在更新的当前 Actor。

10.5.2 Critic：先学会评价数据动作

从 D 采样 (s, a, r, s', d) 。下一状态先由目标 Actor 给动作，再由目标 Critic 估值：

$$y = r + \gamma(1-d)Q_{bar w}(s', \mu_{bar \theta}(s')r)$$

Critic Loss（Critic 损失）为：

$$L_Q(w) = \mathbb{E}_{(s, a, r, s', d) \sim D} [(Q_w(s, a) - sg(y))^2]$$

sg 是 Stop Gradient（停止梯度）：更新在线 Critic 时， y 被当作固定标签，不沿 Target 网络反传。

这里输入 Critic 的 a 是 Replay Buffer 中真实执行过的动作，因为它对应真实观测到的 r, s' 。

这个平方损失怎样把 Q 推向 Target？先看单样本，令误差 $e = Q_w(s, a) - y$ ：

$$\nabla_w L_Q = 2e \nabla_w Q_w(s, a)$$

优化器做梯度下降 $w \leftarrow w - \eta_Q \nabla_w L_Q$ ：

- 若 $Q_w > y$ ，则 $e > 0$ ，更新会让当前 Q 倾向减小。
- 若 $Q_w < y$ ，则 $e < 0$ ，减去负方向会让当前 Q 倾向增大。

所以不需要另外写“把 Q 拉向 y ”的规则，平方损失的梯度已经自动完成这件事。

10.5.3 Actor：把 Critic 当作可微评分器

Actor 要最大化当前 Actor 动作的 Q 值：

$$J_{\mu}(\theta) = \mathbb{E}_{s \sim D} [Q_w(s, \mu_{\theta}(s)r)]$$

对参数 θ 使用链式法则：

$$\nabla_{\theta} J_{\mu} = \mathbb{E}_{s \sim D} [\nabla_a Q_w(s, a)|_{a=\mu_{\theta}(s)} \nabla_{\theta} \mu_{\theta}(s)]$$

这两个因子分别回答：

- $\nabla_a Q_w$ ：动作往哪个方向移动会提高 Q？
- $\nabla_{\theta} \mu_{\theta}$ ：参数怎样变化才能让动作向那个方向移动？

更新 Actor 时，Critic 参数 w 固定，但保留 Q 对动作输入 a 的梯度。此处不能使用 Replay Buffer 里的旧动作 a ，因为旧动作不依赖当前 θ ，无法把梯度传回当前 Actor。

这里要区分“固定 Critic 参数”和“切断整个 Critic”：

```
theta -> Actor(s) -> action -> Critic(s, action) -> Q
      需要梯度      需要梯度      w 不更新，但对 action 的梯度保留
```

若把 Critic 输出整体 `detach`， $\nabla_a Q$ 也会消失，Actor 就没有学习方向。

10.5.4 一个一维 Actor 梯度例子

假设某状态下 Critic 学到：

$$Q(s, a) = 5 - (a - 0.7)^2$$

当前 Actor 输出 $a = \mu_{\theta}(s) = 0.2$ ，且在这个样本上 $\partial \mu_{\theta}(s) / \partial \theta = 0.5$ 。则：

$$\partial Q / \partial a|_{a=0.2} = -2(0.2 - 0.7) = 1$$

$$\partial J_{\mu} / \partial \theta = 1 \times 0.5 = 0.5$$

梯度上升会增大 θ ，从而让动作从 0.2 朝最优点 0.7 移动。若当前动作在 0.7 右侧， $\partial Q / \partial a$ 会变成负数，参数就向相反方向更新。

10.5.5 Critic Target 数值例子

设 $r=1$ 、 $\gamma=0.99$ 、 $d=0$ ，目标 Actor 给出 $a'=0.4$ ，目标 Critic 估计 $Q_{bar\ w}(s', a')=4$ ：

$$y = 1 + 0.99 \times 4 = 4.96$$

若在线 Critic 当前输出 3.5，单样本平方误差是：

$$(3.5 - 4.96)^2 = 2.1316$$

若 $d=1$ ，则 $y=r=1$ ，不能再加入下一状态价值。

10.5.6 探索噪声和目标网络解决不同问题

DDPG 的 Actor 是确定性的。收集数据时通常执行：

$$a_t = \text{clip}_A (\mu_\theta(s_t) + \zeta_t)$$

ζ_t 负责探索；目标网络负责降低 Bootstrap Target 的快速漂移。两者不能互相替代。

目标网络使用 Polyak Soft Update (Polyak 软更新)：

$$\bar{w} \leftarrow (1-\tau)\bar{w} + \tau w$$

$$\bar{\theta} \leftarrow (1-\tau)\bar{\theta} + \tau \theta$$

10.5.7 DDPG 一轮训练的完整流程

初始化在线 Actor/Critic 和对应 Target 网络

初始化 Replay Buffer

重复：

- 用 $a = \text{Actor}(s) + \text{exploration noise}$ 与环境交互
- 存储 $(s, a, r, s', \text{done})$
- 从 Replay Buffer 随机采样 batch
- 用 Target Actor 和 Target Critic 构造 y
- 最小化 $(Q(s,a)-y)^2$ 更新在线 Critic
- 最大化 $Q(s, \text{Actor}(s))$ 更新在线 Actor
- 对两个 Target 网络做 Polyak 软更新

10.5.8 DDPG 为什么容易失败

Actor 会主动寻找 Critic 预测最高的动作。只要 Critic 某个未充分覆盖的区域出现虚假高峰，Actor 就会向那里移动，随后 Target 也可能使用这些不可靠动作 Bootstrap，形成正反馈：

Critic 偶然高估

- > Actor 追逐高估区域
- > Target 使用这个动作
- > 高估继续传播

这正是 TD3 的出发点。

10.6 TD3：围绕“Actor 会利用 Critic 误差”做三项修复

10.6.1 Clipped Double Q：Target 取两个 Critic 的较小值

TD3 学两个独立 Critic Q_{w_1}, Q_{w_2} 。Target 为：

$$y = r + \gamma(1-d) \min_{i \in \{1,2\}} Q_{\bar{w}_i}(s', a')$$

如果一个 Critic 偶然高估，另一个没有同步高估，取较小值可减少过估计进入 Bootstrap Target。代价是可能略偏保守，但对确定性 Actor 而言通常比追逐虚假峰值更安全。

10.6.2 Target Policy Smoothing：不要相信孤立尖峰

TD3 不直接令 $a' = \mu_{\text{bar}\theta}(s')$ ，而是：

$$\varepsilon \sim \text{clip}(\mathcal{N}(0, \sigma_{\text{targ}}^2 I), -c, c)$$

$$a' = \text{clip}_A(\mu_{\text{bar}\theta}(s') + \varepsilon)$$

σ_{targ} 是 Target Noise Standard Deviation（目标噪声标准差）， c 是噪声截断幅度。Critic 被迫学习动作邻域的平均质量，而不是依赖一个极窄的高值点。

注意两类噪声：

噪声	出现位置	目的
ξ_t	当前状态与真实环境交互	收集更多样的数据
ε	下一状态构造训练 Target	平滑 Q Target，抑制尖峰

10.6.3 Delayed Policy Update: Critic 多走几步，Actor 再跟

若每次 Critic 刚更新一步就让 Actor 追随，Actor 会放大 Critic 的短期噪声。TD3 通常每更新 Critic 多次，才更新一次 Actor 和 Target 网络。

“Delayed” 指 Actor/Target 的更新频率低于 Critic，不是把环境 Reward 延迟处理。

10.6.4 三项改进怎样组成一个闭环

双 Critic 取 min：减少高估进入 Target
Target 平滑：减少 Critic 形成尖锐高估
延迟 Actor：减少 Actor 追逐尚未稳定的 Critic

10.6.5 TD3 数值例子

设 $r=1$ 、 $\gamma=0.99$ 、 $d=0$ 。目标 Actor 输出 0.60 ，采到 Target Noise -0.05 ，因此 $a'=0.55$ 。两个目标 Critic 分别输出：

$$Q_{\text{bar } w_1}(s', 0.55) = 8, Q_{\text{bar } w_2}(s', 0.55) = 5.5$$

则：

$$y = 1 + 0.99 \times \min(8, 5.5) = 6.445$$

若沿用单 Critic 的 8，Target 会是 8.92。TD3 不证明 5.5 一定正确，只是避免把某一个网络的乐观误差直接交给 Actor。

10.6.6 TD3 一轮更新

每个训练 step：

1. 采样 replay batch
2. 用 Target Actor + clipped noise 得到 a'
3. 用两个 Target Critic 的 min 构造 y
4. 更新两个在线 Critic
5. 每隔 policy_delay 个 step：
 - 更新 Actor，使 $Q_1(s, \text{Actor}(s))$ 增大
 - 软更新 Actor 和两个 Critic 的 Target 网络

Actor 通常只通过 Q_{w_i} 更新；双 Critic 的核心用途是构造保守 Target。

10.7 SAC：把探索写进最大熵目标

10.7.1 为什么 TD3 之后还需要 SAC

TD3 的探索依赖外加噪声及其调度。SAC 改用随机 Actor，并把策略熵放进目标，让“保持随机性”本身成为优化的一部分。

Maximum-entropy Objective（最大熵目标）为：

$$J(\pi) = \mathbb{E}_{\pi} [\sum_{t=0}^{\infty} \gamma^t (R_{t+1} + \alpha H(\pi(\cdot|S_t)))]$$

因为：

$$H(\pi(\cdot|s)) = -\mathbb{E}_{a \sim \pi} [\log \pi(a|s)]$$

单个采样动作对应的 Soft Value 项是 $Q(s,a) - \alpha \log \pi(a|s)$ 。

10.7.2 SAC Critic：Soft Bellman Target

SAC 通常也使用两个 Critic。对下一状态重采样 $a' \sim \pi_{\theta}(\cdot|s')$ ：

$$y = r + \gamma(1-d) [\min_{i \in \{1,2\}} Q_{bar w_i}(s',a') - \alpha \log \pi_{\theta}(a'|s')]]$$

两个 Critic 分别最小化：

$$L_{Q_i}(w_i) = \mathbb{E}_D [(Q_{w_i}(s,a) - sg(y))^2]$$

Soft Target 同时计入下一动作的长期 Reward 价值和策略随机性价值。

10.7.3 Soft Target 数值例子

设 $r=1$ 、 $\gamma=0.99$ 、 $d=0$ 、双 Q 较小值为 5、 $\log \pi(a'|s')=-0.7$ 、 $\alpha=0.2$ ：

$$5 - 0.2 \times (-0.7) = 5.14$$

$$y = 1 + 0.99 \times 5.14 = 6.0886$$

这里 $-\alpha \log \pi$ 为正，不是“每个低概率动作都应被奖励”。它是熵的 Monte Carlo 样本，只有放在当前策略的动作分布期望下才等价于熵。

10.7.4 SAC Actor：从 Soft-greedy 分布得到 Actor Loss

第一次学习 SAC，不需要先从 KL 投影入手。直接从“Actor 想最大化什么”推即可。固定一个状态，最大熵目标希望最大化：

$$\mathbb{E}_{a \sim \pi_{\theta}} [Q(s,a) + \alpha H(\pi(\cdot|s))]$$

把熵写成 $H = -\mathbb{E}[\log \pi]$ ：

$$\max_{\theta} \mathbb{E}_{a \sim \pi_{\theta}} [Q(s,a) - \alpha \log \pi_{\theta}(a|s)]$$

深度学习框架通常最小化 Loss，因此整体取负号：

$$L_{\pi}(\theta) = \mathbb{E} [\alpha \log \pi_{\theta}(a|s) - Q(s,a)]$$

这就是 SAC Actor Loss 的必要推导。符号检查也很直接：最小化 $-Q$ 会提高 Q ；最小化 $\alpha \log \pi$ 的分布期望会提高熵。下面的 KL 视角用于进一步解释目标分布，属于第二遍理解。给定一个 Soft Q ，理想策略不是只选唯一最大动作，而是：

$$\pi^*(a|s) \propto \exp(Q(s,a) / \alpha)$$

当前 Actor 可通过最小化下面的 Kullback-Leibler Divergence (KL 散度) 逼近它：

$$D_{KL}(\pi_{\theta}(\cdot|s) \parallel \exp(Q(s,\cdot)/\alpha) / Z(s))$$

$Z(s)$ 是 Partition Function (配分函数)，只依赖状态。展开并去掉与 θ 无关的常数，得到常用 Actor Loss：

$$L_{\pi}(\theta) = \mathbb{E}_{s \sim D, a \sim \pi_{\theta}} [\alpha \log \pi_{\theta}(a|s) - \min_i Q_{w_i}(s,a)]$$

最小化它同时做到：

- 让 $Q(s,a)$ 变大；
- 让 $\mathbb{E}[\log \pi]$ 变小，也就是让熵变大。

上面的两个推导得到同一个 Loss：前者从“最大化 Q 加熵”出发，更适合第一次理解；后者说明 SAC 在把策略投影到一个按 $\exp(Q/\alpha)$ 加权的 Soft-greedy 分布。

10.7.5 连续采样怎样把梯度传回 Actor

常见 SAC Actor 输出高斯分布的均值和标准差，再重参数化：

$$\varepsilon \sim \mathcal{N}(0, I)$$

$$u = \mu_{\theta}(s) + \sigma_{\theta}(s) \odot \varepsilon, a = \tanh(u)$$

随机性被放进与 θ 无关的 ε ，所以 a 是 θ 的可微函数。Actor 梯度既经过 $\log \pi_{\theta}(a|s)$ ，也经过 $Q(s,a)$ 对动作的梯度。

由于 $\tanh$ 改变了概率密度，计算 $\log \pi(a|s)$ 时必须加入 Change-of-variables Correction (变量变换校正)。面试中知道这一工程边界即可，不必现场展开 Jacobian 公式。

10.7.6 温度 α 如何自动调节

自动温度属于实现增强。第一次学习只需把 α 当作固定超参数，并记住“熵不足时应增大 α ，熵过高时应减小 α ”。

α 大时更重视熵，策略更随机； α 小时更重视 Q ，策略更确定。设 H_{target} 为 Target Entropy (目标熵)，可用样本 $-\log \pi(a|s)$ 估计当前熵，并优化：

$$L_{\alpha} = \mathbb{E} [\alpha (-\log \pi_{\theta}(a|s) - H_{target})]$$

采用梯度下降时：

- 当前熵低于目标，括号期望为负， α 会增大；
- 当前熵高于目标，括号期望为正， α 会减小。

实现中通常优化 $\log \alpha$ 来保证 $\alpha > 0$ 。不同代码对 Target Entropy 的正负号约定不同，判断时应回到“熵不足就增大 α ”这一语义。

10.7.7 SAC 一轮训练的完整流程

```
用随机 Actor 与环境交互并写入 Replay Buffer
重复若干梯度步：
    采样 replay batch
    从当前 Actor 在  $s'$  重参数化采样  $a'$ 
    用双 Target Critic 的 min 和  $-\alpha \log \pi$  构造  $y$ 
    更新两个在线 Critic
    从当前 Actor 在  $s$  重参数化采样新动作  $a$ 
    最小化  $\alpha \log \pi(a|s) - \min Q(s,a)$  更新 Actor
    可选：更新温度  $\alpha$ 
    软更新两个 Target Critic
```

SAC 不需要 Target Actor，因为 Soft Target 的下一动作直接从当前随机 Actor 采样；目标双 Critic 仍用于稳定 Bootstrap。

10.8 DDPG、TD3、SAC 的统一比较

维度	DDPG	TD3	SAC
Actor	确定性	确定性	随机
数据使用	Off-policy Replay	Off-policy Replay	Off-policy Replay
Critic	单 Q	双 Q	双 Q
探索	外加交互噪声	外加交互噪声	最大熵策略
Target Action	Target Actor	Target Actor + 平滑噪声	当前 Actor 采样
Actor 更新	每步可更新	延迟更新	通常每个训练步更新
主要问题	容易利用 Q 高估	仍需手工探索噪声	实现更复杂，熵与温度需正确处理

选型直觉：

- 学习主线和面试推导：先掌握 DDPG。
- 确定性连续控制基线：优先 TD3，而不是原始 DDPG。
- 希望较稳健探索和高样本复用：通常先尝试 SAC。

10.9 离散与连续混合动作不能直接套标准公式

若动作由离散类型 K_t 和条件连续参数 U_t 构成，例如“等待 / 买入 / 卖出”加“价格与数量”，应写成：

$$\pi_{\theta}(k, u | s) = \pi_{\theta_d}(k | s) \pi_{\theta_c}(u | s, k)$$

θ_d 和 θ_c 分别是 Discrete-head / Continuous-head Parameters（离散 / 连续分支参数）。标准 DDPG/TD3 假设动作整体可微，不能把离散 $\arg \max$ 当作普通连续输出反传。

常见路线：

1. 使用 PPO 等 Score-function 方法，联合两部分 Log Probability。

2. 使用 Hybrid SAC 变体；离散类型较少时对 k 枚举，对条件连续动作采样。
3. 使用 Parameterized-action 方法，让 Critic 显式评价 $Q(s,k,u)$ 。

以 On-policy 联合 Actor 为例：

$$L_{actor} = -\mathbb{E} [(\log \pi_{\theta_d}(K_t | S_t) + \log \pi_{\theta_c}(U_t | S_t, K_t)) \hat{A}_t]$$

$\hat{A}_t$ 是 Advantage Estimate（优势估计）。只训练实际选中类型对应的连续参数分支，并对无效维度和合法范围做 Mask（掩码）。

10.10 实操检查：训练不稳定时看什么

现象	优先检查
Q 值快速发散	Terminal Mask、Reward 尺度、Target 更新、学习率
Actor 动作迅速顶到边界	动作缩放、Critic 虚假梯度、探索噪声、SAC 的 <code>tanh</code> 校正
Return 高度波动	随机种子、评估时是否关闭 DDPG/TD3 探索噪声、Replay Warm-up
TD3 没比 DDPG 稳	是否真的使用双 Target Q 的 <code>min</code> 、延迟 Actor、Target Noise
SAC 熵持续坍塌	α 更新符号、Target Entropy、Log Probability 计算
Critic Loss 降但策略变差	Critic 只在数据动作上拟合好，Actor 动作处可能仍然外推错误

评估确定性性能时，DDPG/TD3 应去掉探索噪声；SAC 常用分布均值或确定性模式执行。训练 Return 与无噪声 Evaluation Return 应分开记录。

10.11 面试高频问题

10.11.1 为什么 DQN 不适合连续动作？

因为 DQN 的决策和 Target 都依赖对动作枚举取 $\max$ 。连续高维动作不可枚举，而每步额外做数值 Argmax 成本高且不稳，因此用 Actor 直接输出动作。

10.11.2 DDPG 的 Actor 为什么不用 Replay 中保存的动作？

Actor 要优化当前 $Q_w(s, \mu_{\theta}(s))$ 。历史动作不依赖当前参数 θ ，无法通过链式法则把 Critic 对动作的梯度传回 Actor。

10.11.3 TD3 的三个改进共同解决什么？

都在限制确定性 Actor 利用 Critic 的估值误差：双 Q 降低高估传播，Target 平滑抑制尖峰，延迟更新让 Actor 少追逐尚未稳定的 Critic。

10.11.4 SAC Actor Loss 为什么是 $\alpha \log \pi - Q$ ？

实现要最小化 Loss。最小化 $-Q$ 会选择高 Q 动作；最小化策略期望下的 $\alpha \log \pi$ 等价于最大化熵。它也可由当前策略逼近 $\exp(Q/\alpha)$ 的 KL 投影推导出来。

10.11.5 SAC 为什么既是随机策略又是 Off-policy？

随机指 Actor 输出分布；Off-policy 指训练可以复用 Replay Buffer 中旧策略的数据。两者描述不同维度，并不矛盾。

10.11.6 Target Policy Smoothing 和探索噪声有什么区别？

前者只在训练 Critic Target 时出现，用于平滑价值估计；后者在真实环境交互时出现，用于扩大数据覆盖。

10.12 原始论文与参考资料

- Lillicrap et al., [Continuous Control with Deep Reinforcement Learning](#), DDPG.
- Fujimoto et al., [Addressing Function Approximation Error in Actor-Critic Methods](#), TD3.
- Haarnoja et al., [Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor](#), SAC.
- Haarnoja et al., [Soft Actor-Critic Algorithms and Applications](#), 自动温度版本与实践扩展。

10.13 本章练习

1. 从 $J_{\mu}(\theta) = Q_w(s, \mu_{\theta}(s))$ 推导单样本 Actor 梯度，并解释两个梯度因子。
2. 给定 $r=2$ 、 $\gamma=0.95$ 、 $d=0$ ，两个 TD3 Target Critic 输出 7 和 5，求 Target；若 $d=1$ 又是多少？
3. 解释 TD3 的 Target Noise 与 Environment Exploration Noise 为什么不能共用一句“都是为了探索”。
4. 给定 SAC 中 $\min Q=3$ 、 $\log \pi=-1.2$ 、 $\alpha=0.1$ 、 $r=0.5$ 、 $\gamma=0.99$ 、 $d=0$ ，计算 Soft Target。
5. 设计一个“离散动作类型 + 连续参数”的任务，写出联合策略分解，并说明为什么标准 DDPG 不可直接使用。
6. 不使用 KL 投影视角，只从“最大化 Q 加熵”推出 SAC Actor Loss 的符号。

▼ 参考答案（点击展开）

1. 链式法则得到 $\nabla_{\theta} J_{\mu} = \nabla_a Q_w(s, a)|_{a=\mu_{\theta}(s)} \nabla_{\theta} \mu_{\theta}(s)$ 。第一项给动作空间中的上升方向，第二项把动作变化映射回参数变化。
2. $y=2+0.95 \times \min(7, 5)=6.75$ 。若 $d=1$ ，Bootstrap 被屏蔽， $y=2$ 。
3. Target Noise 加在下一状态的 Target Action 上，让 Critic 不依赖孤立尖峰；Exploration Noise 加在真实执行动作上，改变采样分布以获得新数据。
4. Soft 下一状态价值为 $3-0.1 \times (-1.2)=3.12$ ，所以 $y=0.5+0.99 \times 3.12=3.5888$ 。
5. 例如交易动作 $K \in \{\text{等待, 买入, 卖出}\}$ ，连续参数 $U=(\text{价格, 数量})$ ，联合策略为 $\pi(k, u|s) = \pi_d(k|s) \pi_c(u|s, k)$ 。离散采样或 Argmax 不具备标准 DDPG 所依赖的连续动作梯度，应使用联合 Score-function 方法、Hybrid SAC 或 Parameterized-action 方法。
6. 最大化 $\mathbb{E}[Q + \alpha H]$ ，代入 $H = -\mathbb{E}[\log \pi]$ ，得到最大化 $\mathbb{E}[Q - \alpha \log \pi]$ 。框架使用梯度下降，因此最小化其负数 $L_{\pi} = \mathbb{E}[\alpha \log \pi - Q]$ 。