

第 12 章：强化学习面试速查与项目准备

12.1 本章符号说明

本章是速查表，会集中复现前面章节的核心符号：

符号/缩写	English	中文	含义
MDP	Markov Decision Process	马尔可夫决策过程	RL 标准建模。
$S / A / P / R$	State / Action / Transition / Reward	状态 / 动作 / 转移 / 奖励	MDP 的状态空间、动作空间、环境转移和奖励函数。
γ	Discount Factor	折扣因子	控制未来 reward 在 return 或 Bellman target 中的权重。
G_t	Return	回报 / 累计折扣奖励	从时刻 t 开始的累计收益。
$V_{\pi}(s)$	State-value Function	状态价值函数	策略 π 下状态 s 的长期价值。
$Q_{\pi}(s,a)$	Action-value Function	动作价值函数	策略 π 下状态-动作对 (s,a) 的长期价值。
$V(s) / Q(s,a)$	Optimal Value Functions	最优价值函数	在所有策略中可达到的最优状态价值和动作价值。
$A_{\pi}(s,a)$	Advantage Function	优势函数	动作相对状态平均价值的优势；这里的 A 不是 action space。
A_t	Advantage Estimate	优势估计	PPO 等算法在样本时刻 t 使用的 advantage 估计值。
$\hat{A}_t^{MC}$	Monte Carlo Advantage Estimate	蒙特卡洛优势估计	REINFORCE with baseline 中的 $G_t - b(s_t)$ 。
K_t / U_t	Discrete Type / Continuous Parameter	离散类型 / 连续参数	混合动作空间中的 categorical choice 和 conditional continuous parameter。
δ_t	TD Error	时序差分误差	一步 TD target 与当前价值估计的差。
$\rho_t(\theta)$	PPO Probability Ratio	PPO 概率比	新策略与旧策略对样本动作的概率之比；特意用 ρ 避免和 reward r_t 混淆。
ϵ_{clip}	PPO Clipping Range	PPO 截断范围	限制 PPO probability ratio 的变化幅度；不是 epsilon-greedy 的探索率。
TRPO	Trust Region Policy Optimization	信赖域策略优化	用平均 KL 约束策略更新，并通过自然梯度近似求解。
$F / CG / FVP$	Fisher Information Matrix / Conjugate Gradient / Fisher-vector Product	Fisher 信息矩阵 / 共轭梯度 / Fisher 向量积	TRPO 中描述策略分布局部曲率、求解自然梯度方向及其无矩阵实现。
y	Bellman Target	Bellman 目标	DQN 或 SAC 中用于训练 critic/Q 网络的目标值。
Q_i^-	Target Twin Q Network	目标双 Q 网络	SAC target 中第 i 个滞后更新的 critic。
α_{SAC}	SAC Temperature	SAC 温度系数	控制 reward 和 entropy 在 SAC 目标中的权衡。

符号/缩写	English	中文	含义
d	Terminal Indicator	终止指示量	$d=1$ 时 transition 真正终止, target 不再 bootstrap。
$J(\theta)$	Objective Function	目标函数	policy optimization 中要最大化的目标。
$L(\theta)$	Loss Function	损失函数	神经网络训练中要最小化的目标。
KL	Kullback-Leibler Divergence	KL 散度	衡量两个策略分布的差异。
DQN / PPO / SAC	Deep Q-Network / Proximal Policy Optimization / Soft Actor-Critic	深度 Q 网络 / 近端策略优化 / 软 Actor-Critic	面试中最高频的三类 deep RL 算法。
RL / RLHF	Reinforcement Learning / Reinforcement Learning from Human Feedback	强化学习 / 基于人类反馈的强化学习	本套课程和对齐流程中的核心概念。
DP / MC / TD	Dynamic Programming / Monte Carlo / Temporal Difference	动态规划 / 蒙特卡洛 / 时序差分	价值估计和控制的基础方法。
behavior policy / target policy	Behavior Policy / Target Policy	行为策略 / 目标策略	前者负责采样数据, 后者是算法真正想学习的策略。
on-policy / off-policy	On-policy / Off-policy Learning	同策略 / 异策略学习	同策略表示采样策略和学习目标一致; 异策略表示用一个策略的数据学习另一个策略。
$\epsilon_{\text{explore}}$	Exploration Probability	探索概率	epsilon-greedy 中随机探索的概率。
epsilon-greedy	Epsilon-greedy Policy	epsilon-greedy 策略	以 $\epsilon_{\text{explore}}$ 概率随机探索, 否则选当前最优动作。
SARSA	State-Action-Reward-State-Action	状态-动作-奖励-状态-动作	使用实际下一动作更新的 TD control 算法。
REINFORCE	REINFORCE algorithm	REINFORCE 算法	Monte Carlo policy gradient 基线算法。
A2C / A3C	Advantage Actor-Critic / Asynchronous Advantage Actor-Critic	优势 Actor-Critic / 异步优势 Actor-Critic	actor-critic 的同步和异步版本。
GAE	Generalized Advantage Estimation	广义优势估计	PPO 常用的 advantage 估计方法。
DDPG / TD3	Deep Deterministic Policy Gradient / Twin Delayed DDPG	深度确定性策略梯度 / 双延迟 DDPG	连续动作控制算法。
BCQ / CQL / IQL / DT	Batch-Constrained Q-learning / Conservative Q-Learning / Implicit Q-Learning / Decision Transformer	批约束 Q 学习 / 保守 Q 学习 / 隐式 Q 学习 / 决策 Transformer	四条代表性 Offline RL 路线。
DPO	Direct Preference Optimization	直接偏好优化	使用成对偏好和参考策略直接训练语言模型策略。
UCB	Upper Confidence Bound	置信上界	bandit 中基于不确定性 bonus 的探索方法。

符号/缩写	English	中文	含义
MLP	Multi-Layer Perceptron	多层感知机	CartPole DQN 项目中常用的小型神经网络。
PG	Policy Gradient	策略梯度	直接优化策略参数的一类方法。

12.2 本章目标

本章用于面试前快速复习。你需要整理：

- 核心概念速查。
- 常见算法横向对比。
- 高频公式。
- 高频问答。
- 项目表达模板。

12.3 本章主线

本章不是引入新算法，而是把前面所有内容压缩成面试表达结构。复习顺序是：先用一张图串起 MDP、Bellman、DP、MC/TD、DQN、Policy Gradient、Actor-Critic、PPO/SAC；再横向比较算法；最后把项目按“问题建模、状态动作奖励、算法选择、训练稳定性、指标和失败案例”讲清楚。

12.4 本章使用方式

本章原则上不引入新算法名词，只做复习压缩。读本章时如果遇到陌生词，先回到对应章节：

陌生词类型	回看章节
MDP、Bellman、return、value	第 1 章
DP、Policy Iteration、Value Iteration	第 2 章
MC、TD、SARSA、Q-learning、on-policy/off-policy	第 3 章
epsilon-greedy、UCB、Thompson Sampling、regret	第 4 章
function approximation、Deadly Triad、replay、target network	第 5-6 章
Policy Gradient、REINFORCE、baseline、advantage	第 7 章
Actor-Critic、A2C/A3C、GAE	第 8 章
TRPO、PPO、ratio、clipping、KL	第 9 章
DDPG、TD3、SAC、entropy	第 10 章
Model-based、Offline RL、Imitation、RLHF、DPO	第 11 章

12.5 速查和高频问答

12.5.1 核心概念速查

MDP：

$$(S, A, P, R, \gamma)$$

Return:

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

Value:

$$V_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s]$$

Q value:

$$Q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t | S_t = s, A_t = a]$$

Advantage:

$$A_{\pi}(s, a) = Q_{\pi}(s, a) - V_{\pi}(s)$$

REINFORCE with baseline 的样本 advantage:

$$\hat{A}_t^{MC} = G_t - b(s_t)$$

Bellman expectation:

$$V_{\pi}(s) = \mathbb{E}_{\pi}[R_{t+1} + \gamma V_{\pi}(S_{t+1}) | S_t = s]$$

Bellman optimality:

$$Q^*(s, a) = \mathbb{E}[R_{t+1} + \gamma \max_{a'} Q^*(S_{t+1}, a') | S_t = s, A_t = a]$$

TD error:

$$\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$$

Policy Gradient:

$$\nabla J(\theta) = \mathbb{E}[\nabla \log \pi_{\theta}(a|s) A_{\pi}(s, a)]$$

TRPO 的局部约束问题与自然梯度方向:

$$\max_x g^T x \text{ subject to } 1 / 2x^T F x \leq \delta_{KL}$$

$$x \propto F^{-1} g$$

PPO ratio。这里用 ρ_t 表示 probability ratio，避免和即时 reward r_t 使用同一个字母:

$$\rho_t(\theta) = \pi_{\theta}(a_t | s_t) / \pi_{old}(a_t | s_t)$$

PPO clipped objective:

$$\mathbb{E}[\min(\rho_t A_t, \text{clip}(\rho_t, 1 - \epsilon_{clip}, 1 + \epsilon_{clip}) A_t)]$$

DDPG Actor Gradient:

$$\nabla_{\theta} J = \mathbb{E}[\nabla_{\theta} Q_w(s, a)|_{a=\mu_{\theta}(s)} \nabla_{\theta} \mu_{\theta}(s)]$$

TD3 Target:

$$y = r + \gamma(1-d) \min_{i \in \{1,2\}} Q_i^-(s', a')$$

SAC soft target:

$$y = r + \gamma(1-d) [\min_i Q_i^-(s', a') - \alpha_{SAC} \log \pi(a'|s')]$$

12.5.2 算法横向对比

算法	类型	on/off-policy	关键点	适用
Policy Iteration	DP	模型已知	evaluation + improvement	小规模 MDP
Value Iteration	DP	模型已知	Bellman optimality backup	小规模 MDP
Monte Carlo	value estimation	on-policy 常见	完整 return	episodic task
TD(0)	value estimation	on-policy 常见	bootstrap	在线估值
SARSA	value-based	on-policy	target 用实际 a'	表格控制
Q-learning	value-based	off-policy	target 用 max	表格控制
DQN	value-based	off-policy	replay + target network	离散动作
REINFORCE	policy-based	on-policy	Monte Carlo PG	教学基础
A2C/A3C	actor-critic	on-policy	critic 降方差	离散/连续
TRPO	actor-critic	on-policy	KL 约束 + natural gradient	稳健策略更新、推导基础
PPO	actor-critic	on-policy	clipped objective	通用稳定基线
DDPG	actor-critic	off-policy	deterministic actor	连续动作
TD3	actor-critic	off-policy	double Q + delayed update	连续动作
SAC	actor-critic	off-policy	maximum entropy	连续动作
BCQ/CQL/IQL	offline RL	fixed dataset	动作约束 / 保守 Q / in-sample learning	固定日志
DT	sequence modeling	fixed dataset	RTG 条件动作预测	离线轨迹
DPO	preference optimization	fixed dataset	reference-relative pairwise loss	语言模型偏好对齐

12.5.3 高频概念问答

12.5.3.1 RL 为什么难？

因为 RL 同时面对 delayed reward、探索与利用、非 i.i.d. 数据、动作影响未来数据分布、credit assignment 和训练稳定性问题。

12.5.3.2 Bellman 方程为什么重要？

Bellman 方程描述了价值函数的递归自治关系：当前价值等于即时 reward 加未来价值。绝大多数 value-based 和 actor-critic 方法都直接或间接基于 Bellman backup。

12.5.3.3 On-policy 和 off-policy 区别？

On-policy 学习当前采样策略的价值或改进当前策略。Off-policy 用 behavior policy 的数据学习另一个 target policy，样本效率更高，但有分布偏移风险。

12.5.3.4 MC 和 TD 区别？

MC 用完整 episode 的真实 return，不 bootstrap，bias 小但 variance 大。TD 用一步 reward 加下一状态价值估计，能在线更新，variance 小但有 bootstrap bias。

12.5.3.5 SARSA 和 Q-learning 区别？

SARSA 是 on-policy，target 使用实际采样的下一个动作。Q-learning 是 off-policy，target 使用下一状态最大 Q 值。

12.5.3.6 DQN 的两个核心稳定技巧？

Experience replay 和 target network。前者打破样本相关性并复用样本，后者稳定 bootstrap target。

12.5.3.7 Double DQN 解决什么？

缓解 DQN 中 $\max$ 操作造成的 Q 值过估计。它用 online network 选动作，用 target network 评估动作。

12.5.3.8 Policy Gradient 怎么理解？

如果某个动作带来正 advantage，就增加该动作在该状态下的概率；如果 advantage 为负，就降低概率。公式是：

$$\nabla J = \mathbb{E}[\nabla \log \pi(a|s) A_{\pi}(s,a)]$$

12.5.3.9 Baseline 为什么不引入 bias？

因为 baseline 不依赖 action，而：

$$\mathbb{E}_{a \sim \pi}[\nabla \log \pi(a|s)] = 0$$

因此减去 baseline 只改变方差，不改变梯度期望。

12.5.3.10 为什么理论公式用 Q_{π} ，REINFORCE 实现用 G_t ？

因为：

$$Q_{\pi}(s,a) = \mathbb{E}[G_t | S_t=s, A_t=a]$$

Q_{π} 是条件期望， G_t 是一条轨迹上采样到的随机回报。REINFORCE 没有真实 Q 函数，只能用 G_t 作为 Monte Carlo 样本。

12.5.3.11 离散加连续的混合动作怎样建模？

把动作写成 (K, U) ，并分解联合策略：

$$\pi(k, u|s) = \pi_d(k|s) \pi_c(u|s, k)$$

先用 categorical head 选择类型 k ，再由条件连续分支输出该类型所需的参数 u 。联合 log probability 是两部分之和，并且只训练实际选中类型对应的连续分支。

12.5.3.12 PPO 为什么常用？

PPO 把 TRPO 的显式 KL 约束近似为易于一阶优化的 clipped objective，稳定性好、实现简单、适用面广。Clip 限制的是 Surrogate Objective 的收益，不保证更新后的实际 Ratio 永远处于区间内，因此仍要监控 Approximate KL 和 Clip Fraction。

12.5.3.13 SAC 为什么适合连续控制？

SAC 是 off-policy，样本效率较高；最大熵目标鼓励探索并提升稳定性；双 Q 网络缓解过估计，因此在连续控制任务中表现稳定。

12.5.3.14 Offline RL 为什么难？

因为不能继续探索收集数据。学习策略可能选择数据集中没覆盖的动作，critic 对这些动作估计不可靠，容易出现 extrapolation error。

12.5.3.15 TRPO 的 CG、FVP 和 Line Search 各做什么？

FVP 在不显式构造 Fisher 矩阵时计算 Fv ；CG 反复调用 FVP，近似求解 $Fx=g$ ；Line Search 再检查实际 Surrogate 是否改善、实际 KL 是否满足约束，必要时缩小步长。

12.5.3.16 TD3 的三个改进为什么是一条主线？

确定性 Actor 会寻找 Critic 最高点，也会放大估值误差。双 Q 取较小值减少过估计进入 Target，Target Policy Smoothing 抑制尖锐假峰，Delayed Update 减少 Actor 追逐尚未稳定的 Critic。

12.5.3.17 Offline RL 与 Off-policy 有什么区别？

Off-policy 表示可以使用其他策略的数据，但通常仍可继续交互纠错；Offline RL 的数据集固定，策略进入 OOD 区域后不能获得新反馈。因此普通 DQN/SAC 使用 Replay Buffer，并不自动意味着适合 Offline RL。

12.5.3.18 PPO-RLHF 与 DPO 的核心区别？

PPO-RLHF 用当前策略生成回答、显式 RM 打分、Critic 估值并做在线策略优化；DPO 通常在固定偏好对上，比较 Chosen/Rejected 相对 Reference Policy 的 Log-ratio，直接优化 Pairwise Loss，不需要 Critic。

12.6 面试表达模板和项目准备

12.6.1 面试中算法讲解模板

回答某个算法时，按这个顺序讲：

- 1. 它解决什么问题？
- 2. 是 value-based、policy-based 还是 actor-critic？
- 3. 是 on-policy 还是 off-policy？
- 4. 核心目标函数或更新公式是什么？
- 5. 关键 trick 是什么？
- 6. 相比前一个算法改进在哪里？
- 7. 局限是什么？

例如讲 DQN：

DQN 是把 Q-learning 扩展到高维状态输入的 deep RL 算法。它用神经网络近似 $Q(s,a)$ ，适合离散动作空间。核心 target 是 $r+\gamma \max_a Q_{target}(s',a')$ 。为了稳定训练，它使用 replay buffer 打破样本相关性、复用历史经验，并使用 target network 稳定 Bellman target。它的局限是难以处理连续动作空间，并且存在 Q 值过估计问题，后续 Double DQN 对此做了改进。

12.6.2 项目准备建议

面试前建议至少准备一个可讲清楚的 RL 小项目。

优先级：

- 1. CartPole with DQN。
- 2. LunarLander with PPO。
- 3. Pendulum or HalfCheetah with SAC。
- 4. 简化推荐系统 bandit。
- 5. RLHF toy example，例如偏好数据训练 reward model。

12.6.3 面试例子索引

准备面试时，建议把算法和例子绑定记忆：

算法/概念	推荐例子	为什么适合
MDP / Bellman	GridWorld	状态、动作、转移、奖励最直观。

算法/概念	推荐例子	为什么适合
DP	已知地图的 GridWorld	可以明确说明“已知环境模型”。
MC	Blackjack	episode 短，完整 return 容易得到。
TD	在线推荐或持续控制	不想等 episode 结束，每步都能更新。
SARSA / Q-learning	Cliff Walking	on-policy 与 off-policy 差异明显。
Bandit	广告推荐冷启动	探索和利用最直接。
Function Approximation	Atari 或推荐系统	状态空间无法枚举。
DQN	CartPole / Atari	离散动作 + Q 网络。
Policy Gradient	连续控制机器人	动作连续，难以枚举 max。
Actor-Critic / GAE	游戏或机器人控制	Actor 选动作，Critic 降低方差。
PPO	RLHF 或 LunarLander	策略更新稳定，工程常用。
TRPO	连续控制的小批策略更新	可说明 KL 几何、自然梯度、CG 和 Line Search。
DDPG / TD3 / SAC	机械臂、MuJoCo	连续动作控制。
Model-based RL	机械臂 MPC	真实交互贵，用模型内规划复用数据。
Offline RL	历史推荐日志	只能用离线数据，重点处理 OOD 动作。
Imitation Learning	自动驾驶示范数据	从专家轨迹学习行为。
RLHF / DPO	聊天模型对齐	对比显式 RM 在线 Rollout 与固定偏好对优化。

回答时不要只说“我用 DQN 做 CartPole”。更好的结构是：

CartPole 是离散动作控制任务，状态低维连续，动作是 left/right，reward 是存活步数。DQN 用 Q 网络输出两个动作价值，配合 replay buffer 和 target network 稳定训练。

12.6.4 项目表达模板

项目背景：

任务建模：

状态空间：

动作空间：

奖励设计：

算法选择：

训练流程：

关键工程细节：

实验指标：

遇到的问题：

改进方向：

12.7 项目讲法

12.7.1 CartPole DQN 项目讲法

任务建模：

- State: 小车位置、速度、杆角度、角速度。
- Action: 向左或向右施加力。
- Reward: 每保持一步平衡得到 1。
- Done: 杆倾斜过大或小车越界。

算法选择:

- 动作空间离散, 适合 DQN。
- 用 MLP 近似 Q 函数。
- epsilon-greedy 探索。
- replay buffer 存储 transition。
- target network 稳定 target。

可以强调的问题:

- epsilon decay 如何设置。
- replay buffer 大小。
- target network 更新频率。
- loss 曲线不稳定是否正常。
- reward 是否能达到环境上限。

12.7.2 LunarLander PPO 项目讲法

任务建模:

- State: 位置、速度、角度、角速度、腿部接触信息。
- Action: 离散喷气控制。
- Reward: 接近着陆点、平稳降落、节省燃料等。

算法选择:

- PPO 稳定且适合 policy optimization。
- 使用 GAE 估计 advantage。
- 使用 entropy bonus 保持探索。
- 使用 clipped objective 限制策略更新。

可以强调:

- PPO 是 on-policy, 采样效率不如 DQN/SAC。
- 但训练稳定, 调参相对友好。
- advantage normalization 对训练很重要。

12.7.3 推荐系统 Bandit 项目讲法

任务建模:

- State/context: 用户画像、上下文、历史行为。
- Action: 推荐某个 item 或策略。
- Reward: 点击、停留、转化、长期留存。

算法选择:

- 如果动作不影响长期状态, 可先用 contextual bandit。
- 可比较 epsilon-greedy、UCB、Thompson Sampling。

注意点:

- 线上探索有风险, 需要控制流量。
- reward 延迟和偏差要处理。

- 离线评估有 selection bias。

12.8 最终复习

12.8.1 面试前最终检查清单

- 能手写 Bellman expectation 和 optimality equation。
- 能解释 MC、TD、DP 的区别。
- 能写出 SARSA 和 Q-learning 更新公式。
- 能解释 DQN 两个核心 trick。
- 能解释 Double DQN 为什么缓解过估计。
- 能推导 policy gradient 的 log-derivative trick。
- 能解释 Q_π 是 G_t 的条件期望，以及理论 advantage 和样本 advantage estimate 的区别。
- 能证明 baseline 不引入 bias。
- 能写出离散加连续混合动作的联合策略与 joint log probability。
- 能解释 Actor-Critic 和 GAE。
- 能写出 TRPO 的 KL 约束，并解释 Natural Gradient、CG、FVP 和 Line Search。
- 能手写 PPO clipped objective。
- 能从 DDPG 讲到 TD3 三项修复，再解释 SAC 的最大熵目标。
- 能说明 Offline RL 的 extrapolation error，并对比 BCQ、CQL、IQL、DT。
- 能区分 Model-based RL、Offline RL、Imitation Learning、PPO-RLHF 与 DPO。
- 能讲一个完整 RL 项目。

12.8.2 30 分钟口述复习路线

1. 5 分钟：MDP、return、V/Q、Bellman。
2. 5 分钟：DP、MC、TD、SARSA、Q-learning。
3. 5 分钟：DQN、Double DQN、Dueling、Replay。
4. 5 分钟：Policy Gradient、baseline、Actor-Critic、GAE。
5. 5 分钟：TRPO/PPO、DDPG、TD3、SAC。
6. 5 分钟：Model-based、Offline RL、Imitation、RLHF/DPO、项目总结。

12.9 本章练习

1. 不看笔记，用两分钟讲清从 MDP 到 PPO/SAC 的全课程主线。
2. 面对“离散动作在线交互”“连续动作在线交互”“固定 Transition 日志”“只有专家动作”“固定偏好对”五个场景，分别给出算法候选并说明依据。
3. 用统一的 target、data、policy update 三个维度，对比 DQN、PPO 和 SAC。
4. 按项目表达模板，口述一个 CartPole DQN 项目，并至少说出两个可能失败的原因。

▼ 参考答案（点击展开）

1. **两分钟主线**：MDP 定义 state、action、transition、reward 和 discount；return 的期望得到 V/Q ，Bellman 方程给出递归关系。模型已知时用 DP 做精确 backup；模型未知时 MC 用完整 return、TD 用 bootstrap target。SARSA/Q-learning 把 prediction 推到 control；状态太大时用函数逼近，DQN 通过 replay 和 target network 稳定 Q-learning。Policy Gradient 直接优化 policy，Actor-Critic 用 critic 降方差，GAE 平衡 bias/variance，PPO 限制 on-policy 更新幅度；连续动作下 DDPG/TD3/SAC 用 actor 输出 action，其中 SAC 用随机策略和最大熵目标增强探索。
2. **场景选型**：离散动作且可在线交互，可从 DQN 或 PPO 开始；连续动作且可在线交互，可优先 SAC，若需要确定性执行可比较 TD3。固定 Transition 日志应使用 BCQ、CQL、IQL、DT 等 Offline RL 路线并检查数据覆盖；只有专家动作时先做 BC，有在线专家可考虑 DAgger；固定 Chosen/Rejected 偏好对可用 DPO，而当前 Policy 持续采样并由 RM 打分时才是 PPO-RLHF 的闭环。
3. **统一对比**：DQN 的 data 来自 epsilon-greedy behavior policy 和 replay buffer，target 是 $r+\gamma \max Q$ ，通过最小化 TD loss 更新 Q，再由 argmax 导出 policy；PPO 的 data 来自旧 policy 的短期 rollout，target/学习信号是 return 或 GAE advantage，通过 clipped ratio 直接更新 stochastic policy；SAC 的 data 来自 replay buffer，soft Q target 含 entropy 项，同时更新双 critic 和随机 actor，属于 off-policy actor-critic。

4. **CartPole DQN 示例**：state 是位置、速度、杆角度和角速度；action 是向左或向右；每存活一步 reward 为 1。Q 网络输出两个 action value，使用 epsilon-greedy 收集 transition，replay buffer 随机采样，target network 构造稳定 target。指标可看 episode return、成功率和样本量。失败原因包括 epsilon 衰减过快导致探索不足、target 更新过频导致 target 不稳、没有正确处理 terminal mask、学习率过大或 replay warm-up 不足。